

進捗報告：変数共有関係を表す数式グラフを用いた GNN に基づく文献からの物理モデル構築

かずひろ

2026 年 4 月 13 日

1 研究目的

科学文献 PDF から数式を自動抽出し、自然言語で記述されたプロセス条件（例：「CSTR の定常濃度を求めたい、入力流量と反応速度定数」）に対して、最適な物理モデル（数式の集合）を自動選択する Retrieval システムを開発する。数式間の変数共有関係をグラフ構造で表現し、グラフニューラルネットワーク（GNN）ベースの検索手法の有効性を検証する。

2 使用データ

2.1 データ概要

項目	値
総数式数	3,244
ソース数	71 (PDF 39 + ハンドブック 32)
総変数ノード	3,704
グラフエッジ (二部)	33,638
訓練ケース	1,107 (123 コア × 9 バリエーション)

2.2 参考文献リスト (PDF 資料)

主要な PDF ソースから抽出した数式 (合計 2,574 式)。

#	ソース	式数	分野
1	Seborg et al., <i>Process Dynamics and Control</i> , 3rd Ed.	308	プロセス制御
2	Seborg, <i>Process Dynamic and Control</i> , Chap. 2	108	プロセス制御
3	Bequette, <i>Process Control: Designing Processes and Control Systems for Dynamic Performance</i>	482	プロセス制御

#	ソース	式数	分野
4	Woolf et al., <i>Chemical Process Dynamics and Controls</i>	521	化学プロセス動特性
5	Ingham et al., <i>Chemical Engineering Dynamics</i> (Wiley)	70	化学工学動特性
6	Marlin, <i>Process Control</i> , Chapter 3–4	161	プロセス制御
7	Svrcek et al., <i>A Real Time Approach to Process Control</i>	61	プロセス制御
8	Corriou, <i>Process Control</i> (Springer, 2018)	226	プロセス制御
9	Corriou, <i>Process Control</i> , Chap. 1/1–6 (分割抽出)	104	プロセス制御
10	Aris (1974), 反応系の合理的解析	33	反応工学
11	Moser et al. (2018), ワイン発酵モデル	61	バイオプロセス
12	Liu & Guo (2013), プレウロムチリン発酵モデル	15	発酵工学
13	Phisalaphong et al. (2006), エタノール発酵最適化	15	発酵工学
14	Bhandari et al. (2009), バイオプロセス速度論	9	バイオプロセス
15	燃焼関連論文 3 本 (2023–2024)	79	燃焼工学
16	高分子反応器論文	9	高分子工学
17	熱交換器論文 (動モデル)	71	伝熱工学
18	物質移動・対流論文	42	輸送現象
19	熱分解・電気化学・大豆油速度論文	59	反応工学・電気化学
20	その他 (Applied Sciences, Energies 等)	50	各種

2.3 ハンドブック式 (LLM 生成, 合計 670 式)

電子バージョンハンドブックを利用できないので, Google Gemini 2.5 Pro の知識ベースから 32 ドメインの基礎方程式を生成した.

Round 1 (15 ドメイン, 基礎式): 流体力学 (25 式), 伝熱 (25), 物質移動 (20), 熱力学 (25), 反応工学 (25), プロセス制御 (25), 電気化学 (20), バイオプロセス (20), 環境工学 (20), 振動学 (20), 電気工学 (20), 高分子工学 (20), 燃焼工学 (20), 分離プロセス (20), 輸送現象 (25)

Round 2 (16 ドメイン, 新規+応用式): 原子力工学 (20), 半導体物理 (20), 音響学 (20), 光学 (20), 地盤工学 (20), 航空力学 (20), HVAC (20), 食品工学 (20), 製薬工学 (20), 構造力学 (20), 化学工学基礎 (20), 流体力学応用 (20), 伝熱応用 (20), 反応工学応用 (20), 熱力学応用 (20), 電気化学応用 (20), プロセス制御応用 (20)

2.4 Google Gemini API 利用に関する確認事項

本研究では数式抽出および訓練ケース生成に Google Gemini API (gemini-2.5-pro) を使用している. 利用規約上の主要な確認事項:

確認すべき事項:

- 現在の利用が有料枠か無料枠かにより, データの取り扱いが異なる
- 無料枠の場合, 抽出プロンプトや生成結果が Google のモデル改善に使用される可能性がある
- 学会発表・論文文化にあたり, AI 生成コンテンツの利用開示が各学会の規定に準拠しているか

項目	有料枠 (Paid)	無料枠 (Unpaid)
出力の所有権	Google は所有権を主張しない	同左
モデル改善への使用	使用されない	使用される可能性あり
人間レビュー	なし	確認される可能性あり

確認が必要

参考 URL :

- Gemini API 利用規約: <https://ai.google.dev/gemini-api/terms>
- Generative AI 追加規約: <https://policies.google.com/terms/generative-ai>
- データログポリシー: <https://ai.google.dev/gemini-api/docs/logs-policy>

3 情報抽出手法

3.1 PDF から数式の構造化抽出

使用モデル: Google Gemini 2.5 Pro (Structured Output モード)

PDF ファイルを Gemini API にアップロードし、以下のプロンプトで数式を構造化 JSON として抽出する。出力スキーマは Pydantic モデルで定義し、`response_json_schema` パラメータで型安全な JSON 出力を強制している。

入力: PDF 文書ファイル 出力: 数式の JSON 配列 (各要素: `source_id`, `eq_id`, `equation`, `variables`, `context_text`, `domain`)

```
Extract all numbered equations and equations found in the appendices
from this textbook in LaTeX format. For each equation, identify the
"variable definitions" and the "physical meaning (context)" from the
surrounding text.
Constraints: - Extract the content EXACTLY as it appears in the
literature. Do not make unauthorized corrections or modifications. -
Preserve every variable symbol and subscript exactly as printed: e.g. if
the source writes  $c_w$  (specific heat of water), do NOT change it to  $c_p$ .
Never "normalize" or "standardize" notation.
Output a single JSON array. Each element must have these fields: -
source_id: string (e.g. PDF filename) - eq_id: string (e.g. "eq_1") -
equation: string (LaTeX form) - variables: object {symbol: definition}
- context_text: string (physical meaning) - domain: string (e.g. "CSTR
Kinetics")
```

Gemini 無料枠制約 :

- レート制限: 5 RPM (12 秒間隔で呼び出し)
- ページ上限: 約 1,000 ページ. pypdf で 80 ページ単位に分割 (3 冊の大型テキストブック, 39 チャンク)

3.2 ハンドブック式の LLM 生成

入力: ドメイン名, トピックリスト, 生成式数 出力: 数式の JSON 配列 (抽出と同一スキーマ)

```
You are an expert in {domain_label} and mathematical modeling. Generate exactly {n} fundamental equations used in {domain_label}, in LaTeX format.
Cover these topics: {topics}
For each equation provide: - source_id: use exactly "{source_id}" - eq_id: "eq_1" through "eq_{n}" (sequential) - equation: LaTeX form (use standard notation) - variables: object {symbol: definition with units} - context_text: brief physical meaning (1--3 sentences) - domain: "{label}" or a more specific sub-domain
IMPORTANT: - Each equation MUST be distinct (no duplicates). - Include differential and algebraic forms where applicable. - Variables dict must include ALL symbols in the equation.
```

トピックリストの例(流体力学): Navier–Stokes equations, Bernoulli equation, Hagen–Poiseuille flow, Darcy–Weisbach friction, boundary layer equations (Blasius), drag and lift coefficients, continuity equation, Euler equation, potential flow, vorticity equation, turbulent flow, open channel flow (Manning, Chezy), orifice flow, Torricelli’s theorem

3.3 論文の自動取得

Semantic Scholar API により 15 カテゴリのクエリで関連論文を自動検索し, Open-access PDF をダウンロード.

検索クエリの例: “fluid dynamics pipe flow mathematical model equations”, “electrochemical cell battery model equations”, “bioprocess fermentation kinetic model mathematical” 等 (15 カテゴリ, 各 20–30 件検索)

結果: 180 論文発見 → 49 論文に PDF リンクあり → 17 本ダウンロード成功 → 308 式抽出

3.4 訓練ケースの生成

3.4.1 コアケース生成

3,244 式のカタログ (851K キャラクター) をドメイン別に 300 式以下のバッチに分割し, 各バッチから Gemini 2.5 Pro で物理的に意味のあるケースを生成.

入力: 数式カタログ (model_id, domain, variable_symbols のリスト)

出力: コアケースの JSON 配列 (各要素: case_id, context, input_variables, output_variables, correct_model_ids)

You are helping to create training data for a graph neural network that selects relevant equations for physical process modeling.
 CATALOG ({N} equations, domains: {domain_list}): {catalog_json}
 TASK: Using ONLY the models listed above, create approximately {n_cases} realistic and physically meaningful core training cases.
 For each core case: – Pick one or more model_ids that represent a coherent physical model. – Define a context string describing the physical scenario. – Choose input_variables and output_variables from variable_symbols. – correct_model_ids: list forming a correct mathematical model.
 CONDITIONS FOR correct_model_ids: (1) Given input_variables and the equations, it MUST be possible to solve for all output_variables. (2) The equation set MUST be sufficient and minimal.

結果: 11 バッチ中 9 バッチ成功 (2 バッチは Gemini 503 エラーで失敗) → 123 コアケース

3.4.2 データ拡張

各コアケースから 9 バリエントを Python テンプレートで自動生成.

バリエント	手法	件数	目的
original	そのまま使用	123	ベースケース
context_paraphrased	テンプレートで文脈を言い換え (3 パターン)	369	語彙の多様性向上
swap_io	入力と出力を完全スワップ	123	逆問題への対応力
random_io_from_models	全変数からランダムに I/O 割当 (4 パターン)	492	変数選択の多様性
合計		1,107	

言い換えテンプレート:

1. “This case describes the following physical model: {context}”
2. “In this scenario, the underlying process can be summarized as: {context}”
3. “From the perspective of process modeling, this case focuses on: {context}”

4 グラフ構築と GNN 学習

4.1 二部グラフの構築

数式と変数の関係を二部グラフとして表現する.

項目	値
数式ノード	3,244
変数ノード	3,704
二部エッジ	33,638 (双方向)
ノード特徴量	768 次元 (CodeBERT [CLS] 埋め込み)

ノード特徴量の計算：

- 数式ノード: “Equation: {LaTeX} / Context: {context_text}” を CodeBERT (microsoft/codebert-base) に入力し, [CLS] トークンの 768 次元埋め込みを使用
- 変数ノード: その変数を含む全数式の CodeBERT 埋め込みの平均

エッジの定義: 数式 i が変数 j を含む場合, (i, j) と (j, i) の双方向エッジを張る. 数式間の間接的な関連は, 変数ノードを介した 2 ホップのパスとして表現される.

4.2 GNN アーキテクチャ

2 種類の GNN ベースアプローチを実装した.

4.2.1 (A) GCN Retriever

コンポーネント	構成
数式エンコーダ	2 層 GCN (GCNConv 768 $\rightarrow$ 768 $\rightarrow$ 768, Dropout 0.1)
クエリエンコーダ	TF-IDF $\rightarrow$ SVD(256 次元) $\rightarrow$ MLP(256 $\rightarrow$ 512 $\rightarrow$ 768)
損失関数	Sampled InfoNCE (温度 $\tau = 0.07$)
負例数	64/ケース
最適化	AdamW (lr = 2×10^{-3} , weight_decay = 10^{-4})
エポック数	3

4.2.2 (B) 残差 GCN SVD 洗練

TF-IDF+SVD の強いベースライン埋め込みを出発点とし, GCN で残差的に洗練する.

コンポーネント	構成
ベースライン埋め込み	TF-IDF $\rightarrow$ SVD(256 次元) $\rightarrow$ L2 正規化
GCN Refiner	2 層 GCN(256 $\rightarrow$ 256 $\rightarrow$ 256) + 学習可能パラメータ α
出力	$\mathbf{E}_{\text{refined}} = \text{L2norm}(\mathbf{x} + \alpha \cdot \mathbf{h})$ ($\alpha = 0$ で初期化)
損失関数	Sampled InfoNCE (温度 $\tau = 0.07$)
負例数	128/ケース
エポック数	10

4.2.3 (C) 2 段階リランカー (主要手法)

Stage 1 で TF-IDF+Jaccard により候補 50 件を抽出し, Stage 2 で MLP リランカーが特徴量ベクトルに基づきリランキングする.

Stage 1: 候補抽出 (固定重み)

$$\text{score} = 0.7 \times \cos_{\text{TF-IDF}} + 0.3 \times \text{Jaccard}(IO_{\text{query}}, V_{\text{eq}}) \quad (1)$$

上位 50 件を候補として抽出.

Stage 2: MLP リランカー

入力(n 次元) $\xrightarrow{\text{Linear}(64)}$ ReLU $\rightarrow$ Dropout(0.1) $\xrightarrow{\text{Linear}(64)}$ ReLU $\rightarrow$ Dropout(0.1) $\xrightarrow{\text{Linear}(1)}$ σ

ハイパーパラメータ	値
隠れ層	64 次元 $\times$ 2 層
損失関数	マージンランキング損失 (margin = 0.1)
負例数	min(8, 利用可能数)/正例
バッチサイズ	16
エポック数	15
最適化	AdamW (lr = 10^{-3} , weight_decay = 10^{-4})

4.3 特徴量の設計

4.3.1 ベース 7 特徴量 (reranker-7)

#	特徴量名	計算方法
0	テキスト類似度	TF-IDF cosine (クエリ context, 式の context+equation+domain)
1	I/O 変数 Jaccard	Jaccard(クエリ入出力変数, 式の変数集合)
2	SVD 埋め込み類似度	TF-IDF $\rightarrow$ SVD(256 次元) 空間での cosine 類似度
3	入力変数カバー率	$ input_vars \cap eq_vars / input_vars $
4	出力変数カバー率	$ output_vars \cap eq_vars / output_vars $
5	式変数中のクエリ割合	$ IO_set \cap eq_vars / eq_vars $
6	ドメイン一致	クエリ context と式 domain の部分文字列一致 (0/1)

4.3.2 クエリ条件付きグラフ特徴量 (reranker-10 で追加される 3 次元)

核心: これら 3 特徴量はすべてクエリに条件付き (同じ候補式でもクエリごとに異なる値をとる). クエリに依存しない固定 GNN 埋め込みとは本質的に異なるアプローチである.

5 評価方法と結果

5.1 評価設定

評価指標の説明:

- **MRR (Mean Reciprocal Rank):** 各クエリについて, 正解数式が検索結果の何位に現れるかの逆数の平均. MRR= 1.0 は全クエリで正解が 1 位, MRR= 0.5 は平均 2 位.

#	特徴量名	計算方法	捉える情報
7	2 ホップ到達率	クエリ I/O 変数のうち、変数共有グラフ上で候補式に 2 ホップ以内に到達可能な割合	間接的変数関連
8	グラフ近傍重複度	Jaccard (候補式の近傍式集合, クエリ変数を含む式集合)	構造的近接性
9	間接変数ブリッジ比率	候補式の変数のうち、クエリ変数には含まれないが、クエリ変数を持つ他式にも出現する変数の割合	隠れた接続

項目	設定
比較手法	baseline (固定重み), reranker-7 (7 特徴量 MLP), reranker-10 (+ グラフ 3 特徴量)
評価指標	MRR (Mean Reciprocal Rank), Recall@ K ($K = 1, 3, 5, 10$)
乱数シード	5 種類 (42, 123, 456, 789, 1024)
データ分割	source_id (論文/ソース) 単位で train 60% / val 20% / test 20%
統計量	5 seed 平均 $\pm$ 標準偏差, Bootstrap 95% 信頼区間 (2,000 反復)

- **Recall@ K** : 上位 K 件に正解が含まれるクエリの割合.
- **source_id 単位分割**: 同一論文の数式が訓練とテストに分かれることを防ぎ、データリークを防止.

5.2 主要結果：データ規模によるスケーリング効果

5.2.1 全体 MRR (5 seed 平均 $\pm$ 標準偏差)

式数	baseline	reranker-7	reranker-10 (graph)
975	0.875 $\pm$ 0.088	0.885 $\pm$ 0.119	0.879 $\pm$ 0.123
1,613	0.900 $\pm$ 0.069	0.942 $\pm$ 0.052	0.948 $\pm$ 0.046
3,244	0.924 $\pm$ 0.040	0.937 $\pm$ 0.018	0.949 $\pm$ 0.031

5.2.2 95% 信頼区間 (3,244 式)

5.2.3 Original ケース (LLM 合成でないケース) のみの MRR

5.2.4 グラフ特徴量の効果 (reranker-10 – reranker-7)

5.2.5 バリエント別 MRR (3,244 式)

5.2.6 Seed 別の詳細 (3,244 式, baseline)

注: 全手法・全 seed で Recall@3 = 1.000 (上位 3 件に正解が必ず含まれる).

手法	MRR	95% CI
baseline	0.924 ± 0.040	[0.894, 0.954]
reranker-7	0.937 ± 0.018	[0.922, 0.951]
reranker-10	0.949 ± 0.031	[0.924, 0.973]

式数	baseline	reranker-7	reranker-10 (graph)
975	0.839	0.860	0.842
1,613	0.885	0.936	0.935
3,244	0.921	0.942	0.952

式数	Δ MRR	解釈
975	-0.006	グラフが害
1,613	+0.006	ほぼ同等
3,244	+0.012	グラフが有効

バリエント	baseline	reranker-7	reranker-10
original	0.921	0.942	0.952
context_paraphrased	0.927	0.939	0.954
swap_io	0.928	0.943	0.954
random_io_from_models	0.923	0.933	0.944

seed	テスト件数	MRR	Recall@1	Recall@3
42	180	0.879	0.778	1.000
123	171	0.884	0.789	1.000
456	252	0.946	0.893	1.000
789	261	0.958	0.927	1.000
1024	99	0.955	0.909	1.000

6 考察

6.1 データ規模がグラフ構造の価値を決定する

本研究の最も重要な発見は、グラフ特徴量の有効性がデータ規模に明確に依存するスケーリング則である。

- **975 式 (スパースグラフ)** : 変数ノードの次数が低く、2 ホップ到達率がほぼ 0/1 に二値化. グラフ特徴量はリランカーにノイズを注入し、性能を悪化させた (Δ MRR = -0.006).

- **1,613 式（遷移領域）**：グラフがやや密になり、グラフ特徴量が微小ながら正の寄与を示すようになった ($\Delta\text{MRR} = +0.006$).
- **3,244 式（密グラフ）**：変数ノードの次数が十分に増加し、2 ホップ到達率・近傍重複度が連続的な値をとるようになった。グラフ特徴量が候補間の有意な差別化を可能にし、全手法中最高性能を達成 ($\Delta\text{MRR} = +0.012$).

この結果は、グラフ構造特徴量には一定のデータ密度の閾値が存在し、約 1,600 式/2,000 変数付近に転換点があることを示唆する。

6.2 クエリ条件付きグラフ特徴量の有効性

初期に試行したクエリに依存しない GNN 埋め込み (GCN Retriever, 残差 GCN SVD 洗練) はいずれもベースラインを超えられなかった。一方、クエリの入出力変数に条件付けしたグラフ特徴量は、十分なデータ規模のもとで有効に機能した。

これは、数式 retrieval において「どの変数を介してグラフ上で関連しているか」がクエリごとに異なるため、固定的な埋め込みでは捉えきれない情報があることを示唆する。

6.3 語彙的手法の頑健性とグラフの補完的役割

TF-IDF + Jaccard ベースラインは 3,244 式で MRR 0.924 を達成しており、極めて強い。学習型手法の-margin は +1.3% (reranker-7) から +2.5% (reranker-10) である。

グラフ特徴量は語彙的手法を置き換えるのではなく補完するものとして機能しており、2 段階アーキテクチャ (語彙的候補抽出 → グラフベースリランキング) の妥当性が示された。

6.4 分散の縮小

データ拡大により、全手法で 5 seed 間の分散が大幅に縮小した (baseline: 0.088 → 0.040, reranker-7: 0.119 → 0.018)。これは評価の統計的信頼性の向上を意味し、データの多様性がモデルの安定性にも寄与することを示す。

7 今後の計画

優先度	項目	目的
高	論文執筆	GNN を用いた物理モデル自動構築を主テーマに
中	訓練ケース増強 (123 → 200+ コア)	API 失敗分 2 バッチの再実行
低	GNN 学習特徴量の再テスト	GCN-refined SVD を 3,244 式で再評価
低	5,000 式超への拡大	スケーリング曲線の全体像解明, 飽和点の同定