開発記録：科学文献からの数式抽出パイプライン

AutoPMob プロジェクト

更新日：2026 年 11 月 9 日

目次

1 概要 3

2 遭遇した問題と解決策 3
- 2.1 API モデル 404（モデル未提供） . . . 3
- 2.2 レートリミット（429 RESOURCE_EXHAUSTED） . . . 3
- 2.3 数式内の変数表記の揺れ（c_w と c_p） . . . 4
- 2.4 変数表記の統一（訓練用正規化） . . . 4

3 技術メモ 4

4 各ファイル・ディレクトリの役割 5
- 4.1 プロジェクトルート（実行スクリプト・メタファイル） . . . 5
- 4.2 設定・運用補助 . . . 6
- 4.3 データ・実験成果物（リポジトリに含まれる例） . . . 6
- 4.4 ドキュメント . . . 7

5 データセット定義と評価（次の開発者向けガイド） 7
- 5.1 データ構造（Equation と Training Case） . . . 7
- 5.2 タスク定義（Equation Retrieval / Model Selection） . . . 7
- 5.3 なぜ MRR を使うか（採用理由） . . . 7
- 5.4 MRR と Recall@K の計算方法 . . . 7
- 5.5 データ分割（リーク防止のための paper/source_id split） . . . 8
- 5.6 再現可能な実験手順（何をどう動かすか） . . . 8
- 5.7 現時点の結論（次に何をすべきか） . . . 8

6 GNN の仕組みと埋め込み（次の開発者向け） 8
- 6.1 なぜ現状のグラフ構築では GNN の強みを活かせないか（分析） . . . 8
- 6.2 グラフの構築（`build_graph_data.py` → `equation_graph.pt`）【二部グラフ版】 . . . 9
- 6.3 式の埋め込みの 2 系統 . . . 9
- 6.4 GNN の役割（2 種類の使い方） . . . 10
- 6.5 スコアリングと学習 . . . 10
- 6.6 ファイルと役割の対応 . . . 10

7 今後の予定・TODO 10

7.1 試したいこと・実験アイデア（大胆に） 11

8 **更新履歴** 11

1 概要

本ドキュメントは、GNN（グラフニューラルネットワーク）を用いた物理モデル自動構築の研究の一環として開発している、科学文献 PDF から数式と変数定義を抽出するパイプラインの開発記録である。記録内容は研究室ゼミの報告および将来の研究論文の素材として利用する。

パイプラインの目的

- 科学文献の PDF を入力とし、番号付き数式および付録の数式を LaTeX 形式で抽出する。
- 各数式について変数定義（variable definitions）と物理的意味（context）を周辺テキストから抽出する。
- 抽出結果を JSON 形式で保存し、物理モデル自動生成モデルの訓練データとして利用する。

技術スタック

- API: Google Gemini API（`gemini-2.5-flash`）
- SDK: `google-genai`（PDF 直接アップロード、Structured Output 対応）
- スキーマ検証: Pydantic
- 出力: `extracted_equations.json`（および表記正規化版 `extracted_equations_normalized.json`）

2 遭遇した問題と解決策

2.1 API モデル 404（モデル未提供）

現象

- `gemini-1.5-pro` を指定して `generateContent` を呼ぶと、API から `404 NOT_FOUND` が返る。
- エラーメッセージ: “models/gemini-1.5-pro is not found for API version v1beta”.

原因

- 利用環境（API version v1beta）では `gemini-1.5-pro` が提供されていない、またはモデル ID が変更されている。

対応

- 呼び出しモデルを `gemini-2.0-flash` に変更。のちに無料枠の都合で `gemini-2.5-flash` に変更。
- 利用可能なモデル一覧は `https://ai.google.dev/gemini-api/docs/models` 等で確認する。

2.2 レートリミット（429 RESOURCE_EXHAUSTED）

現象

- リクエスト直後に `429 RESOURCE_EXHAUSTED` が返る。
- メッセージに “Quota exceeded for metric: ... generate_content_free_tier_..., limit: 0” とあり、無料枠のリクエスト数・トークン数が 0 に制限されている。

原因

- 無料ティアのクォータが枯渇している、または当該プロジェクトでは `gemini-2.0-flash` の無料枠が 0 に設定されている。

対応

- 利用可能なモデルに変更：`gemini-2.5-flash` では「1 分あたり 5 回（5 RPM）」の枠が利用可能であったため、モデルを `gemini-2.5-flash` に統一。
- 5 RPM を超えないよう、`generate_content` の呼び出し前に「前回呼び出しから最低 12 秒（60/5）経過するまで待機」する処理を追加。
- リトライ回数・待機時間は当初「12 回・最大 300 秒」としていたが、ユーザ体験を考慮して「5 回・初

回 15 秒・最大 60 秒」に短縮（レートリミット時のみリトライ）。

2.3 数式内の変数表記の揺れ（c_w と c_p）

現象

- 論文では 5 番・6 番の式で「水の比熱」を明示するため c_w を用いているが、抽出結果ではすべて c_p になっていた（eq_5, eq_6）。

原因（推定）

- **LLM の記号正規化**：熱力学では比熱の記号として c_p が一般的なため、モデルが c_w を c_p に「統一」して出力した可能性。
- **PDF の見た目**：フォントによっては下付きの w と p が似て見え、誤読した可能性。
- **意味の同一視**：「水で満たされている」という文脈で c_w と c_p を同一視し、c_p に揃えた可能性。

対応

- プロンプトを強化：「変数記号・添字は文献の表記をそのまま抽出する。c_w を c_p に変更しない」旨を明記。
- 訓練用には「同じ物理意味の変数は正規化する」方針とし、`config/notation_map.json` と `normalize_notation.py` を用意。c_w/Cp/cp 等を c_p に統一する後処理を導入。抽出はできるだけ原文のまま、訓練前に正規化する二段構えにした。

2.4 変数表記の統一（訓練用正規化）

要望

- 物理モデル自動生成モデルの訓練のため、同じ物理意味を持つ変数の表記をすべて統一したい（モデル誤読・論文側の表記揺れのいずれも吸収）。

対応

- `config/notation_map.json` で「正規表記（canonical）」と「揺れ（alternatives）」を定義。
- `normalize_notation.py` で、抽出済み JSON の `equation` および `variables` のキー・説明文に置換を適用し、`*_normalized.json` を出力。
- 抽出パイプラインに `-normalize` オプションを追加し、抽出直後に正規化版を保存できるようにした。

3 技術メモ

- **Structured Output**：Pydantic の `model_json_schema()` で配列スキーマを組み、`response_mime_type: application/json` と `response_json_schema` を渡して JSON 配列を取得。
- **ファイルアップロード**：`client.files.upload()` で PDF をアップロードし、`state` が `ACTIVE` になるまでポーリング。`Part.from_uri()` でコンテンツに含める。
- **環境変数**：`GEMINI_API_KEY` または `GOOGLE_API_KEY`。オプションで `EXTRACT_EQUATIONS_MIN_INTERVAL`（5 RPM 用）、`EXTRACT_EQUATIONS_MAX_RETRIES` 等。
- **開発記録の自動追記と GitHub 同期**：Cursor のルール（`.cursor/rules/development-log.mdc`）で、**全ての変動**（機能追加・新スクリプト・バグ修正・設定変更等）の内容と理由を `development_log.tex` の「更新履歴」に追記するよう指示。あわせて、変更後は必ず `git add`、`git commit`、`git push` を実行し、GitHub へ同期する運用とする。
- **コミット時の自動 push**：`.git/hooks/post-commit` で `git commit` のたびに `git push` を実行するため、コミットすればリモートへ反映される。
- **統合パイプライン** `build_equation_graph.py`：`input_pdfs/` 内の「未抽出」PDF のみ一括処理（処

理済みは processed_pdfs.json で管理、1 ファイルごとに 15 s 待機で 5 RPM 対策)。LLM 知識から化学工学基礎式を 20 個生成（Handbook)。抽出・生成結果を単一の unified_equations.json に統合（既存時は追記、source_id+eq_id で重複排除)。-mode pdf|handbook|all、-processed-list で処理済み一覧を指定可能。

- **API モデル**：当初 gemini-1.5-pro、のち gemini-2.5-flash（5 RPM)、RPD 制限対策で gemini-2.0-flash に変更後、高性能化のため gemini-2.5-pro に統一。
- **デフォルト API キー**：環境変数未設定時に限り、開発用デフォルトキーを使用するように変更（extract_equations.py、build_equation_graph.py、test_api.py)。
- **論文メタデータ取得** fetch_papers.py：Semantic Scholar API でクエリ A/B 各 50 件のメタデータを取得し、paper_dataset_links.json に保存。オープンアクセス PDF URL を has_open_access_pdf、open_access_pdf_url で明示。429 時はリトライと SEMANTIC_SCHOLAR_API_KEY 対応。
- **グラフ前処理** build_graph_data.py：unified_equations.json から**式–変数二部グラフ**の Data を構築し equation_graph.pt に保存（詳細は各ファイル・ディレクトリの役割)。
- **訓練ケース生成** generate_training_cases.py：LLM で約 150 件のコアケースを生成（context、input_variables、output_variables、correct_model_ids)。正解モデルは「入力が与えられれば出力を解ける」「十分かつ最小限の数式群」となるようプロンプトで制約。Python で入出力スワップ・ランダム入出力・context 言い換えにより 1 コアから 5–6 バリアントを生成し、900 件以上を training_cases.json に保存。
- **可視化・分析** analyze_dataset.py：数式グラフ・訓練ケースの統計と可視化。ドメイン分布、次数分布、埋め込みの PCA（ドメイン色分け)、変数共起ネットワーク、訓練ケースの variant 分布・正解モデル数分布。論文付録向け dataset_report.txt と figures/*.png を出力。

4 各ファイル・ディレクトリの役割

リポジトリ内の主要なパスと、その責務の一覧である（.gitignore 対象や個人環境依存は除く)。

4.1 プロジェクトルート（実行スクリプト・メタファイル）

- README.md：環境構築、代表的なコマンド、リポジトリ構成の入口。
- CLAUDE.md：別ツール・別環境で開発を続けるときの引き継ぎ要約（目的・データ・実験結論・スクリプト対応)。
- research_context.md：研究メモ用（CLAUDE.md へのポインタを含む)。
- requirements.txt：Python 依存パッケージの一覧。
- extract_equations.py：単一 PDF を Gemini API に渡し、数式・変数定義・周辺文脈を JSON で抽出する。
- normalize_notation.py：抽出済み JSON の式文字列・変数キー等を config/notation_map.json に従い訓練向けに正規化する。
- build_equation_graph.py：input_pdfs/ の未処理 PDF を一括抽出し、必要に応じ Handbook 式を LLM 生成し、unified_equations.json に統合する（スキップ管理は processed_pdfs.json)。
- fetch_papers.py：Semantic Scholar API で論文メタデータを取得し paper_dataset_links.json に保存する。
- build_graph_data.py：unified_equations.json から式ノード・変数ノードの二部グラフを構築し、各ノードに CodeBERT [CLS]（768 次元、変数側は含有式の平均）を付与して equation_graph.pt

（PyTorch Geometric）を出力する。

- generate_training_cases.py：LLM でコアケースを生成し、入出力スワップ等でバリアントを増やして training_cases.json を構築する。
- validate_dataset.py：式のグローバル ID 参照、ケースと式の変数整合、重複などを検査し validate_dataset_report.json を出力する。
- add_context_paraphrases.py:訓練ケースの文脈のみ言い換えたバリアントを training_cases.json に追加する。
- analyze_dataset.py：グラフ・訓練ケースの統計と図表を生成し、dataset_report.txt と figures/ に書き出す。
- baseline_retrieval_eval.py：TF-IDF、変数 Jaccard、混合ベースライン等の retrieval 評価ロジック（単体実行および実験ランナーから利用）。
- run_retrieval_experiments.py：複数の scoring 方式を同一の source_id 分割で学習・評価し、結果を experiments/ に JSON と Markdown で保存する。
- train_gnn_retriever.py：equation_graph.pt 上で式側を GCN または GAT で更新し、クエリを SVD→MLP で揃えて InfoNCE 型で学習する簡易スクリプト（レポートは gnn_train_eval_report.json）。
- train_gnn_refine_svd.py：式・クエリを同一 TF-IDF+SVD 空間に置き、式埋め込みを残差 GCN で更新する実験用スクリプト（gnn_refine_svd_report.json）。
- test_api.py：Gemini API の疎通確認用。

4.2 設定・運用補助

- config/notation_map.json：同一物理量の記号揺れを正規表記に寄せるための対応表。
- scripts/install-git-hooks.sh：コミット後に git push する post-commit フックを入れるためのインストール用シェル。
- .cursor/rules/development-log.mdc:コード変更時に本 development_log.tex を更新し GitHub に同期するよう指示するエディタ用ルール。

4.3 データ・実験成果物（リポジトリに含まれる例）

- unified_equations.json：全ソースを統合した数式ライブラリ（グラフ構築・訓練ケースの参照元）。
- training_cases.json：retrieval タスクの入力（文脈・I/O 変数）と正解式 ID 集合。
- equation_graph.pt：PyG Data（x, 二部 edge_index, num_equations, edge_index_eq_eq 等）。
- processed_pdfs.json：build_equation_graph.py が既に処理した PDF ファイル名のリスト。
- paper_dataset_links.json：fetch_papers.py の取得結果（PDF URL 等）。
- extracted_equations.json：単一 PDF 抽出の典型出力（中間・サンプル用）。
- experiments/retrieval_experiments.json：方式比較実験の分割・ハイパラ・指標の機械可読ログ。
- experiments/retrieval_experiments.md：上記実験の表形式サマリ。
- validate_dataset_report.json：データセット検証の詳細結果。
- dataset_report.txt：analyze_dataset.py のテキスト要約。
- gnn_train_eval_report.json / gnn_refine_svd_report.json / baseline_eval_report.json：各スクリプトの評価サマリ（実行時に更新）。
- input_pdfs/：一括抽出の入力 PDF を置くディレクトリ。
- figures/：分析スクリプトが出力する図（PNG 等）。

4.4 ドキュメント

- docs/development_log.tex：本ドキュメント（開発記録の原本）。
- docs/README.md：development_log.tex を PDF にビルドする手順。
- docs/GITHUB_SYNC.md：リモート同期に関する補足メモ。

5 データセット定義と評価（次の開発者向けガイド）

5.1 データ構造（Equation と Training Case）

Equation（unified_equations.json）

- 1 要素が 1 つの数式（ノード）で、主なキーは source_id, eq_id, equation, variables, context_text, domain。
- variables は辞書で、キーが変数シンボル（例: C_A）、値が物理意味の説明文（例: Concentration of component A）。
- **グローバル ID の注意**: eq_id は文書内ローカルのことがあるため、訓練や評価では **必ず** <source_id>__<eq_id> 形式（例: handbook_chemeng__eq_1）を「式 ID」として扱う。

Training Case（training_cases.json）

- 1 要素が 1 つの推論タスクで、主なキーは case_id, variant_type, context, input_variables, output_variables, correct_model_ids。
- correct_model_ids は「このケースの正解となる数式集合（1 本以上）」であり、各要素は **必ず** <source_id>__<eq_id> 形式。
- **variant_type**: original, swap_io, random_io_from_models, context_paraphrased（I/O と正解モデルを保持し文脈だけ言い換え）。

5.2 タスク定義（Equation Retrieval / Model Selection）

本研究の基本タスクは、与えられたケース (context, input_variables, output_variables) から、式集合ライブラリ（全式）内の correct_model_ids を上位にランキングする **retrieval** として定義する。各ケースは正解が 1 本のことも複数本のこともある（multi-positive）。

5.3 なぜ MRR を使うか（採用理由）

本タスクでは「正解が上位に出てくること」が重要であり、特に **1 本目の正解**が何位に現れるかがユーザ体験（候補式提示）に直結する。また、ケースによって正解式が複数あるため、分類精度（accuracy）のような単一ラベル前提の指標は不適切である。そのため、ランキングの早期精度を評価できる **MRR（Mean Reciprocal Rank）** と **Recall@K** を主要指標として採用した。

5.4 MRR と Recall@K の計算方法

各ケース i について、モデルが全式をスコアリングし降順に並べた順位列を考える。正解集合を G_i（correct_model_ids に対応するノード集合）とする。

- **BestRank**：$r_i = \min\{\mathrm{rank}(e) \mid e \in G_i\}$（正解集合のうち最も上位に来た式の順位）
- **Reciprocal Rank**：$RR_i = \frac{1}{r_i}$
- **MRR**：$\mathrm{MRR} = \frac{1}{N}\sum_{i=1}^{N} RR_i$

- **Recall@K**：$\text{Recall@K} = \frac{1}{N}\sum_{i=1}^{N} \mathbb{I}[r_i \le K]$

ここで N は評価対象ケース数。正解が複数ある場合でも、最初に当たる正解の順位（BestRank）で評価する。

5.5 データ分割（リーク防止のための paper/source_id split）

同一文書から抽出された式や文脈が train と test に混ざると、文字列一致により過大評価（リーク）になる。そのため、分割は **source_id（論文/教科書）単位**で行い、case の `correct_model_ids` から source_id を推定して train/val/test に割り当てる。実装例は `run_retrieval_experiments.py`（`experiments/retrieval_experiments.json` に split を保存）。

5.6 再現可能な実験手順（何をどう動かすか）

- **健全性チェック**：`python validate_dataset.py`（式 ID 参照、I/O 変数整合、重複など。レポートは `validate_dataset_report.json`）。
- **訓練ケース増強（context のみ言い換え）**：`python add_context_paraphrases.py`（`training_cases.json` を更新）。
- **統計と図の更新**：`python analyze_dataset.py`（`dataset_report.txt` と `figures/`）。
- **方式比較とハイパラ探索**：`python run_retrieval_experiments.py`（結果は `experiments/retrieval_experiments.`

5.7 現時点の結論（次に何をすべきか）

現状では、学習を伴う GNN/MLP 系よりも、**TF-IDF（文脈）+ 変数集合 Jaccard（I/O 一致）**を混合した `baseline_mix` が最良である。次の開発では、(1) negative sampling を hard negative 化、(2) 変数をノードとして明示した二部グラフ化、(3)「正解式集合の整合性（最小十分性）」を利用した学習目的の改善、などによりベースライン超えを狙う。

6 GNN の仕組みと埋め込み（次の開発者向け）

6.1 なぜ現状のグラフ構築では GNN の強みを活かせないか（分析）

GNN の強みは、**タスクに効く構造をグラフに載せ、その上で局所的な集約をしてノード表現を磨く**ことにある。当初の「式をノード、共通変数があればエッジ」という設計には、次のような限界がある。

（1）エッジが極端に密になり、構造の弁別力が弱い

- ノード数 N に対し、変数を 1 つでも共有する式ペアに無向エッジを張ると、t, T, V, C_A など頻出変数を含む式が多数つながる。実際のデータでは 975 ノードで約 16 万本のエッジとなり、1 式あたり平均で非常に多くの式と隣接する。
- その結果、「同じ物理モデルに属する式」と「たまたま t や T を共有するだけの式」が区別されず、メッセージパッシングで無関係な情報が混ざり、ノード表現がシャープに磨かれない。

（2）変数共有と retrieval の正解が対応していない

- タスクは「与えられたケース（context + I/O 変数）に合う式をランキングする」retrieval である。正解は「そのケースの入出力を満たす式集合」であり、変数名の共有は「候補になりうる」必要条件にすぎない。
- 多くの不正解の式も t や T を共有するため、グラフのつながりだけでは「このクエリに正解」というシグナルが弱く、GNN の集約が retrieval に直結しにくい。

（3）変数がグラフ上に明示されていない

- 変数はエッジの「条件」としてしか現れず、ノードとしては存在しない。そのため「この式はクエリの

出力変数 C_A を含む」といった情報を、メッセージパッシングで明示的に扱えない。のちにクエリ条件（I/O 変数）に依存した重み付けやサブグラフを入れることも難しい。

（4）ホモフィリー仮定が成り立ちにくい

- 多くの GCN 系モデルは「つながっているノードは似ている」という仮定で学習する。ここでは「つながり＝1 つでも変数名が被った」なので、ドメインが違っても t だけ共有でつながる、といったノイズが多く、ホモフィリーが弱い。そのため、隣接ノードからの集約が「関連の強い式」に絞られず、GNN の利点が生かしづらい。

以上から、**「式＝ノード・共通変数＝エッジ」だけの同質グラフは、retrieval というタスクに対して GNN の強みを十分に引き出せる設計にはなっていない**、という結論になる。改善の方向性として、(i) 変数を明示した**式–変数二部グラフ**で「どの変数を介してつながるか」を構造に載せる、(ii) クエリの I/O 変数に応じたエッジ重みやサブグラフにする、(iii) 訓練ラベルを利用して「同じ正解に共起する式」同士をエッジで結ぶ、などが考えられる。

6.2 グラフの構築（build_graph_data.py → equation_graph.pt）【二部グラフ版】

タスクに効く構造と局所集約を両立させるため、**式ノードと変数ノードの二部グラフ**を採用する。

- **ノード**：**式ノード**（0 から $N_{\text{eq}} - 1$）と **変数ノード**（N_{eq} から $N_{\text{eq}} + N_{\text{var}} - 1$）。式ノードは `unified_equations.json` の並びと一致。変数ノードは全式から出現する変数名のユニーク集合に 1 対 1 で対応する。
- **エッジ**：式 i が変数 v を含むときのみ、無向エッジ $(i,\ N_{\text{eq}} + j)$ と $(N_{\text{eq}} + j,\ i)$ を張る（j は変数 v の ID）。式同士は直接つながらず、**変数ノードを介した 2 ホップ**で「同じ変数を含む式」に情報が伝わる。これにより集約が「どの変数を共有しているか」に沿った形になり、局所性も保たれやすい。
- **ノード特徴** `x`：式ノードには従来どおり **CodeBERT** の [CLS] ベクトル（768 次元）。変数ノードには、その変数を含む式の CodeBERT ベクトルの平均を 768 次元特徴として与える（学習可能な変数埋め込みにすることも可能）。`x` の形状は $(N_{\text{eq}} + N_{\text{var}},\ 768)$。
- **保存内容**：`Data(x=x, edge_index=edge_index, num_equations=`N_{eq}`)` に加え、後方互換のため式どうしの隣接 `edge_index_eq_eq`（$0..N_{\text{eq}} - 1$ のみのインデックス）も保存する。学習・評価では式埋め込みは GCN 出力の **先頭** N_{eq} **行**のみを用いる。

6.3 式の埋め込みの 2 系統

Retrieval 実験では、式の表現に次の 2 系統がある（スクリプトによってどちらを使うかが異なる）。

系統 A：CodeBERT ノード特徴（`equation_graph.pt` の `x`）

- 上記のとおり、事前学習済み CodeBERT で式 + 文脈をエンコードした 768 次元ベクトル。学習時には L2 正規化してコサイン類似度＝内積として使う。
- `train_gnn_retriever.py` の「式側は `x` をそのまま（または GCN で更新）」や、`run_retrieval_experiments.py` の `q_mlp_to_x` で使用。クエリ側は SVD 空間のベクトルを MLP で 768 次元に写す方式。

系統 B：TF-IDF + TruncatedSVD（同一空間でクエリと式を比較）

- 式テキスト：`context_text`, `equation`, `domain` を連結した文字列を TF-IDF（`TfidfVectorizer`、lowercase, max_features=50000, ngram_range=(1,2)）でベクトル化し、TruncatedSVD で 256 次元に圧縮。L2 正規化したものを式埋め込み E_0 とする。
- クエリ（ケース）テキスト：`context` と `INPUT <input_variables>`, `OUTPUT <output_variables>` を連結し、同じ TF-IDF と SVD で 256 次元に写し L2 正規化したものをクエリ埋め込み Q とする。
- スコアは $E_0^\top Q$（内積＝コサイン類似度）。`svd_cos` ベースラインや `train_gnn_refine_svd.py` の入力はこの空間。

6.4 GNN の役割（2 種類の使い方）

パターン 1：式特徴を CodeBERT x のまま、GCN で更新（train_gnn_retriever.py）

- 式埋め込みは $z = \mathrm{GCN}(x, \mathrm{edge_index})$。2 層 GCN（GCNConv(in_dim, 768), ReLU, Dropout, GCNConv(768, 768)）の出力を L2 正規化。クエリは SVD ベクトルを QueryEncoder（MLP）で 768 次元に写し、$z^\top q$ でスコア。InfoNCE 風の負例サンプリングで学習。
- 現状の実験では、クエリと式が別空間（SVD vs CodeBERT）から来るため学習が難しく、このパターン単体ではベースラインを下回っている。

パターン 2:SVD 空間で式埋め込みを GCN で残差更新(train_gnn_refine_svd.py, gnn_refine_svd_residual)

- 式の初期埋め込みは系統 B の E_0（256 次元、L2 正規化済み）。これを 2 層 GCN の入力とし、$h = \mathrm{GCN}(E_0)$ を計算したあと、**残差混合** $E = E_0 + \alpha \cdot h$ で更新（α は学習可能スカラー、初期値 0 でクリップ）。最終的に E を L2 正規化して式埋め込みとする。クエリは同じ SVD 空間の Q のまま、スコアは $E^\top Q$。
- $\alpha = 0$ のときは GCN を通さないので SVD コサインと同一。グラフ構造（変数共有）の情報を少しずつ取り込む設計。学習はサンプルされた負例に対する InfoNCE 的損失。

6.5 スコアリングと学習

- いずれの方式でも、式埋め込みとクエリ埋め込みは L2 正規化してから内積をとるため、スコアは **コサイン類似度** に等しい。
- 学習時：各訓練ケースについて正解式を 1 本選び、ランダムに多数の負例式をサンプル。正解を 1 位にしたいので、正解・負例のスコアに温度 τ（例 0.07）をかけた logits に対して cross-entropy（正解インデックス 0）を最小化（InfoNCE 型）。

6.6 ファイルと役割の対応

- build_graph_data.py：**式–変数二部グラフ**を構築。x は式ノード＋変数ノードの特徴、edge_index は二部エッジ、num_equations と edge_index_eq_eq（式同士の隣接）も保存。
- train_gnn_retriever.py：式埋め込みは GCN/GAT 出力の先頭 num_equations 行を使用（二部グラフ対応）。クエリ＝ SVD → MLP。-use-gnn / -no-gnn で GNN の有無、-gnn-type gcn|gat で GNN 種類を切替。
- train_gnn_refine_svd.py：式＝ SVD(E_0) を残差 GCN で更新、クエリ＝ SVD(Q)。edge_index_eq_eq（式同士のみ）を使用。
- run_retrieval_experiments.py：上記に加え baseline_mix、svd_cos、q_mlp_to_x、gnn_refine_svd_residual を同一分割で比較。二部グラフ時は式ノードのみ x[:num_equations] と edge_index_eq_eq を利用。

7 今後の予定・TODO

- 複数 PDF の一括処理と正規化の一括適用。
- 正規化ルール（notation_map.json）のドメイン別拡張。
- 抽出結果の検証用テスト（期待する数式との差分チェック）。
- GitHub との同期と CI（テスト・リント）の検討。

7.1 試したいこと・実験アイデア（大胆に）

- **GNN の種類**：GCN に加え GAT（Graph Attention）を試す。二部グラフでは「どの変数ノードを重視するか」を attention で学習できると有利な可能性。
- **エッジ重み**：変数ごとの IDF や、クエリ I/O 変数との一致度でエッジに重みを付け、メッセージの強さを変える。
- **クエリ条件付きグラフ**：推論時に「このクエリの入力・出力変数を含む式／変数」にだけメッセージを流す、あるいはエッジをマスクする。タスクに効く構造に絞る。
- **Hard negative**：ランダム負例に加え、変数は被るが正解でない式を意図的に負例にし、境界を学習しやすくする。
- **式の言い換え・拡張**：同一式の context 言い換えや変数名の正規化違いをデータ拡張し、埋め込みのロバスト性を高める。
- **評価の安定化**：同じ分割で複数 seed を回し、平均・標準偏差で報告。小規模データなのでばらつきを明示する。

8 更新履歴

- 2026-11-09（LLM との比較：テストケースの平均トークン数を、文字数の比で見積もった 354 から、全件を数えた 303 に直した）：本人の指示「354 を 303 に直して」に対応した。354 は、最も長いテストケースのトークン数（734）を、平均の文字数との比で縮めた見積もりだった。最も長いケースの 1 文字あたりのトークン数（0.47）を全件（平均 0.40）に当てはめたので、17% 大きく出ていた。`run_llm_db_baseline.py` の count3 で、テストケースを全件 1 件ずつ count_tokens（無料）で数えるようにした（`count_task_tokens`）。平均 303.2、中央値 290、最小 82、最大 762 で、4 モデルとも同じだった（1 件ずつの値は `task_tokens_v4.json`）。トークン数の最も多いケース（`dae_X10_090`）でも要求そのものを数え、952,905 トークンで上限に収まる。costs3 は全件の平均を使うようにし、`--pilot-version` で、出力を見積もる試しの版を選べるようにした。11 月 4 日の進捗報告の Table 3 は、出力の仮定を 11 月 4 日のまま（Claude Haiku 5.5 は版 3 の試しの 972、ほかは 2,000）にして、`costs_v4_runs3_pilotv3.json` から作り直した。テストケースの入力の列と合計が下がり（例：Claude Fable 5.1 は 17.8 → 15.2、合計 1,726.3 → 1,723.7）、1 モデルの費用は 252〜1,724 ドル、2 モデルは 1,420〜2,307 ドルになった。読み出しの割合（69〜95%）は変わらない。報告は 4 ページのまま。版 4 の試しの出力で見積もる `costs_v4_runs3.json` も、全件の平均で計算し直した。テストは 81 件すべて通る。
- 2026-11-09(2)（LLM との比較：同じ式を 1 本と数える（延べなし）Recall@20・MAP@20 を計算した）：本人の決定「今の分割のまま。文献単位の確認は書き添えない。重複はデータベースの正常現象とみなし、報告と文献で言及しない。LLM の結果について、重複した同じ式を延べなしで Recall を計算する」に対応した。`llm_recall_dedup.py` を新しく作り、式の同一性を表記（`latex_key`）で決めて、正解集合でも答えでも同じ式を 1 本と数えた（正解集合の中の同じ式は 1 本にして K を減らす＝設定 A・B とも 10 件、同じ出典の中の同じ式も同じ式とみなす、答えの中の同じ式の 2 本目以降は数えない）。既存の *_equiv（別の出典の同じ式だけを正解とみなし、K はそのまま）との違いはこの 3 点。LLM は保存した答え（`ranked_keys`）、提案手法は `proposed_top20/` の上位 20 件を同じ規則で採点した。結果（10 通りの分割の平均 ± SD、ID 判定 → 延べなし）：設定 A は Opus 5.5 が Recall@20 0.924 → 0.932、MAP@20 0.761 → 0.823、Haiku 5.5 が 0.497 → 0.530、0.300 → 0.330、提案手法が 0.981 → 0.983、0.857 → 0.903。設定 B は Opus 0.899 → 0.912、0.744 → 0.794、Haiku 0.532 →

0.562、0.313 → 0.339、提案手法 0.966 → 0.969、0.823 → 0.860。延べなしでも 10 通りすべてで提案手法が上（設定 A の差は Recall@20 +0.051、MAP@20 +0.080）。延べなしで Recall@20 が上がった答えは Opus 170 回・Haiku 477 回（5,019 回中）、下がった答え（正解集合の同じ式を両方挙げたとき）は 14 回・5 回。出力は `experiments/llm_db_baseline/recall_dedup.json`、単体テスト 7 件（`tests/test_llm_recall_dedup.py`）。

- 2026-11-09(1)（データベースで同じ文献が別々のファイルとして入っているものを調べ、分割の単位をファイルから文献に直して提案手法を学習し直した）：本人の指示「先に DB の教科書の重複を整理して」「文献単位の分割で学習し直して比べて」に対応した（LLM の取り直しは予算がないのでしない）。出典 ID は PDF のファイル名で、同じ文献が別々のファイルとして入っているものが 38 文献・88 ファイル（3,646 式）あった：Seborg（本全体と第 2 章だけのファイル。同じ LaTeX の式 67）、Corriou（2018 年の第 2 版の全体、その第 1 章の抜き出し 2 つ、2004 年の初版の第 1 章）、Marlin（本全体と第 3・4 章。式の重なりはほぼない）、OpenAlex の収集で 2〜3 分野の検索に重なった論文 35 報。分割は出典 ID 単位なので、同じ本のファイルが「テスト」と「訓練か検証」に分かれた分割が、設定 A で Seborg 7 通り・Corriou 8 通りあった（方針は最初から文献単位で、DB のほうが「1 ファイル = 1 文献」の前提を破っていた）。`doc_split_rerun.py`（docs・splits・train・compare）を新しく作り、同じ文献のファイルをまとめる対応（`experiments/doc_split/source_documents.json`：収集の番号を除いた名前・DOI・手で挙げた教科書）、文献単位の層化分割（`splits.json`。同じ特徴量・同じ種・同じ外す一覧で、出典の印だけを文献にした）、提案手法の学習し直し（検証用のケースが 10 通りすべてで選んだ設定 w30-70・hard を固定。1 分割あたり 50〜100 秒）、集計（`compare.json`）を行った。結果：設定 A の提案手法は Recall@20 0.981 ± 0.010 → 0.974 ± 0.015、MAP@20 0.857 ± 0.055 → 0.824 ± 0.062、設定 B は 0.966 ± 0.016 → 0.972 ± 0.015、0.823 ± 0.044 → 0.834 ± 0.044。学習しない Claude Opus 5.5 も、同じ新しいテストケースで 0.924 → 0.913、0.761 → 0.721（設定 A）と同じ向きに同じくらい動いたので、変化はテストケースの構成の違いによるもので、同じ文献の漏れが提案手法の値を押し上げていた証拠はない。LLM の答えがある同じケースで比べた提案手法と Opus の差は、設定 A で Recall@20 +0.061（ファイル単位では +0.057）、MAP@20 +0.102（+0.096）、設定 B で +0.068（+0.067）、+0.077（+0.079）で、10 通りの分割すべてで提案手法が上。新しいテストケースのうち LLM の答えがあるのは 98.2%（A）・99.1%（B）。DB の式と既存の分割（`experiments/llm_db_baseline/splits.json`）は変えていない。単体テスト 17 件（`tests/test_doc_split_rerun.py`）。
- 2026-11-08(1)（LLM との比較：Claude Opus 5.5 が提案手法を上回ったケースの特徴を調べた）：本人の指示「Opus が提案手法を上回ったケースの特徴を調べて」に対応した。既存の出力には正解式の順位しかないため、`dump_proposed_top20.py` で提案手法を同じ設定・同じ乱数で学習し直し、テストケースごとの上位 20 件を書き出した（設定 A・B の各 10 通りの分割。順位は既存の出力と全ケースで一致）。`analyze_opus_vs_proposed.py` で、ケースごとに Opus（3 回の平均）と提案手法（テストに入る分割の平均）を比べた（`experiments/llm_db_baseline/opus_vs_proposed.json`）。設定 A の 1,586 件で、Recall@20 が上回ったのは 36 件（すべて合成のケース。3 回とも全分割より高いのは 12 件）、MAP@20 は 274 件（単一出典 10、出典横断 65、合成 199）。Recall@20 で上回った 36 件は、正解式が多いケース（7 本以上が 26 件）で、25 件は同じ教科書が別々の出典として DB に 2 回以上入っているもの（Seborg の 2 つの PDF、Process Control の 3 つの PDF と 1 章）から作られていた。正解式が 7 本以上の合成のケースで上回った割合は、その教科書から作られたケースで 26%、ほかで 4%（設定 B でも 29%、5%）。ただしその教科書のケースでは Opus が下回った割合も 70% で、両方の Recall@20 が下がる（提案手法 0.75、Opus 0.65）。上回ったケースでは、提案手法の上位 20 件に、正解式と同じ式の別の出典の写し（1 件あたり 3.9 本）と、変数がすべて入出力に含まれる不正解の式（9.2 本）が並び、Opus だけが上位 20 件に入れた正解式（58 本）は、入出力との変数

の重なりが小さく（Jaccard 0.17）、説明文との文章類似度も低かった（0.07）。出典横断のケースでは、変数の重なりが最も小さい正解式の Jaccard が下位 3 分の 1 のときに MAP@20 で上回る割合が 20%（ほかは 6〜8%）で、Opus の MAP@20 は重なりによらずほぼ一定（0.78、0.77、0.77）、提案手法は下がる（0.92 → 0.86）。説明文が分野ラベルの語を含むかと、正解式の変数の数には、この差との関係が見られなかった。

- 2026-11-07(1)（LLM との比較の本実行：Claude Haiku 5.5 と Claude Opus 5.5 で、10 通りの分割のテストケース 1,673 件をケースごとに 3 回、計 5,019 回ずつ解かせた）：本人の指示「1,300 ドルをチャージした。その方針でテストを進めましょう」に対応した。版 4 の指示文、effort high、8 本並列で `run3 -seeds all` を流した（試しの 1 回目の答えは再利用）。応答の `stop_details`（安全分類器が止めたときの種類と説明）を記録に残すようにした。上限は試しを含めた累計で Haiku 258、Opus 1,085 ドルとした。API の失敗はなく、2 モデルとも 5,019 回すべてそろった。費用は試しを含めて Haiku 255.23、Opus 1,058.93 ドル（本実行の分は計 1,267.33 ドルで、見積もりの 1,267 ドルとほぼ同じ）。キャッシュの保存はモデルごとに 2 回（試しと本実行の最初）だけだった。Haiku は 144 回（2.9%）で答えを返さず（stop_reason が refusal。種類を記録した 139 回はすべて bio）、Opus は 0 回。集計（`evaluate3`、ケースごとに 3 回の平均、10 通りの分割の平均 ± 標準偏差）：設定 A で Opus は Recall@20 0.924 ± 0.018、MAP@20 0.761 ± 0.063、Haiku は 0.497 ± 0.063、0.300 ± 0.050（提案手法 0.981 ± 0.010、0.857 ± 0.055、ベースライン 0.906 ± 0.020、0.680 ± 0.063）。設定 B で Opus 0.899 ± 0.013、0.744 ± 0.044、Haiku 0.532 ± 0.038、0.313 ± 0.027。Opus は 10 通りの分割のすべてでベースラインより高く、提案手法より低かった（Recall@20 と MAP@20 の両方、設定 A と B の両方）。Haiku はすべての分割で両方より低かった。回の間のぶれ（上位 20 件の集合の Jaccard 係数の平均）は Opus 0.57、Haiku 0.32。テストは 79 件通る。
- 2026-11-04(21)（初期の 9 報を Gemini 2.5 Pro で抽出し直し、古い抽出と対応づけて 146 件のケースを判定した）：親セッションの依頼（加藤先生の 3 回目のコメント K5）。`initial9_reextract.py`（facts、extract、match、baseline）を新しく作り、`docs/初期 9 報の抽出し直し_2026-11-04.md` にまとめた。9 報すべての書誌を確定した（`038.pdf` は Laszczyk ほか (2017) の Process Control 2017 の会議論文）。PDF は 4 報を配布元から取得し、3 報は本人が入手した（大学の契約の 2 報と、自動の取得を拒む MATEC）。本人の承認（7 報、のちに 2 報を追加）で、9 報を 1 回ずつ抽出した。応答のモデルの版は 9 報とも `gemini-2.5-pro`、費用は 1.157 ドル（トークン数と公式の料金から計算）、新しい抽出は 155 式。古い 162 式のうち 154 式が 1 対 1 に対応づき、LaTeX の文字列まで同じ式は 36 式だった。原文との照合（`038.pdf` と MATEC の 22 式）では、新しい抽出のほうが原文どおりの式が 16、古い抽出のほうが原文どおりの式が 1、違いのない式が 5。新しい抽出は、CPD の原文にある 3 式を取りこぼした。146 件の判定は、ID の付け替えだけで使える 19 件、入出力変数の記号の付け替えで使える 34 件、要件 1〜3 が崩れる 86 件、対応のない正解式がある 7 件。崩れる主な原因は、新しい抽出が時間 t で微分する式のすべて（28 式）で t を変数に挙げたことである（データベースのほかの出典は 79%、古い抽出は 24 式中 6 式）。t の違いだけで崩れるのは 24 件。判定に、変数と式のつながりを保ったまま記号を 1 対 1 に付け替えられるかを調べる `find_relabel` を加え、同じ PDF を 2 回抽出した組での確かめも同じ判定で数え直した（50 式以下の出典で A 26%、B 26%、C 44%、D 4%）。案は、9 報を新しい抽出に差し替え（a1）、53 件を残して 93 件を外す（c1。設定 A は 1,731 件から 1,638 件になる）。先生の判断待ち。`unified_equations.json` と `training_cases.json` は変えていない。
- 2026-11-04(20)（LLM との比較の費用の見積もりを絞るため、Claude Haiku 5.5 と Claude Opus 5.5 で 50 ドル以内の試しを流した）：本人の指示「総額の範囲が広すぎるので、まず 50 ドルを実行して総額の概算を絞りたい。モデルは Haiku 5.5 と Opus 5.5 にする」に対応した。`run_llm_db_baseline.py pilot3` に `-sample`（10 通りの分割で解かせる 1,673 件から無作為に選ぶ。乱数の種 20261104）と

-workers を加え、回の番号を必ず記録するようにした（試しの答えを本実行の 1 回目として使うため）。並列で流しても上限を超えないように、走っている呼び出しの分を見込んで止めるようにした。版 4 の指示文で、同じ順の無作為な 200 件から、上限（Haiku 10 ドル、Opus 38 ドル）に達するまで解かせた：Haiku 187 件 9.98 ドル、Opus 154 件 36.85 ドル、合計 46.83 ドル。API の失敗はなく、キャッシュの保存はモデルごとに最初の 1 回だけで、残りはすべて読み出しだった。出力（考えた分を含む）の平均は、ケースの種類の割合で重みを付けて Haiku 1,046、Opus 878 トークン。costs3 に、1 回ごとの実際の費用から 5,019 回の総額とその 95% 区間（種類ごとのブートストラップ）を出す処理を加えた：Haiku 253 ドル（252〜255）、Opus 1,055 ドル（1,039〜1,076）、2 モデルで約 1,308 ドル（出力を 70〜8,000 トークンと仮定した前の見積もりは 1,216〜2,112 ドル）。3 通りの分割（3,921 回）なら Haiku 198、Opus 825 ドル。Haiku は合成のケース 5 件で答えを返さなかった（stop_reason が refusal）。テストは 78 件通る。

- 2026-11-04(19)（LLM との比較の指示文を版 4 にした：「list up to 20」を「list 20」にし、20 件に満たないときに埋める 1 文を消した）：本人の指示「プロンプトの『If they are fewer than 20, continue with the other equations most likely to be needed for this model, until the list has 20 IDs.』を消して良い」と「『list up to 20 equation IDs』を『list up 20 equation IDs』にして」に対応した。後者は、相談のうえ、英語として正しい「list 20 equation IDs」にした。run_llm_db_baseline.py に版 4 の指示文 SYSTEM_V4（版 3 から、この 2 か所だけを変えたもの）を加え、count3、costs3、pilot3、run3、evaluate3 が使う版を RUN_VERSION = "v4" にした。版 3 の試し（Claude Haiku 5.5 の 3 件 × 3 回）は変える前の文で解かせたので、記録のファイルが分かれ、本実行では再利用しない（出力のトークン数の見積もりにだけ使う）。count_tokens（無料）で数え直すと、データベースの部分は 952,185 → 952,144 トークンになった（token_counts_v4.json、costs_v4_runs3.json）。11 月 4 日の進捗報告では、付録のプロンプト、本文の「最大 20 個」「20 個に満たなければ…埋める」「20 件までしか答えない」、952,144、Table 3 の読み出しの 2 つのセル（238.9、1,194.7）、2 モデルの費用の上限（2,311 → 2,310 ドル）を直した（4 ページのまま）。修論では、付録のプロンプト、付録の表の「up to 20 identifiers」、4 章の「up to 20 equations」を直した（72 ページのまま）。テストは 75 件すべて通る。8 月 31 日の報告書の付録のプロンプトは変えていない。
- 2026-11-04(18)（11 月 4 日の進捗報告の「比較の目的」を、長所と短所を見つけることに改めた）：本人の指摘「結果は提案手法と LLM 手法のそれぞれのメリット、デメリットを発見すること。精度を比べるだけじゃない」に対応し、1 節の「比較の目的」を次のように書き直した：同じデータベースと同じ判定の規則のもとで、提案手法と LLM のそれぞれの長所と短所を見つける。精度を比べるだけでなく、どのようなケースでどちらが正解式を上位に選べるか、費用、答えの回ごとのばらつきも比べる。高性能と低コストの 2 モデルで、モデルの規模による違いも見る。
- 2026-11-04(17)（11 月 4 日の進捗報告の 1 節に、比較の目的を書いた）：本人の指示「大規模言語モデルとの比較実験は何を得るのを目標にしているか、その結果を何のために使うかを 1 節で簡潔に」に対応し、progress_report_2026-11-04_llm_comparison.tex の 1 節の先頭に「比較の目的」の項目を足した：同じデータベースと同じ判定の規則で、LLM が作りたいモデルに使う式をどれだけ上位 20 件に選べるかを測り、提案手法と古典的な情報検索手法と比べる。結果は、提案手法の精度を外部の手法である LLM と比べた評価として示すのに使う。高性能と低コストの 2 モデルで、モデルの規模による違いも見る。LLM の正式名称はこの項目に移した。本文は 1〜3 ページ（全体 4 ページ）のまま。
- 2026-11-04(16)（11 月 4 日の進捗報告に、LLM に与えるプロンプトだけを付録として戻した）：本人の指示「LLM を使ったらプロンプトを付録に載せて」に対応し、progress_report_2026-11-04_llm_comparison.tex に Appendix A（LLM に与える指示文と入力の形。21c332b の版と同じ内容）だけを戻し、2.2 節の参照「指示文と入力の形は Appendix A」も戻した。呼び出しの設定と記録、費用の見積もりの前提（旧 Appendix B、C）は戻していない。全体は 4 ページ（本文 1〜3 ページ）。

- 2026-11-04(15)（11 月 4 日の進捗報告の付録をいったん無くした）：本人の指示「付録を一旦無くして。これは全体ゼミなので、具体的すぎる部分は議論しない」に対応し、progress_report_2026-11-04_llm_comparison.tex の Appendix A〜C（LLM に与える指示文と入力の形、呼び出しの設定と記録、費用の見積もりの前提と料金の表）を削除し、本文から付録への参照（4 か所）を消した。全体は 3 ページになった。付録の中身は、この版より前の commit（21c332b）に残っている。
- 2026-11-04(14)（11 月 4 日の進捗報告の今後の計画を 1 項目にした）：本人の指示で、progress_report_2026-11-04_llm_comparison.tex の今後の計画を「ゼミでの議論を受けて、比べ方と使う 2 つのモデルを決め、加藤先生の承認を得てから流す」だけにした（データベースを変える作業の方針と、各モデルで数件を試すことの 2 項目を消した）。全体は 5 ページのまま。
- 2026-11-04(13)（LLM との比較：Claude Haiku 5.5 の費用を、試しの実測の出力トークン数で見積もった）：本人の問い「今回試した出力トークン数を見積もりにできない？」と指示「その案で直して」に対応した。run_llm_db_baseline.py の costs3 に、試し（pilot3）の記録から 1 回あたりの出力のトークン数を見積もる処理（measured_output_tokens）を足した。種類（単一出典、出典横断、合成）ごとに平均し、本実行で解かせる 1,673 件の種類の割合（4.7%、35.9%、59.4%）で重みを付ける。Haiku 5.5 では、種類ごとの平均が 58、153、1,540 トークンで、重みを付けると 972 トークンになり、5,019 回の費用は 265.5 ドル（2,000 トークンの仮定）から 252.6 ドルになった（読み出しの割合 95%）。ほかのモデルは試していないので 2,000 トークンの仮定のまま。試験 1 件を足し、計 72 件が通る。報告書：2.4 節の「流してみないと分からない」を「Haiku 5.5 は試しの実測から約 970 トークン、ほかは 2,000 トークンと仮定」にし、Table 3 の Haiku 5.5 の行とキャプション、1 モデル 253〜1,726 ドル、2 モデル 1,421〜2,311 ドル、読み出しの割合 69〜95%（アブストラクト、1 節、2.4 節）、Appendix C の O の説明を直した。
- 2026-11-04(12)（LLM との比較：異なるテストケースごとに 3 回解かせる形に、本実行のコマンドと集計と報告書を直した）：本人の指示「3 回にして、本番のコマンドも直して」に対応した（Haiku 5.5 の試しで、合成のケースの Recall@20 が回によって 0.600、0.800、0.000 と変わったため。2026-11-04(11)）。run_llm_db_baseline.py：run3 は、ケースごとに --runs 回（既定 3 回、V3_RUNS）独立に解かせ、回ごとに記録する。全ケースの 1 回目を先に、次に 2 回目、3 回目の順に進める（run_plan）。試しで解かせた 3 件 × 3 回は再利用する（10 分割で計画 5,019 回、残り 5,010 回）。evaluate3 は、回ごとに判定し、ケースの値は回の平均とする（answers_by_run、mean_over_runs）。あわせて、回ごとの集計（summary_by_run）と回の間のぶれ（variability）も出す。回のそろっていないケースは集計しない。costs3 は、API を呼ばずに、token_counts_v3.json のトークン数から回数に応じた費用と内訳を計算する（experiments/llm_db_baseline/costs_v3_runs3.json）。試験 4 件を足し、計 71 件が通る。報告書（progress_report_2026-11-04_llm_comparison.tex）：呼び出しの回数の段落を「異なるテスト用のケースごとに 3 回、独立に解かせ、ケースの値は 3 回の平均。1 モデル 5,019 回」にし、試しの結果と、回の間のばらつきも示して大きければ増やし小さければ減らすことを書いた。費用は 1 モデル 266〜1,726 ドル、2 モデルで 1,434〜2,311 ドル、読み出しの割合は 69〜90%（アブストラクト、1 節、2.4 節、Table 3、Appendix C の n を直した）。記録の項目に何回目の解答かを足した。全体は 5 ページのまま。
- 2026-11-04(11)（LLM との比較：同じケースを 3 回解かせたときのぶれを、Claude Haiku 5.5 で 3 件だけ試した）：本人の問い「異なるテストケースごとに 1 回しか解かせないの？ 3 回繰り返すと指示した気がする（ばらつきが大きければ増やし、小さければ減らしてよい）」に対応した。経緯：10/14 の加藤先生の方針は「全テストケースで 3 回」だったが、10/14 に「3 通りの分割で 1 回ずつ」と解釈し、10/15 夜に本人の判断で「異なるテストケースごとに 1 回」にしていた。run_llm_db_baseline.py の pilot3 に --case-ids と --runs を足し、回ごとに記録（run）して、回の間のぶれ（上位 20 件の答えの集合の

Jaccard 係数、並びまで同じ割合、Recall@20 と AP@20 の回の間の標準偏差）を `run_variability` で集計するようにした（試験 2 件、計 67 件）。本人の承認（Haiku 5.5 だけ、上限 3 ドル）で、種類の違う 3 件（単一出典 core_032_v1、出典横断 ms_pfr_kin_001、合成 dae_X5_000）を 3 回ずつ解かせた。費用は計 0.99 ドル（うち 0.60 ドルはデータベースのキャッシュへの保存）。**結果**：9 回とも読める答えだったが、回ごとに答えが大きく違った。答えの集合の Jaccard 係数の平均は 0.22 で、並びまで同じ回の組はなかった。Recall@20 は、core_032_v1 で 3 回とも 1.000（正解式の順位は 4、5、8 位）、ms_pfr_kin_001 で 3 回とも 0.500、dae_X5_000 で 0.600、0.800、0.000 とばらついた（回の間の標準偏差の平均 0.139、最大 0.416）。答えが 20 個に満たない回（6 個、15 個）と、同じ ID を重ねた回もあった。出力のトークン数は 34〜2,427 で、見積もりの 2,000 より少ない回が多い。記録：`experiments/llm_db_baseline/raw/claude-haiku-5-5__eqd__ex-none__high__v3.jsonl`、集計 `experiments/llm_db_baseline/variability_claude-haiku-5-5__eqd__ex-none__high__v3.json`。3 件だけなので、ぶれの大きさの目安にしかならない。

- 2026-11-04(10)（11 月 4 日の進捗報告の今後の計画から、済んだ項目を消した）：同じ文字列の式も正解とみなす判定を LLM の答えにも使えるようにする実装が済んだので（2026-11-04(8)）、本人の指示で、`progress_report_2026-11-04_llm_comparison.tex` の今後の計画の 4 つ目（この実装）を消した。計画は 3 つになった。
- 2026-11-04(9)（11 月 4 日の進捗報告の表のキャプションを短くし、Table 1 のキャプションを戻した）：本人の指示「Table 1 のキャプションを戻して。長すぎるから短縮して」に対応し、`progress_report_2026-11-04_llm_comparison.tex` の Table 1 に短い英語のキャプション（Information used by each method.）を戻した。Table 2 と Table 3 のキャプションも 1 行に短くした（Table 2 は比べる相手の Recall@20 と MAP@20 で 10 通りの分割の平均と標準偏差、Table 3 は 1,673 回で出力 2,000 トークンの費用）。全体は 5 ページのまま。
- 2026-11-04(8)（LLM との比較：別の出典にある同じ式も正解とみなす判定を、LLM の答えにも使えるようにした）：本人の指示「判定を LLM の答えにも使えるように実装して」に対応し、`run_llm_db_baseline.py` に、提案手法と baseline と同じ規則の判定を足した。同じ式の印は、LaTeX から空白と `\left`、`\right`、`\,`、`\;`、`\!`、`\quad` を除いた文字列（`set_aware_reranker.latex_key` と同じ）。答えを順に見て、まだ数えていない正解式と同じ印の式が、正解式そのものか別の出典の式なら、その正解式の順位とする（1 本の正解式は 1 回だけ。DB にない ID は数えないが順位を占める。`set_aware_reranker.equiv_ranks` と同じ）。`evaluate3` は、ID による値に加えて、この判定の値（`summary_equiv`、`comparison_equiv`）と、比べる相手の同じ判定の値（`reference_equiv`、kato1021 の per-case 出力の `ranks_equiv` から）も出す。試験を 6 件足した（計 65 件）：規則がパイプラインの関数と一致すること、正解式 3,132 本のうち 386 本に別の出典の同じ式があること（報告書と同じ）、比べる相手の値が `experiments/kato1021/main.json` の table_equiv と一致すること（全ケースの Recall@20 は提案手法 0.983、baseline 0.908）。LLM の答えがない状態で `evaluate3` が動くことも確かめた。有料の呼び出しはしていない。
- 2026-11-04(7)（11 月 4 日の進捗報告で、同じ文字列の式も正解とみなす判定を手法の節に入れた）：本人の指摘「LLM には式の出典も説明文も渡さないので、出典が違って形が同じ式は LLM には区別できない」に対応し、`progress_report_2026-11-04_llm_comparison.tex` の 2.3 節の判定の段落に、空白と LaTeX の間隔や括弧の大きさの命令を除いて同じ文字列の式が別の出典にあれば、それも正解とみなした値もあわせて示す（どの手法にも同じ規則）と書いた。今後の計画の 4 つ目は、この判定を LLM の答えにも使えるように実装する項目にした（提案手法と baseline の値は `experiments/kato1021/main.json` の table_equiv で計算済み。`run_llm_db_baseline.py` にはまだない）。
- 2026-11-04(6)（11 月 4 日の進捗報告の、使うモデルの数と書き方をそろえた）：本人の指示に対応し、

progress_report_2026-11-04_llm_comparison.tex の 1 節の「4 つのモデルについて見積もった（1 モデル 89〜583 ドル）」を「2 つのモデルで 1 回ずつ解かせる費用を見積もった（モデルの組み合わせによって 482〜780 ドル）」にし、2.2 節の「2 つに減らしてよいという加藤先生の助言に沿って」を消した。費用の表（Table 3）は、候補の 4 モデルのまま。

- 2026-11-04(5)（11 月 4 日の進捗報告の Table 1 の英語のタイトルを消した）：本人の指示「Table 1 の英語のタイトルを消して」に対応し、progress_report_2026-11-04_llm_comparison.tex の Table 1（各手法が使う情報）のキャプションの文を消し、番号「Table 1」だけを残した（本文の「Table 1 にまとめる」の参照を生かすため）。全体は 5 ページのまま。
- 2026-11-04(4)（11 月 4 日の進捗報告で、解いた例を渡さない理由をゼロショットに改めた）：本人の指摘「解いた例を渡さない理由は、トークンの上限を超えることより、ゼロショットを守るためである」に対応し、progress_report_2026-11-04_llm_comparison.tex の 2.2 節の「解いた例」の理由を「正解の分かっているケースを例として見せずに解かせる（ゼロショット）ため」にした。入力が上限を超えることと、データベースを分けて渡すと結果が変わるおそれの 2 文は削除した。
- 2026-11-04(3)（11 月 4 日の進捗報告の 2.1 節から、比較の動機の誤った文を削除した）：本人の指摘「『データベースとクエリを渡すだけで LLM が提案手法と同じ精度を出せるなら、提案手法を訓練して使う意味は小さい』は正しくない。本手法の目標は高精度だけではなく、すべての数式の出典をたどれることもある」に対応し、progress_report_2026-11-04_llm_comparison.tex の 2.1 節からこの文を削除した。前後の文（LLM は式を自ら選べる可能性がある、そこで同じデータベースとクエリを渡して比べる）だけでつながる。本文は 1〜3 ページ（全体 5 ページ）のまま。
- 2026-11-04(2)（11 月 4 日の進捗報告の議論したい点に、比較の公平さを加えた）：本人の指示「議論したい点に『この比較方法は公平でしょうか』を入れて（この比較方法で本当に本手法と LLM の性能比較をできるでしょうか）」に対応し、progress_report_2026-11-04_llm_comparison.tex の 1 節の議論したい点を 2 つにした。(1) この比較方法は公平か（提案手法と LLM の性能を本当に比べられるか）、(2) もっと費用を抑えて比べる方法はないか。公平かどうかが費用の議論の前提になるので、公平さを先にした。本文は 1〜3 ページ（全体 5 ページ）のまま。
- 2026-11-04（11 月 4 日の進捗報告から「前回の振り返り」節を削除した）：本人の指示「（アブストラクトに古典的な情報検索手法の説明は）足さなくていい。そして『前回の振り返り』節を削除して」に対応し、progress_report_2026-11-04_llm_comparison.tex の 2 節（研究の全体像）を削除した。その節でだけ定義していた語（baseline、正解集合と正解式、ケースの分け方、分野ラベル、合成のケース）は、本文の初出に短い説明を移した。アブストラクトは変えていない。本文は 1〜3 ページ（全体 5 ページ）。テンプレートの必須の節である「前回の振り返り」は、本人の判断で置かない。本人の質問「古典的な情報検索手法の精度は低かったのでは」への答え（報告書には書かない）：以前の 0.521 は、重みを文章類似度寄り（0.7、0.3）に固定し、上位 K 件（K は正解式の数）で数えた値である。今の 0.906 は、重みを検証用のケースで選び（変数寄り）、上位 20 件で数えた値である。同じデータを上位 K 件で数えると、baseline は 0.607、提案手法は 0.782 である（experiments/kato1021/main.json の R-Precision）。
- 2026-11-01（全体ゼミ（11 月 4 日）の進捗報告「大規模言語モデルとの比較の方法と費用」を作った）：本人の指示「今回の LLM との比較手法を新しい進捗報告にしたい」に対応し、docs/**ゼミ** latex **テンプレ**/progress_report_2026-11-04_llm_comparison.tex（と .bib、.pdf。jresume、platex → pbibtex → dvipdfmx、5 ページで、本文は 4 ページ目の上まで）を新しく作った。**本人の決定**：ゼミは 11 月 4 日。2 節「前回の振り返り」は、前回の計画やコメントには触れず、毎回同じ本研究の全体像（目的、データベースとケース、提案手法、評価と結果）を書く節にする。方向性 2（第 1 段の候補 2,000 式から選ばせる案）は載せない。議論したい点は「もっと費用を抑えて比べる方法はないか」で、本文には費用の内訳だけを示し、考えた案は載せない。今後の計画に期限を設けない。**中身**：3 節に、LLM に渡すもの（ID、

式の表記、分野ラベルだけの全 11,146 式と、テストケース 1 件のクエリ。出典は渡さず、式の並びと ID を振り直す。解いた例は渡さない）とその理由、各手法が使う情報の表、ID による判定と Recall@20・MAP@20 の式、比べ方（提案手法と同じ 10 通りの分割で、何通りで上回ったか）、呼び出しの回数（異なるテストケースごとに 1 回で 1,673 回）、比べる相手の値（`experiments/kato1021/main.json`。全ケースの Recall@20 は baseline 0.906 と提案手法 0.981、MAP@20 は 0.680 と 0.857）、費用の内訳（`experiments/llm_db_baseline/token_counts_v3.json`。1 モデル 89〜583 ドルで、68〜90% はデータベースの読み出し）を書いた。Appendix には、指示文（版 3）、呼び出しの設定と記録、費用の見積もりの式と料金を置いた。料金は、Anthropic の料金表で確かめ直した（2026-11-01）。Claude Sonnet 5.5 のキャッシュの読み出しは 100 万トークンあたり 0.10 ドル（入力の 0.05 倍）で、`run_llm_db_baseline.py` の値と一致した。有料の呼び出しはしていない。試験 59 件は通る。

- 2026-10-27(3)（修論の数値を、説明文を書き直し 1 件を除いた 1,731 件の再計算の値に替えた）：親セッションの依頼。再計算（8b77e73、`experiments/kato1021/`）の値を、旧値新値対応表（`docs/加藤先生指示_2026-10-21_説明文書き直しと 92 件除外_旧値新値対応表.md`）のとおりに修論に入れた（Abstract、第 1・5・6・7 章、付録の表）。上回った分割の数が変わった主張も直した（§6.3 の (i) は 3/10、(iii) の Recall@20 は 9/10、分野の一致度を足したときの MAP は 9/10、§6.4 の設定 A の (3)−(2) は 7/10、§6.5 の差は分野の一致 −0.008 と合併の 3 通り、hard negative は 20/20、付録 A.4 は約 2.4 倍）。§6.5 には、特徴量が 2〜3 個の MLP では 1 つの分割だけ大きく下がることがある（統一したラベルの 1 分割で 0.931 が 0.798）と書き足した。第 6 章の冒頭の「再計算が終わるまで」の注記は消した。**図**：`generate_figures_thesis.py` を kato1021 の JSON を読む形にして、結果の図 6 枚（fig_method_comparison、fig_characteristic、fig_mechanism、fig_greedy_3way、fig_pfi、fig_n1_coverage）を作り直した。PFI と N_1 の図は、報告書の `fig_pfi_recall20_ja_final_1021` と `fig_n1_full_coverage_ja_1021` と同じデータ・同じ値の英語版。fig_mechanism は凡例が線を隠していたので、図の下に移した。**説明の明確化**：加藤先生の 3 回目のコメントへの返答案（`docs/加藤先生コメント対応_2026-08-31 報告_3 回目.md`）に沿って、第 4 章の出典横断の作り方（9 組の語の規則は組を集めるときに当てる、分野の組ごとに DB の順で最初の 200 組を集める、使った 101 組はすべて微分方程式を含み、496 件中 277 件は 2 式とも微分方程式）と、分割の作り方（種ごとに 400 通りの候補、L1 距離は訓練とテストの間だけで比べ、検証用は比べない、10 分割で計 4,000 通り）を書き直した。重複は「除くべき」と断定せず、事実だけを書いた（ID で判定するので別の出典の同じ式は不正解になる、同じ式が上位 20 件の枠を占めうる。限界の 4 番目と今後の課題の 2 番目）。latexmk は exit 0、未定義の参照 0、本文 1〜25 ページ、全体 72 ページ。
- 2026-10-27(2)（8/31 報告の数値を、説明文を書き直し 1 件を除いた 1,731 件の再計算の値に替えた）：第 1 段のやり直しのセッションの再計算（8b77e73、`experiments/kato1021/`）が終わったので、報告書の §3.4 以降と付録 A〜C の数値を、旧値新値対応表（`docs/加藤先生指示_2026-10-21_説明文書き直しと 92 件除外_旧値新値対応表.md`）のとおりに替えた（96 か所）。対応表の新値 385 個がすべて本文にあることは、スクリプトで確かめた。上回った分割の数が変わった主張も直した（§5 (i) は 3/10、(iii) の Recall@20 は 9/10、x_{10} の MAP は 9/10、§6 の (3)−(2) は 7/10、§7 の差、hard negative は 20/20、付録 C は約 2.4 倍）。§7 には、特徴量が 2〜3 個の MLP では 1 つの分割だけ大きく下がることがあると書き足した。§1 の「数値は計算が終わったら更新する」の注記は、計算し直したことの記述に替えた。あわせて、加藤先生の 3 回目のコメント（10/25）で「わからない」とされた説明を、コードで確かめて書き直した（§3.2 の出典横断の作り方、§3.3 の分割の作り方、§9 の重複）。§10 の今後の課題には、LLM が作ったデータの人手の確認、定義の文章を使う照合、N_1 の決め方と同じ式の扱いを加えた。10/21 版から変えた箇所の注釈付き PDF（21 件）は、`annotate_revision_0831_r3.py` で作った。報告書は 57 ページになった。
- 2026-10-27（LLM との比較：外す一覧 v3 の分割と、比べる相手の値を kato1021 にそろえる）：外す

ケースの一覧が v3（experiments/kato1020/excluded_cases_v3.json、92 件 = 未知の変数が決まらない出典横断の 91 件と、2 冊の教科書の式から成る単一出典の core_019_v1）になり、説明文 113 件が書き直された（e995ca0）のに合わせ、experiments/llm_db_baseline/splits.json を作り直した（run_llm_db_baseline.py splits -exclude ...）。設定 A は 1,731 件で、10 通りの分割はどれも 81e206e の分割から core_019_v1 を除いただけになり、ほかのケースの割り当ては変わらなかった（core_019_v1 は種 42・789・1024・9999 でテスト、ほかで訓練）。設定 B は同じ。説明文の書き直しは層化分割に使う量を変えないので、分割には効かない。テストと検証の並びは、第 1 段のやり直しのセッションの再計算（experiments/kato1021/raw/final/ の逐次選択の 2 通りの出力と baseline の出力、commit 8b77e73）と 20 通りすべてで一致した。比べる相手（提案手法：$N_1 = 2{,}000$、重み $(0.3, 0.7)$、検証で選んだ hard negative。baseline：TF-IDF、検証で選んだ重み）は experiments/kato1021/ から読み、分割ごとの値も平均も experiments/kato1021/main.json と一致した（設定 A の Recall@20 は 0.981 と 0.906、MAP@20 は 0.857 と 0.680）。呼び出しの回数（異なるテストケースの数）は 10 分割で 1,673 回、3 分割で 1,307 回、1 回分の入力の最大は 952,918 トークン。費用の見積もり（出力 2,000 トークン/回）は 4 モデルの合計で 10 分割 1,261 USD、3 分割 990 USD。版 3 の記録には、使った training_cases.json とテストケースの文の sha256 も残すようにした。有料の呼び出しはまだしていない（モデルは 2 つに減らしてよいと加藤先生から返事があった。分割の数とデータベースの作り直しが決まってから流す）。試験は 59 件。

- 2026-10-27（加藤先生の 3 回目のコメント 13 件を整理し、確認が要る事項を事実とともにまとめた）：加藤先生が 10/21 版（f1076cd）の注釈付き PDF に付けたコメント（2026-10-25、13 件）を、docs/**加藤先生コメント対応**_2026-08-31 **報告**_3 **回目**.md にまとめた。先生の PDF の本文は f1076cd と全 56 ページで一致し、私の注釈 57 件のうち 46 件は先生が消した。先生の方針は、結果を Journal 論文に随時まとめること、文献の集め方を Appendix に書くこと、記号だけの照合、N_1、teacher forcing の順、重複を Discussion と Future work で述べること、LLM との比較を 2 モデルにしてよいこと。確認が要る事項は 3 つある。(1) 初期の 9 報（162 式。設定 A の 146 件の正解集合に入っている）を Gemini 2.5 Pro で抽出し直すか。PDF は 9 報中 2 報しか手元になく、038.pdf は題名も分からない（55 件に関わる）。(2) LLM が作ったデータを人手で確かめる範囲。出典横断の 33 件に加え、Gemini が作った単一出典の 91 件と、基礎式集の 670 式（1,731 件中 384 件の正解集合に入っている）を含めるか。(3) LLM との比較の 2 モデルの組み合わせと分割の数（10 通りの分割で 480〜780 ドル）。先生が「意味がわからない」とした分割の作り方、9 組の語による除外、微分方程式の優先は、コード（stratified_src_split、generate_multisource_v3.py）で確かめて返答案を書いた。9 組の語の規則は列挙するときに当てており、使った 101 組はすべて微分方程式を含む。記号が同じで定義の文章が違う入出力変数 4,070 組のうち、LLM の判定では 3,128 組（77%）が言い換えだった。なお、kato1021 の再計算は、電池切れのため 10/22 02:44〜10/27 17:01 に止まっていた。select は 17:11 に 80 本そろい、続けて final を実行している。
- 2026-10-21(12)（8/31 報告の §9 の件数を 1 件の除外に合わせた）：修論のセッションの指摘で、§9 の「記号が同じで定義が違う変数を正解集合に含むケース」を 1,300 件から 1,299 件に直した（core_019_v1 を除いた 1,731 件で数え直し、私も同じ数を確かめた。LLM の判定で別の量を指す 596 件は変わらない）。報告書と注釈付き PDF を作り直し、前後比較表も合わせた。修論は 9f39c4e で、報告 f1076cd と同じ変更（説明文の書き直し、1 件の除外、ハイパーパラメータの呼び方、数値の注記）が入った。
- 2026-10-21(11)（修論に、説明文の書き直しと単一出典 1 件の除外を入れた。結果の数値は再計算の後で更新）：親セッションの依頼（本人の指示「修論も同じように直して」）。8/31 報告（f1076cd）に入れた変更を修論に入れた。**説明文の書き直し**：出典横断の入出力を選び直した 111 件と元のケース 2 件（ms_pbr_chemeng_001、ms_pfr_arrhenius_001）の説明文を Claude Opus 4.8 で書き直したこと（e995ca0）を第 4 章に 1 文で書き、「説明文が入出力変数と合っていない」の記述（第 4 章、限界、今

後の課題）を消した。付録 A.7 に rewrite_reselected_io_contexts.py の SYSTEM_PROMPT（v6）を一字も変えずに載せた（ast で取り出し、記録 experiments/reselected_io_contexts.json の meta と一致することを確かめた）。参考文献に ClaudeOpus48 を戻した（38 件）。**単一出典 1 件の除外**：2 冊の教科書の式から成る core_019_v1 を評価にも訓練にも使わない（experiments/kato1020/excluded_cases_v3.json、92 件）。単一出典は 91 件（式数 1.33、最大 4、出典数 1.00）、設定 A は 1,731 件、要件 3 が自明に満たされるのは 1,724 件。拡張ケースの入れ替え 1 件は、入出力変数の選び直し 739 件にまとめた。図 2（fig_dataset）を v3 の一覧で作り直した（generate_figures_thesis.py）。**用語**：手法の設定値を hyperparameters とよび、本文の初出（第 1 章）で「訓練の前に決めておく値」と書き、第 3 章で訓練で決まる MLP のパラメータと区別して定義した（旧 constants。要件 4 のモデルの定数はそのまま）。§5.2 と付録 A.1 の題も直した。**数値**：結果の数値（第 5〜7 章、付録の表・図、Abstract・第 1 章の結果）は据え置き、第 6 章の冒頭に「再計算が終わるまで、変更前の 1,732 件での結果」と注記した。報告との違い：限界の「定義の違う記号のある正解集合」は、core_019_v1 を除くと 1,300 件ではなく 1,299 件なので、修論は 1,299 件にした（596 件は変わらない）。latexmk は exit 0、未定義の参照 0、本文 1〜25 ページ、全体 72 ページ。

- 2026-10-21(10)（説明文を書き直し、単一出典の 1 件を外した条件で、c7c4feb ＋ ed41231 の実験と集計をやり直した。計算は 10/27 に終わった）：親セッションの依頼。出典横断の 113 件の説明文を書き直した training_cases.json（e995ca0）と、外す一覧 experiments/kato1020/excluded_cases_v3.json（92 件＝未知の変数が決まらない 91 件＋ 2 冊の教科書の式から成る単一出典の core_019_v1、b7f7cd2。設定 A は 1,731 件）で、c7c4feb ＋ ed41231 と同じ実験と集計をやり直した。出力は experiments/kato1021/（experiments/kato1020/ と同じファイル名。分割ごとの実行の raw/ は非追跡）。報告書の本文は変えていない。旧値 → 新値の対応表は docs/**加藤先生指示**_2026-10-21_**説明文書き直しと 92 件除外_旧値新値対応表**.md（旧値は報告書の db21007 の版の数値で、本文に現れることをスクリプトで照合した。照合できない旧値は 0 件）。**条件の確認**：training_cases.json の db21007 からの違いは 113 件の context だけ（外したケースと合成のケースには 0 件）。分割は、c7c4feb の実行に記録された検証・テストのケース ID から core_019_v1 を除くと、設定 A・B とも 10 通りすべてで一致した（core_019_v1 は種 42・789・1024・9999 でテスト、ほかの 6 通りで訓練）。N1 の規則は 4 つの重み・設定 A と B・全分割で前回と同じ（重み $(0.3, 0.7)$ は 2,000）。設定 B は説明文が変わらないので前回の実行結果を使い、古典的情報検索手法の設定 B は計算し直して完全に一致した。データの数（kato1021_counts.py、data_counts.json）：要件 3 が自明 1,724 件、表 2 の単一出典 91 件・1.33 (4)・1.00（91 件中 67 件が 1 式、61 件が基礎式集の式だけ、全件が 1 つの出典）、定義の文章が違う 1,299 件、LLM の判定で別の量 596 件、正解式の数の平均 3.99、2 本以上 90.4%、同じ文字列の式 386/3,132 本。**結果**（設定 A、10 分割の平均、Recall@20 ／ MAP）：baseline（TF-IDF）0.906 ／ 0.693、一括の並べ直し 0.981 ／ 0.862、逐次選択（訓練も逐次）0.983 ／ 0.877。提案手法は、どの指標でも 10 分割すべてで baseline（TF-IDF・BM25・E5）を上回った。設定 B は前回と同じ値。不正解の選び方は 20 分割すべてで hard negative（前回は設定 A の種 7777 だけ無作為）。**結論が変わった点**：§5 (iii) の集合の特徴量の Recall@20 で上回った分割が 10/10 → 9/10（MAP は 10/10 のまま）、x_{10} だけを加えたときの MAP が 10/10 → 9/10、§6 の設定 A の (3) − (2) の MAP が 9/10 → 7/10、§7 の話題の特徴量と分野ラベルの合併の差（x_7 +0.004 → −0.008、合併 −0.023〜−0.030。上回った分割は 3〜5/10）。「話題の特徴量は加えても一貫して上がらない」などの主張は変わらない。特徴量が 2〜3 個の MLP は、1 つの分割だけ Recall@20 が大きく下がることがあり（前回の x_1・x_2 だけの MLP の種 3141 で 0.800）、差の平均はその分割に左右される。図は docs/figures/fig_pfi_recall20_ja_final_1021.png と fig_n1_full_coverage_ja_1021.png（旧図は上書きしていない）。**途中の中止と停止**：111 件を外す案（v2）と、91 件の除外での実行は、親の指示で途中で止め、出力を experiments/kato1021_v2_

中止/ と `experiments/kato1021_v1` **除外_中止/** に移した（commit しない）。10/21 13:58 ごろ、Bash から nohup で起動した実行役と訓練が一斉に止まったので、以後は新しいセッション（`start_new_session`）に切り離して起動した。10/22 02:44〜10/27 17:01 は電池切れで Mac が休止状態に入り、計算が止まっていた。final と sweep を流した 10/27 17:11〜19:23 には休止はなく（`pmset -g log`）、付録 C の時間はこの間に測った。実装（追加のみ、既定の動作は変えない）：`kato1020_*.py` に環境変数 KATO_OUT・KATO_EXCLUDE・KATO_SETTINGS・KATO_N1_FIX、`kato1020_analysis.py pfi --fig-tag`、`analyze_stage1_n1.py --marks --chosen`、出力先が相対パスのとき進捗の表示で止まる不具合の修正（`os.path.relpath`）。新しいスクリプトは `kato1021_counts.py`（データの数と分割の照合）と `kato1021_mapping.py`（対応表）。環境変数を設定しないとき、ジョブの命令は HEAD と同じ（select 160・final 172・sweep 100 本）で、`experiments/kato1020/` の集計（main・greedy・mech・pfi・sweep）と PFI の図はバイト単位で一致した。tests は 493 passed（`tests/test_kato1021.py`、`tests/test_kato1020_run.py` を追加。論文の図を書き換える `tests/test_fig_overview.py` は除いた）。

- 2026-10-21(9)（8/31 報告を、説明文の書き直しと 1 件の除外まで直して出した。数値は再計算の後で更新する）：本人指示「更新後の実験計算まだ終わっていないけど、まず修正したレポートを出したい。『具体的な数値は追加実験の計算が終わったら更新する』ように追記すればいい」。§3.2 に次の 2 点を書いた。出典横断の 111 件と元のケース 2 件の説明文を、入出力変数に合うように Opus 4.8 で書き直したこと（付録 E に v6 のプロンプト）。単一出典のうち 2 冊の教科書の式から成る core_019_v1 を除いたこと（本人「1 っ件だけ他のケースと違うケースがあるなんて、特異点みたい学習になんの意味もない」）。拡張ケースの入れ替え 1 件は、入出力変数を選び直したものにまとめた（739 件）。§9 の「説明文と入出力変数が合っていない」の項は消した。用語：「手法の定数」を「ハイパーパラメータ（訓練の前に決めておく値）」に、「MLP の重み」を「MLP のパラメータ」にそろえた（本人「定数はなに？第一段階の重み？パラメータ？呼び方を統一させてください」）。要件 4 の「定数」と区別するためで、作文技術チェックリストにも規則を足した。データの数を直した：設定 A は 1,731 件、単一出典は 91 件（式数 1.33、出典数 1.00）、要件 3 が自明なケースは 1,724 件。テストと検証のケースの数の範囲は変わらない。§1 の末尾に「§3.4 以降と付録 A〜C の具体的な数値は、この追加実験の計算が終わったら更新する（今の数値は、書き直す前のケース 1,732 件での結果）」を加え、注釈付き PDF にも橙のコメントを付けた（コメント 57 件）。前後比較表と対応表も合わせた。
- 2026-10-21(8)（出典横断の説明文を、入出力変数に合うように書き直した）：本人の指摘「その 111 件の説明文を llm で書き直すだけでいいじゃん？」。入出力変数を選び直した出典横断のケース（multisource_random_io）は、元の 33 件の説明文をそのまま使っていたので、説明文が入出力変数と合っていなかった（例：ms_cstr_heat_001_rv2 は滞留時間を求めると言うが、滞留時間は入力）。評価に使う 111 件の説明文を、Claude Opus 4.8 で書き直した（`rewrite_reselected_io_contexts.py`。モデルは本人の選択で、LLM との比較で評価する 4 モデルとは別）。元の 33 件を読むと、説明文が自分の出力変数と合っていないものが 2 件あった（ms_pbr_chemeng_001 は触媒重量と出口濃度を求めると言うが、出力は反応速度と滞留時間。ms_pfr_arrhenius_001 は PFR の大きさを決めると言うが、体積は入力）。本人の決定で、この 2 件も同じ方法で直した。指示は 6 版で固めた。v1〜v3 は、元の説明文が挙げていない入力まで列挙することがあった。v4 で、与えるものとして書く量（元の出力で、いまは入力）をプログラムで決めて渡すようにした。v5・v6 で、新しい出力でない量を求めさせない規則（「PFR の大きさを決める」のような暗黙の要求も含む）を加えた。113 件すべてを v6 で作り直し、全件を読んで確かめた。呼び出しは全版で 442 回（入力 502,141、出力 37,823 トークン）。記録は `experiments/reselected_io_contexts.json`（書き直す前と後の説明文、入出力変数、モデル、版）と `experiments/reselected_io_contexts_raw.jsonl`。これに合わせて、いったん決めた 111 件の除外（`excluded_cases_v2.json`、ccb6b91）は取り消して消した。除外は v1 の 91 件に戻

り、設定 A は 1,732 件。その除外での再実行は途中で止めた（commit していない）。全実験のやり直しを、第 1 段のセッションに依頼する。

- 2026-10-21(7)（8/31 報告の数値の誤り 2 件を直した）：修論をそろえたセッションの指摘を、実験の結果（`experiments/kato1020/main.json`、`sweep.json`）で確かめて直した。(1) §4 の設定 B の MAP の差を +0.206 から +0.205 にした（10 通りの分割の差の平均は 0.2053。旧値は、丸めた平均どうしの差だった）。§3.5 に「差は、丸める前の平均から計算した」を加えた。(2) 付録 C の表の被覆率を、小数第 4 位まで示した。設定 A の $N_1 = 1{,}000$ は 0.99983 で、小数第 3 位では 1.000 になり、本文の「被覆率が 1.000 になるのは 2,000 だけ」と食い違っていた。報告書（55 ページ）と注釈付き PDF を作り直した。注釈は、§3.5 のハイライトを新しい文まで延ばしただけである。
- 2026-10-21(6)（修論を、8/31 報告の 2 回目の改訂と同じ事実・同じ数値にそろえた）：親セッションの依頼。英語の修論（`thesis/master_thesis`）を、日本語の 8/31 報告の 2 回目の改訂（4781cdd）と再実験の結果（c7c4feb、`experiments/kato1020/*.json`）にそろえた。**データの作り方**：拡張ケースは訓練にも評価にも使っていない（旧 Introduction の「augmented copies used only for training」は誤り）。式の抽出はすべて Gemini（初期の 9 報を除く 320 報は Gemini 2.5 Pro、初期の 9 報は版の記録なし。cc9301e の「追加した文献は Claude」は誤り）。文献の集め方（最初の検索は関連度の順、補った検索は被引用数の順、10 報は取得できた PDF の数、人の目で選別していない、重複 35 文献・44 出典分）、単一出典（一覧を 11 回に分けて渡した、残りの 1 件は 2 冊の教科書の式）、出典横断（手で書いた語の一覧、手で決めた 15 組、定義の照合は 9 組の語だけで 496 件中 471 件は定義が違う、説明文の型は分類の組ごと、33 件は Claude がプログラムに直接書いた、選び直しの手順、どの 2 本も記号を共有しないのは 105 件）、合成の手順の順序（先に式を X 本、後で出力変数）を、生成コードと実データのとおりに書き直した。**評価の条件**：未知の変数が決まらない 91 件を除外（設定 A は 1,732 件）、$N_1 = 2{,}000$、主指標は Recall@20、R-Precision（旧 Recall@K）、定数は検証用のケースで選ぶ（第 1 段の重みは $(0.3, 0.7)$ に固定、不正解は 20 分割中 19 で hard negative、baseline の重みは分割ごと）、検定はやめて何通りの分割で上回ったかを書く、別の出典の同じ式を正解とみなした値を表 3 に併記。自由度ゼロ停止（旧 §3.5・§6.5、停止条件の充足率）、第 1 段の再設計の節（旧 §6.8）、検定の節（旧 §5.5）、「二つの介入で因果を確かめた」という主張を削除した。**結果**：第 5〜7 章、Abstract、第 1 章の数値・表・図を c7c4feb の結果に置き換えた（設定 A の Recall@20 は 0.906 → 0.981、MAP は 0.690 → 0.860、設定 B は 0.825 → 0.966 と 0.626 → 0.832。どれも 10 通りすべてで上回る）。図は `generate_figures_thesis.py` を新しい JSON を読む形に書き直して作り直し、日本語の 2 図（`fig_pfi_recall20_ja_final`、`fig_n1_full_coverage_ja_1020`）の英語版（`fig_pfi`、`fig_n1_coverage`）を作った。使わなくなった `fig_dof_stop`・`fig_stage1_redesign`・`fig_topic_diagnosis` は消した。**LLM との比較**：本人の決定（「旧結果を消し、報告と同じ」）で、旧版（Sonnet 4.5 の直接生成、Opus 4.8 と Fable 5.1 の等価判定）の結果・図・κ を消し、データベースを渡して ID で判定する新しい比較の方法を第 5 章に書いて「未実行」とした。参考文献から ClaudeOpus48・ClaudeFable51・Hangos（自由度ゼロ停止の節だけで引いていた）を外した（37 件）。**付録**：定数の表、baseline の重み 12 通りと提案手法の重み×不正解の選び方の表、正解式の数と入力変数の数で分けた表、N_1 を変えた結果、分野ごとの検索語と文献 329 件の一覧（英語版。`make_thesis_appendix_tables.py` で `docs/appendix_materials` から作り、数値・DOI・出典 ID が元の表と全行で一致することを確かめた）、合成のケースの例（`dae_X3_016`）、LLM に与えたプロンプトを載せた。本文は 1〜25 ページ（規範 20〜28 ページ）、全体 72 ページ。`latexmk` は exit 0、未定義の参照は 0。報告との違い：設定 B の MAP の差は、報告の本文では丸めた平均の差から +0.206 だが、分割で対にした差の平均は +0.2053 なので、修論では +0.205 と書いた。
- 2026-10-21(5)（注釈付き PDF のコメントの理由を短くした）：本人指示「もし理由は加藤先生のコメントなら記入不要。それ以外の理由を簡潔に書く」。`annotate_revision_0831_r2.py` で、加藤先生のコ

メント（注釈と取消線）と 10/14 の議論の方針による修正には「理由」を書かないようにし、それ以外の理由（生成コードとデータで確かめて直した誤りなど、11 件）だけを 1 文で書いた。応えたコメントと方針の番号は、スクリプトの中に記録として残した。コメント 58 件の文字数は、合計 11,150 字から 3,854 字に減った（docs/progress_report_2026-08-31_methods_results_revision2_comments.pdf）。

- 2026-10-21(4)（8/31 報告の 2 回目の改訂の前後比較表を作った）：本人指示「修正したところの前後比較表をください」。docs/8-31 **報告_改訂 2_前後比較表**.md に、10/12 版（ad911df）と 10/21 版（4781cdd）の本文を節ごとに並べ、理由を付けた。理由は、加藤先生の 2 回目の注釈の番号、10/14 の方針、誤りの訂正のいずれか。数値の旧値と新値の全体は docs/**加藤先生指示**_2026-10-20_**旧値新値対応表**.md を参照する形にした。
- 2026-10-21（LLM との比較：91 件を外した分割に合わせ直す）：出典横断の 91 件（未知の変数のそれぞれに、それを決める式を 1 本ずつ割り当てられないケース。experiments/kato1020/excluded_cases.json）を評価と訓練から外す本人の決定（2026-10-20）に合わせ、experiments/llm_db_baseline/splits.json を、91 件を外してから同じ層化分割で作り直した（run_llm_db_baseline.py splits -exclude ...）。設定 A は 1,732 件（テストは分割ごとに 298〜527 件）、設定 B は前と同じ。テストと検証の並びは、第 1 段のやり直しのセッションの最終の出力（experiments/kato1020/raw/final/、commit c7c4feb）と 20 通りすべてで一致した。分割の関数は HEAD と同一で、HEAD の関数で作り直しても一致する。呼び出しの回数（異なるテストケースの数）は、10 分割で 1,674 回、3 分割で 1,308 回になった（外す前は 1,665 回と 1,204 回）。1 回分の入力は変わらず最大 952,918 トークン。費用の見積もり（出力 2,000 トークン/回、キャッシュの書き込みを含む）は、4 モデルの合計で 10 分割 1,262 USD、3 分割 990 USD。比べる相手を、同じ分割の最終の設定に替えた：提案手法（$N_1 = 2{,}000$、第 1 段の重み $(0.3, 0.7)$、不正解の選び方は分割ごとに検証用のケースで選んだもの）と baseline（TF-IDF、重みは分割ごとに検証用のケースで選んだもの）。値は報告書（4781cdd）の §4 と一致する（設定 A の Recall@20 は 0.981 と 0.906）。検定はやめ、10 通りの分割のうち何通りで上回ったかを数える（compare_splits）。試験は 59 件。有料の呼び出しは、加藤先生の返事を待ってまだしていない。
- 2026-10-21(3)（作文技術チェックリストに、加藤先生の 2 回目の注釈から学んだ規則を追記した）：docs/**作文技術チェックリスト**.md の 3〜6 節に、10/12 改訂版への注釈 35 件（K11）から学んだ規則を追記した。追記した規則は次のとおり。先行研究との関係は上流・下流のつながりで書く。モデルと呼べない正解集合は外す。照合規則の穴（同じ記号・別の定義）を書く。訓練の手順は一般的な名前（teacher forcing）で書く。データの作り方は「どうやって？」に答えられる細かさで書く。LLM を使ったらプロンプトを付録に載せる。文献の集め方は並べ方と止めた基準まで書く。件数が分割で変わる理由を書く。定数は検証用のデータで選ぶ。指標は標準の名前で呼ぶ（R-Precision）。緩めた判定の結果も示す。読み手が判断できない検定は使わない。データの記述を提出前に生成コードと照合する規則も足した（10/12 版に誤りが 8 件残っていたため）。
- 2026-10-21(2)（8/31 報告を、加藤先生の 2 回目の注釈 35 件と 10/14 の議論の方針で改訂した）：本人指示「修正したレポートにもう一度コメントをつけてくれました。それらを踏まえて改善してください」。先生の注釈（10/14・10/15、35 件。私の修正注釈 78 件のうち 62 件は先生が消した）を PyMuPDF で取り出し、対応表 docs/**加藤先生コメント対応**_2026-08-31 **報告_2 回目**.md を作った。先生の PDF と手元の版の本文は全ページ一致。事実の確認はサブエージェントが生成コード、実データ、git の履歴で行ない、docs/**加藤先生コメント 2_事実確認**_2026-10-20.md と付録の素材 docs/appendix_materials/（文献 329 件の一覧、検索語、プロンプト）にまとめた。本人の決定：未知の変数が決まらない 91 件を評価と訓練から除く、検定をやめる、式の抽出はすべて Gemini（10/12 の「追加した文献は Claude」は誤り）、記号の定義の食い違いは事実を書くだけ、第 1 段の重みは $(0.3, 0.7)$ に固定して $N_1 = 2{,}000$ にそろえる。docs/progress_report_2026-08-31_methods_results.tex を全面的に書き直した（55 ページ。うち付録 D の文献の一覧が約 34 ページ）。§2.1 に、提案手法を Kato and Kano (2025) の上

流に置く問題設定、記号が同じで定義が違う変数の扱い、上位 n 件を提示する形を書いた。自由度ゼロ停止（旧 §2.2.4、§7）は削除した。§2.2 に、hard negative と、逐次選択の訓練が teacher forcing であることを書いた。§3 は、文献の集め方、ケースの作り方を生成コードどおりに書き直し、検証用のケースで定数を選ぶ手順、R-Precision の名前、同じ式を正解とみなす評価を加えた。§4〜§8 と付録 A〜C を、c7c4feb の結果（`experiments/kato1020/`）で書き直した。LLM との比較は、Slack での相談の返事を待っていて、結果は次の版で示す。10/12 版の誤り（生成コードで確認）：拡張ケースは訓練にも評価にも使っていない。初期の 39 報のうち 15 報は自動取得。補った検索は被引用数の順だった。出典横断の定義の照合は 9 組の語だけで、496 件中 471 件で定義の文章が違う。説明文の型は分類の組ごとだった。189 は「少なくとも 1 式がほかと共有しない」件数で、91 件を除くと、どの 2 式も共有しないのは 105 件。合成の手順の順序が違っていた。旧 §8 の k-means の分野ラベルの合併は、x_7 がほぼ常に 0 になる作りで、効果を測れていなかった。`annotate_revision_0831_r2.py` で、修正箇所の注釈付き PDF `docs/progress_report_2026-08-31_methods_results_revision2_comments.pdf` を作った。コメントは 58 件で、色の内訳は、書き直し 26、実験や計算 24、誤りの訂正 6、次の版 2。理由には先生のコメントの原文、10/14 の方針、生成コードでの確認を書いた。1 ページ目に、色の意味と削除した節の付箋を置いた。公開リポジトリなので、事実確認の資料から、教科書の PDF の入手元についての推測と、git の履歴の API キーについての記述を外した（本人には直接伝えた）。

- 2026-10-21（加藤先生の 2 回目のコメントと本人の決定による再実験：91 件を外し、定数を検証用のケースで選び、検定をやめた）：加藤先生が改訂版の報告書に付けた 2 回目のコメント（2026-10-14〜15、35 件）のうち実験に関わるものと、本人の決定（2026-10-20・21）に沿って、2026-10-15 の再実験（`experiments/kato1014/`）をやり直した。報告書の本文は変えていない（親セッションが書き直す）。旧値 → 新値の対応表は `docs/`**`加藤先生指示`**`_2026-10-20_`**`旧値新値対応表`**`.md`（2026-10-14 版を置き換える）。**(1) 91 件を外す**（先生「モデルと呼べるのか？」、本人の決定）：未知の変数のそれぞれに決める式を 1 本ずつ割り当てられないケースを、評価と訓練から外した。判定は `analyze_kato_0831_followup.py` の `gt_checks` と同じ完全マッチング（`kato1020_exclusions.py`）で、91 件（すべて出典横断、87 件が入出力を選び直した派生）。91 件すべてで、どれかの正解式の変数がすべて入力変数になっている（両方向で一致）。一覧は `experiments/kato1020/excluded_cases.json`。設定 A は 1,732 件、設定 B は変わらない。`set_aware_reranker.py --exclude-cases` で分割の前に除く。**(2) 定数を検証用のケースで選ぶ**（先生「検証データで選択できないだろうか？」）：分割ごとに、検証用のケース（分割の val の出典）の Recall@20 で、baseline の重み（TF-IDF・BM25・E5 の各 12 通り。`kato1020_baselines.py`）と、提案手法の第 1 段の重み（4 通り）と不正解の選び方（無作為／hard negative）を選んだ（160 本の訓練、`kato1020_run.py select`、`--eval-val`）。N1 は重みと分割ごとに、訓練と検証のケースで全正解式が入る値を千の位に切り上げた（`kato1020_n1.py`：重み $(0.3, 0.7)$ は全分割で 2,000、$(0.7, 0.3)$ は 4,000〜6,000）。重みの差は検証用の Recall@20 で小さく（設定 A で 0.9797〜0.9827、分割間の標準偏差は約 0.015）、分割ごとに選ぶと N1 が 2,000〜6,000 にばらついたので、本人の決定（2026-10-21、案 (b)）で第 1 段の重みを $(0.3, 0.7)$ に固定し、全節を $N_1 = 2{,}000$ にそろえた。不正解は検証用で選んだ hard negative（20 分割中 19。設定 A の種 7777 だけ無作為）。baseline の重みは分割ごとの選択のまま（TF-IDF は設定 A で $(0.3, 0.7)$ と $(0.4, 0.6)$ が 5 分割ずつ）。ほかの定数（$m = 5$、$\gamma = 0.1$、不正解 8 件、15 エポック、隠れ層 64）は固定。重みごとの検証用とテストの値は `experiments/kato1020/selected.json` の grid（付録の表用）。**(3) 別の出典にある同じ式を正解とみなす**（先生「性能が不当に低く評価されている可能性」）：空白などを除いて同じ LaTeX で別の出典の式（§3.5 の 386/3,132 本と同じ定義。`latex_key` で再現）を、並べた順に 1 対 1 で正解と数えた（`--equiv` の `ranks_equiv`）。**(4)〜(6)**：検定はやめ、10 通りの分割で何通り上回ったかを示す。主指標は Recall@20、ほかに R-Precision（旧 Recall@K）、MAP、MAP@20。付録用に N1 = 50〜2,000 の

比較と計算時間を出した（`kato1020_run.py sweep`）。**主結果**（10 分割の平均、Recall@20 ／ MAP）：設定 A で baseline（TF-IDF）0.906 ／ 0.690 に対し、提案手法の一括の並べ直し 0.981 ／ 0.860、逐次選択（訓練も逐次）0.982 ／ 0.874。設定 B で 0.825 ／ 0.626 に対し 0.966 ／ 0.832、0.971 ／ 0.849。BM25・E5 を含めてどの指標でも 10 分割すべてで上回った。同じ式も正解とすると、設定 A の一括は 0.983 ／ 0.879、逐次（訓練も逐次）は 0.989 ／ 0.904、baseline は 0.908 ／ 0.705。**§5〜§9.1**（設定 A）：(i) 同じ重みの baseline から x_1・x_2 だけの MLP にしても上がらない（Recall@20 −0.015、上回ったのは 4/10）。(ii) 基本の特徴量の向上はほぼ式の特化度 x_6（+0.080、10/10）。(iii) 集合の特徴量は Recall@20 +0.006・MAP +0.073（どちらも 10/10）。PFI：変数の 6 特徴量をまとめてシャッフルすると Recall@20 が 0.981 → 0.020（10/10 で低下）、話題の 4 特徴量は 0.973（低下 0.008、10/10 で低下）。逐次選択：MAP で一括 < 推論のみ < 訓練も逐次（訓練も逐次 − 一括 +0.014、正解式 8 本以上で +0.032、どちらも 10/10）。Recall@20 は 0.98 付近で差が小さい。話題の特徴量：候補 2,000 件の中でも正解式を見分ける（AUC：潜在意味類似度 0.910、文章類似度 0.848、候補内の相関 −0.026）が、x_7・x_3 を足しても一貫して上がらず（上回ったのは 3/10 と 2/10）、x_{10} は MAP だけ +0.013（10/10）、分野ラベルの合併も一貫した効果はない（上回ったのは 3〜4/10）。誤りの位置（種 42。この分割は難しく Recall@20 0.974）：第 1 段の見逃しはなく、上位 20 件に入らない正解式 85/1,624 本はすべて第 2 段の並べ方による。**N1 の比較**（付録 C 用、一括の並べ直し、設定 A）：N_1 = 50・200・500・1,000・2,000 で Recall@20 は 0.959・0.978・0.980・0.981・0.981、MAP は 0.845・0.857・0.859・0.858・0.860、被覆率は 0.964〜1.000、1 回の訓練と評価は 54〜162 秒（6 並列）。N_1 を 500 より大きくしても精度はほぼ変わらないが、全正解式が候補に入るのは 2,000（`experiments/kato1020/sweep.json`、図 `docs/figures/fig_n1_full_coverage_ja_1020.png`。N1 = 2,000 の値は §4 の実行と一致）。PFI の図は `fig_pfi_recall20_ja_final.png`（横軸は「10 通りの分割の平均」）。実装（追加のみ、既定の動作は変えない）：`set_aware_reranker.py` に `--exclude-cases`・`--eval-val`・`--equiv`、`--fast` のときの時間の記録。tests は `tests/test_kato1020_*.py`（6 本）と既存の高速版の tests を合わせて 57 passed。直前の commit の `run_mode` と、既定の旗の 18 通りで per-case が一致することも確かめた。分割ごとの実行は `experiments/kato1020/raw/`（非追跡）。集計は `kato1020_analysis.py`（main ／ greedy ／ mech ／ pfi ／ sweep）、対応表は `kato1020_mapping.py`。対応表には付録 A（古典的情報検索手法の重み 12 通り × TF-IDF・BM25・E5 のテストの値）の表も載せた。

- 2026-10-15（加藤先生の指示 1・2・4：LLM との比較のやり直しの準備）：8/31 報告の「LLM 直接生成」（Claude Sonnet 4.5 に式を LaTeX で書かせ、Claude Opus 4.8 で等価を判定し、各設定 50 件を 1 回）を、2026-10-14 のミーティングの加藤先生の指示 1・2・4 に従ってやり直すための準備をした（親セッションから分けたセッション。報告書の本文は変えていない）。スクリプト `run_llm_db_baseline.py`、試験 `tests/test_llm_db_baseline.py`（58 件）、出力 `experiments/llm_db_baseline/`。進め方と費用は、加藤先生に確認いただく資料 `docs/llm_comparison_plan_2026-10-15.tex`（commit cbcc854）にまとめてあり、本実行は先生の確認と本人の承認を待つ。**判定と指標**：LLM が返した式の ID だけで判定し、等価性は判定しない。データベース（DB）にない ID と読めない出力はその順位を占める不正解とし、同じ ID の 2 回目以降は除く。指標は Recall@20 と MAP@20（標準の定義。上位 20 件の外の正解式は $P(e) = 0$）。提案手法と baseline の値も同じ式で計算し、10 分割の値が 8/31 報告の表と一致することを確かめた（例：提案手法 $(0.3, 0.7)$ の設定 A で Recall@20 0.957、並べた全体の MAP 0.850）。**分割の固定**：`set_aware_reranker.py` の層化分割を、設定 A（1,823 件）と B（1,000 件）の種 10 通りで再現し、`splits.json` に固定した。テストケースの並びは既存の per-case 出力（提案手法 $(0.3, 0.7)$、baseline $(0.4, 0.6)$）と 20 通りすべてで一致した。作成時の作業ツリーの `set_aware_reranker.py` は別セッションの変更を含んでいたが、分割の関数は HEAD と同一で、HEAD の関数で作り直しても訓練・検証・テストがすべて一致した。**当初の設計は 1 回の入力に入らない**：訓練と検証の全ケースを例題として毎回渡すと、count_tokens で、DB の最小の形（ID・式の表

記・分野ラベル・出典）だけで 880,793 トークン、例題が設定 A で 380,428〜406,745（B で 284,001〜309,383）、1 回分は A で 1,287,889、B で 1,190,682 となり、4 モデル（Claude Haiku 5.5・Sonnet 5.5・Opus 5.5・Fable 5.1。数えた値は 4 モデルで同じ）の入力の上限 1,000,000 を超える。8/31 の Sonnet 4.5 は上限が 200,000 で使えない。形式を確かめる試しの呼び出しを 2 件（Opus 5.5、DB 全体と例題 300 件、入力 967,619 トークン、計 5.03 USD）行い、出力の形とキャッシュの読み出しを確かめた。式の表記を構造の部分だけ短くして 1 回に収める案も試算した。`\left`・`\right`、細い空白、`\frac{a}{b}` → a/b、1 文字の添字の波括弧、空白を、DB の全変数記号 13,220 種の記号としての現れ方が全 11,146 式で変わらない範囲で短くした（`compress_check.json`。評価ケースの入出力変数と正解式の組 174,913 組でも現れ方は変わらない）。それでも指示文と DB は 831,967 トークンにしか減らず、最も小さい分割でも上限を 110,505 トークン超えた。**本人の決定（2026-10-15、版 3）**：例題は渡さない（ゼロショット）。DB は分けずに 1 回で渡し、各式は ID・分野ラベル・式の表記（元のまま）だけをタブで区切って 1 行にする。出典は渡さず、式を乱数の種 20261015 で無作為に並べて ID を振り直した（`db_ids_v3.json`）。指示文には、課題、正解の式の組が満たす条件（Kato & Kano, 2025 の要件 1〜3。8/31 報告 §2.1）、DB の読み方、答え方（最大 20 個、重要な順）を書いた。4 モデルとも effort は high、思考の要約を記録し、出力の上限は 32,000 トークン（ストリーミングで受ける）。例題がないので同じケースへの入力はどの分割でも同じになり、呼び出しは異なるテストケースごとに 1 回（10 分割で 1,665 回、3 分割で 1,204 回）とし、答えはそのケースがテストに入るすべての分割で使う。1 回の入力は最大 952,918 トークン（出力に 47,082 残る）。費用の見積もり（出力 2,000 トークン/回、キャッシュの書き込みを含む）：10 分割で Haiku 89、Sonnet 195、Opus 391、Fable 581 USD、3 分割で 64、142、284、423 USD。比較には、別セッションの新しい設定（提案手法 $N_1 = 2{,}000$・hard negative、baseline $(0.3, 0.7)$）の同じ分割の値も並べる。再現：`python3 run_llm_db_baseline.py splits`（分割の固定）、`fix-order`（版 3 の並び）、`count3`（トークン数と費用）、承認後に `pilot3 -model ...`、`run3 -model ... -seeds ... -budget-usd ...`、`evaluate3 -model ...`。

- 2026-10-15（加藤先生の指示 3・4・5：第 1 段の候補数の見直しと、§4〜§8 の再実験）：2026-10-14 のミーティングで加藤先生が 8/31 報告の改訂版を確認し、一部対応の箇所に 5 つの方針を出した。このうち 3（第 1 段で全正解式を候補に含めるには N_1 がいくつ要るか。含められなければ第 1 段を外す）、4（自由度ゼロ停止をやめ、Recall@20 に固定して評価する）、5（§5〜§8 を第 1 段の重み $(0.3, 0.7)$ でやり直す）を、親セッションから分けたセッションで行った（1・2 の LLM との比較は別セッション）。報告書の本文は変えていない。旧値 → 新値の対応表は `docs/加藤先生指示_2026-10-14_旧値新値対応表.md`。**指示 3**：重み $(0.3, 0.7)$ の第 1 段の点数で全 11,146 式を並べ、各正解式の順位（同点は最も後ろの順位）を数えた（`analyze_stage1_n1.py`、`experiments/kato1014/n1_coverage_w30-70.json`、図 `docs/figures/fig_n1_full_coverage_ja.png`）。点数 0 の正解式はなく、全ケースで全正解式が候補に入る N_1 は 1,880（設定 A・B とも）、99% のケースなら A 579・B 847。全正解式を入れるのに $N_1 > 579$ が要る 18 ケース（設定 A の 1%）はすべて合成で、正解式は 5〜10 本、入出力変数は 21〜58 個と多く、最も下位の正解式は変数が 1〜3 個（$T = 470.21$°C のような数値例の式など）で、変数の一致度が 0.020〜0.065、文章類似度が 0.001〜0.087 と小さい（単一出典は $N_1 = 18$、出典横断は 66 で全部入る）。分割ごとに訓練と検証のケースで求めた N_1 は 1,233〜1,880 で、千の位に切り上げると 10 分割すべてで $N_1 = 2{,}000$（テストの被覆率は全分割で 1.000）。境目の大きさなので、$N_1 = 2{,}000$ と第 1 段なし（11,146 件）の試行（種 42）と所要時間、訓練の不正解の選び方（候補から無作為に 8 件／そのときのモデルの点数が高い 8 件＝ hard negative）の比較を本人に示した。本人の選択（2026-10-15）「$N_1 = 2{,}000$」「hard negative」（10 分割で無作為以上なら、という条件つき）。10 分割の一括の並べ直しで hard negative は Recall@20 と MAP の両方で無作為を上回った（A +0.006・+0.020、B +0.009・+0.023、すべて 10/10）ので条件を満たす（この比較には本実験と同じテストのケースを使ったので、わずかに楽観的な偏りがありうる）。第 1 段なし

は種 42 で精度が同じか低く（A の Recall@20 ／ MAP 0.989 ／ 0.862、hard 0.994 ／ 0.921）、時間は約 3 倍だった（`experiments/kato1014/raw/pilot/`、非追跡）。**実装**（既定の動作は変えない）：`stage2_fast.py`（第 2 段の特徴量を式×変数の疎行列でまとめて計算し、第 1 段の順位をケースごとに使い回す。既定の計算とビット単位で同じ値）。`set_aware_reranker.py` に `--fast`、`--neg-pool`、`run_mode(on_trained=...)`（PFI などの分析用）、逐次選択の訓練にも `--hard-neg`、候補 10,000 件以上のときの候補外の印（10^9）を足した。種 42 で、既定の経路（編集後）と `--fast` が `xs1`（一括、$N_1 = 50$）、`xs1_k200`（訓練も逐次、$N_1 = 200$）、`xk50`（推論のみ逐次）の per-case と 423/423 件一致した（`--fast` は約 8 倍速い）。tests は `test_stage2_fast.py` ほか 6 本（39 passed）。リポジトリ全体の tests は 1 件を除いて通る（`tests/test_fig_overview.py` は、図 1 から degrees of freedom” を外した 09-29 の変更に追いついていない既存の失敗）。最終レビュー（別の Claude）：既定の動作は HEAD と同じ、高速版は端の場合でも同じ値。指摘の分野ラベルの合併の誤り、下位のケースの説明、文言を直した。**指示 4**：主指標を Recall@20 とし、MAP（標準の定義）を併記した。並行の LLM との比較と並べるため、上位 20 件で打ち切った MAP@20 も出した（本人の依頼）。自由度ゼロ停止はやめた。baseline の重みは 12 通りを Recall@20 で選び直して $(0.3, 0.7)$（A 0.908、B 0.829。`analyze_kato1014_baselines.py`）。**主結果**（$N_1 = 2{,}000$、hard negative、10 分割、Recall@20 ／ MAP）：設定 A で baseline 0.908 ／ 0.691 に対し、一括の並べ直し 0.982 ／ 0.869、逐次選択（推論のみ）0.983 ／ 0.881、逐次選択（訓練も逐次）0.983 ／ 0.885。設定 B で 0.829 ／ 0.630 に対し 0.966 ／ 0.832、0.970 ／ 0.844、0.971 ／ 0.849。どれも 10 分割すべてで baseline を上回った（$p = 0.00195$）。逐次選択の向上は MAP に出て（訓練も逐次 − 一括：A +0.016、B +0.018、正解式 8 本以上で +0.031・+0.032、10/10）、Recall@20 は 0.98 付近で差が小さい（A は有意でない）。**§5〜§9.1 のやり直し**（設定 A、$N_1 = 2{,}000$、hard negative）：(i) 同じ重みの baseline から $x_1 \cdot x_2$ だけの MLP にしても上がらない（Recall@20 −0.009）。旧版の +0.080 は重み $(0.7, 0.3)$ より良い重みを学習で見つけた分と考えられる。(ii) 基本の特徴量の向上はほぼ式の特化度 x_6（+0.075）で旧版と同じ。(iii) 集合の特徴量は Recall@20 で +0.006、MAP で +0.076（どちらも 10/10）で、効果は正解式をより上位に並べる形で出る。PFI（`kato1014_pfi.py`、図 `docs/figures/fig_pfi_recall20_ja_n2000_hard.png`。旧図は上書きしない）：変数の 6 特徴量をまとめてシャッフルすると Recall@20 が 0.982 → 0.021、話題の 4 特徴量は 0.974（低下 0.008、$p = 1.8 \times 10^{-5}$）で、小さいが 0 と有意に異なる（旧版は $p = 0.10$）。逐次選択は MAP で一括 < 推論のみ < 訓練も逐次の順を保つ（上の主結果）。話題の特徴量：候補 2,000 件の中でも話題の特徴量は正解式を見分ける（AUC：潜在意味類似度 0.913、文章類似度 0.852。旧版の候補 50 件では 0.594 と 0.437。候補内の相関 −0.052、旧版 −0.404）ので、旧版の原因 (1)(2) は $N_1 = 50$ で生じていたもの。それでも $x_7 \cdot x_3$ を足しても上がらず（−0.007、−0.017）、x_{10} は MAP だけ +0.009（$p = 0.0098$）。分野ラベルの合併は、旧版（`run_domain_merge_ablation.py`）が式のラベルを群の名前（“C12” など）に置き換えたので、k-means の 100 群・40 群では説明文と部分文字列で比べる x_7 がほとんど 1 にならず（1,823 ケース中 5 件、最終レビューの指摘）、合併の効果を測れていなかった。x_7 を「説明文が式の群のどれかの元のラベルを含めば 1」に直して（`kato1014_domain_merge.py`。合併なしでは元の x_7 と per-case が 4,594/4,594 件一致）やり直すと、粗くするほど Recall@20 が下がった（表記をそろえた 1,958 種 −0.022、100 群 −0.028、40 群 −0.036、Wilcoxon $p \le 0.027$）。x_{10} の PFI の打ち消し合いは見えなくなった（Mann–Whitney $p = 0.081$、旧版 1.3×10^{-8}）。誤りの位置（種 42）：第 1 段の見逃しはなく、上位 20 件に入らない正解式は 1,579 本中 19 本ですべて第 2 段（旧版は $N_1 = 50$ で 61.8% が第 1 段）。§9.3 の重みの比較は $N_1 = 50$ のまま Recall@20・MAP で数え直した（$(0.3, 0.7)$ が最良のまま。全正解式が入る N_1 も重み $(0.7, 0.3)$ 5,537、$(0.5, 0.5)$ 3,017、$(0.3, 0.7)$ 1,880、$(0.0, 1.0)$ 2,249 で最小）。出力：`experiments/kato1014/`（`main_n2000_hard.json`、`greedy_n2000_hard.json`、`mech_n2000_hard.json`、`pfi_n2000_hard.json`、`topic_diag_n2000_hard.json`、`case_outcomes_n2000_hard.jso`

baselines_stats.json、weights_n50.json、旧値の再現の確認 *_check_w70-30_k50.json）。分割ごとの実行は experiments/kato1014/raw/（再生成できるので非追跡）。実行は run_kato1014.sh と run_kato1014_extra.sh、集計は analyze_kato1014_{main,greedy,mech,pfi}.py、対応表は kato1014_mapping.py。

- 2026-10-14(2)（修正箇所の注を、加藤先生と同じ PDF の注釈に作り直した）：本人指示「1 ページ目はいらない。『#9・#10 修正』みたいの言い方もやめて、そのタグがどのコメントを指してるのが元のコメント付きの pdf を見ないとわかんない。コメントをページ内に入れるではなく、加藤先生みたいなコメント機能を使ってください」。2026-10-14 の版（用紙を広げて余白に注を組み込んだ版、make_revision_marked_0831.py）を削除し、annotate_revision_0831.py（PyMuPDF）に置き換えた。改訂版の PDF（18 ページ、本文は変えない）に、ハイライト注釈とポップアップのコメントを付けて docs/progress_report_2026-08-31_methods_results_revision_comments.pdf に保存する。加藤先生の注釈（Acrobat、作成者 kato）と同じ形で、作成者は「一洋」。コメントは「修正：…」と「理由：8/31 版 p.N「(先生がハイライトした語句)」へのコメント「(先生のコメント)」」。先生のコメントは 8/31 版の注釈 78 件の本文から引く（PyMuPDF で抽出。「重み歯科」の変換の誤りだけ直した）ので、番号を使わず、元の PDF を開かなくても分かる。取消線と挿入は、消した語句と入れた語句を書いた。場所は改訂版 PDF の文字列で決める（NFKC と空白の除去でそろえ、ヘッダーとページ番号は除く。一意でなければ止まる）。表 2 をまたぐ段落は表を除いてハイライトし、ページをまたぐハイライトの 2 ページ目には「前のページから続く」とだけ書いた。コメント 78 件（黄 53、青 16、橙 9）と、1 ページ目に色の意味の付箋 1 件。注釈を除いた各ページの文字は改訂版と同じ（照合済み）。
- 2026-10-14（8/31 報告の改訂版に修正箇所の注を付けた版を作った）：本人指示「PDF にして、修正したところをハイライトし、修正内容と理由を簡略に書く」（加藤先生との打ち合わせで改訂状況を確かめられるため）。make_revision_marked_0831.py が改訂版の tex（本文は変えない）から docs/progress_report_2026-08-31_methods_results_marked.tex を作り、lualatex でビルドする。用紙の幅だけを 286 mm に広げて右の余白に注を置くので、本文の折り返しとページ番号は改訂版と同じ（ラベルのページを照合して一致）。ハイライトは lua-ul、注は marginpar（marginfix）。色は、黄＝注釈に対応して書き直した箇所、青＝計算や実験を追加した箇所（MAP の数え直しを含む）、橙＝一部だけ対応し相談したい箇所（#54、#57、#59）。ハイライト 90 か所、注 77 件。注の番号は対応表（docs/**加藤先生コメント対応**_2026-08-31 **報告**.md）と同じ。表紙に、見方、数値と結論が変わった主な点、相談したいこと 4 点をまとめた。あわせて、改訂版 §1 の「次の 4 点を改めた」を「次の 5 点」に直した（(1)〜(5) を挙げているため）。ltjsarticle 版と jresume 版の PDF、Overleaf 用 zip の tex を作り直した。
- 2026-10-13(2)（8/31 報告の追加実行の結果を git に追加）：本人指示「xk50 と xs1_B も commit して」。experiments/xk50/（最良の重み $(0.4, 0.6)$ の baseline の per-case 付き 20 件、逐次選択の $N_1 = 50$ の推論のみと訓練も逐次の 40 件、各ログ）と experiments/xs1_B/（設定 B の第 1 段の重み $(0.3, 0.7)$ の 10 seed とログ）を追加した。analyze_kato_0831_followup.py、analyze_greedy_3way_k50.py、generate_figures_thesis.py が読むデータで、これで集計を再現できる。完了マーカー sweep_B_k50.done（空）は、既存の .gitignore（experiments/*.done）の方針に合わせて外した。
- 2026-10-13（作文技術チェックリストに本人の指摘 3 件を追記）：docs/**作文技術チェックリスト**.md の 2 節と 11 節に、2026-10-12 の本人の指摘 3 件を追記した：未回答の質問がなければ 2.2 節は見出しごと消す（「なし」と書いて残さない）、議論したい点には他の人の判断や意見が要ることだけを置き、やってみないと分からないことは今後の計画に「試す」として置く、全体ゼミの報告は他の分野の人も読むので、この研究に固有の細部は程よく略し、結果を変える手順は 1 文で残す。memory の全体ゼミ資料の決まりも同じ内容に更新済み。

- 2026-10-12(4)（先生方のコメントから学んだ作文技術を 1 つのチェックリストにまとめた）：本人指示「コメントから学んだ作文技術をしっかり残して、これからの進捗報告にも使えるようにする」。`docs/作文技術チェックリスト.md` を新規作成した。加藤先生の 6 回分（2026-06 の 18 件、08-16 の 7 件、09-27 の 52 件、09-29 の 16 件、8/31 報告への 78 件）、江口先生の 18 件、本人の指摘、作業中に見つけた誤りから、規則を 11 の節（最重要の 12 項目、構成、問題設定と定義、手法、データと実験設定、比較手法と評価方法、結果、数値と統計、図表、用語と表記、提出前の確認）にまとめ、各規則に理由、コメントの前後の例、出典（回と番号）を付けた。提出前の確認には grep の手順（注意語、2 つだけの「・」、行の途中の % コメント）を入れ、注釈が返ってきたときの手順（注釈の抽出、先生の PDF と手元の版の比較、対応表、他の文書への反映、チェックリストへの追記）も書いた。Claude の memory に、書く前と提出前にこのチェックリストを使う規則（`feedback_writing_checklist`）を加え、指標の式を実装から書き起こす規則（MAP の件）を `feedback_verify_method_guarantees` に足した。
- 2026-10-12(3)（修論の MAP を標準の定義にそろえた）：本人指示「修論も標準の定義の MAP にそろえて」（親セッション経由。日本語版は 599d836 で対応済み）。§5.3 の AP を標準の定義（K で割り、並べた中にない正解式は 0。提案手法では第 1 段の候補に入らなかった正解式が 0 になる）だけで書き、実装の定義は % source コメントに 1 行残した。表 3 の提案手法の MAP を `kato_0831_followup_stats.json` map_standard の値に改めた（設定 A：重み $(0.7, 0.3)$ 0.796、$(0.3, 0.7)$ 0.850。設定 B：0.715、0.795）。§6.1 は「MAP でも最良の baseline を 10 分割すべてで上回る（A +0.104、B +0.088）」と書いた。baseline 側の確認：`external_baselines.py -save-per-case` を scratch に出力して再実行し（学習なし・決定的。集計値は既存の JSON と全ラベルで完全一致）、正解式の順位を得た。順位 10,000 以上の正解式は文章だけの重み $(1.0, 0.0)$ だけ（A 176/17,420 本、B 101/13,468 本）で、ほかの行（BM25・E5 を含む）は両定義で MAP が同じ。付録の重み 12 通りの表では $(1.0, 0.0)$ の設定 A の MAP だけが 0.148 から 0.147 に変わった（B は 0.170 のまま）。図に MAP はない。ビルド：`latexmk -gg` exit 0、未定義参照 0、本文 1〜28 ページ。
- 2026-10-12(2)（修論を 8/31 報告の改訂と同じ事実にそろえた）：親セッションの指示で、加藤先生の注釈 78 件に沿って改訂した日本語版（`docs/progress_report_2026-08-31_methods_results.tex`、b1b3045）で確かめた事実に、英語の修論（`thesis/master_thesis`）を合わせた。新しい実験はしていない。第 3 章：問題設定を Kato and Kano (2025) の 4 要件（入出力の完全性、自由度の整合 $N_{\mathrm{DoF}}(S) = |V(S)| - |S| = |\mathcal{I}|$、可解性、定数式の一意性）で書き直し、自由度の定義に Seborg et al. (2010) を文献に加えた（40 件）。正解・不正解を式 ID で定義し、別の出典の同じ式は不正解と数えると書いた。停止条件 (a)(b) を要件 1・2 との関係（出力だけ、等号を不等号に緩めたもの）で書き、先生の反例（$y_1 = x$, $y_1 = x + 1$, $y_2 = z$）を入れ、“closed”・閉包率をやめて停止条件の充足率にした。第 1 段の重みを (w_t, w_v) に変数化し、被覆率の実測値を手法の節から §6.7 に移した。f_7 の定義（一方が他方に含まれれば 1）と式の文脈テキスト（抽出 LLM が前後の本文をもとに書いた説明）を実装と抽出の指示に合わせた。第 4 章：評価 1,823 件の正解集合はすべて要件 1〜3 を満たすが、91 件（5.0%、すべて出典横断、87 件は入出力を選び直した派生）は式と未知変数の完全マッチングがないこと、正解式 3,132 本のうち 386 本は同じ文字列の式が別の出典にあることを追記した（`kato_0831_followup_stats.json` gt_checks。91 件の内訳は同じ判定で数え直した）。第 5・6 章、Abstract、第 1・7 章：主比較を最良の重み $(0.4, 0.6)$ の baseline に改めた（設定 A 0.607 → 0.743 で +0.136、$d_z = 6.9$。設定 B 0.559 → 0.689 で +0.130、$d_z = 10.1$。第 1 段 $(0.3, 0.7)$ は 0.780 と 0.740）。+0.222 は同じ重みの baseline との差としてだけ残した。表 3 に重みの列、第 1 段 $(0.3, 0.7)$ の行、MAP と Recall@20 の標準偏差を加え、付録に重み 12 通りの表と逐次選択の $k = 50$ ／ 200 の表を加えた。重み $(0.7, 0.3)$ の Recall@20 は最良の baseline とほぼ同じ（A 0.909 対 0.907、$p = 0.49$。B 0.838 対 0.827、$p = 0.049$）。§6.2 を最良の重みの baseline で数え直し（正解式 1 本で −0.012、2 本以上で +0.10〜+0.18）、出典数の分割も数え直した（+0.12、+0.15、+0.19。3 以上は 59 件で交絡

あり)。§6.4 に $k = 50$ の 3 通り（B $0.689 < 0.709 < 0.717$、A $0.743 < 0.762 < 0.765$）を加えた。LLM 直接生成は、最大 $\max(12, K + 4)$ 本を重要な順に書かせて平均 11.6 本、判定は先頭 12 本、設定 A の $n = 48$ は判定 2 件の失敗によると書き、根拠のない「経験式は検索が有利」と「集合として組めない」を削除した。限界を 9 項にした。**MAP の定義の食い違い**：`evaluate_multi_eq.py` の AP は、並べた中に入った正解式だけで平均する（入らなかった正解式を 0 と数えない)。baseline は全データベースを並べるので両定義で同じだが、候補 k 件しか並べない提案手法の MAP は標準の定義より高く出る（設定 A 0.863 → 0.796、設定 B 0.832 → 0.715。保存済みの per-case の順位から読み取りだけで再計算)。修論では実装どおりに AP を定義し、標準の定義の値を併記した。標準の定義でも、最良の baseline を 10 分割すべてで上回る。日本語版報告の MAP の式（$1/K$ で割る）は実装と合っていない。図：PFI を日本語版と同じ構成の英語版にした（`generate_figures_thesis.py` の `pfi()`。配色は dataviz の検証スクリプトで確認)。比較の図と特性別の図を最良の重みの baseline に、DoF-stop の図の注記を停止条件の充足率に改め、図 1 の “degrees of freedom 0”・“closed” と、逐次選択の図の “By difficulty” をやめた。抽出モデル：本人確認（親セッション経由、「追加した文献の抽出は Claude を使った」）を受け、§4.1 と §5.4 に「研究の初期に集めた 39 報は Gemini 2.5 Pro、その後に追加した文献は Claude（版の記録なし）で抽出」と書き、基礎式集を生成したのは Gemini 2.5 Pro と明記した（日本語版 §3.1 と同じ。TODO は解消)。Claude への指示が数値例・一段の代入・演習問題の式を除くことも書き、第 1 章と §6.6 の「1 つの LLM が抽出」を複数形に改めた。訂正：1e8bd63 では第 1 章の % source コメントの後ろに次の文が同じ行で続いたため、“The database holds 11,146 equations from 361 sources” で始まる文の前半が消えていた（PDF では文頭の欠けた文になった)。行を分けて直し、PDF の本文に小文字で始まる文が残っていないことを確かめた。ビルド：`latexmk -gg` exit 0、未定義参照 0、文献 40 件（`main.aux` の引用初出順と一致)、Overfull は既存の目次の 5 件。本文は 1〜28 ページ（規範 20〜28 の上限、圧縮設定のまま)。引き継ぎメモは side-session-notes の `thesis_alignment_2026-10-12.md`。

- 2026-10-12（8/31 報告を加藤先生の注釈 78 件に沿って改訂)：本人指示「加藤先生がコメントつけてくれた、それらを踏まえてレポートを修正して」。注釈は 8/31 版 PDF への強調 68、取消線 4、挿入 5、付箋 1（2026-09-18 と 09-25 付)。全件の対応は `docs/加藤先生コメント対応_2026-08-31報告.md`。`docs/progress_report_2026-08-31_methods_results.tex`（ltjsarticle、18 ページ）と jresume 版（15 ページ、Overleaf 用 `docs/seminar_overleaf_20261012_methods_results.zip`)：§2 を先生の構成案（問題設定 → 提案手法の概要（図 1 新規）→ 第 1 段 → 第 2 段 → 逐次選択 → 自由度ゼロ停止）に組み替えた。問題設定は Kato and Kano (2025, Computers & Chemical Engineering 200:109147) の 4 要件と自由度の定義（変数の数 − 式の数、Seborg et al. 2010）で書き、正解と不正解を定義した。手法の数値を変数（$N, N_1, m, w_t, w_v, \gamma, n_{\mathrm{neg}}$）にし、10 特徴量、損失、指標を式で定義した。自由度ゼロ停止の「返す集合は解ける形で閉じている」は先生の反例（$y_1 = x$, $y_1 = x + 1$, $y_2 = z$）で撤回した。比較手法の重みを 12 通り比べ（付録 A)、最良の $(0.4, 0.6)$ を本文に使った（設定 A 0.607、B 0.559)。提案手法は最良の baseline を A +0.136、B +0.130（第 1 段の重み 0.7/0.3)、+0.173、+0.181（0.3/0.7）上回る（10 分割すべて)。ただし重み 0.7/0.3 の Recall@20 は最良の baseline と差がない（A 0.909 対 0.907、$p = 0.49$)。新規の実行：設定 B の第 1 段の重み 0.3/0.7（`run_stage1_weights_B.sh`、Recall@K 0.740 ± 0.040、0.7/0.3 から +0.051、10/10)。最良重みの baseline の per-case 再実行（集計値は既存と一致）と、逐次選択 3 通りの $N_1 = 50$（`run_kato_0831_followup.sh`、`analyze_greedy_3way_k50.py`)。設定 B の $N_1 = 50$ は $0.689 < 0.709 < 0.717$ で $N_1 = 200$ と同じ順（正解式 8 本以上の差は +0.021 で $N_1 = 200$ の +0.056 より小さい)。設定 A の $N_1 = 50$ も $0.743 < 0.762 < 0.765$ と同じ順（(3) と (2) の差 +0.002 は有意でない、$p = 0.49$。8 本以上で (3)−(1) +0.013)。集計は `analyze_kato_0831_followup.py` → `experiments/kato_0831_followup_stats.json`。確かめた事実：評価 1,823 件の正解集合はすべて

要件 1〜3 を満たすが、出典横断の 91 件（5.0%）は式と未知変数の完全マッチングがない（どれかの正解式の変数がすべて入力変数）。正解式 3,132 本のうち 386 本（12.3%）は、空白などを除いて同じ文字列の式が別の出典にある（ID 判定では不正解と数える）。LLM 直接生成は平均 11.6 本を書き、判定は先頭 12 本まで、設定 A の 2 件は判定結果がない（$n = 48$）。検証用の分割は使っていない。図：PFI を 1 枚にまとめ、横軸をシャッフル後の Recall@K にした（`generate_pfi_recall_figure.py`）。図 3 の記号を N_1 にした（`analyze_stage1_sweep.py`）。抽出モデル：本人の確認（「追加した文献の抽出は Claude を使った」）を受け、初期の 39 報は Gemini 2.5 Pro、追加した文献は Claude（`extract_equations_claude.py`）と書いた。Claude の版は記録がないので書かない（スクリプトの既定 `claude-opus-4-5-20250805` と docstring の Opus 4.7 が食い違う）。Claude の指示は式周辺の文章を「周辺の本文をもとに物理的な意味を 1〜3 文で説明」とし、数値の計算例と演習問題の式を除くので、式周辺の文章の定義を「LLM が式の前後の本文をもとに書き出した説明」に改めた。修論を直しているセッションにも伝えた。MAP の定義の訂正：修論のセッションの指摘で、実装の AP（`evaluate_multi_eq.py`）は並べた中にある正解式だけで平均し、報告 §3.5 の標準の定義（K で割り、並べた中にない正解式は 0）と違うと分かった。報告の表 3 を標準の定義で数え直した（提案手法 0.7/0.3 で A 0.863 → 0.796、B 0.832 → 0.715、0.3/0.7 で 0.850 と 0.795。baseline は全式を並べるので同じ。標準の定義でも最良の baseline を 10 分割すべてで上回る。`experiments/kato_0831_followup_stats.json` の map_standard）。

- 2026-10-09（追加実験：検証用ケースで τ と第 1 段の重みを選ぶ）：本人の選択（2026-10-08）「τ を検証用ケースで選ぶ」。2026-10-08 の実験では D1 の τ を Youden の J で決め、第 1 段の重みは記号版で選んだ文章 0.3・変数 0.7 を使ったが、τ の感度が大きく、D1 の被覆率は重み 0.5・0.5 で最良だった。設計書 §7（結果を見る前に追記）：seed ごとに訓練用ケースで学習し、検証用ケースの Recall@K が最大の設定を選び、その設定のテスト用ケースの値を報告する（テスト用ケースは選択に使わない）。D1 は $\Delta\tau \in \{0, +0.02, +0.04, +0.06, +0.08\}$（$\tau$ ＝その seed の Youden の τ ＋ $\Delta\tau$）× 重み（文章, 変数）$\in \{(0.7, 0.3), (0.5, 0.5), (0.3, 0.7)\}$ の 15 通り、S1 は公平のため重み 3 通り。選んだ S1 の模型で記号の付け替えも評価した。同点は本実験の既定に近い方。実装は `tune_var_description.py`（`run` ／ `merge`）、`run_var_description_tuning.sh`（設定 A・B を seed の前半と後半に分けて 4 並列）、`analyze_var_description.py tuned-stats`、tests（速いテスト 259 passed、RUN_SLOW 72 passed）。整合の確認：既定の点（$\Delta\tau = 0$、重み 0.3・0.7）のテストの値は、2 設定 × 2 条件 × 10 seed × 4 指標の 160 個すべてで本実験と一致した。**選ばれた設定**：S1 は両設定とも 10 seed すべてで既定の重み（0.3・0.7）。D1 は設定 A で（+0.04、0.3・0.7）が 6、（+0.04、0.5・0.5）が 3、（+0.02、0.5・0.5）が 1、設定 B で 4・5・1。格子の端（+0.08）は 0 回で、τ はおよそ 0.89 が選ばれた。**結果**（Recall@K、10 seed）：D1 は選び直しで設定 A 0.326 → 0.442（+0.116、95% 信頼区間 $[0.103, 0.128]$）、設定 B 0.286 → 0.371（+0.085）と有意に上がった。それでも記号の照合（S1 は選び直しても同じ 0.780 ／ 0.745）との差は A −0.338（$[-0.355, -0.320]$）、B −0.374 で有意に低く、置き換えは成り立たない。一方、選び直した D1 は、記号を 50% 付け替えた記号の照合（A 0.215、B 0.235）を有意に上回った（A +0.227、B +0.136）。出力は `experiments/var_desc_tuned_{A,B}.json`、検定は `experiments/var_desc_tuned_stats.json`。4 並列の実行は約 7.8 時間かかった（見込みは約 2 時間）。
- 2026-10-08(3)（進捗報告の目的の書き方を修論とそろえた）：本人指示「進捗報告の目的の書き方もそろえて」に対応し、2026-10-08(2) で修論に入れた「使える可能性の高い式を提示し、利用者が組み立てて確かめる」に合わせた。`docs/ゼミ latex テンプレ/progress_report_2026-09-27_related_work.tex`：Abstract の目的の文（「モデル構築に必要な数式を自動で選定する手法」→「作りたいモデルに使える可能性の高い数式を提示する手法」＋「提示した数式からモデルを組み立てて確かめるのは利用者である」）、§3.1 と表 1 の「必要な式を上位に並べる」→「使える可能性の高い式を上位に並べる」、

§3.3 の「求めるのは……集めた式が連立方程式として解けること」→「提示する式が変数でつながり、一緒にモデルに使えること」、表 1 の数式検索の行の「連立方程式として解ける式の集合を探す」→「一緒に提示する式との変数のつながりも見て、モデルに使える可能性の高い式を探す」（自由度ゼロ停止は解ける集合を保証しないため）。`latexmk` exit 0・5 ページ（変更前と同じ）・未定義参照なし。配布用 PDF を更新し、Overleaf 用 zip `docs/seminar_overleaf_20261008_related_work.zip`（4 エントリ：`.tex`・`.bib`・`jresume.cls`・`latexmkrc`。10-08 の別報告の zip と名前がぶつからないよう報告名を付けた）を作り、展開し直して単体で exit 0・5 ページを確認した。作成中の `progress_report_2026-10-08_var_description.tex`（別セッションの作業、未追跡）は Abstract の同じ 1 文だけを書き換え、そのセッションに知らせた（コミットはそのセッションに任せる）。08-31 以前の報告は発表済みの記録として変えていない。

- 2026-10-08(2)（修論の目的の書き方を「使えそうな式を提示する」にそろえた）：本人の方針（2026-10-01）「本研究の目的は完璧で必ず使える物理モデルを出すことではなく、使えそうな数式を提示すること」に合わせ、手法の出力を「モデルを構成する式の集合を取り出す」と書いていた箇所を、「モデルに使えそうな式を提示し、利用者がそれを組み立てて確かめる」に改めた。対象は Abstract（`main.tex`：目的の文、集合で評価する理由の文、自由度ゼロ停止を「提示する式の本数を決める」規則として記述）、`Introduction.tex`（図 1(b) の説明、目的の段落に「完成したモデルではなく使えそうな式を提示し、利用者が組み立てて確かめる」を追加、「unusual answer」を「候補どうしが依存し合う検索問題」に具体化）、`Method.tex`（問題設定を「要求されたモデルの式が上位に来るように並べ、上位を候補として提示する」に、正解集合を「テストケースが指定する式の集合（§4.2）」に）、`Conclusion.tex`（第 1 段落。9/29 の訂正で残っていた「選んだ集合が系として閉じたら止まる」も停止条件の記述に置き換え）、`RelatedWork.tex`（組合せ法・数式検索との相違の 2 文）、`Dataset.tex`（テストケースの定義の 1 文）。図 1 の中の文言（例の CSTR 3 式は自由度 0 で解ける）は例として正しいので変えていない。`latexmk -gg` exit 0・33 ページ（変更前と同じ、本文 25 ページ）・未定義参照なし。
- 2026-10-08（変数を記号でなく説明で照合する実験：置き換えと頑健性）：本人の発案（2026-10-01）「数式データの中の記号や変数を、全部それらの自然言語の記述に切り替えて、変数の一致度などの特徴量を記述の類似度や一致度で測るとしたらどうなるか」。設計書 `docs/superpowers/specs/2026-10-01-variable-description-matching-design.md`（commit d04e41c）と計画書 `docs/superpowers/plans/2026-10-01-variable-description-matching.md`（commit 7723f3b）に従って実装・実行した（コードと結果は作業ツリー、未 commit）。**方法**：変数を説明文で表し、2 つの説明の E5（`intfloat/e5-base-v2`、両側に接頭辞 `query:`）のコサイン類似度がしきい値 τ 以上なら同じ変数とみなす。1 対 1 の最大マッチングの数 $|M|$ を、記号版の一致数の代わりに同じ計算式へ入れて、reranker-10S の 10 個の特徴量を求める。τ は seed ごとに訓練ケースの組（正例＝正解式の中の同じ記号の説明、負例＝同じ正解式の別の記号の説明）で Youden の J が最大の値。第 1 段は全 11,146 式に対し、$|M|$ の上限（対応先のある入出力変数の数と式の変数の数の小さい方）で近似する。記号版は 0/1 の一致行列と $\tau = 1$ で、既存の特徴量と完全に一致する。条件は S0（既報の再現）、S1（記号の照合。説明文中の記号は言葉に書き直す）、S1-r50 ／ r100（テストケースだけ入出力の 50% ／ 100% の記号を LLM が提案した別の記号に替え、S1 の模型で評価）、D1（LLM による言い換え）、D0（正解式の説明の写し。漏れの参考）。第 1 段の重みは文章 0.3・変数 0.7。設定 A（1,823 件）と設定 B（合成 1,000 件）× 10 seed。**実装**：`var_matching.py`、`var_desc_qc.py`、`var_conditions.py`、`run_var_description.py`（と `.sh`）、`make_var_descriptions.py`、`analyze_var_description.py` と pytest 6 本（186 passed、2 skipped は RUN_SLOW の回帰テスト）。S0 は設定 A・seed 42 で既報の Recall@K 0.8402538556793877、MAP、Recall@20 と、第 1 段の被覆率（0.9670508667903073 ／ 0.9202866372367196）に完全に一致した。最終レビュー（Claude Fable 5.1）の指摘で、一括実行のシェルが失敗を検出するように直し、品

質の確認で不合格のケースを除いた比較を検定に足した。**生成**：Anthropic API の `claude-opus-5-5`（effort medium、JSON スキーマによる構造化出力）。試行 20 件（18 件合格）→本人の了承→ Message Batches で 1,805 件→品質の確認で不合格の 110 件を通常の API で最大 2 回作り直し（54 件が合格）。全 1,823 件を `claude-opus-5-5` が生成し、不合格のまま残ったのは 55 件。費用は 43.93 USD。入力の記号 Ω_0 がオーム記号（U+2126）で書かれ、LLM が 3 回ともギリシャ文字のオメガ（U+03A9）で返した 1 件は、NFC 正規化で 1 つの入力記号に当たるときだけ入力の綴りに読み替えて救った（判定が変わったのはこの 1 件だけ）。無作為に選んだ 50 変数の目視で、意味の誤りは 0 件。`meaning_conflict`（渡した説明どうしが別の量）は 955/33,360 変数（2.86%、605 ケース）で、仕様の 5% 未満のため除外しない。**事前確認**：D1 の AUC 0.900（ゲート 0.80 を通過）、全ケースで決めた τ は 0.850。D0 の AUC は 0.976。**結果**（Recall@K、10 seed の平均）：設定 A は S0 0.780、S1 0.780、S1-r50 0.215、S1-r100 0.000、D1 0.326、D0 0.846。設定 B は 0.740、0.745、0.235、0.000、0.286、0.781。D1−S1 は A -0.453（95% 信頼区間 $[-0.472, -0.435]$）、B -0.459 で有意に低い（対応のある t 検定と Wilcoxon の符号順位検定の両方で $p < 0.05$）。族別でも単一出典 -0.373、出典横断 -0.463、合成 -0.454 と、すべての族で低い。記号の付け替えで S1 は有意に下がり（A -0.565 ／ -0.780、B -0.510 ／ -0.745）、D1 は S1-r100 を有意に上回る（A $+0.326$、B $+0.286$）。S1−S0 は同程度（A -0.0001、信頼区間 $[-0.008, 0.008]$）。品質の確認で不合格のケースを除いても変わらない（A は 53 件を除いて D1−S1 -0.453）。図は `figures/fig_var_description.pdf`、検定は `experiments/var_desc_stats.json`。**読み**（仕様 §5 で結果を見る前に決めた読み方による）：置き換えは成り立たない。記号が文献どおりなら、汎用の E5 としきい値による説明の照合は、記号の照合に大きく劣る。頑健性については、記号の照合は利用者の記号が文献と一致することに依存する。説明の照合は記号を使わないので構成上この影響を受けず、50% を付け替えた記号の照合より平均で高い（A 0.326 対 0.215。この比較は事前に決めた比較に入っていないので検定していない）。D0 は手法の性能としては示さず、言い回しの一致による底上げの大きさ（A $+0.520$）としてだけ示す。**原因の手がかり**：第 1 段の被覆率（上位 50 件、設定 A の全ケース）は S1 0.969 に対し D1 0.710（重みを文章 0.5・変数 0.5 にすると 0.744）、D0 0.975。言い換えた説明の照合では、第 1 段の候補から正解式が落ちる。D1 の第 1 段の近似と厳密な $|M|$ の食い違いは候補の 29〜33%。τ の感度（設定 A・seed 42）は、τ 0.830 で 0.255、0.850 で 0.357、0.870 で 0.453。同じ式の中の別の変数と分けるように決めた τ は、全データベースとの照合には低すぎる。E5 が分けられない例は、棚段の X_i と X_{i+1}（類似度 0.977）や、入口と出口の濃度（0.929 対 0.933）。また記号を 100% 付け替えると、別の記号がデータベースの別の式にもあるため誤った式が上がり、第 1 段の被覆率は文章だけ（0.517）より低い 0.135 になる（設定 B・seed 42）。**限界**：D1 の言い換えは正解式の説明から作るので、利用者が一から書く説明より楽観的な見積もりである。最大マッチングは同点の対応を行の順で選ぶ。被覆率の掃引の τ は標本内（seed 42 の訓練ケースで決め、全ケースで平均）。**運用**：本実験は前のセッションの終了で設定 A の D1 の途中で止まったため、足りない run だけを同じ引数で再開し、停止前の 7 seed の値と完全に一致することを確かめてから合わせた（`experiments/var_desc_A.json` の `resumed`）。進捗報告の下書き（設計のみ、2 ページ）は `docs/ゼミ latex テンプレ/progress_report_2026-10-08_var_description.tex`。本人の指示で、進捗報告は全ての生成と実験が終わってから書く。

- 2026-09-29(6)（提示件数 K を正解式の数に合わせる場合と、固定する場合の比較）：本人指示「K を正解モデルの数に合わせたときの結果と、K を固定（10 や 20 などテストデータのモデルを覆う値）としたときにどうなるか検証してみたい」。`analyze_fixed_k.py` を新設し、ケースごとの順位から上位 c 件（$c = K, 5, 10, 20, 50$）の再現率・正解式が全部入る割合・適合率・混じる不正解の式の数を、乱数 10 通りの平均で出した（`experiments/fixed_k_stats.json`）。設定 A は `strat_A.json` の per_case を使い、既存の Recall@5/10/20・FullRecall と小数 4 桁まで一致。設定 B は per_case がなかったので `-save-per-case` で再実行し（`experiments/strat_B_percase.json`、乱数ごとの Recall@K

が strat_B.json と完全一致)、正典は上書きしていない。設定 A（古典的手法 → 本手法）：再現率は $c = K$ で 0.521 → 0.743、10 で 0.746 → 0.890、20 で 0.836 → 0.909、50 で 0.912 → 0.912。全部入る割合は 0.178 → 0.451、0.536 → 0.726、0.644 → 0.761、0.762。適合率は 10 件で 0.301、20 件で 0.157（不正解が約 7 本・17 本混じる)。差は $c \leq 20$ で乱数 10 通りすべてで本手法が上（$p = 0.002$)、$c = 50$ では両手法の上位 50 件が第 1 段の候補そのものなので全 4,594 件で同じ。本手法は上位 13 件で上限 0.912 の 99% に届き、古典的手法が本手法の上位 10 件の再現率に届くには 37 件が要る。設定 B も同じ傾向（$c = K$ で 0.466 → 0.689、10 で 0.610 → 0.801、20 で 0.721 → 0.838、50 で 0.843 で一致、古典的手法は 34 件が要る)。正解式が 6〜10 本のモデルは、20 件に固定しても全部入るのは 0.30（A）で、第 1 段で落ちた式は何件提示しても戻らない。自由度ゼロ停止の実験（学習版逐次モデル・候補 200 件、experiments/xd_dof/）でも同じモデルで比べると、設定 A で K ＝正解数は再現率 0.797・適合率 0.797・平均 3.8 件、10 件固定は 0.931・0.329、20 件固定は 0.962・0.175、自由度ゼロ停止は 0.819・0.775・平均 4.7 件（完全一致 0.526 は K ＝正解数と同じ)。

- 2026-09-29(5)（自由度ゼロ停止は閉じた式集合を保証しない：報告と修論の言い過ぎを訂正）：本人の問い「入出力変数を含む自由度ゼロの数式群はどうやって見つける？上位から 1 つずつ選んで、必ずそうなるとは限らないよね」を受けて実装と保存済みの結果を確認した。set_aware_reranker.py の greedy_close は後戻りなしの貪欲選択で、足すたびに数の条件（出力変数がすべて現れ、入力変数以外の変数の数 $\leq$ 式の数）を見て、初めて満たした時点で止め、20 式で満たさなければ 20 式を返す。experiments/xd_dof/ のケース別結果では、閉じなかったのが設定 A 297/4,594 件・設定 B 295/2,432 件（乱数ごとの平均で 6.4%・11.7%）で、すべて合成ケース（9 割が 6 式以上)、98〜99% は正解式のどれかが第 1 段の候補 200 件に入っていなかった。閉じた件でも正解と完全一致は A 56%・B 42%。条件は数えるだけで、入力変数が現れること・式の独立性（別文献の同じ式を 2 本と数える)・未知数と式の割り当て・数値解は見ない。訂正：報告の Abstract を「上位から 1 式ずつ選び、選んだ式に出力変数がすべて現れ、入力変数以外の変数の数が式の数以下になった時点で選択を止める（20 式選んでも満たさなければ打ち切る)」に（510 字)。修論は Abstract（“returns a solvable set”)・序論（“a ranked, solvable equation set”、貢献 2、“answers are solvable”)・§3.1（closed の定義を数の条件＝必要条件と明記し、反例 $f_1(x), f_2(x), f_3(y, z)$ を追加、\label{sec:formulation} を付与)・§3.5（“closed by construction” を削除し、保証しないことと理由を書いた)・§6.5（閉じない割合と原因、閉じても解けるとは限らない、“closure guarantee” を撤回し [CombineEq] 型の組合せ探索と割り当ての確認を今後へ)・§6.9（限界を 8 つに)・第 7 章（今後の課題に 1 文)・データの章（合成ケースは各式が自分の出力を 1 つ持つので割り当てが成り立つ、と理由を明記)・付録（DoF-stop の上限 20 式）を直した。33 ページ（+1)・未定義参照なし・引用の初出順 39 件一致。報告 5 ページ、Overleaf 用 zip と配布用 PDF を更新。別の発見（未対応、本人に報告)：正解の式集合はすべて数の条件を満たす（2,838 件すべて正方）が、式と未知変数の完全マッチング（Hopcroft–Karp）がないものが 194 件あった。入出力をランダムに選び直した変種だけ（単一出典の random_io_from_models 103 件＝学習にも評価にも使わない拡張、出典横断の multisource_random_io 87 件と multisource_v3 4 件）で、入力変数だけの式が 1 本入り、残りの式が出力変数を 2 つ決める形になっている。出典横断の 91 件は設定 A の評価用 1,823 件の 5.0% にあたる。合成ケースは 1,000 件すべてマッチングあり。
- 2026-09-29(4)（修論第 2 章に、2 回目のコメントのうち当てはまる 3 件を反映)：本人指示「修論第 2 章も同じように直して」に対応した。RelatedWork.tex：(1) §2.1 の [ZhangEquiv]/[DAEEquiv] の書き分け（“two algorithms … the former … the latter calls two equation groups equivalent when they can be transformed into the same form”）を、同じ手順の 1 つの computer-algebra algorithm として 1 文にまとめた（片方の式群にだけ現れる変数を消去し、残った式を 1 つずつ比べ、見た目ではなく計算で判定する。第 1 章の書き方とそろえた。引用は番号順に \cite{DAEEquiv,ZhangEquiv})。(2) “Context should matter where variables cannot decide” を “Context is needed …” に（報告の

「だと考えている」→「である」に合わせた)。(3) §2.5 の “retrieving several equations as one answer is a different problem … calls for its own task definition” を削除し、“We found no formula-search benchmark that imposes this joint condition.” で止めた。K の決め方は第 2 章ですでに “can stop once the selected set closes as a system (Chapter 3)” と書いているので変更なし。`latexmk -gg` exit 0・32 ページ・未定義参照なし・引用の初出順と参考文献の並び(39 件)が一致。

- 2026-09-29(3)(ゼミ報告の改訂版への加藤先生の 2 回目のコメント 16 件に対応):本人指示「修正版にまたコメントしてくれた。それらに対応してください」(`20260929_進捗報告_kazuhiro_SK.pdf`)。注釈を PyMuPDF で取り出し、位置と本文を対応づけた。先生が見た PDF と手元の版を文字で比べると、本人が Overleaf で確認者を「加藤」にし、2.2 節(未回答だった質問への対応)を消していたので、手元の tex にも取り込んだ。日付は 9 月 29 日に。Abstract は先生の朱どおり箇条をやめて 1 段落にし(「本研究の目的は…である」「提案手法は 2 段階の処理から構成される」「提案手法を」、「本手法で」削除)、「上位 K 件を提示する(K はモデルを構成する数式の数)」への「事前にわからないはず。どうやって決めるのか」には、9/9 のゼミで報告した自由度ゼロ停止(K を与えずに止めても完全一致率は K を与えた場合と同じ 0.526、`experiments/dof_stop_stats.json`)を手法の文に書いて答えた。Abstract は 421 字 → 489 字(空白を除く)。2.1 節は「前回(8 月 31 日付の報告)」を「前回のゼミ(9 月 9 日)」に、「厳しい方の判定」を「判定し直した LLM の判定」にし、判定器の名前(Claude Opus 4.8 と Claude Fable 5.1)を書いた(608 組・一致率 88.0%・$\kappa = 0.72$・73 組中 71 組・0.254 → 0.198 は `experiments/judge_agreement_stats.json` と一致)。3.1 節の「[7] と [8] は何が違うのか」は、両論文の要旨を読み直すと手順が同じ(数式処理システムで片方の式群にだけ現れる変数を消去し、式を 1 つずつ比べる)で、[8] の「同じ形に変形できる」は等価の呼び方であって [7] の「同じ計算をするか」と別の基準ではなかった。違いは対象と評価([7] は MathML の式群を CSTR などの事例で示し Web アプリも作成、[8] は微分代数方程式系を対象に生成した 50 組ですべて正しく判定。[8] は [7] を引用していない)だけなので、1 文にまとめた。「だと考えている」は先生の朱どおり「である」に。3.5 節の「複数の式の検索は単一の式の検索と別の問題として設定する必要がある」は、断定できない(それを示すだけで論文になる)との指摘で削除した。`latexmk -gg` exit 0・5 ページ・未定義参照なし。配布用 PDF と Overleaf 用 zip(`docs/seminar_overleaf_20260929.zip`、単体で exit 0)を作った。修論第 2 章の同じ箇所は 09-29(4) で直した。
- 2026-09-29(2)(Zhang ら 2022 の中身を確認し、報告と修論の説明を直した):出版社が自動取得を拒み未確認だった Zhang, Kato, Kano (2022) “Equivalence Judgment of Equation Groups Representing Process Dynamics” の要旨・序論・各節の抜粋・結論を本人が提供した。mathematically equivalent という表現は使っておらず(加藤先生の注釈 25 の見立てどおり)、等価性は “not by their appearance but by the calculations they perform” で判定し、MathML の式群を SymPy(数式処理システム)に変換して共有しない変数を消去する、と確認した。報告 3.1 節に「どちらも数式処理システムで式を扱い、[7] は見た目ではなく同じ計算をするかで、[8] は同じ形に変形できるかで判定する」と書き、修論 §2.1 は computer algebra を両方に戻して ZhangEquiv の判定基準を書き足した(09-28 に未確認のため DAEEquiv だけに限っていた)。報告 5 ページ・修論 32 ページ、いずれも `latexmk -gg` exit 0・未定義参照なし。配布用 PDF・Overleaf 用 zip・対応表(注釈 25 の要確認を解除)を更新した。同論文の序論は、AutoPMoB を 5 つの作業(文書の検索、HTML への形式変換、情報の抽出、等価性の判定、モデルの再構成)として説明し、見た目に基づく数式の類似度(Zhong and Zanibbi 2019、Mansouri ら 2019)は等価性の判定には向かないと述べている(本人に報告、未反映)。
- 2026-09-29(ゼミ報告の Abstract を約 400 字に短縮し、考察を追加):本人指示「アブストラクトに考察を足して 400 字ほどに。実験の部分は『評価した結果、Recall@K … 0.521 から 0.743 に上がった』のように略してよい」に対応した。実験の箇条を「実験・結果・考察」とし、情報源単位の約 6:2:2 の分割・乱数 10 回・LLM 直接生成(48 ケースで 0.254)の文と、ケースの中身の括弧書きを削除し

た。Recall@K の短い定義（上位 K 件に入った正解式の割合）は、主な指標なので残した。考察は既報の結果（アブレーションと順列特徴量重要度）から 1 文：「並べ直しでは、主に変数の重複率に基づく特徴量が効き、文脈の近さはほとんど効かなかった」。手法の箇条の「2 段構えである」も削った。Abstract から消えた LLM の正式名称は本文の初出（1 節の 1 つめ）へ、$N_1 = 50$ は 3.1 節の被覆率の文へ移した（LLM の 48 ケースの説明は 3.4 節に残る）。Abstract は 558 字 → 422 字（英字も 1 字と数えた場合）。`latexmk -gg` exit 0・5 ページ・未定義参照なし。配布用 PDF と Overleaf 用 zip（`docs/seminar_overleaf_20260928.zip`）を作り直し、単体で exit 0 を確認。加藤先生のコメントと修正の対応表（Artifact、40 項目）も更新した。

- 2026-09-28(3)（修論第 2 章に、ゼミ報告への加藤先生のコメントのうち当てはまるものを反映）：本人指示「修論第 2 章も同じように直して」に対応した。`RelatedWork.tex`：(1) §2.1 の [ZhangEquiv][DAEEquiv] の “such as … mathematically equivalent” を削除し、2 本の対象（プロセスの動特性を表す式群／微分代数方程式系）を分けて書き、DAEEquiv の要旨どおり「同じ形に変形できるとき equivalent」と定義した（computer algebra は DAEEquiv だけに付けた。ZhangEquiv の要旨は出版社が自動取得を拒み未確認）。VARAT に正式名称を付けた。(2) §2.1 の式の組合せ法との違いを、入力（説明文と文脈も取る）と出力（要件を満たす組合せを全部ではなく、説明文に合う式を上位に並べ、閉じたら止まる）の違いに書き直した。「文脈で 11,146 式を絞れる」は撤回し、変数だけで被覆率 0.961、文脈を足して 0.967（§6.8）、並べ直しも変数の重なりが主（§6.3）、評価ケースが入出力変数を正解式の記号から取ることを書き、文脈が要る場面は未実証（§6.9）と明記した。(3) §2.2 の SR の定義（旧 “data from an unknown function”）と問題（旧「分野の知識を顧みない」）を、LLM-SR の要旨（組合せが膨大な仮説空間、知識で探索が効率化し out-of-domain で精度向上）で書き直した。SINDy・ALAMO に正式名称を付け（SINDy は arXiv 版本文、ALAMO は AIChE J. の要旨で確認）、ALAMO の説明を要旨どおり（少数のシミュレーションや実験から、できるだけ正確で簡潔なモデル）にした。「返す式はすべて出典を保つ」を文献由来の 94% に限定した。(4) §2.3 の第 1 段を first-stage retriever ／ first-stage retrieval と明記し、BERT に正式名称を付けた。(5) §2.4 の LLM の問題を「生成した式の正しさを出典で確かめられない。連立すると 1 式の誤りがつながる変数すべてに及ぶ」に書き直し、記法・経験式の推測を削除した。(6) §2.5 を比べ方（文字列・木構造 [Approach0]・埋め込み [Tangent-CFT]。本研究は変数の集合だけで比べる素朴な方法で、高度化は今後の課題）と検索対象（単一の式か、系を閉じる式の集合か。別の問題設定として定義が要る）の 2 観点に組み直し、NTCIR・ARQMath に正式名称を付けた。`main.tex` の参考文献に Tangent-CFT（ICTIR 2019、pp.11–18、CrossRef で照合）を追加し、数式検索の 4 件を新しい初出順に並べ替えた（39 件）。`Conclusion.tex` の今後の課題の 1 つめに「式どうしの比較に数式検索の木構造・埋め込み表現を借りられる」を 1 文追加した。`latexmk -gg` exit 0・32 ページ・未定義参照なし、`main.aux` の初出順と `bibitem` の順が 39 件すべて一致。ギャップ分析（W1）に追記した。
- 2026-09-28(2)（ゼミ進捗報告に加藤先生のコメント 52 件を反映し、2026 年度全体ゼミ資料テンプレートに移行）：先生が PDF の注釈機能で付けたコメント（強調 23・取消線 15・挿入 14）を PyMuPDF で抜き出し、本文の該当箇所と対応づけて反映した。**構成**：Overleaf の最新テンプレート（HSL_report_template、`jresume.cls` は手元と同一）に合わせ、Abstract（研究概要）・進捗と議論のポイント・前回の振り返り（計画の達成状況／未回答だった質問）・本文・今後の計画（期限つき）の順にした。10pt・余白 25mm、図表のキャプションは英語、文献は bib ファイル（`progress_report_2026-09-27_related_work.bib`、30 件）と natbib の `\citet` ／`\citep`（unsrtnat）。修論本体は全員が参照できないので、修論（章番号・参考文献数）への言及を消した。**Abstract**：目的を先生の文に差し替え、手法の箇条はデータ数を変数（N_1、K）で書き、細かい特徴量の説明を本文へ移した。実験の箇条にデータ（文献 329 件＋ LLM で作成した基礎式集 32 件、11,146 式、評価 1,823 ケース、情報源単位で約 6:2:2、乱数 10 通り）、古典的情報検索手法の中身（第 1 段と同じ採点

で全式を並べる)、LLM 評価の 48 件の意味（判定の費用のため一様に抜き出したケース数）を書いた。**内容の訂正**：(1) 式の組合せ法 [Kato and Kano 2025] との違いは「文脈で式を絞れる」では立たない（変数だけで被覆率 0.961、文脈を足して 0.967、並べ直しも変数の重複率の特徴量が主)。評価ケースが入出力変数を正解式と同じ記号で与えることも一因と書き、文脈が要る場面（要件を満たす組合せが複数ある、ユーザが文献と違う記号を使う）は未実証として、議論したい点と今後の計画に回した。(2) [6][7] は「数学的に等価」と書いていない（[7] の要旨は「同じ形に変形できるとき等価とよぶ」、Europe PMC の全文にも mathematically equivalent はない)。[6] は出版社のページが自動取得を拒むため題目の範囲で書いた。「など」をやめて対象（プロセスの動特性を表す式群、微分代数方程式系）を明記。(3) シンボリック回帰の定義（「未知の関数から得たデータ」）と問題（LLM-SR の要旨どおり、式の形の候補が膨大でデータだけでは探しにくい）を書き直した。SINDy の正式名称 Sparse Identification of Nonlinear Dynamics は arXiv 版本文で確認。(4) LLM の問題を「生成した式の正しさを根拠で確かめられない。連立すると誤りが広がる」に書き直し、記法・経験式の推測を削除。(5) 同日の修論 §4.1 の訂正（基礎式集 670 式＝ 6.0% は LLM が生成し出典の文書がない）に合わせ、「どの式にも出典がある」を「文献由来の式（94.0%）には出典がある」に改めた（先生の朱「モデルを構成する数式にはすべて出典がある」も同様)。(6) 数式検索を本研究の一部（式どうしの比較）と位置づけ、検索手法（文字列・木構造・埋め込み。Tangent-CFT を文献に追加）と検索対象の 2 観点で整理した。**用語**：クエリ、式周辺の文章、変数の重複率、同義性の判定。「・」は 3 つ以上の並列に限り、英語論文の著者名は英語で書き、略語は初出で正式名称を付けた。**前回の振り返り**：8/31 報告の計画 4 項目の状況を書き、LLM 等価判定の第 2 判定器の結果（608 組・一致率 88.0%・$\kappa = 0.72$・厳しい判定で 0.254 → 0.198）を初めて報告した。BM25 と埋め込みベクトル検索の結果の報告は、先生の指示で保留し、実験設定の妥当性の確認を優先する。書誌は CrossRef で DOI・巻・号・頁を照合した（BM25 は原刊行の Vol.3(4) を維持)。`latexmk -gg` exit 0・5 ページ・未定義参照なし・はみ出しなし。配布用 PDF を更新し、Overleaf 用 zip `docs/seminar_overleaf_20260928.zip`（tex・bib・cls・latexmkrc）を新規作成、展開し直して単体で exit 0 を確認。修論第 2 章にも同じ問題（数学的に等価・記法と経験式・文脈で絞れる・シンボリック回帰の問題）が残るが、今回は報告書だけを直した。

- 2026-09-28（ケース族の記述の訂正：「文献掲載」の定義の誤り・出典の内訳・出典横断の定義)：本人の疑問「文献掲載 92 件の正解式数の平均が 1.34 しかないのが気になる。92 件の論文をまとめて送ってほしい」に対応して出典を調べ、次の誤りを確認した（いずれも 2026-08-09 の用語改訂時に生成コードを確かめずに書いた記述が元)。(1) **文献掲載（as-published）の定義が事実と異なる**：92 件は 92 本の論文ではなく、実在の文書 11 件に由来する 31 件と、LLM が生成した基礎式集（`handbook_*`）に由来する 61 件である。正解集合は、`generate_training_cases.py` が Gemini 2.5 Pro に式 ID・出典・分野名・変数記号だけのカタログ（式の本文と文献は渡さない）を与えて「必要十分かつ最小」の組を選ばせ、のちに `filter_solvable_cases.py`（入力を与えたとき未知数＝式数）で絞ったもので、92 件中 67 件が 1 式。例：`core_020_v1` は Marlin の教科書が 5 式 (14.1)–(14.5) で「DOF $= 5 - 5 = 0$」と書く系から (14.4) の 1 式だけを正解にしている。(2) **文献横断（cross-document）の定義も不正確**：731 件中 192 件は基礎式集どうしの組で文献を含まない。また開発時に Claude が書いた 33 組とその入出力派生 198 件の計 231 件のうち 189 件は、式どうしが変数を 1 つも共有しない（「共有変数でつなぐ」が成り立つのは `multisource_v3` の 500 件：共有変数 2 個以上)。(3) **§4.1 の出典の内訳**：「PDF 328 種・基礎式集 33 種 709 式」は技術報告 ORNL/SPR-2018/864（39 式）を基礎式集に数えていた。正しくは文書 329 件 10,476 式（94.0%）＋基礎式集 32 件 670 式（すべて Gemini 2.5 Pro が生成)。(4) 第 1 章の「表記を正規化した」は §4.1（正規化なし）と矛盾し、第 2 章の「返す式はすべて監査できる文献にある」「LLM の役割は抽出と合成ケースの説明文のみ」は (1)(3) と矛盾していた。8/09 の改訂理由「文献掲載・文献横断のケースも微分代数系である」も、単一出典では 92 件中 2 件しか当てはまらない。**訂正**：族名を as-published → **single-source**（単一出典)、cross-document

→ **cross-source**（出典横断）に改め、表 2 の列名を Documents spanned → Sources spanned にした（値は元から source_id 単位なので不変）。修論は `Dataset.tex`（§4.1 の内訳、§4.2 の族の定義を書き直し、表 2、構成上の性質に「入出力変数は正解式の変数記号から取る（4 族とも 100%）」を追加、§4.4 の document → source）、`Experiment.tex`、`Introduction.tex`（内訳と族の説明を訂正し「表記の正規化」を削除）、`RelatedWork.tex`（出所の主張を「94% が文献由来」に、LLM の役割に基礎式集の生成・単一出典の正解集合・出典横断の 33 組を追加）、`Method.tex`・`Conclusion.tex`（source document → source）、`ResultsAndDiscussion.tex`（§6.2 の出典数、限界の第 1 項に単一出典の正解集合が LLM の選択であることを追加、第 5 項の理由を「入出力変数を正解式の記号から取る」に）を直した。図 `fig_dataset`・`fig_characteristic` はラベルだけ変えて再生成した（数値は不変）。08-31 の進捗報告（ltjsarticle 版・jresume 版）も内訳・呼称・表 2・出典単位の分割・限界の理由を同様に直し、表の後に単一出典と出典横断の作り方を追記した（8 ページ・7 ページを維持）。`docs/`**論文の主張**`_2026-08-09.md` の用語表・改訂理由・Q5（合成ケースの式は 1,000 件中 939 件が文献由来のみ）も訂正した。性能・件数・平均などの数値は一切変わらない。`latexmk -gg` exit 0・32 ページ（本文 24 → 25 ページ）・未定義参照なし。出典の確認資料（92 件の一覧 CSV・抜粋 PDF 31 件・中小文献の全文 8 点）は本人に送付済み（リポジトリ外）。

- 2026-09-27(4)（ゼミ進捗報告の今後の課題から「修論の仕上げ」を削除）：本人指摘「『修論の仕上げ』と書いてるけど、修論はまだ完成していないのでは」に対応し、今後の課題の 3 項目めを「修論の執筆を続ける。まだ骨子の段階の付録（ハイパーパラメータの感度・合成ケースの実例・LLM への指示文）を書き、各章を推敲する」に改めた（提出直前の手順である「書式を規定に戻す」「博士課程の学生に確認してもらう」は外した）。確認した修論の状態：第 1–7 章は本文の初稿あり（第 3–5 章 08-09、第 6 章 08-30、第 2 章 08-31 ／ 09-27 改訂、第 1・7 章と要旨 09-07）、付録は骨子のまま（211 語）、B2（感度）・W4（付録）・W5（書式の復元）・W6（D チェック）は未着手。`latexmk` exit 0・5 ページ、配布用 PDF と Overleaf 用 zip を作り直し単体で exit 0 を確認。
- 2026-09-27(3)（ゼミ進捗報告から「加藤先生のご指摘」の明記を削除）：本人指示「今回の進捗の 3. 先行研究との違いの整理に、加藤先生からの指摘と言明する必要ない」に対応。§2 の 3 項目めを「特にシンボリック回帰と研究室の式の組合せ法との違いとして、本研究が数値データではなく文献由来の式に基づいてモデルを組み立て、その際に文脈を扱える点を明確にし、修論にも反映した」に改め、同じ趣旨の §8 まとめの「加藤先生にご指摘いただいたとおり」も削った（本文に加藤先生の名前はなくなった。`.tex` 冒頭のコメントの経緯記録は残す）。`latexmk` exit 0・5 ページ。配布用 PDF と Overleaf 用 zip を作り直し、zip は展開し直して単体で exit 0 を確認。
- 2026-09-27(2)（ゼミ進捗報告の「研究全貌」を書き直し）：本人指摘「研究全貌の内容がおかしい。ターゲットは化学プロセスだけじゃなく物理モデル。この研究も加藤先生の研究の中核ではない。前回の『前回ゼミレビュー』の方が正しかった」に対応。§1 を、前回までの「前回ゼミレビュー」と同じ構成（研究の目的 1 文＋手法の骨格＋到達点の 2 項目、空白を除き 325 字）に書き直した：目的は「科学文献から数式を集めておき、作りたい物理モデルの説明文と入出力変数を入力すると、そのモデルを構成するのに必要な数式の集合を提示する」、手法は 2 段構え（第 1 段＝説明文と式の周りの文章（文脈）の近さと入出力変数の重なり、第 2 段＝ 10 特徴量の MLP、うち 3 個が集合の特徴量）、到達点は Recall@K 0.521 → 0.743 と LLM 直接生成 0.254（48 件）。化学プロセスへの限定・「本研究は AutoPMoB の中核」の記述・CSTR の例を削除し、図 1 のキャプションも「段階を担う」→「段階に位置する」に弱めた。LLM・Recall@K・集合の特徴量を §1 で定義したので、§2・§5 の重複定義を削った。`latexmk` exit 0・5 ページ・未定義参照なし。配布用 PDF と Overleaf 用 zip を作り直し、zip は展開し直して単体で exit 0 を確認。メモリの研究全貌の指針（誤りの元）も訂正した。
- 2026-09-27（ゼミ進捗報告の改訂と修論第 2 章への加藤先生の指摘 2 点の反映）：本人指示 3 点に対応した。(1)「修論の話は進捗報告に入れない」は 08-09 報告だけの指示で、今回は**修論の進捗報告**とし

て書く。(2) 最初の節を「前回ゼミレビュー」から**「研究全貌」**（約 300 字で研究のイメージを掴んでもらう。以後の全報告の形式）に変える。(3) 加藤先生の指摘 2 点—— **シンボリック回帰との違い**（文脈を扱える／数値からの物理モデル導出ではなく文献由来の数式ベースのモデリング／ SR の skeleton 候補にも使える）と **Kato & Kano (CACE 2025) との違い**（文脈を扱える）——を踏まえて報告を審査し直す。**報告**：`docs/ゼミ latex テンプレ/progress_report_2026-09-27_related_work.tex`（09-26 版を改名・全面改訂、5 ページ）。題目を「修士論文の進捗：関連研究と本研究の位置付け」に、§1 を研究全貌（空白を除き 332 字：課題・AutoPMoB・入出力・CSTR の 3 式・2 段構えと文脈）に、§2 を修論の進捗 3 項目（第 2 章の執筆／参考文献 4 → 38 件・うち先行研究 29 件／加藤先生の 2 点の反映）にした。§3 の式の組合せ法との違いを「文脈を扱える」に書き換え、根拠に既報の数値のみ（文章類似度だけで全 11,146 式を並べた AUC 0.913、第 1 段の被覆率 変数のみ 0.961 → 文章 3 割 0.967）を置いた（最終 Recall@K の差 0.7799 対 0.7762 は未検定のため使わない）。**§4 シンボリック回帰を新設**：Schmidt & Lipson（Science 2009）・SINDy・AI Feynman（Sci. Adv. 2020）・ALAMO・LLM-SR を、各原典のアブストラクトで確認した範囲で記述（LLM-SR 要旨の「従来の SR は主にデータだけから式を取り出し、分野の事前知識を顧みないことが多い」「LLM が skeleton を提案し係数をデータに当てはめる」を根拠に使用）。審査で見つけた誤り 4 件も直した：§6 の「前節の LLM-SR」（LLM-SR は §4）、研究全貌の主語の欠落、「361 文献」（実際は論文 PDF 328 ＋基礎式集 33 なので「文献など 361 件」）、AutoPMoB を「作業の自動化」と書いた誤り（構築器の名前）。引用 29 件＝修論第 2 章の先行研究 29 件と同一（キー名のみ違う）を機械照合、`\cite` 初出順＝`\bibitem` 順。`latexmk` exit 0・5 ページ・未定義参照なし・Overfull なし。配布用 PDF `docs/progress_report_2026-09-27_related_work.pdf` と Overleaf 用 zip `docs/seminar_overleaf_20260927.zip`（3 エントリ、展開し直して単体で exit 0・5 ページ）を作り直し、09-26 版の PDF・zip は削除した。**修論**：`RelatedWork.tex` を改訂した。§2.1 の相違の段落を「文脈を扱える」に書き換え（数値は第 6 章 §6.6 への参照で済ませる）、研究室の既往 3 件（Nagayama ら NLDB 2024・Zhang ら CACE 49・Kato & Kano CACE 52）を追加、**§2.2 Equation Discovery from Numerical Data を新設**（旧 §2.1 の SINDy・ALAMO を移し、Schmidt & Lipson・AI Feynman・LLM-SR を加えて、相違＝文献由来の式・文脈・skeleton 候補）、§2.4（LLM）から LLM-SR を §2.2 へ移した。あわせて §2.3 の「集合特徴は MMR と逆符号で報酬を与える」を「二つの関係を測る」に弱めた（学習した重みの符号は未確認のため）。第 1 章 P8 の章構成の文に equation discovery from numerical data を追加。参考文献は 33 → 38 件、`main.aux` の初出順に機械的に並べ替え完全一致を確認。`latexmk -gg` exit 0・31 ページ・未定義参照なし（Overfull 4 件は既存：付録の目次 3・データ章の表 1）。メモリも更新（進捗報告の読み手ルールの訂正・見本の §1 を研究全貌に・加藤先生の 2 点を新規メモ）。

- 2026-09-26（ゼミ進捗報告「先行研究の調査と本研究の位置付け」を作成）：本人指示「W1（Related Work の本文化＋文献収集）の成果を次のゼミで報告したい」に対応し、**`docs/ゼミ latex テンプレ/progress_report_2026-09-26_related_work.tex`**（jresume・platex → dvipdfmx・4 ページ）を新規作成した。本人ルール「修論の話は進捗報告に入れない」に従い、章を書いた事実ではなく**研究上の知見（本研究の位置付け・新しさ）**として構成した：§1 前回ゼミ（08-31 全体版）レビュー／§2 今回の進捗 3 項目／§3 物理モデルの自動構築（研究室の AutoPMoB 系＋データからの式発見 SINDy・ALAMO）／§4 情報検索と再順位付け（MMR との対比）／§5 LLM による直接生成（出典の有無）／§6 数式検索（単式 vs 解ける集合）／§7 まとめ（分野 × 返すもの × 違いの表 1）と今後の課題。図 1 は tikz で本文内に描いた AutoPMoB の 4 段階と研究室の先行研究の対応（本研究を「モデルの構築」段階に青字で配置、外部画像なし）。文献は 27 件（修論収載の 24 件＋研究室の既往 3 件：Zhang ら CACE 49・Kato & Kano CACE 52・Nagayama ら NLDB 2024。いずれも 2026-08-31 に書誌を検証済み）を本文の初出順に並べ、`\cite` の初出順と `\bibitem` 順の完全一致を機械的に確認した。**最も近い先行研究＝加藤・加納 (2025, Comput. Chem. Eng.)** の記述は、OpenAlex 収録の原文アブス

トラクト（本日取得）の範囲に限った（冗長・中間的・矛盾する式の混在／入出力の完全性・整合性など 4 要件による式の組合せとして定式化／漏れなく（perfect recall）かつ無駄な計算を省くアルゴリズム／8 事例で全ての目的モデルを構築）。修論 W1 の「3 点を併せ持つ研究はない」式の包括的な新規性主張は、同論文が集合・出典・式間の関係をすべて扱うため**報告では採らず**、分野ごとの違い（同法＝要件による漏れのない組合せ／本研究＝大規模 DB からの学習による選択）として書き、両者の連携（本研究で絞った式を同法に渡す）を今後の課題に置いた。数値は前回報告済みの値のみ（baseline 0.521・本手法 0.743・LLM 0.254（48 件）・集合特徴 0.693 → 0.743）。未報告の A2（BM25・E5）と B1（第 2 判定器）の結果は載せず、A2 は「次回報告」と記した。略語は初出で展開（MLP・LLM・TF-IDF・MMR・ALAMO・ARQMath・NTCIR（公式サイトで正式名称を確認）・AutoPMoB）。SINDy は正式名称を原典で確認できなかったため展開せず内容で説明した。`latexmk` exit 0・4 ページ・未定義参照なし・Overfull なし。配布用 PDF を `docs/progress_report_2026-09-26_related_work.pdf` にコピーし、Overleaf 用の自己完結 zip `docs/seminar_overleaf_20260926.zip`（`.tex` ＋ `jresume.cls` ＋ `latexmkrc` の 3 エントリ、図は tikz のため `figure/` 不要）を作成、展開し直して単体で `latexmk` exit 0・4 ページを確認した（zip は従来どおり非追跡）。Overleaf 側は Compiler を **LaTeX** にする。

- 2026-09-07(5)（B1: LLM 等価判定の検証——第 2 判定器 Claude Fable 5.1 との一致度）：LLM 直接生成の採点が判定器 claude-opus-4-8 の等価判定に依存する点（§6.9 第 4 項）を検証するため、本人指定の第 2 判定器 `claude-fable-5-1` に、第 1 判定器と**同じ 147 ケース・同じ順序・同じプロンプト**（`evaluate_llm_equiv.py` から `build_prompt()` を切り出して共有、生成式は上位 12 件）で 608 ペア（設定 A 183・B 279・全体 146）を再判定させた（`judge_second_opinion.py`、adaptive thinking、fallbacks は使わない＝拒否時に第 1 判定器へ落ちるのを防ぐ、拒否 0・欠測 0、全呼び出し `claude-fable-5-1` で応答、入力 206,296・出力 50,033 トークン、約 4.6 USD、3 ラベル並列で 7.5 分）。一致度は `analyze_judge_agreement.py`（pytest 4 本、Cohen's κ は sklearn と照合）で算出し `experiments/judge_agreement_stats.json` に保存した。**結果（608 ペア）**：「等価な生成式あり」ラベルの一致率 0.880・$\kappa = 0.721$、「上位 K 件内に等価式あり」（Recall@K の判定単位）の一致率 0.910・$\kappa = 0.722$、番号まで同じ 0.875。不一致 73 ペアのうち 71 は「Opus 4.8 は等価と認め Fable 5.1 は認めない」で**第 2 判定器のほうが厳しい**。第 2 判定器のもとでの LLM 直接生成は Recall@K 設定 A 0.198（第 1 判定器 0.254）・B 0.150（0.226）・全体 0.251（0.300）、coverage 0.338 / 0.234 / 0.463（0.419 / 0.343 / 0.567）。判定器で水準は動くが、提案手法 0.743 / 0.689 との差の結論は変わらない（むしろ広がる＝表 3 の第 1 判定器の値は LLM 側に寛大な値）。判断規則（$\kappa \geq 0.6$ だが Recall@K の差 > 0.03）に従い、修論に両判定器の値を併記した：§5.2 に検証の段落（608 ペア・一致率・κ・不一致の向き）、§6.1 の LLM 段落に第 2 判定器の値、表 3 キャプションに「第 2 判定器では 0.198 / 0.150」、§6.9 第 4 項を「第 2 判定器で照合したが人手検証はなし」に、付録 A.1 に判定器 2 種の行、参考文献に Claude Opus 4.8（発表ページ）と Claude Fable 5.1（製品ページ、いずれも実在を確認）を追加し初出順（Sonnet 4.5 → Opus 4.8 → Fable 5.1 → E5）を維持。第 1 章 P6 の「a second model judges」は「a separate model」に修正。あわせて、第 1 章の本文化（W2）で VARAT が ProcessBERT より先に初出するようになっていたため参考文献の 6・7 番を入れ替え、全 33 件が aux の `\citation` 順と完全一致することを機械的に再確認した。`latexmk -gg` exit 0・30 ページ・未定義参照なし。人手検証（本人が 20–30 ペアを判定）は未実施＝残す。設計書 `docs/superpowers/specs/2026-09-07-b1-second-judge-design.md`。
- 2026-09-07(4)（W3: 修論第 7 章 Conclusion の本文化と Abstract の書き直し）：第 7 章を骨子（貢献 3 点＋将来 3 方向）から 3 段落に本文化した：(1) 何をしたか（課題の定式化・2 段階＋集合特徴・学習版逐次選択・DoF-stop）、(2) 何が分かったか＝貢献 3 点（可解性を保証したベンチマーク／ Recall@K 0.521→0.743・0.466→0.689、BM25・E5 の最良混合 $\leq$ 0.602/0.555、LLM 0.23–0.30 ／機構＝変数の重なり・話題は第 1 段の後で冗長、介入 2 回＝学習版逐次 +0.056（X$\geq$8）・第 1 段再設計 0.780、DoF-stop

閉包率 94%/88% vs oracle 87%/78%)、(3) 限界からの今後の課題 3 方向 (scheduled sampling と「式がどの変数を決めるか」の新特徴／ DB 外の式・異なる記法を含む実タスクでの検証／ AutoPMoB パイプラインへの統合＝抽出・等価判定の下流、シミュレータの上流)。「第 1 段の再設計」は A1 で実施済みのため将来課題から外し介入として記載（ギャップ分析 W3 の指示)。**Abstract** を初稿から全面書き直し (3 段落・約 300 語: 問題と課題／手法とデータ／結果・機構・介入・自己停止)。閉包率の表記は第 1 章・第 7 章・Abstract で「94% in the mixed setting and 88% in the synthesized-only setting (oracle 87% / 78%)」に統一（第 1 章 P6 の「0.88 and 0.94」は設定 B→A 順で紛らわしかったため設定名付きに修正)。数値は第 6 章と同じ一次データ（`% source:` 付き)。`latexmk -gg` exit 0・30 ページ・未定義参照なし・Overfull は既存 1 件のみ。これで第 1–7 章と Abstract の全てが本文化された。設計書 `docs/superpowers/specs/2026-09-07-w3-conclusion-abstract-design.md`。残: B1 (LLM 判定の検証)・B2 (K_REF 感度)・W4 (付録転記)・W5 (圧縮設定復元)・W6 (D チェック)。

- 2026-09-07(3) (W2: 修論第 1 章 Introduction の本文化と図 1 の新規作成)：骨子 P1–P8 を 8 段落に本文化した (P1 物理モデルの役割と構築の負担／ P2 AutoPMoB の 4 段階と要素技術／ P3 本研究の課題と「集合として評価しなければならない理由」を CSTR の 3 式 (物質収支 ODE・反応速度式 $r_A = kC_A$・アレニウスの式 $k = A\exp(-E/RT)$、未知数 C_A, r_A, k の 3 つ＝自由度ゼロ) で具体化／ P4 手法 (第 1 段の混合スコア・第 2 段の 10 特徴 MLP と集合特徴 3 つの言葉での定義・学習版逐次選択・DoF-stop)／ P5 データと層化分割／ P6 結果 (古典 IR +0.22、BM25・E5 の最良混合 $\leq 0.602/0.555$、LLM 0.23–0.30、機構＝変数の重なり、介入 2 回、DoF-stop の閉包率)／ P7 貢献 3 点／ P8 章構成)。骨子の常套句 "play an important role" は具体 (設計・制御・デジタルツイン) に置換し、略語は初出で展開 (CSTR・ODE・MLP・LLM・DoF)、数値は全て `experiments/*.json` と照合して `% source:` を付けた。**図 1** (`figures/fig_autopmob_overview.pdf/.png`) を `generate_figures_thesis.py` の `overview()` で新規作成：(a) AutoPMoB の 4 段階 (Documents → Extraction → Equivalence judgment → **Equation-set retrieval (this study)** → Physical model)、(b) 本研究の入出力 (Query ＝説明文＋入出力変数 → 11,146 式・361 source の DB → 文献別に色分けした CSTR の 3 式を共有変数 r_A・k の辺で結び「3 equations, 3 unknowns: DoF 0」)。辺は共有変数に厳密対応 (加藤ルール B1/B3)、τ は持ち込まない。pytest 2 本 (生成物とラベル・辺ラベルの検証)。`latexmk -gg` exit 0・30 ページ (28 → 30)・未定義参照なし・Overfull は既存 1 件のみ。図は章 2 ページ目の上部に配置された (圧縮設定解除後に再確認)。設計書 `docs/superpowers/specs/2026-09-07-w2-introduction-design.md`。残: W3 (第 7 章と Abstract)。
- 2026-09-07(2) (A2: 外部ベースラインの補強—— BM25・密ベクトル検索 E5 を修論の評価枠で測定)：ギャップ分析 A2 に対応し、古典 IR (TF-IDF 0.7 ＋変数 Jaccard 0.3、全 DB 順位付け、学習なし) の文章スコアを BM25 (自前実装、$k_1 = 1.5$, $b = 0.75$, 単語ユニグラム, Lucene 形式の非負 IDF) と E5 (`intfloat/e5-base-v2`、平均プーリング＋ L2 正規化、接頭辞 query:/passage:、Hugging Face から 438 MB 取得) に差し替え、設定 A・B × 層化分割 10 seed で Recall@K_correct / MAP / Recall@20 を測った (`external_baselines.py`・`analyze_external_baselines.py`・`run_external_baselines.sh`、pytest 7 本)。分割・指標は `set_aware_reranker.py` / `evaluate_multi_eq.py` の関数を流用し、TF-IDF・重み $(0.7, 0.3)$ が `strat_A/B.json` の baseline の per-seed 値を完全に再現することを回帰テストで確認した。BM25 のスコアは非有界、E5 のコサインは狭い帯域に集中するため、クエリごとに min–max 正規化してから変数項と混合し、混合重みは $w_{\mathrm{t}} \in \{1, 0.9, \ldots, 0.1, 0.05, 0\}$ の 12 点を掃引した (テスト分割で最良を選ぶ＝外部側に有利な比較)。**結果**：文章のみでは全スコアラーが弱く (設定 A: TF-IDF 0.120 / BM25 0.150 / E5 0.146、設定 B: 0.153 / 0.164 / 0.178)、変数 Jaccard 単独の 0.603 / 0.541 が支配的であった。最良混合 (いずれも $w_{\mathrm{t}} = 0.1$) でも BM25 0.601 / 0.555、E5 0.602 / 0.544 (説明文のみのクエリなら 0.598 / 0.547) で、古典 IR の最良混合 0.607 / 0.559 と 0.02 以内に並び、変数

単独を上回る幅は最大 +0.004（A）／ +0.018（B）にとどまる。提案手法 0.743 / 0.689 は最良の BM25・E5 混合を設定 A で +0.142 / +0.141、設定 B で +0.134 / +0.145 上回り、全 10 seed で勝つ（Wilcoxon $p = 0.00195$、$d_z = 5.7$ / 6.2（A）、9.6 / 13.4（B））。第 1 段の候補窓としても BM25・E5 混合の被覆率は $k = 50$ で最大 0.965 / 0.961 と w30-70 の 0.967 を超えず、密ベクトルへの第 1 段差し替えは天井を上げない（A1 との統合は不要と判断）。固定重み $(0.7, 0.3)$ では min–max 正規化した文章項の実効重みが生コサインより大きく、BM25 0.247 / E5 0.428（A）に落ちる。「同じ重み」の意味が正規化に依存するため、表では最良混合で比較した。**修論への反映**：§5.2 に外部ベースライン 2 種の定義（内部 1・外部 3 に修正）、§6.1 の表 `tab:overall` に設定ごと BM25・E5 の 2 行追加と段落 1 本（文章のみ／最良混合／ $(0.7, 0.3)$ ／被覆率／検定）、図 `fig:comparison` のキャプションを 3 手法名で明示、§6.9 Limitations に第 7 項（既製エンコーダ・未微調整）、付録 A.1 に BM25・E5 の設定 3 行、参考文献に E5（Wang ら, arXiv:2212.03533、31 件目、初出順を維持）。`latexmk -gg` exit 0・28 ページ・未定義引用なし。第 1・7 章（骨子）には W2/W3 で反映するためのメモを残した。データ：`experiments/external_baselines_A.json / _B.json`（60 ラベル × per-seed）、`external_baselines_coverage.json`（被覆率 $k = 10$–400）、`external_baselines_stats.json`（対応あり検定）。E5 の埋め込みキャッシュ `experiments/embeddings/` は再生成可能なので非追跡（.gitignore）。設計書 `docs/superpowers/specs/2026-09-07-a2-external-baselines-design.md`。

- 2026-09-07（リポジトリ整理：未コミット作業の取り込みと .gitignore の成文化）：本人指示「全ての修正を commit して」に対応し 3 コミットに整理した。① `chore(repo)`: これまで名前指定ステージで避けてきた除外対象（`.cursor/` 156 件・experiments のログ／ done マーカー／スモーク退避／シード別生データ `xd*`・`xg*`・`xs1*`・ゼミテンプレ配下の図と LaTeX 中間物・参照用の先輩修論ソース `thesis/TexSource/`・`unified_equations.bak.json`）を.gitignore に成文化し、作業ツリーで削除済みだった `CLAUDE.md` の削除を確定（作文ルール等の内容は Claude memory に移管済み）。② `feat(analysis)`: 未コミットだった `judge_llm_equivalence.py`（公平等価採点・判定 Opus 4.8）・`diagnose_comp_coh.py` ＋ `run_comp_coh_subsets.sh`（gComp/gCoh 冗長性診断）・`analyze_feature_x_difficulty.py` のベクター PDF 出力対応・`experiments/ablation_x_difficulty.json`（難易度クロスの統合データ 7.2MB、図の再現に必要）を追跡。③ `docs(seminar)`: ゼミテンプレのビルド基盤（`jresume.cls`・`latexmkrc`・`main.tex`・`reference.bib`・`Fig.eps`・旧報告 tex 2 点）と完成報告 PDF 2 点（06-14 jresume 版 7p・08-09 改訂版 4p）を追跡。テンプレ配下 `figure/` は従来どおり非追跡（Overleaf zip で配布・再生成可能）。
- 2026-08-31（W1: 修論第 2 章 Related Work の本文化と文献 4 件 → 30 件の拡充）：ギャップ分析（`docs/論文化ギャップ分析_2026-08-30.md`）の W1 に対応。骨子 4 節（AutoPMoB 要素技術／ IR と再ランク／ LLM 直接生成／数式検索）を本文化し、各節末に本研究との相違を明示した。文献は 4 軸の並列ウェブ検証で収集し、**全 30 件を一次ページ（CrossRef・arXiv・ACL Anthology・出版社・NTCIR proceedings 等）で書誌確認**（作文ルール B3 遵守・捏造ゼロ）。収穫の柱は加納研 AutoPMoB 系 6 件：CSTR Case Study (CACE **49**, 2022)・Prototype (CACE **53**, 2024)・ProcessBERT (IFAC-PapersOnLine **55**, 2022；**金上修論の引用を公刊版に差し替え**)・VARAT (J. Chem. Eng. Japan **58**, 2025)・DAE 等価判定 (Sci. Rep. **13**, 2023)・**式結合 (Comput. Chem. Eng. 200, 2025) ＝最近接の先行研究**で、§2.1 に「4 要件による結合＝規則固定」vs「本研究＝選択の学習＋閉包での自己停止」の対比を書いた。§2.2 は MMR との**逆符号**の対比（多様性でなく可解性）、§2.3 は出所（provenance）と推論時 LLM 不使用、§2.4 は単式検索 vs 連立閉包の集合、で締めた。あわせて第 1 章 P1/P2（digital twin レビュー・AutoPMoB 概念論文）、第 3 章（Hangos & Cameron・Salton・Manning・Deerwester・Liu）、第 4 章（Gemini 2.5, arXiv:2507.06261）、第 5 章（生成 Claude Sonnet 4.5 の web 引用と判定 Claude Opus 4.8 のモデル名を本文に明記、R-precision に Manning）へ引用を挿入。thebibliography は引用初出順に整列し、`main.aux` の `\citation` 順と完全一致を確

認。ビルド exit 0・28 ページ（25 → 28）・未定義引用なし（Overfull 5 件は既存の付録目次・表由来）。検証済みだが件数規範（20〜30 件）のため見送った候補 11 件（Nougat・Tangent-CFT・MathBERT・AI Feynman・ChemCrow・NTCIR-10・Sentence-BERT・Nagayama et al. NLDB 2024・Zhang et al. CACE 49・Kato & Kano CACE 52・Gemini 1.0）はギャップ分析 W1 の完了記録に書誌付きで残した（即追加可能）。

- 2026-08-31（進捗報告用の日本語全体版を作成・LLM 直接生成の帰属誤りを訂正）：本人指示「進捗報告用に Methods と Results and Discussion の日本語バージョンを」に対応し、`docs/progress_report_2026-08-31_methods_results.tex/.pdf`（8 ページ・lualatex/ltjsarticle・である調）を新規作成した。構成＝ §1 位置づけ／ §2 手法（定式化・第 1 段・10 特徴量表（加藤先生確認済みの表を流用）・逐次選択・自由度ゼロ停止）／ §3 データと評価（ケース 3 種の表・新旧呼称の対応「オリジナル→文献掲載、DAE →合成」を 1 文で明記）／ §4 全体比較／ §5 内訳と PFI ／ §6 逐次選択／ §7 自由度ゼロ停止／ §8 話題の近さ（**打ち消し合い＝相殺を初めて報告**）／ §9 誤りの所在（61.8%→k=200 で逆転・誤りの 2 型）／ §10 第 1 段の作り直し（A1 実験）／ §11 限界／ §12 まとめ。§6–§9 はゼミ報告未掲載だった結果、§10 は新規実験。図は既存の日本語版 `fig_pfi_importance` と、新規生成した `docs/figures/fig_stage1_redesign_ja`（`analyze_stage1_sweep.py --report-figure` を新設。英語版と同レイアウト・箱ひげ＋被覆率曲線）。あわせて**重大な帰属誤りを発見・訂正**：修論 §5.2 等の「LLM 直接生成は生成器と判定器が同一モデル（claude-opus-4-8）ゆえ LLM 有利で保守的」という記載は誤りで、**正しくは生成 claude-sonnet-4-5-20250929・判定 claude-opus-4-8 の別モデル**（commit `5fbcf65` のコミットメッセージ「生成は Sonnet 4.5」で確定。predictions JSON にはモデル欄が無く、`% source` コメントが現行のスクリプト定数を写して誤記していた）。修論 4 箇所（§5.2 の段落・§5.4 出典コメント・§6.1・表 3 キャプション・§6.9 限界）と `docs/論文の主張_2026-08-09.md`（過大主張回避の表・想定質問 Q4）を「判定は別の上位モデル／人手検証は未実施」に書き換えた。2026-08-30 に私が表 3 キャプションを「another LLM →同一モデル」へ直した修正は誤りだった（元の記載が正しかった）ため復元に相当する。修論再ビルド 25 ページ・未解決参照なし。日本語版の LLM 記述は訂正後の事実で執筆。**追記（本人指摘への対応）**：「最良重みが分かったなら最初から 0.3/0.7 と書けばよく、§10 は不要では」との指摘を受け、日本語版の旧 §10 を §9 に統合した（節題「誤りの過半は第 1 段で生まれる — 作り直すと 0.743→0.780」。誤り分析 → 介入 → 回復を 1 節で完結）。最初から新重みを書けない理由（§4–§8 の全数値が旧重みの系で測られている／重みの根拠が誤り分析そのもの）は本文に 1 文で明記し、§1 に「§4–§8 は現行重みでの結果」の断りを追加。今後の課題の先頭に「既定重みを 0.3/0.7 に切り替えて全実験を張り直す」を置き、ギャップ分析に **A3（re-basing、要相談）**として仕様化した（再実行は `--stage1-w-*` で機械的だが、選択効果の相関 −0.404 や誤り分解 61.8% など旧重み依存の数値が変わり §6.6 一部と §6.7 の書き換えを伴うため、切り替えは先生と合意の上で）。さらに §2.5 冒頭の「並べ直しは何本返すかを利用者が知っている前提に立つ」の 1 文が分かりにくいとの指摘を受け、①並べ直しの出力は順位であり集合にするには採る本数が要る、②評価では正解式数 K を教えている、③実際の利用者は K を知らない、の 3 文に展開して書き直した（当初③に付けた構造の説明と CSTR の例は本人指示で削除）。あわせて §2.4 に逐次選択の 1 本目の選び方（固定参照での第 2 段採点の 1 位。第 1 段の 1 位とは限らない）を明記し、未定義の内輪語「静的な並べ直し」を「前節の並べ直し」に置換した。最後に本人依頼で**ゼミテンプレ（jresume）版**を作成：`docs/ゼミ latex テンプレ/progress_report_2026-08-31_methods_results.tex/.pdf`（7 ページ、platex→dvipdfmx、latexmk exit 0・未解決参照なし）。図はベクター PDF（`figure/fig_pfi_importance.pdf` を最新版に更新、`fig_stage1_redesign_ja.pdf` を新規同梱）。Overleaf 用の自己完結 zip（.tex ＋ jresume.cls ＋ latexmkrc ＋ figure/*.pdf、Compiler=LaTeX で上げる）を `~/Desktop/seminar_overleaf_2026-08-31.zip` に作成した。

- 2026-08-30(2)（A1 実験：第 1 段の変数寄り再設計で §6.7 の予測を検証、修論 §6.8 を新設）：ギャップ分析の最優先項目 A1 を実装・実行・本文化まで完了した。(1) **実装（TDD、11 テスト）**：`stage1()` に混合重み引数 `w_text`/`w_var`（既定 0.7/0.3 ＝完全後方互換）を追加し、`set_aware_reranker.py` に `--stage1-w-text`/`--stage1-w-var` を新設して**訓練時候補生成・評価時候補生成・baseline 全 DB 順位付けの 3 箇所**へ配線（重み変更が訓練の負例分布にも一貫して効く）。既定重みでの再実行が正典 `experiments/xd/reranker-10S__42.json` を per-case 423 件まで完全再現することを確認してから、w70-30 参照には既存正典（`xd/`・`strat_A.json`・`xg_A/train`）を再利用した。(2) **被覆率スイープ（`analyze_stage1_weights.py`）**：$k = 50$ で w70-30 0.9203 → w50-50 0.9608 ／ **w30-70 0.9671（全 k で最良）** ／ w00-100 0.9610。端点 2 つは既存実測（blend 0.9203・jaccard 単独 0.9610）と一致（検算）。**最良は予測した「変数のみ」でなく中間重み**＝文章項は低重みなら限界的に有効。(3) **再訓練実験（`run_stage1_weights.sh`, 3 重み× baseline/reranker-10S × 10 seed・設定 A・$k = 50$・層化）**：reranker-10S は 0.7429 → w50-50 0.7664 ／ **w30-70 0.7799**（+0.037, **Wilcoxon** $p = 0.00195$, $d_z = 2.4$, **全 10 seed 改善）** ／ w00-100 0.7762。**4 重みの被覆率順序と最終指標順序が完全一致**。最難端 X≥8 で +0.094 ＝§6.7 が特定したボトルネック（落ちるケースは被覆 0.83）で回復が最大。baseline 自体も 0.521 →約 0.60（学習なしの取り分）で、再ランカーの上乗せ +0.18 は同重みでも維持。上限増分 +0.047 の約 8 割が最終指標に到達。(4) **最強構成でも検証（`run_stage1_weights_k200.sh`, 学習版 greedy・$k = 200$・30-70・10 seed）**：0.7968 → **0.8098**（+0.013, **Wilcoxon** $p = 0.0098$, $d_z = 1.1$, **9/10 seed）**、X≥8 で +0.035（$p = 0.00195$）。$k = 200$ では被覆率差が +0.015 に縮むが、その 88% が最終指標に変換＝再ランカーは第 1 段が入れた正解候補をほぼ使い切る。(5) **修論への反映**：§6.8「Second Intervention: A Variable-weighted First Stage」を新設（Limitations は §6.9 へ）。§6.7 末尾の「次の介入実験に指定する」を「§6.8 が実行し確認した」に差し替え、**予測→介入→回復の第 2 の弧**（第 1 の弧＝逐次選択 §6.4）として記述。重み選択への多重比較批判に対し「3 つの変数寄り重みすべてが全 seed で有意＝結論は最良重みの選択に依存しない」を明記。図 `fig_stage1_redesign`（(a) 重み別被覆率曲線・(b) $k = 50$ の箱ひげ、英語）を新規生成。ビルド 25 ページ・未解決参照なし。統計は `experiments/stage1_weight_coverage.json`・`stage1_weight_stats.json`（per-seed 付き、集計 `analyze_stage1_sweep.py`）、per-seed 生データは `experiments/xs1/`・`xs1_k200/`（非追跡）。ギャップ分析の A1 を完了打ち消しにし、次の最優先を W1（Related Work ＋文献収集）に更新。
- 2026-08-30（修論 第 6 章 Results and Discussion の本文化・図の英語化・論文化ギャップ分析）：本人指示「いま得られている結果を論文に掲載できるレベルで Methods と Results and Discussion の形に文書化し、発表に欠けている実験・考察を洗い出す」に対応。(1) **第 6 章の本文化**：骨子 P1–P9 を §6.1–§6.8 の段落形式に全面書き換え（`ResultsAndDiscussion.tex`）。執筆時に全記載値を `experiments/*.json` と再照合し、各段落に `% source:` コメントで一次データを残した。(2) **骨子に無かった追加**：§6.3 に向上 +0.222 の 3 段分解（学習のみ 0.521 → 0.601 ／ 7 特徴 → 0.693（うち特化度単独 +0.090、Wilcoxon $p = 0.00195$）／集合特徴 → 0.743）を `experiments/xd/` から明記。§6.6 に**分野一致（集合版）の相殺分析**を新設：向きが合う 1,169 ケースで置換により −0.012、逆向き 414 ケースで +0.034（Mann–Whitney $p = 1.3 \times 10^{-8}$）、加重和 −0.0002 が全体 PFI ≈ 0 を再現（`pfi_profile_stats.json`、ケース集約済みで疑似反復なし）。§6.7 に $k = 200$ の誤り分解（stage1 由来 61.8%→28.4% で主因が並べ替えに逆転、`case_outcomes_seed42_k200.json`）を追記。§6.8 に教師強制の限界を追加し §3.4 の前方参照を回収。(3) **記述の裏取りで得た per-case 検証**：DoF 停止の完全一致は oracle-K と全 7,026 レコードで不一致 0（平均の偶然一致でないことを確認）。サイズ誤差は設定 B で 545/545 全件が過大方向（早期停止 0）、設定 A は 4,594 件中 1 件のみ早期＝「ほぼ一方向」と正確に記載（当初の「全て過大」は設定 A で誤りと判明し訂正）。(4) **図の英語化と用語統一**：`fig_topic_diagnosis` 英語版を新規生成（`diagnose_topic_features.py` に `--lang en` を追加。パネル (b) に全 DB AUC の菱形を重畳し「全 DB では強いが候補内で崩

れる」を 1 枚で示す。JSON 再計算はバイト一致で決定性を再確認)。`fig_pfi` は日本語版の流用だったため `generate_figures_thesis.py` に英語版 `pfi()` を新設。凡例の旧用語（DAE only ／ Original ／ Multi-source）を改訂用語（synthesized only ／ As-published ／ Cross-document）へ統一（`fig_dataset`・`fig_method_comparison`・`fig_greedy_3way`・`fig_dof_stop`)。表 3 キャプションの誤記（判定器は「別の LLM」でなく生成器と同一モデル）を訂正。(5) **ビルド**：`latexmk -gg main.tex` exit 0、24 ページ、未解決参照・未定義引用なし。第 3–5 章は曖昧表現の走査（常套句・無根拠の有意）で問題なし。(6) **ギャップ分析**：`docs/論文化ギャップ分析_2026-08-30.md` を新規作成。欠けている実験を優先度付きで仕様化（A1: 第 1 段の変数寄り再設計＝ §6.7 の宣言の回収、A2: BM25・密ベクトルの外部ベースライン、B1: LLM 判定の人手検証、B2: K_REF 感度)、執筆残（第 1・2・7 章、参考文献 4 件 →25–40 件、付録転記、圧縮設定復元、D 課程チェック)、投稿判断事項（投稿先・データ公開範囲）を整理し、着手順を提案。

- 2026-08-16（加藤先生の 7 コメント対応：進捗報告の分かりにくい箇所を修正）：加藤先生が `progress_report_2026-08-09_SK.pdf` に付けた 7 件の注釈（PyMuPDF で抽出，著者 kato）に対応して報告書と較正実験を修正した．(1)「AUC の説明が意味不明」→ 正解式 1 本と不正解式 1 本の全組で値を比べ正解式が大きい組の割合と数える，という手順の形に書き直した．(2)「入出力だけ変えた組が 1.000 は当たり前では」→ そのとおりなので「説明文を変えていないので当然で，同じ説明文が 1 になる確認にとどまる」と明記し，内容同一の証拠は言い換えの組（0.944）であると位置づけ直した．図の行名にも（説明文は同じ）を付けた．(3)「無作為でなく無関係な 2 ケースと比較すべき／異なるケースで類似度が高くなるのはどんなとき？」→ `calibrate_similarity_scale.py` に**無関係な組**（出典文献が重ならず同じ物理モデルにも由来しない組，n=191,722）を実装して基準を置き換えた（中央値 0.213，無作為 0.218 とほぼ同じ．JSON には両方保存)．高類似の無関係な組は 3.9%（> 0.5）で，(i) 同種の装置・現象を扱う組（CSTR どうし 0.70)，(ii) 文献横断ケースの説明文が同じ雛形で文面がほぼ同じ組（最大 0.999）と特定し，本文に 1 項目を追加した．(4)(5)「意味の近さ 1 つの AUC って何？」→「意味の近さという特徴量 1 つだけで正解式を並べたときの AUC」の形に展開．(6)「類似度 0.437 って何？」→ 数値がすべて AUC であることを各所で明記（「文章類似度の AUC は 0.437」)．表 1 のキャプションに「列は不正解式の範囲の違い」を追記．(7)「乱数とシャッフルの関係・手順が分からない」→ §4 方法を手順の形に書き直した（対象特徴量だけ候補式間で入れ替え他は元のまま／入れ替え方を変えて 20 回平均／さらにデータ分割と訓練をやり直した乱数 10 通りのモデルで全体を繰り返し平均と標準偏差)．4 ページ維持・pytest 51 passed．その後の本人指示で，(2) に対応して書いた「入出力だけ変えた組の 1.000 は説明文を変えていないので当然」の 2 文は**不要**として削除し，代わりに結果の 1 項目めに**比較の基準に使う「無関係な組」の説明**（出典文献が重ならず，同じ物理モデルにも由来しない組）を置いた（方法 (a) と合わせて 2 箇所で定義し，数値のそばで基準が分かるようにした)．さらに「説明文を同じ雛形から作ったため文面がほぼ同じ組」の意味が伝わらないとの指摘を受け，実データを数えて具体的に書き直した：`generate_multisource_v3.py` の `context_template` が示すとおり，文献横断ケースの説明文は定型文に共有変数名を差し込んで生成している．設定 A の文献横断 731 件を，変数名を伏せて数えると**定型文は 57 通りしかなく**（最多は熱交換器と制御付き反応器の各 45 件)，正解式が別文献の別ケースでも変数名以外は説明文が同一という組ができる．これが最大 0.999 の正体であり，ケースの作り方に由来しベクトルの性質ではない旨を明記した．**ただしこの「57 通りの定型文」という書き方は不正確だった**：本人の問い「文献横断ケースの正解式は 2 つだけか」を機に数え直すと，731 件の説明文は **2 系統**である．`multisource_v3` 500 件が定型文 24 通り（テンプレートに共有変数名を差し込む，最多 45 件)，`multisource_original` 33 件＋`multisource_random_io` 198 件＝ 231 件は手書きの説明文 33 通りを入出力変数だけ変えた派生が再利用したもの（合計 57 通り)．後者は「変数名を差し込む」仕組みではないので，内訳を分けて書き直した．なお正解式数は 731 件中 710 件（97.1%）が 2 式，21 件が 3 式（すべて `multisource_original`

系）である．最終的に本人判断で**この (ii) の項目自体を削除**し，「無関係な組でも類似度が高くなる」の説明を (i) 同種の装置・現象を扱う組（CSTR どうしで 0.70）だけに絞った．削除して差し支えないことは数値で確認済み：無関係な組 191,662 件のうち cos $>$ 0.5 は 7,340 件で，その内訳は話題が実際に近い組が大半（説明文が同一の組は **335 件＝ 4.6%** にすぎない）．定型文由来の組は最大値 0.999 を作るが**典型ではない**ので，(i) だけを残しても誤導にならない．最後に本人要望で **10 特徴量の意味と計算方法をまとめた表**を §1 に追加した（表 1)。定義は実装（`set_aware_reranker.py` の `compute_features_with_set` と `compute_set_aware_features`）と照合済み：基本 7 個は文章類似度（TF-IDF コサイン）・意味の近さ（256 次元 SVD のコサイン）・分野の一致（分野名が説明文に現れれば 1)・変数の一致度 $|V_q \cap V_e|/|V_q \cup V_e|$・入力変数の被覆・出力変数の被覆・式の特化度 $|V_q \cap V_e|/|V_e|$，集合 3 個は補完性 $|(V_q \cap V_e) \setminus V_S|/|V_q|$・一貫性 $|V_e \cap V_S|/|V_e|$・分野の一致（集合版)，参照集合は第 1 段の上位 `K_REF`= 5 件である．表の追加で一度 5 ページになったため，本文中の重複した定義の括弧書きを削除し，§4 方法・§5・今後の課題を圧縮し，図 2 を `0.88` → `0.80` 幅にして 4 ページに戻した．さらに本人の指摘「文章類似度の重みは 0.7 のはずでは」を受けて**重みの表記を実装に合わせた**：第 1 段は `two_stage_query_conditioned.py` の `stage1()` で `argsort(-(0.7*ts + 0.3*vs))[:k]` と計算しており，重みは 0.7 と 0.3 である．§3 の「文章類似度を重み 7 で使って」は**誤り**なので「重み 0.7 を掛けて」に修正し，§1 の「7 対 3 の重みで足した」も比なのか値なのか紛れるため「それぞれ 0.7 と 0.3 の重みを掛けて足した」に改めた．最後に本人の問い「『訓練し直さないので直接測れる』とはどういう意味か」に答えて §4 の当該文を書き換えた：**訓練し直すと他の特徴量が肩代わりできる**ためアブレーションは「その特徴量が無くても課題が解けるか（必要性)」を，PFI はモデルを固定するので「今あるモデルがその特徴量をどれだけ当てにしているか（依存)」を測る，という対比を本文に明示した（式の特化度で PFI +0.617 対 アブレーション +0.090 が食い違う理由)．アブレーション値は `experiments/xd/` で再確認（土台 A 0.601 → ＋式の特化度 0.691)．**加藤先生に再確認いただくため注釈版 PDF を作成**：`docs/annotate_revisions_2026-08-16.py`（PyMuPDF）で修正 10 箇所をハイライトし，右余白に「ご指摘・要望 → 修正内容と理由」の付箋を付けた（`progress_report_2026-08-09_topic_revised_annotated.pdf`)．その後の本人指示で**加藤先生のご指摘で直した 7 箇所だけ**に絞り，付箋の中身も出所や見出し記号を外して**一言の修正理由のみ**にした（本人の見直しによる修正＝重み 0.7・特徴量の表・「訓練し直さない」の書き換えはハイライトもコメントも付けない)。最終形はハイライト 14・付箋 7．最後に**ゼミ資料テンプレ（jresume）版に移植**した：`docs/ゼミ latex テンプレ/progress_report_2026-08-09_topic.tex`．ltjsarticle 版から本文をそのまま移し，(1) プリアンブルを `jresume`（`a4j,dvipdfmx,11pt`）に差し替え，(2) タイトルを `\markright` ＋ `center` ＋ `flushright` のテンプレ書式に，(3) 図の参照を `figures/*.png` から `figure/*.pdf`（ベクター）に変更した．図 2 点は `docs/figures/` から **ゼミ latex テンプレ/figure/** へコピー済み．`platex` → `dvipdfmx` でエラー 0・4 ページ・内容は ltjsarticle 版と同一．注釈（ハイライト）は入れていない．さらに Overleaf へ直接アップロードできる自己完結 zip を作成した：`docs/seminar_overleaf_20260809.zip`（`figure/` の PDF 2 点＋ `jresume.cls` ＋`.tex` ＋ `latexmkrc` の 6 エントリ。2026-08-31 版 `seminar_overleaf_20260831.zip` と同じ構成)。**展開し直して単体で検証済み**：`latexmk` が exit 0・エラー 0・A4 4 ページで通ることを確認した。zip 自体は従来どおり git 非追跡とする。Overleaf 側は Upload Project 後に Compiler を **LaTeX**（pdfLaTeX 不可）にする．

- 2026-08-11(進捗報告の書き直し:報告内容を **2 点に絞る**):`docs/progress_report_2026-08-09_topic.tex` を全面的に書き直した．報告する内容を (1) 意味の近さは SVD 空間で十分な区別を作れているが第 2 段では効かない，(2) PFI で各特徴量の重要度を測った，の 2 点に限定し，正解・不正解のケース分析（誤りの内訳・誤りの 2 型・被覆率）と PFI のケース別分解（分野一致度の相殺）は次回に回して本文から外した．実験 1 は較正の箱ひげ図（`fig_similarity_scale`）を主図に据え，候補内

AUC は表に集約した（全 DB 0.950 対 候補 50 件 0.594）．実験 2 は 10 特徴量と 2 群の PFI 図（`fig_pfi_importance`）を主図とした（変数の重なり 6 特徴量 +0.678，話題の近さ 4 特徴量 +0.006，$p = 0.10$）．図の凡例・軸ラベルを報告書の用語に統一（テキスト類似→文章類似度，入出力 Jaccard →変数の一致度，意味類似 (SVD) →意味の近さ，特化度→式の特化度 等．プログラム識別子を排除）し，`generate_pfi_figure.py` と `calibrate_similarity_scale.py` の図サイズと表題を調整した．意味の近さ・式の特化度・分野の一致・分野の一致（集合版）の定義を本文に加え，自己完結させた．その後，本人指摘「図の文字が小さすぎる」を受けて**両図の文字を 1.5 倍**にした（両スクリプトに倍率定数 `FS` を導入し，目盛り・軸ラベル・凡例・値ラベル・表題の全指定に適用）．図の外形寸法は 1% 以内で不変なので，報告書に同じ幅で貼ったときの実寸がそのまま 1.5 倍になる．PFI 図は文字拡大で (b) の縦軸ラベルが枠外へはみ出したため，ラベルを「Recall@K の低下」に短縮し左右のパネル幅比を 2.3:1 から 2.0:1 に変えた．さらに本人指示で実験 2 の節題を「各特徴量の重要度を PFI（Permutation Feature Importance）方法で測る」に変更し，略語 PFI を §2 の初出で導入して §4 本文の重複した正式名称を外した（英語名が節題で改行分断されないよう `\mbox` で囲んだ）．

- 2026-08-09（PFI のケース別依存プロファイル：**分離度仮説の不成立**と分野一致度の**相殺**の実証）：順列特徴量重要度（PFI，Permutation Feature Importance）を集約値からケース単位に降ろし，ある特徴量を置換したとき正解から不正解へ転じるケースを同定して属性で特徴づける分析を追加した（`analyze_pfi.py` を拡張し per-case 収集を統合，`analyze_pfi_profile.py` を新規作成）．設定 A・10 シード・20 置換で per-case 50,534 記録を出力．集約 `pfi_results.json` は既存版と**バイト単位で同一**であり，集約 PFI と乱数系列の保持を実証した．**当初仮説（分離度 sep が大きいケースほど反転しやすい）は成立しなかった**．sep（正解式と不正解式の特徴値の差）と期待 Recall 低下の Spearman 順位相関は補完性 $\rho = -0.011$（$p = 0.78$，非有意），一貫性 $\rho = +0.105$（$p = 0.005$），分野一致度 $\rho = +0.243$（$p = 2.9 \times 10^{-11}$，$n = 727$ ケース）で，**効かないとしてきた分野一致度が最も強い単調性を示した**．補完性の依存ケースは sep がむしろ低い（標準化平均差 −0.31）．代わりに頑健に現れたのは**系の大きさ**で，依存ケースは正解式数・入力変数数・出力変数数・出典数がいずれも大きい（一貫性の正解式数で標準化平均差 +0.49）．分野一致度の集約 PFI が ≈ 0 なのは寄与が無いためではなく**相殺**による：全ケース母集団で分離時（sep > 0）の平均低下 +0.012 に対し逆分離時（sep < 0）は −0.034 と符号が反転する（Mann–Whitney $p = 1.3 \times 10^{-8}$）．すなわち置換は分離時には性能を下げ，逆分離時には上げる．なお解析途上で**疑似反復**（同一ケースが複数シードのテストに出現し，2,067 記録が実は 727 ケース，平均 2.84 回）を独立観測として検定していた誤りを発見し，ケース単位に集約してから検定するよう修正した．修正前は補完性が $p = 0.009$ と有意に見えていたが，修正後は $p = 0.78$ で有意性は消えた．また依存群と頑健群に同一ケースが重複していた（補完性で 62.5％）問題も同時に解消した．結果：`experiments/pfi_per_case.json`，`experiments/pfi_profile_stats.json`，`docs/figures/fig_pfi_dependence_profile.png`．
- 2026-06-03（Stage2 reranker 強化の試行と**負の結果**）：厳格 Recall@K_correct の向上を狙い，`set_aware_reranker.py` に (1) hard negative マイニング（`--hard-neg`：現在スコア上位の negative を採用），(2) listwise 損失（`--loss listwise`：multi-positive softmax CE），(3) 出力補完特徴 gOutNov（候補が参照集合に無い出力変数を固有に覆う割合）と新モード `reranker-10S2`（gDom→gOutNov）・`reranker-11S`（set-aware 4 特徴量）を追加した（既存 reranker-10S は不変・後方互換）．DAE・3 シードで比較した結果，**全構成が Recall@K_correct = 0.771–0.776（差 ≤ 0.006）でシード標準偏差 ±0.07 の内側**に収まり，hard negative・listwise・gOutNov のいずれも有意な改善を生まなかった．Recall@20 は 0.91 で候補自体は上位に揃うため，律速は候補を**独立にスコアする**現行 MLP が**集合としての選択**を表現できない点にあると診断．次の本質的改善は候補集合の相互作用を陽に扱う**構造的拡張**（候補集合への注意機構／ GNN，逐次的集合構成）と結論した．結果：`experiments/stage2_{feat,hardneg,listwise}.json`．**（追記：greedy 逐次選択は**

成功）上記の負の結果を受け，診断「集合選択が律速」を直接検証するため `set_aware_reranker.py` に**推論時 greedy 集合構築**（`--greedy`：1 式選ぶごとに set-aware 特徴量を既選択集合を参照に再計算して次を選ぶ）と関数 `greedy_order`，`compute_set_aware_features` の `ref_indices` 引数を追加した（学習済みモデルをそのまま使用，新規学習不要）．DAE・3 シードで **reranker-10S/10S2/11S すべてが** +0.015–0.018 **一貫して改善**（`stage2_greedy.json`）．効いた 2 レバー（top-k 拡大と greedy）を結合し，reranker-10S・5 シードで **Recall@K_correct** 0.745 → 0.792 **(**+0.048**，**+6.4%**)，Recall@20** 0.887 → 0.953 を達成（`cap_ref.json`, `cap_greedy200.json`）．損失・負例の改良では届かなかった厳格指標を「集合としての選択」が動かすことを実証．図 H（`docs/figures/fig_v6_stage2.png`）を追加し v6 §精度向上を更新．次は greedy の学習段階導入（teacher forcing）が課題．**（追記 2：near-miss 分析）**「漏れた正解がどれだけ上位に詰まっているか」を測る指標を新設．`evaluate_multi_eq.py` の `case_metrics` が各正解式の順位 `ranks` を返すようにし，`generate_figures_v6.py` の `fig_nearmiss` で**回復曲線 Recall@**$(K+m)$（正解数 K に余裕 m を足した Recall，m=0 が Recall@K_correct）と**超過順位（順位 $-K$）の累積分布**を作図（候補 200 件予算で統一）．DAE・top-200・3 シードで baseline ／ reranker-10S ／ +greedy を比較した結果，**reranker・greedy は漏れた正解の 45–47% を上位 3 件以内に詰める**（baseline 18%），$K+3$ で Recall ≈ 0.9．本手法の誤りの大半が near-miss であり，残る far-miss（漏れの 12–13% が候補 200 件外）が Stage1 強化の余地と判明．図 I（`fig_v6_nearmiss.png`）を v6 §精度向上に追加．データ：`experiments/ranks_std.json`, `experiments/ranks_greedy.json`．**（追記 3：ゼミ報告 2026-06-14 作成）**前回ゼミ（2026-05-19，3,244 式・1,338 ケース・MRR 0.963）からの進捗をまとめた新ゼミ報告 `docs/progress_report_2026-06-14_seminar.tex/.pdf`（7 ページ，前回と同形式，日付 2026-06-14）を作成．構成：前回レビュー → データ大規模化（11,146 式・2,838 ケース）→ 評価指標精緻化（Recall@K_correct）→ 評価結果（難易度勾配の 3 者比較・文献横断 LLM 比較・議論点 (1) への回答=仮説 B・頑健性）→ 精度向上（greedy・near-miss）→ 今後．前回の議論点 (1)「関連性の低い式も精度向上に機能するか」へは，フル DB vs 限定 DB（+0.048，$p = 0.044$）で**回答**した．Ultracode の検証 workflow（9 エージェント並列）で全数値を実験 JSON に敵対的照合し **86 件 MATCH**，指摘 23 件（用語の和文説明・文献横断 LLM 比較の補完・Recall@20 の表記統一・記号 K と top-k の区別等）を修正した．

- 2026-06-02（進捗報告 v6 作成：データ拡大・難易度勾配・仮説 B 再検定・頑健性・LLM 同一条件比較の統合）：前回 v5（3,244 式・1,107 ケース）以降の Phase 3–5 成果と外部比較を**差分版の進捗報告 v6** としてまとめ，`docs/progress_report_2026-06-02_v6.tex`（lualatex / ltjsarticle, 8 ページ）を新規作成．主な内容：(1) データ規模 11,146 式・2,838 ケース（DAE 1,000 件含む），(2) 難易度勾配で本手法の Recall@K_correct 優位が標準 +0.127 → +DAE +0.210 → DAE のみ +0.217 と拡大，(3) 仮説 B 再検定でフル DB が Recall@K_correct で有意（+0.048，$p = 0.044$, Cohen's $d = 0.74$ 中；MRR_first では飽和し差なし）と判明し v5 の暫定結論「DB 規模の影響なし」を訂正，(4) ハイパラ sweep 13 設定で Recall@K_correct レンジ 0.0094（シード間 std の約 1/10）と頑健性を確認，(5) **外部ベースライン（LLM 直接生成）との同一条件比較を現行 11,146 式 DB で整合．LLM 比較の再評価手順**：LLM 評価済みの単一ソース 29 件・複数ソース 20 件サブセットに対し，`set_aware_reranker.py --modes baseline,reranker-10S --seeds 10 --save-per-case` で自然 5 variant（original / context_paraphrased / random_io_from_models / multisource_original / multisource_random_io）学習・per-case 出力を生成し（`experiments/phase6_full_percase.json`），各対象ケースを**テスト分割に入ったシードのみ**で集計（リーク防止の held-out 評価）する `aggregate_llm_subset_v6.py` を新規作成（出力 `experiments/phase6_llm_subset_comparison.json`）．結果（Recall@K_correct）：単一ソースは baseline 0.982 ／ reranker-10S 0.975 がいずれも LLM 0.707 を圧倒，複数ソースは baseline

0.575 < LLM 0.842 < **reranker-10S** 0.942 となり，古典 IR 単独では複数文献の組合せに不足し Set-aware リランカーが本質的に必要であることを同一条件で実証．なお和文太字は明朝に太字ウェイトが無いため `BoldFont` を角ゴシックに設定した．**（同日追記）**v5 の構成を参考に v6 を**図駆動で簡潔化**（8 → 5 ページ；目次・重複表を図に統合）し，機械学習研究者視点の図 4 点を新規作成（`generate_figures_v6.py` → `docs/figures/fig_v6_{dataset,gradient,impact,llm}.png`）：(A) データセット内訳・難易度分布，(B) 難易度勾配〔中核〕，(C) 正解式数別の改善＋指標飽和（仮説 B）の対比，(D) LLM 三者比較．各図はシード分散のエラーバー・差分注記・統一配色（baseline 灰／本手法 青／ LLM 橙）で「1 図 1 主張」とした．**（同日追記 2：LLM 難ケース比較・精度向上・アブレーション）**加藤先生の「LLM で解けるなら不要では」「図 B に LLM も並べよ」とのご指摘を受け，`evaluate_llm_dae.py` を新規作成し DAE 難ケースで LLM 直接生成（Claude）を評価．`generate_figures_v6.py` の図 B を **3 者比較**（baseline ／ LLM ／ reranker-10S）に更新し，**全難易度で reranker > baseline > LLM**（最難 DAE で LLM 0.264 に対し本手法 0.699, 約 2.6 倍）を示した．精度向上として Stage1 の retrieval 天井を診断（DAE Recall@50 = 0.86, 高 X で取りこぼし X=10 で 0.68）し，候補数 top-k を 50 → 200 に拡大して reranker-10S を再評価，**実用 Recall@20 を** 0.912 → 0.968 **に改善**した（`topk_dae_{50,100,200}.json`；厳格 Recall@K_correct は +0.02 で，Stage2 の順位付けが律速と判明）．Set-aware 3 特徴量のアブレーション（`ablation_setaware.json`）で **gComp・gCoh が主力，gDom は寄与薄**と判明．図 E（シード分散）・F（アブレーション）・G（精度向上）を追加し v6 は 7 ページに．画像内タイトルの図番号は LaTeX キャプション採番へ一本化した．

- 2026-06-01（Phase 5 完了：reranker ハイパーパラメータ sweep と頑健性の確認）：`set_aware_reranker.py` に `--hidden-dim`, `--margin`, `--batch-size`, `--n-neg-samples`, `--weight-decay` を追加し，sweep 実行用 `run_phase5_sweep.py`（config を子プロセスで並列実行・結果集約）と分析用 `analyze_phase5_sweep.py`（ランキング・パラメータ感度・best 抽出，複数 sweep を `--config-glob` で横断結合可）を新規作成．GPU サーバ初期化補助 `setup_gpu_server.sh`（rsync + Docker コンテナ + 依存導入 + CUDA 確認 + sweep キックオフ）も作成．**実行構成**：固定軸 `reranker-10S` + 10 seed + 訓練データ（original + multisource_v3 + dae_X*），探索軸 lr ∈ {1e-4, 3e-4, 1e-3, 3e-3, 1e-2}，hidden_dim ∈ {64, 128, 256}，epochs ∈ {20, 40}，margin ∈ {0.1, 0.3}．計 13 config を評価（A100×4 サーバ 8 config + ローカル lr sweep 5 config）．**結果（主指標 Recall@K_correct）**：全 13 config が 0.7321–0.7415 に収まり，**config 間レンジ** 0.0094 **は seed 間標準偏差** 0.1008 **の約 1/10**．すなわち探索したいずれのハイパーパラメータ（lr を 100 倍振っても，hidden_dim・epochs・margin を変えても）**統計的に有意な差を生まない**．best config は lr=3e-4, hidden_dim=64, epochs=40, margin=0.1（R@K_c = 0.7415）だが既定値（lr=1e-3, hidden=64, epochs=15）との差は誤差範囲．**結論**：reranker-10S の強さはハイパーパラメータの微調整に依存せず**頑健**であり，「脆弱なチューニング由来の見かけ上の性能」ではないことを定量的に確認した（査読対策として重要）．**運用上の知見**：本手法は MLP が小さく **GPU 加速の恩恵がほぼ無い CPU-bound** 処理であり，共有 GPU サーバ（過負荷時 load 53/16 コア）より**非競合のローカル実行の方が予測可能**．長時間 CPU ジョブは `caffeinate -i` でスリープ抑止が必須．保存先：`experiments/phase5_sweep/`（config 個別 JSON），`experiments/phase5_best.json`.
- 2026-05-29（Phase 4 完了：特性別性能分析 + 仮説 B 再検定）：**(1) 仮説 B（Full DB vs Narrow DB の本手法 MRR 差）を 3 指標で再検定．**旧結果は `MRR_first` のみで $p = 0.78$（n.s.）と「DB 規模の影響なし」と結論したが，`MRR_first` は天井 1.0 付近で飽和する指標であった．新指標 `Recall@K_correct`（K = 正解式数 n_{correct}，R-Precision と同義）で同検定を行うと，**Full DB** 0.9229 vs **Narrow DB** 0.8749，差 +0.0480（paired t: $t = 2.34$, $p = 0.044$；Wilcoxon $p = 0.037$；Cohen's $d = 0.74$ medium）と**中程度効果の有意差**を確認．**MAP** も 0.953 → 0.931

($p = 0.096$, $d = 0.59$ medium）と境界域で同方向の差．これにより「サチった指標が差を隠していた」ことが明確になり，DB 拡張の効果は実際にはあるが評価指標の選択によって見え方が変わる，という重要な知見を得た．保存先：`experiments/phase4_hypothesis_b_test.json`．**(2) 特性別 (stratified) 性能分析．** `set_aware_reranker.py` に `--save-per-case` フラグを追加して各ケースの評価結果を JSON にダンプする機能を実装し，10 seed・1,592 ケース・1,223 ユニーク（original + multisource_v3 + dae_X1..X10）について `baseline` vs `reranker-10S` を 4 軸（正解式数 n_{correct}，横断ソース数 n_{sources}，入力変数数 n_{input}，出力変数数 n_{output}）で層別化．主要結果（差は `Recall@K_correct`）：$n_{\text{correct}} = 1$ では +0.02 と差なしだが，$n_{\text{correct}} = 2$ で +0.21，$= 3$ で +0.26，5-10 で +0.24 と**複数式ケースで大幅改善**．n_{input} = 1-3 では −0.02（baseline がすでに 0.92）で本手法不要，11+ で +0.25（baseline 0.45 → reranker 0.70）．**Recall@K_correct** は MRR_first の天井問題を解消し，提案手法の真の改善幅（baseline 0.526 → reranker 0.735，+0.21）を露わにした．`analyze_phase4_characteristic.py` と `analyze_phase4.py` を新規作成・更新．保存先：`experiments/phase4_characteristic_analysis.json`，図 `docs/figures/fig_phase4_stratified.png`.

- 2026-05-28（Phase 3 完了：制約付き実験 A/B + DAE データセット）：**(1) DAE 訓練ケース 1,000 件追加**．`generate_dae_cases.py` を新規作成し，Anthropic API（Claude Sonnet 4.5）で $X \in \{1, 2, \ldots, 10\}$ の各値について 100 件ずつ生成（合計 1,000 件，`variant_type = dae_X{N}`）．アルゴリズム：(i) ランダムに ODE を 1 本選択し正解集合の初期種とする，(ii) その微分変数を出力初期値に追加，(iii) 同一ソース内の変数共有式を優先的に正解集合に追加，(iv) $|$ 正解集合 $| = X$ になるまで反復，(v) $X > 1$ の場合は追加された各式の代表変数を出力に加えて自由度 0 を保証，(vi) 残り変数を入力とし context を Claude API で生成．最終訓練ケース数：1,838 → 2,838．**(2) Phase 3 制約付き実験**．`set_aware_reranker.py` に `--variants` フィルタ（プレフィックスマッチ対応）と `--output` オプションを追加．実験 A（`original + multisource_v3 + dae_X*`）と B（`dae_X*` のみ）を 10 seed で実行．結果：A で baseline MRR_first 0.8024 → reranker 0.9232（+0.121），B で baseline 0.7806 → reranker 0.9057（+0.125）．**DAE のみ**に絞ると **ベースラインの MRR_first が** 0.78 **まで低下**（フルデータでは 0.917）し，本手法の改善幅が拡大（MAP +0.30）．DAE 系ケースが従来 random_io 拡張より格段に **難しいデータ**であることが定量的に示された．**(3) Phase 1 評価指標拡張**．`evaluate_multi_eq.py` に `Recall@K_correct`（$K = n_{\text{correct}}$）を追加．従来の `MRR_first` は飽和しやすく改善幅が見えにくい問題を解消．Phase 3 結果での Recall@K_correct：A で 0.525 → 0.735（+0.210，**+40% 相対**），B で 0.481 → 0.699（+0.218，**+45% 相対**）．関連スクリプト・データ：`generate_dae_cases.py`, `run_phase3_experiments.sh`, `experiments/phase3_A_original_multi_dae.json`, `experiments/phase3_B_dae_only.json`.
- 2026-04-18（自由度検証済 1,107 ケースでの主要結果の再評価）：`two_stage_query_conditioned.py` を 5 seed で再実行．**reranker-10 の優位性が消失**し，reranker-7 が最良となる大きな結果の変化を観測（baseline 0.924 → 0.937，reranker-7 0.937 → **0.959**，reranker-10 0.949 → 0.939）．全体として各手法の MRR が向上したことから，自由度検証により学習・評価双方の品質が改善していることが示された．reranker-10 のグラフ特徴量（#7–9）は初回データの不正ケース（物理的に解けないケース）で正解順位を押し上げる役割を果たしていた可能性があり，現行の特徴量設計の見直しが必要．進捗レポート v2 § 5 に新しい結果表・バリアント別・初回データとの差分を追加，§ 6 考察に再解釈を追記，§ 7 今後の課題に「グラフ特徴量の再設計」を高優先度で記載．実験結果は `experiments/query_conditioned_comparison.json` に保存.
- 2026-04-19（追補レポート作成：自由度解析 + Set-aware 特徴量）：前回報告（v2）後の一連の研究成果を追補報告としてまとめ，`docs/progress_report_2026-04-19_addendum.tex` を新規作成．主な内容：(1) 自由度解析による訓練データ品質改善（1,107 件を全件可解に再構成），(2) 既

存グラフ特徴量 f7–f9 の診断（f9 は AUC 0.087 で逆信号など）と限界の明確化，(3) Set-aware 3 特徴量（gComp=補完性，gCoh=一貫性，gDom=ドメイン一致）の設計と評価，(4) 複数式評価指標（MRR_worst, Recall@K, MAP）の導入．10 seed paired t-test の結果：MAP 0.936 → 0.955（$p = 0.004$），複数式 Recall@3（旧 FullRecall@3）0.628 → 0.693（$p = 0.032$），複数式 MRR_worst 0.376 → 0.397（$p = 0.024$）．reranker-10S（基本 7 + set-aware 3）が統計的に有意な改善を達成．論文化の方向性を「Set-aware graph features for multi-equation retrieval」に確定．関連スクリプト：`filter_solvable_cases.py`, `expand_solvable_random_io.py`, `diagnose_graph_features.py`, `graph_feature_ablation.py`, `evaluate_multi_eq.py`, `set_aware_reranker.py`．実験結果：`experiments/graph_feature_diagnosis.json`, `experiments/graph_ablation_results.json`, `experiments/multi_eq_evaluation.json`, `experiments/set_aware_results.json`．**2026-05-08 追記**：FullRecall@K（全正解上位 K 内割合）から標準的な Recall@K（$|R_q \cap \mathrm{Top}_K|/|R_q|$ の平均）に指標を切替．`evaluate_multi_eq.py` に Recall@K 計算を追加し再実行．

- 2026-04-18（自由度=0 を保証する random_io の追加生成）：自由度フィルタで 707 件に減少した訓練データを，**自由度=0 を構成上保証する新規 random_io** を追加生成することで 1,107 件に復元．`expand_solvable_random_io.py` を新規作成し，各コアの正解式変数集合 V と方程式数 n_{eq} に対し，V から n_{eq} 個を出力として選び残りを入力とする全組合せから，既存の入出力組と重複しないものを採用する方式で 400 件生成．新規 400 件全てが自由度解析をパス．最終内訳：original 93, paraphrased 279, swap_io 2, random_io 733（元 333 +新規 400）= 1,107 件．進捗レポート v2 § 3.4.2 を「自由度解析＋可解ケース追加生成」に再改訂，§ 2.1 概要表・§ 4.5 正例・§ 5 結果注記・§ 7 今後の課題の数値を 1,107 に更新．
- 2026-04-18（自由度解析による訓練ケースのフィルタ実装）：加藤先生指摘「物理的に解けないケースは学習に使ってはいけない」への対応．`filter_solvable_cases.py` を新規作成し，各訓練ケースについて正解式集合の変数数と独立方程式数を照合する自由度解析を実装．判定条件：(i) 入出力変数が全て式集合内にあること，(ii) 出力変数が未知側にあること，(iii) ｜未知｜ ≤ 方程式数（relaxed：過剰決定系も物理的に解けるため許容）．訓練データ 1,107 ケースに適用した結果，707 ケース（63.9%）のみが可解と判定されたため，`training_cases.json` を差し替え（元データは `training_cases.pre_dof_filter.bak.json` に退避）．内訳：original 123→93, context_paraphrased 369→279, swap_io 123→2（98% 除外），random_io 492→333．swap_io は入出力非対称の元ケースが大多数であったため激減．進捗レポート v2 § 3.4.2 を「自由度解析の実装済み」へ改訂，§ 2.1 概要表・§ 4.5 正例定義・§ 5 結果の注記・§ 7 今後の課題に反映．MRR 再評価は今後の課題として明示．
- 2026-04-17（進捗レポート v2 の § 2.1 拡充：変数表記揺れの方針明記）：前回加藤先生に「変数表記の正規化に取り組む」と述べた件について，実データ（3,244 式）を精査した結果を受け，**現段階では全面正規化を行わない判断**に改めた旨を `progress_report_2026-04-13_v2.tex` の § 2.1 に明文化．表記揺れの実態（比熱が $c_p/C_p/c_w/Cp$ の 4 種 99 回、前指数因子が 3 種 31 回、密度が 3 種 251 回）を表で示し，全面正規化を行わない 3 つの根拠（(1) 記号の多義性による誤正規化リスク、(2) 文献単位の分割評価下では同文献内の表記が一貫し効果限定的、(3) 現 MRR 0.949 で誤差の主因でない可能性）を明記．実装済みの `normalize_notation.py`（3 物理量ルール）によるアブレーション実験を今後の内部検証として位置づけ．レポート本文では具体的なファイル名への言及は削除し，長期方針（各変数の物理的意味の自然言語記述を埋め込み空間で比較し，意味的に近いノード同士をグラフ上でソフトに接続する学習的アプローチ）のみを記載．
- 2026-04-17（進捗レポート v2 への注釈付与機構の刷新）：v2 PDF へのハイライト＋スティッキーノート付与を，従来の「固定文字列マッチ」方式から**提出版 PDF とのテキスト単語レベル差分**方式に全面変更（`docs/annotate_report_v2.py` を新規作成，旧 `add_annotations.py`/`add_annotations2.py`

を置換）．pymupdf の get_text("words") で両 PDF の単語列を取り，difflib.SequenceMatcher で差分を取ることで，**実際に変更された箇所のみを正確にハイライト**（タイトルなど未変更箇所の誤ハイライトを解消）．正規化は Unicode NFC、ダッシュ類・引用符類・全角句読点・各種空白を統一し表記揺れを吸収．結果：321 箇所のハイライト（equal=1,234 単語・insert=217 単語・replace=242 単語）と 25 箇所のスティッキーノート（各修正に対応する加藤先生コメント内容を詳述）．

- 2026-04-09（Phase 1 Round 2: 3,244 式への拡大 + 再評価）：expand_dataset.py にハンドブック第 2 弾（新 10 ドメイン＋既存 6 ドメインの応用式、計 320 式）と大型 PDF 分割抽出（pypdf で 80 ページずつ分割、3 冊 39 チャンク）を追加。結果：**1,613 式 → 3,244 式**、ソース 52 → 71、変数 2,098 → 3,704。generate_training_cases.py を大規模カタログ対応に改修（ドメイン別バッチ分割＋ 503 リトライ）。123 コア → 1,107 訓練ケースで 5 seed 比較：
  - baseline: MRR 0.924 ± 0.040, original 0.921
  - reranker-7: MRR 0.937 ± 0.018, original 0.942
  - reranker-10 (graph): MRR $\mathbf{0.949 \pm 0.031}$, original **0.952**

  核心的発見：(a) グラフ特徴量（reranker-10）が全指標・全 variant で最良、(b) reranker-7 を明確に上回る（+1.2% overall, +1.0% original）、(c) 975 式 →3,244 式のスケーリングでグラフ特徴量の有効性が単調増加。「データ規模がグラフ構造の価値を解放する」仮説を強く支持。Gemini API キーをハードコードから環境変数専用に変更済み。
- 2026-03-31（Phase 1: データ拡大 + 再評価）：expand_dataset.py を新規作成し、3 つの手法でデータセットを拡大。(1) ハンドブック式の大幅拡張：LLM 知識から 15 新ドメイン（流体力学・伝熱・物質移動・熱力学・反応工学・プロセス制御・電気化学・バイオプロセス・環境工学・振動・電気工学・高分子・燃焼・分離・輸送現象）で 330 式を生成。(2) Semantic Scholar API で新論文を探索、open-access PDF 17 本をダウンロード。(3) 新規 + 既存未処理 PDF 15 本から 308 式を抽出。結果：**975 式 → 1,613 式**（+65%）、ソース 22 → 52。訓練ケースも再生成（154 → 187 コア、1,343 → 1,680 拡張）。拡大データでの再評価結果（5 seed）：
  - baseline: MRR 0.900 ± 0.069, original 0.885（旧: $0.875, 0.839$）
  - reranker-7: MRR 0.942 ± 0.052, original 0.936（旧: $0.885, 0.860$）
  - reranker-10 (graph): MRR $\mathbf{0.948 \pm 0.046}$, original 0.935（旧: $0.879, 0.842$）

  核心的発見：データ拡大により (a) リランカーがベースラインを明確に上回る（+4–5%、旧 +1% 未満）、(b) グラフ特徴量が初めて悪化せず全体 MRR で最良、(c) 分散が半減（0.119 → 0.052）。「モデル改善より先にデータの質と量が重要」という仮説を実証。また、ハードコードされた Gemini API キーが GitHub 公開でリーク報告されたため、全 5 ファイルから削除し環境変数のみに変更。
- 2026-03-30（Phase 3b: クエリ条件付きグラフ特徴量）：two_stage_query_conditioned.py を新規作成。二部グラフ（式–変数）の構造情報をクエリ条件付きで特徴化する 3 指標を設計：(1) 2-hop reachability（クエリ変数から候補式への到達率）、(2) graph neighbor overlap（候補式のグラフ近傍とクエリ変数関連式の Jaccard）、(3) indirect bridge ratio（候補変数がクエリ変数関連式にブリッジする比率）。7 次元リランカーに 3 特徴を追加した 10 次元リランカーで 5 seed 比較。結果：**クエリ条件付き特徴量も改善に寄与せず**。MRR 0.879 ± 0.123（7 次元の 0.883 ± 0.119 から微低下）、original MRR 0.842（7 次元の 0.860 から −0.018）。GCN ベース特徴量（Phase 3）と同様のパターン。**結論**：現データ規模（975 式・154 original ケース）ではグラフ構造が有効な追加信号を提供しない。7 次元学習リランカー（no-gnn）が最良手法として確定。論文では「なぜグラフが効かないか」の分析を contribution に含める。
- 2026-03-30（Phase 3: GNN 特徴量統合）：two_stage_retrieval_gnn.py を新規作成し、3 方式を 5 seed で比較。(1) baseline_mix（固定重み）、(2) no-gnn リランカー（7 次元特徴、学習済み MLP）、(3) gnn リランカー（+GCN-refined SVD/CodeBERT 特徴の 9 次元）。結果：**no-gnn リランカーが**

最良（MRR 0.885 ± 0.113、original 0.857）。GNN 特徴を追加すると分散が増大し性能低下（MRR 0.873 ± 0.148）。原因分析：(a) CodeBERT GCN のセルフシフト特徴はケース依存情報を持たない、(b) SVD GCN の学習が不十分（5 epoch, 64 sample）、(c) グラフ構造がクエリ固有の情報を反映していない。**結論**：特徴の重み付けを固定→学習に変えるだけで改善が得られるが、現状のグラフ構造から有効な特徴を抽出するにはクエリ条件付き GNN が必要。

- 2026-03-30（Phase 2: 2 段階 retrieval）：`two_stage_retrieval.py` を新規作成。Stage 1 で `baseline_mix` が Top-K（$K = 50$）候補を高速に取得し、Stage 2 でニューラルリランカー（7 次元特徴量、3 層 MLP、ペアワイズ margin loss）が精密にリランキング。5 seed 評価の結果、全体 MRR 0.875 → 0.881（+0.006）。**original ケースでは** MRR 0.839 → 0.856（+0.017）と改善を確認。ただし seed 456 で劣化するなど分散が大きく、統計的有意性は未達。
- 2026-03-30（データ品質修正）：`fix_dataset_quality.py` を新規作成。暗黙変数（s, t）を 277 式に追加、重複ケース 43 件を除去（1386 → 1343）。バックアップを `*.bak.json` に保存。
- 2026-03-30（Phase 0: 評価基盤の確立）：論文化を見据え、研究の土台を再設計。
  - **ベースライン失敗分析**（`analyze_baseline_failures.py` 新規作成）：全 1386 ケースで `baseline_mix` を評価し、失敗ケース（RR < 0.5）の 85 件（6.1%）を 4 パターンに分類。**cross_domain**（100%）と **context_divergence**（78%）が支配的 — クエリと式の語彙が異なるケースでベースラインが失敗しており、意味理解（GNN/ニューラル）が有効な領域を特定。可視化を `figures/failure_analysis_summary.png` に出力。
  - **複数 seed 評価の導入**（`run_retrieval_experiments.py` 改修）：5 seed（42, 123, 456, 789, 1024）で source_id 分割を変え、平均 ± 標準偏差と 95% bootstrap CI を報告する `-seeds N` モードを追加。結果：`baseline_mix` の Test MRR = 0.890 ± 0.095（95% CI [0.804, 0.949]）。単一 seed（0.899）では見えなかった高分散を確認。
  - **variant_type 別評価の標準化**：original ケースの MRR = 0.851 ± 0.080 に対し、random_io_from_models の MRR = 0.925 ± 0.112 と合成ケースが有意に簡単であることを定量的に確認。論文では original ケースの指標を主要報告とする方針。
- 2026-03-30（TeX）：`development_log.tex` の `inputenc` を UTF-8 のみに整理し、更新履歴の Markdown 風バッククォートをやめてファイル名をタイプライタ体コマンドで囲む表記に修正、`uplatex` でコンパイル可能に。TeX は `brew install texlive` で `pdflatex`/`uplatex`/`dvipdfmx` を利用（手順は `docs/README.md`）。
- 2026-03-30：Claude Code 向け `CLAUDE.md` と `research_context.md` のポインタを追加。各ファイル・ディレクトリの役割を新設し各ファイルの役割を記載。技術メモの `build_graph_data.py` を二部グラフ版の説明に修正し当該節へ参照。
- 2026-03-18（試したいこと・GAT 追加）：開発記録に「試したいこと・実験アイデア」を追加（GAT、エッジ重み、クエリ条件付きグラフ、hard negative、データ拡張、複数 seed 評価）。`train_gnn_retriever.py` に GAT エンコーダと `-gnn-type gcn|gat` を追加。
- 2026-03-18（グラフ構築の改善）：現状の「式＝ノード・共通変数＝エッジ」では GNN の強みを活かせないという分析を開発記録に全文追記。**式–変数二部グラフ**に変更（`build_graph_data.py`）。式ノードと変数ノードを明示し、エッジは「式が変数を含む」のみ。式埋め込みは GCN 出力の先頭 `num_equations` 行を使用。`edge_index_eq_eq` で後方互換を確保。`train_gnn_retriever.py`、`run_retrieval_experiments.py`、`train_gnn_refine_svd.py`、`analyze_dataset.py` を二部グラフ対応に修正。
- 2026-03-18（GNN・埋め込みの説明）：開発記録に「GNN の仕組みと埋め込み」セクションを追加。グラフ構築（ノード＝式・エッジ＝変数共有・特徴＝ CodeBERT）、式埋め込みの 2 系統（CodeBERT `x` と TF-IDF+SVD）、GNN の 2 パターン（`x` を GCN で更新する方式と SVD 空間での残差 GCN）、

スコアリング・学習の流れ、各スクリプトの役割を記載。

- 2026-03-18（方式比較とハイパラ探索）：retrieval 方式（`baseline_mix`, `svd_cos`, `q_mlp_to_x`, `gnn_refine_svd_residual`）を同一の train/val/test（source_id 単位）で比較し、学習率・重み減衰のグリッド探索を自動実行するランナー `run_retrieval_experiments.py` を追加。結果は `experiments/retrieval_experiments.md` に表で出力し、現状では `baseline_mix`（TF-IDF+ 変数 Jaccard）が最良であることを確認。
- 2026-03-18（GNN 次ステップ）：SVD+I/O 文字列ベースラインを維持したままグラフ構造の寄与を検証するため、SVD 空間上で式埋め込みを GCN で**残差的に**更新する実験スクリプト `train_gnn_refine_svd.py` を追加。素朴な GCN は埋め込みを崩して性能低下したため、学習開始時はベースライン同等（$\alpha = 0$）になる残差混合に変更して安定化。
- 2026-03-18：データセット解析と訓練準備を拡張。`dataset_report.txt` の変数 TOP15 に物理意味を併記し、ドメインを論文用に合併して図（ドメイン分布・埋め込み）を可読化。訓練ケースに `context_paraphrased` を追加し、健全性チェック（ID 整合・変数整合・重複）とベースライン評価を実装。さらに PyG の `equation_graph.pt` を用いた retriever の 1epoch 動作確認スクリプトを追加（context+I/O 変数をクエリ特徴に含めて改善）。
- 運用ルール変更：全ての変動を開発ログに書き、変更のたびに `git commit` と `git push` で GitHub へ自動同期するよう Cursor ルールを強化（`.cursor/rules/development-log.mdc` および本ドキュメント技術メモを更新）。
- 開発ログに変動履歴を追記：モデル（gemini-2.5-pro 等）、デフォルト API キー、処理済み PDF 管理、`fetch_papers.py`、`build_graph_data.py`、`generate_training_cases.py`（correct_model_ids の条件含む）、`analyze_dataset.py`。GitHub 同期はコミット・push で行う。
- `build_equation_graph.py` を追加（PDF 一括、Handbook 生成、`unified_equations.json` 統合）。処理済み PDF を `processed_pdfs.json` で管理し未抽出のみ処理するよう変更。
- 開発記録の自動追記ルール（Cursor）とコミット時自動 push（post-commit フック）を導入。
- 初版：モデル変更、レートリミット対策、c_w/正規化の記録を追加。
- 2026-07-12（有意差検定スクリプト）：baseline vs reranker-10S の対応ある Wilcoxon 符号順位検定を実装（`analyze_significance.py`）。設定 A/B とも Recall@K_correct・MAP・Recall@20 の全指標で p=0.00195（両側、10 乱数全て reranker > baseline のため理論最小値）。Cohen dz は Recall@K_correct で 11.9〜12.9、MAP で 9.4〜32.3 と強効果。TDD に従い pytest で検証済み（tests/test_significance.py）。出力は `experiments/significance_stats.json`。
- 2026-07-12（greedy 3 者比較の設定 A 拡張）：DAE のみ（設定 B 相当）で実施済みの 3 者比較（静的参照／推論のみ greedy ／学習版 greedy）を設定 A（原型 + 複数文献 +DAE、1,823 件）に拡張。`run_greedy_3way_A.sh` を新規作成し、reranker-10S・層化分割・top-k 200・10 シード（計 30 ジョブ）で実行。集計は `analyze_greedy_3way.py` を引数化（`--dir` ／`--out-json` ／`--out-fig` ／`--tag`。無引数時の既定挙動・出力はバイト同一で不変）して流用。結果（Recall@K_correct、seed 平均± SD、n=10）：静的参照 0.7568 ± 0.0560、推論のみ greedy 0.7865 ± 0.0487、学習版 greedy 0.7968 ± 0.0530 で、DAE のみと同じ 静的 < 推論 < 学習版 の順序を再現。検定（Wilcoxon 符号順位、両側）：train vs static は $\Delta = +0.0400$、p=0.00195 で有意、infer vs static は $\Delta = +0.0297$、p=0.00195 で有意。一方 train vs infer は $\Delta = +0.0103$、p=0.13086 で有意差なし（DAE のみでは p=0.03711 で有意だった差が、設定 A では検出されず）。最難端 X≥8 でも train vs static は $\Delta = +0.0481$、p=0.00195 で有意、train vs infer は $\Delta = +0.0086$、p=0.06445 で有意差なし。統計は `experiments/greedy_3way_A_stats.json`、図は `docs/figures/fig_greedy_3way_A.png`（生の per-case 出力 `experiments/xg_A/` はコミット対象外）。
- 2026-07-12（修論 Phase 1 完了：全体検証とアウトライン PDF の確定）：`docs/superpowers/specs/2026-07-12-master`

に基づく Phase 1（TeX 骨格・章別 3 階層アウトライン・追加実験・英語図 7 点）が完了し、全体検証を実施。`thesis/master_thesis/` で `latexmk -gg main.tex` が exit 0 で 26 ページの `main.pdf` を生成し、7 章＋ Appendix A–C を目次に確認、未解決参照（`??`）・未定義引用（`[?]`）はともに 0 件（`main.log` にも undefined 警告なし）。スペック照合：(1) 表紙（jsbook・和文表紙・英語本文）は研究室過去 4 本の形式を踏襲、(2) 全 7 章の P 系列（トピックセンテンス）のみを通読し一貫した要約になることを確認、(3) 本文の主要数値を `experiments/strat_A.json`・`strat_B.json`・`significance_stats.json`・`greedy_3way_stats.json`・`greedy_3way_A_stats.json`・`feature_x_difficulty_stats.json`・`dof_stop_stats.json` と 1 件ずつ突合し全て一致（記憶値なし）、Appendix A のハイパーパラメータも `strat_A.json` の `config` と `set_aware_reranker.py` のデフォルト値に一致することを確認、(4) 第 6 章§ 6.4「$X \geq 8$ で $+0.056$」は `greedy_3way_stats.json` の `tests_hard_X8plus.train_vs_static`（learned greedy vs 静的参照）を正しく参照しており、train vs infer との混同はないことを確認、(5) 追加実験 1（有意差検定）・2（greedy3 者比較の設定 A 拡張）は commit `8a8f4bf`・`e2914cc` で既にコミット済み。軽微な指摘：第 4 章§ 4.3（DAE ケース生成の $X = 1..10$ ／各 100 件）と§ 4.4（層化分割の 6:2:2・候補 400 通り）の一部数値に直近の `% source:` コメントが付いていない箇所があり、値自体は他章・他ファイルで裏付けられているため捏造ではないが、Phase 2 の本文化時に出典コメントを補うこと。Phase 1 完了につき、次は先生方への骨子（アウトライン）PDF レビュー依頼（ゼミ提出）。

- 2026-07-12（機構の考察一式と進捗報告）：加藤先生の「特徴量を設計して精度が上がっただけでは Kaggle と変わらない。なぜ上がるのかの考察が重要」とのご指摘に対応する 3 実験を実施し、進捗報告 `docs/progress_report_2026-07-12_mechanism.tex/.pdf`（4 ページ）にまとめた。報告書では読みやすさを優先し、3 者比較（静的参照／推論のみ greedy ／学習版 greedy）は「従来（基準固定）／逐次選択（学習・推論とも基準更新、＝学習版 greedy）」の 2 者に簡約して提示し（中間の「推論のみ greedy」と教師強制・scheduled sampling 等の専門用語は報告書からは省略。完全な 3 者比較は本記録と `greedy_3way_stats.json` に保持）、図は機構の層別図 1 点のみ掲載した。(1) 特徴量×難易度クロス：`run_feature_x_difficulty.sh`（reranker-7 に集合特徴量を 1 つずつ追加した 5 モード × 10 シード、設定 A・層化分割・per-case 保存）→ `analyze_feature_x_difficulty.py`（シード対応 t 検定＋正解式数・入力変数数の層別図 `fig_mechanism_fingerprint.png`、統計 `feature_x_difficulty_stats.json`）。gComp $+0.052$（$p < 0.001$）・gCoh $+0.050$（$p < 0.001$）が上乗せのすべてを担い、gDom は -0.000（$p = 0.98$）で寄与なし。上乗せは複数式・多変数のケースに限られ、入力 16 変数以上では $+0.035$ に縮小。前回報告の改善 $+0.222$ は「基本 7 特徴量の重み学習 $+0.172$」＋「集合特徴量 $+0.050$」に分解できることを確認。(2) 学習版 greedy：`set_aware_reranker.py` に `--train-greedy`（教師強制の逐次集合構築。各ステップで既選択集合を参照に set-aware 特徴量を再計算し、次の正解式を負例より上へ押す）と `--seed-list`（並列実行用）を追加し、静的参照／推論のみ greedy ／学習版 greedy の 3 者比較（DAE のみ・top-k 200・10 シード、`run_greedy_3way.sh` ／ `analyze_greedy_3way.py`）。Recall@K_correct は $0.724 < 0.756 < 0.765$、train vs static $\Delta = +0.041$（$p < 0.001$）、train vs infer $\Delta = +0.009$（$p = 0.036$）、X≥8 で差最大（$+0.056$）。実験 1 で予測した「固定参照による頭打ち」が介入で回復し、機構を因果として確認。(3) 自由度ゼロ停止：`--stop-dof`（`greedy_close` ／ `set_metrics` ／ `is_closed` を新設）で、正解式数 K を与えず「出力変数が全て被覆され、かつ未知数の数 ≤ 式数」の時点で選択を停止（`run_dof_stop.sh` ／ `analyze_dof_stop.py`、統計 `dof_stop_stats.json`、図 `fig_dof_stop.png`）。完全一致率は K 既知と同一（DAE 0.368 ／設定 A 0.526）、集合 F1 の低下は僅少（設定 A -0.008、$p = 0.006$）、解ける系の割合は 0.88 ／ 0.94 で上位 K 件の 0.78 ／ 0.87 を上回る。事前検証：正解集合の自由度ゼロは全 variant で成立（オリジナル 92・文献横断 731・DAE 1,000 の全件）、部分集合での早期成立なし（DAE 1,000 件 × 8 順序で 0 件）。ただし K ＝出力変数数がほぼ

全件で成立するため K 予測自体は自明である点を報告に明記。コード・図・統計は commit `08c371d`。進捗報告の図 3 点は作文ルールに合わせ文言を清書（比喩・プログラム変数名・未定義略語を排除）。

- 2026-07-12（baseline→7 特徴量の分解）:「集合特徴量の内訳は説明したが、baseline（古典的検索）から 7 特徴量 MLP への +0.172 の内訳が未説明」との本人指摘を受け、中間条件 `reranker-2`（baseline と同じ 2 特徴量〔text_sim・io_jaccard〕のみを MLP で学習。`MODE_CONFIGS` に `base_subset` を追加、既存モード非破壊）を実装し、設定 A・層化分割・10 シードで実行（`run_reranker2.sh`、出力 `experiments/xd/reranker-2__*.json`）。結果（Recall@K_correct、シード対応 t 検定）: baseline 0.521 → 同 2 特徴量 MLP 0.601（**重み付けの学習** +0.080、$p < 10^{-6}$）→ 7 特徴量 0.693（**特徴量の追加** +0.092、$p < 10^{-6}$）→ 集合特徴量 0.743（+0.050）。合計 +0.222 で前回報告と一致し、**改善の全 3 段が分解できた**。進捗報告（4 ページ版）の §2・表 1・§3・考察・まとめに反映。あわせて本人の手動修正の誤字等を修正（タイトル「訓練特徴量」→「設計した特徴量」、ご指摘引用の「効くの考察」→「効くのかの考察」、§1 の「前回」重複）。追加した 5 特徴量（意味類似・入力被覆・出力被覆・式の特化度・分野一致）のどれが +0.092 を担うかは未分解（報告書の限界に明記）。
- 2026-07-14(進捗報告を実験 1 のみに絞る):本人の指示により、進捗報告 `progress_report_2026-07-12_mechanism` から実験 2（逐次選択）・実験 3（自由度ゼロ停止）の節を本文ごと削除し、**実験 1（精度向上の分解と層別）のみの 3 ページ構成**に変更。タイトル後半を「精度向上の分解と、効く場所の特定」に、考察を 2 項目（課題の性質・限界）に、まとめを分解の結果のみに整合。その後、本人の指示（「次回にも書く必要ない、進捗報告でしない」）により今後の課題からも逐次選択・停止規則の予告を削除し、報告書から実験 2・3 への言及を完全になくした（限界 (iii) も「推定である」の表現に整理）。実験 2・3 の完全な結果は本記録（2026-07-12 の項）と `greedy_3way_stats.json` ／ `dof_stop_stats.json` に保持。
- 2026-07-14（全特徴量の個別分解：+0.092 の内訳と話題特徴の無効性）：本人指摘「『上乗せ』の比較先が曖昧」「『どの特徴量が効くか』の実験で基本 7 特徴量を対象から除いている」を受け、基本特徴量も 1 つずつ分解した。`MODE_CONFIGS` に `reranker-2+Svd/InCov/OutCov/Spec/Dom`（土台＝ 2 特徴量に基本特徴量を 1 個ずつ追加。`base_subset` で列を選択）を追加し、設定 A・層化分割・10 シードで実行（`run_base_ablation.sh`）。結果（土台 A ＝ 2 特徴量 MLP 0.601 からの差、シード対応 t 検定）：**式の特化度** +0.090（$p < 0.001$）**が** +0.092 **のほぼ全部を担い、これ 1 個で 7 特徴量**（0.693）**にほぼ到達**。入力被覆 +0.019（$p < 0.001$）・出力被覆 +0.006（$p = 0.002$）は小、**意味の近さ（SVD）** −0.002（$p = 0.48$）**・分野の一致** +0.002（$p = 0.06$）**は効果なし**。集合版の分野一致（gDom $p = 0.98$）と合わせ、**話題の近さを見る特徴量はどの形でも効かない**という対称的な結論を得た。進捗報告の表 1 を全 10 特徴量の個別効果（土台 A/B の 2 段はしご）に再構成し、「上乗せ」を「土台からの差」に統一（比較先を明示）、結論・考察・まとめを「効くのは変数の重なり、効かないのは話題の近さ」に書き換え。3 ページ維持。追加 5 特徴量の内訳は分解済みとなり、限界からは削除。統計は per-case JSON（`experiments/xd/reranker-2_*__*.json`）に保持。
- 2026-07-14（分野一致度の負の結果を修論本文に明文化）：本人の問い「分野一致度の特徴量が精度向上に効かないのは、分野分けが広すぎて個別化できないためか。分野をさらに細かくすべきか」を実データで検証し、前提が逆であることを確認した。特徴量が照合する `domain` フィールドは、論文収集に用いた 32 分野（`fetch_papers_32domains.py`）ではなく、**抽出時に大規模言語モデル（Gemini 2.5 Pro）が式ごとに自由記述で付けた分野名**である。`unified_equations.json`（11,146 式）で集計すると、異なる分野ラベルは **1,998 種**、うち 27.9% が 1 回のみの出現、1 論文あたり平均 6.36 種で、表記ゆれ（“Transport Phenomena” と “Transport phenomena” を別物として扱う）も多い。したがって分野が広すぎるのではなく細かすぎ、完全一致（集合特徴量）も部分文字列一致（基本特徴量）もまばらにしか成立しないため信号にならない。分野をさらに細かくすると疎性が悪化するだけであり、話題の近さは文章類似度・変数の一致度がすでに担う（本課題は同じ話題ではなく同じ変数で解ける）。数値照合：基本版の分野一致は土台 2 特徴量 0.6010 → 0.6034（+0.0024、対応 t 検定 $p = 0.063$、Wilcoxon

$p = 0.123$、`experiments/xd/reranker-2__*.json`・`reranker-2_Dom__*.json` の 10 シード)、集合版の分野一致 (gDom) は -0.0001 ($p = 0.98$、`feature_x_difficulty_stats.json`) で、いずれも効果なし。この負の結果を修論本文 `thesis/master_thesis/ResultsAndDiscussion.tex` に独立節 §6.6「The Null Result for Topic Agreement」として追加し (Limitations の直前。既存 Limitations は §6.7 に繰り下げ、P7→P8)、分野ラベルの生成主体を第 4.1 節 (Gemini 2.5 Pro) と整合させた。`uplatex` で目次・本文の描画を確認済み。

- 2026-07-15 (分野ラベル合併の検証:合併しても domain 特徴は効かない):§6.6 の「分野一致度が効かないのは分野が細かすぎるため」に対し、「ラベルを合併して粗くすれば効くようになるか」を検証した。コミット済み `set_aware_reranker.py` の `run_mode` を外部から呼び、式ごとの分野ラベル列 (`eq_domains`) だけを合併ラベルに差し替えて基本版 domain 特徴つき `reranker-2+Dom` (基本 2 特徴量+分野一致) を再学習する検証スクリプト `run_domain_merge_ablation.py` を新規作成 (パイプライン本体は無改変)。合併は 3 粒度:L1 (小文字化・記号除去・語尾複数形の統合で 1,998→1,958 群)、KMeans による 100 群、KMeans による 40 群 (32 収集分野スケール)。短い分野名では TF-IDF + average-linkage 凝集クラスタリングが単一クラスタに退化したため、L2 正規化 TF-IDF 上の KMeans を採用。設定 A・層化分割・top-k 50・10 seed で、domain 不使用の `reranker-2` (0.6010、既存 `experiments/xd/` を再利用) を base とし対応 t 検定:**Recall@K_correct の差はどの粒度でも ≈ 0 で全て非有意** (orig $+0.0024$ / $p = 0.06$、L1 $+0.0006$ / $p = 0.68$、K100 -0.0001 / $p = 0.84$、K40 $+0.0004$ / $p = 0.63$)。元ラベルのわずかな $+0.002$ すら合併で消える。**障害は疎性でなく冗長性**:第 1 段の候補集合が既に話題的に近いため、合併した分野一致は正解候補と不正解候補を分離しない。この結果で修論 §6.6 を「分野を細かくすると疎性が悪化する (推定)」から「細かくしても疎性が悪化し、粗くしても (合併しても) 寄与は ≈ 0 (実測)」の両方向の主張に格上げした。統計は `experiments/domain_merge_stats.json`。
- 2026-07-21 (P-77 紹介スライド):PSE ASIA 2026 のポスター P-77 (台湾科技大、LLM + MCP による Aspen Plus 操作自動化) を研究室ゼミで紹介するスライド 8 枚を作成。仕様 `docs/superpowers/specs/2026-07-21-p77-seminar-slides-design.md`・計画 `docs/superpowers/plans/2026-07-21-p77-seminar-slides.md` に基づき、本文・台本を `scripts/seminar_p77/content_p77.py`、描画を `scripts/seminar_p77/build_p77_slides.py` に実装 (PSE Asia 発表テンプレのマスターを流用、自作図 3 点、ノート欄に台本約 12 分)。pytest (`tests/test_p77_content.py`・`tests/test_p77_slides.py`) で 8 枚構成・全テキスト 20pt 以上・略称の正式名称併記・禁止語 (格上げ表現含む)・台本分量を機械検証。出力 `~/Desktop/`**ゼミ/論文紹介**`_P77_LLM_Aspen_`**かずひろ**`.pptx` はリポジトリ外のためコミット対象外。
- 2026-07-21 (紹介スライド v2 改稿):発表者レビュー (「何をやっているか分かりにくい」「抄録だけでは体系的な話に足りない」) を受け、ゼミ紹介デッキを P-77 単独 8 枚から **DTU 論文中心の 10 枚**に全面改訂 (発表 12 分は維持)。中心例を全文公開の Liang, Groll & Sin, arXiv:2601.11650 (Claude Desktop + 自作 MCP サーバ + AVEVA Process Simulation、CC BY 4.0) に変更し、「向く作業・やるべき作業・任せてはいけないこと」の 3 つの問いを背骨に再構成。ツール数は HTML の Table 1 を直接数えて 16 個と確認 (抽出モデルは 18/19 とぶれたため一次確認を実施)。掲載数値はすべて論文実測 (ツール 7 回で約 2,000 変数から要点 24 個、改善案 11 個の著者採点 3/4/3/1/0、還流比反復で純度 84.2→95.1 mol%、算数ミス $+10.9\% \leftrightarrow +12.9\%$、省エネ主張 20〜40% 対 専門家見積 2〜5%)。実装は `content_p77.py` 全面書き換え・`build_p77_slides.py` 改修 (表の可変幅/高さ、構成図 5 箱、回避ルート図削除、出力名・docProps 更新)、pytest を 22 本に拡充 (10 枚構成・論文数値一致・研究室 2 件言及の検証を追加)。出力 `~/Desktop/`**ゼミ/論文紹介**`_LLM_MCP_`**シミュレータ操作_かずひろ**`.pptx` (v1 の P-77 版ファイルは残置)。
- 2026-07-21 (スライドのレイアウト刷新):本人指摘 (スライド 1 で本文が注記に重なる

等）を受け、固定座標レイアウトを廃止し**実フォント計測にもとづく動的配置**に全面刷新。`scripts/seminar_p77/textmetrics.py` を新設し、実際に使うフォント（欧文 IBM Plex Sans ／和文ヒラギノ角ゴシック）のグリフ幅を matplotlib 経由で計測して折り返し行数を算出、全レンダラを「前要素の実測下端から次要素の y を決める」積み上げ方式に変更（表は行高もセル内折り返しから実測）。あわせてレイアウト監査 `audit_presentation`（下端はみ出し・図形内あふれ・テキスト矩形の重なりを検査）と `tests/test_p77_layout.py` を追加。監査の検出力は旧ビルドに適用して重なり 5 件（S2 リード×表、S2/S5/S7 注記×出典、S4 戻りラベル×箇条書き）を検出することで確認し、新ビルドは違反 0 件。全 23 テスト green。

- 2026-08-09（話題特徴が寄与しない原因の実証と正解・不正解ケース分析）：加藤先生の宿題「性能向上手法として期待したことと結果の関連と原因の考察（例：精度向上にほぼ貢献できなかった特徴量）。正解・不正解のケースを見て分析。意味の近さが役立たない原因は TF-IDF→SVD のベクトルがケース間で差が小さかった可能性」に対応する 2 分析を実施し、`docs/考察_特徴量の期待と結果_2026-08-09.md` にまとめた。(1) 診断（モデル非依存、`diagnose_topic_features.py`・pytest 11 本）：**仮説は支持されない**——ケース間クエリベクトルのコサイン類似は中央値 0.218（SVD 空間）・0.070（生 TF-IDF）で 0.5 超は 5.4% にとどまり、svd_sim 単独の全 DB AUC は 0.950 ± 0.003（ベクトルが縮退していれば不可能）。真因は候補絞り込み後の冗長性で、stage1 候補 50 件内では svd_sim の AUC が 0.594 に崩壊（specificity 0.965、変数系 0.72–0.97 は保持）。さらに stage1（0.7×text_sim+0.3×jaccard）の混合選抜が候補内に $\mathrm{corr}(\text{text_sim}, \text{io_jaccard}) = -0.404$ の見かけの負相関を作り、text_sim は候補内 AUC 0.437 と逆向きになることを実測。被覆率（正解式が候補 50 件に入る割合）は混合 0.920 ± 0.004 < Jaccard 単独 0.961 ± 0.002 で、stage1 の混合重みが上限を下げていることも判明（次の介入実験候補）。(2) 正解・不正解ケース分析（`analyze_case_outcomes.py`・seed=42・テスト 423 件・pytest 5 本）：取り逃した正解式 435 本の **61.8% は stage1 見逃し**、38.2% が再ランク見逃し。落ちたケースは正解式数 5.3 vs 2.1・入力変数 17.8 vs 10.8（いずれも Mann-Whitney $p < 0.001$）で既報の難易度プロファイルと一致。反実仮想の救済可能性 P(見逃し正解 > 誤上位) は svd_sim 0.516 ± 0.040・domain 0.494 とコイン投げ同水準（io_jaccard は 0.375 で誤り側が優位）＝**話題特徴を強めても残存誤りは救えない**。具体例で誤りの型を同定：別文献の数学的同一式（話題類似はむしろ誤りを推す。$dX/dt = \mu X$ の重複）、式の向き（どの変数を左辺で決めるか）の欠落、類似式ファミリによる候補占拠。出所検証では誤り候補の同一文献率は 22.2% に過ぎず、話題の均質さは文献重複＋選抜由来。図 `docs/figures/fig_topic_diagnosis.png/.pdf`（(a) ケース間類似分布、(b) 候補内 AUC・SEM エラーバー付き）、統計 `experiments/topic_feature_diagnosis.json`・`case_outcomes_seed42.json`。並行セッションが同ブランチで PFI per-case 本実行（`pfi_per_case.json` 生成、約 2 時間）を担当中のため、本セッションからの重複実行は停止して委譲。
- 2026-08-09（修論 第 3–5 章の本文化・ケース族の用語改訂・第 6 章に誤り分析節を新設）：本人指示の今後の方針「現状のデータセット・提案手法・評価方法を論文形式（Methods / Experiments 相当）でまとめる。オリジナル・文献横断・DAE の言葉の使い方は変更する。論文の主張を考える」に対応。(1) **用語改訂**：正解集合の作り方という単一の軸で命名し直した（`original`→**as-published** ／文献掲載、`multisource_*`→**cross-document** ／文献横断、`dae_X*`→**synthesized** ／合成、拡張→augmented）。旧称は出所と作り方の 2 軸を混ぜており、「オリジナル」はケースの性質でなくデータセットの履歴を指し、「DAE」は他の族も満たす性質（文献掲載・文献横断のケースも微分代数系）を族名にしていた。設定 A/B は「混合」「合成のみ」と併記。全章（Introduction / Dataset / Experiment / Results / Conclusion / Appendix）に適用。(2) **第 3 章 Method の本文化**：問題定義（自由度 $\mathrm{DoF}(S) = |\text{未知数}| - |S|$ と閉包条件）・第 1 段・第 2 段・逐次選択・自己停止を段落形式で執筆し、特徴量表（10 特徴の定義と群）を新設。**実装を一次情報として骨子の誤記 4 件を訂正**：①第 1 段のスコアは 2 特徴の混合（$0.7\,\text{text_sim} + 0.3\,\text{io_jaccard}$）であり「7 特徴」ではない（7 特徴は

第 2 段 MLP の入力)、② MLP の隠れ層は 64 ユニット **2 層**（骨子は 1 層)、③集合特徴の参照集合は第 1 段上位 K_REF=5 件（候補集合 $k = 50$ とは別物)、④閉包条件は DoF ≤ 0 かつ出力被覆（骨子の DoF $= 0$ は等号のみで狭い)。(3) **第 4 章 Dataset の本文化**：一次データから全数値を再実測（式 11,146 = PDF 328 文献 10,437 式＋生成参照集合 33 種 709 式、変数記号 13,220、分野ラベル 1,998・singleton 27.9%・文献あたり 6.36)。族ごとの出所を実測（文献横断は 100% が 2 文献以上・最大 3、文献掲載 1.1%・合成 4.1%)、評価 1,823 件の 90.8% が 2 式以上・平均 3.90 式。**K ＝出力変数数が文献横断・合成で 100%（文献掲載 92.4%）** = K 予測が自明であることを本文に明記。(4) **第 5 章 Experiment の本文化**：主指標 Recall@K_correct が **R-precision と同一**であること（窓＝正解数なので precision と recall が一致、evaluate_multi_eq.py で確認)、拡張除外の根拠（含めると baseline 0.521→0.622 で差が +0.222 → +0.156 に縮む)、**候補窓のハンディキャップ**（baseline は全 DB を順位付けするが再ランクは候補被覆 0.920 が上限)、**LLM 比較の生成器と判定器が同一モデル**（ともに claude-opus-4-8）で LLM 側に有利な保守的比較であることを明記。(5) **候補窓の被覆率を実測**：$k = 50$ で 0.9203（全正解被覆ケース 77.2%)、$k = 100$ 0.9569、$k = 200$ 0.9775（90.3%)、$k = 400$ 0.9895。(6) **第 6 章**：§ 6.6 を「分野一致」から「話題全般（Topic Similarity)」に拡張し P7′（ベクトル差仮説の棄却・全 DB AUC 0.950 対 候補内 0.594・選択効果 −0.404）を追加、**§ 6.7 Error Analysis を新設**（誤りの 61.8% は第 1 段・被覆 0.920 対 変数単独 0.961・救済可能性 0.516・等価式重複と式の向きの 2 型)。既存 Limitations は § 6.8 に繰り下げ、節参照を \label/\ref 化。(7) **主張の文書化**：docs/**論文の主張**_2026-08-09.md に貢献 C1–C7・主張しないこと 5 項（自動構築した／K を当てられる／LLM より優れた手法である 等)・想定質問 Q1–Q5・用語対応表をまとめた。ビルド確認：latexmk -gg main.tex exit 0、21 ページ、未解決参照・未定義引用なし。

- 2026-08-09（進捗報告：話題の近さの限界と誤りの所在)：今回の議論と追加実験を進捗報告 docs/progress_report_2026-08-09_topic.tex/.pdf（5 ページ）にまとめた。構成は決定版見本（6_17 進捗報告）に準拠し、§1 前回ゼミレビュー、§2 今回の進捗（番号リスト 6 項目)、§3 実験 1（意味の近さはどこで力を失うか)、§4 実験 2（正解・不正解のケースを見る)、§5 修士論文の本文化とケースの呼び方の整理、§6 考察、§7 まとめと今後の課題。加藤先生のご指摘（期待と結果の関連・原因の考察／正解不正解ケースの分析／ TF-IDF→SVD のベクトル差仮説）を §2 冒頭に明示し、以降がその回答になる形にした。**新規の追加実験**：第 1 段の絞り込み方ごとの被覆率を $k = 10, 25, 50, 100, 200, 400$ で測る analyze_stage1_coverage.py（pytest 6 本、--figure-only で再計測なしの作図が可能）を新規作成。現行の混合（文章 0.7 ＋変数 0.3）は $k = 50$ で 0.920・$k = 200$ で 0.977 に対し、**変数の一致度だけで絞ると $k = 50$ で 0.961**、文章類似度だけでは 0.431、意味の近さだけでは 0.518 であった（experiments/stage1_coverage.json)。被覆率は第 2 段 Recall@K_correct の上限を与えるので、第 1 段を変数寄りに再設計する介入実験の根拠になる。図は新規 docs/figures/fig_stage1_coverage.png（(a) 絞り込み方別の被覆率、(b) 救済可能性。ともに誤差棒＝標準誤差)。**図の清書**：fig_topic_diagnosis のパネル (b) が specificity・io_jaccard 等のプログラム変数名のままで作文ルール A6（アンダースコア表記は文書・論文で使わない）に反していたため、diagnose_topic_features.py に日本語ラベル表（式の特化度・変数の一致度・意味の近さ 等）を追加して再生成し、軸ラベルの “SEM” も「標準誤差」に、“stage1” も「第 1 段」に改めた。再実行で topic_feature_diagnosis.json はバイト単位で不変（決定的であることを確認)。
- 2026-08-09（コサイン類似度の物差し)：本人の「コサイン類似度の中央値 0.218 のイメージがつかない。0.218 ってどのくらい違うのか」という問いに答えるため、同じ空間の中に基準となる組を置いて較正した（calibrate_similarity_scale.py、pytest 8 本)。式本文で学習した TF-IDF→SVD 空間へ全 2,838 ケースを射影し、コサイン類似度の中央値を組の種類別に測ると、**同じ核モデルから入出力だけ変えた組** 1.000（四分位 0.982 – 1.000、n=1,050)、**同じケースの説明文を書き換えただけ**

の言い換えの組 0.944（0.926 – 0.962、n=276）、**同じ文献に由来する別ケースの組** 0.445（0.302 – 0.588、n=16,123）、**無作為な 2 ケースの組** 0.218（0.149 – 0.313、n=199,882）であった。決め手は**言い換えの組 276 組のうち** 0.218 **以下が 1 組もない**（0.0 パーセンタイル）ことで、内容が同じ組と無作為な組は分布が重ならない。0.218 付近の実例は「微生物がグルコースを消費する発酵系」と「PI 制御下のタンク液位の応答」で話題は明確に異なる。全ケースが英語の化学工学の文章のため共通語彙による下駄があり、無関係でも 0 にはならない（実質的な範囲は 0.15〜1.0）。この較正により §3 の「ベクトル差が小さいという仮説の棄却」が目に見える形になったので、進捗報告 §3 に 1 項目と箱ひげ図（`docs/figures/fig_similarity_scale.png`、図 2）を追加し 6 ページとした。統計は `experiments/similarity_scale.json`。

- 2026-08-09（進捗報告の改訂：PFI の追加と 4 ページへの圧縮）：本人の指摘を受けて進捗報告 `docs/progress_report_2026-08-09_topic.tex` を段階的に改訂した。(1) **候補件数の取り違えを訂正**：「データ拡張後に第 1 段の候補を 200 件に上げた」との指摘で確認したところ、主要比較 `strat_A/B` は $k = 50$、逐次選択・自己停止（2026-07）は $k = 200$ と使い分けていた。今回の分析は全て $k = 50$ で行っていたため $k = 200$ で測り直し（`analyze_case_outcomes.py`・`diagnose_topic_features.py` に `--top-k` を追加、既定 50 で挙動不変）、**「誤りの主因は第 1 段（61.8%）」が** $k = 50$ **限定の主張**であったことが判明した。$k = 200$ では第 1 段由来は 28.4% に下がり並べ替えの誤りが 71.6% と逆転する（見逃し 435 本 →373 本、Recall@K 0.791→0.807）。一方で「話題の近さでは救えない」は強まった（救済可能性 0.516→0.421 と 0.5 を下回る）。(2) **PFI が未報告であったことの訂正**：前回報告書（ヘッダ 2026-07-14）に PFI の図が入っているのを見て「前回報告済み」と書いたが、追記コミットは `cefe85a`（2026-07-15）＝ゼミ後で、配布版には入っていなかった。PFI は一度も報告していないため、動機・方法・全体結果（変数群 0.743 → 0.065、話題群 +0.006 n.s.、特化度 +0.617）から書き起こす節に改めた。あわせてケース別分解の結果—— **分野の一致の寄与ゼロは「効かない」ではなく相殺**（正しい向きのケース 1,169 件で +0.012、逆向き 414 件で −0.034 ＝シャッフルすると精度が上がる、$p = 1.3 \times 10^{-8}$）——を追加した。(3) **読み手に合わせた書き直し**：チーム内語（「変数寄り」「文章 0.7 ＋変数 0.3」）を平易化し、§ 1 に 2 段構えの説明を追加（それが無いまま「第 1 段」「候補 50 件」を使っていた）。前方参照の補足（「後述の AUC で 0.950」）と、主語のない「取り逃した正解式」を排除。修論に関する記述（用語整理の節）は進捗報告から全削除。定義のない造語「合成ケース」を「設定 B（DAE のみ 1,000 件）」に戻した。(4) **4 ページに圧縮**：本人指示により 7 ページ →4 ページ。考察節をまるごと削除し、難しい議論（選択効果＝候補内の見かけの逆相関、コサイン類似度の較正、依存ケースの属性分析）と図 2 点を落とした。残したのは仮説の検証・候補を絞った後で効かなくなること・誤りの所在・誤りの 2 型・PFI と相殺。比喩（「下駄」「足を引っ張る」「居座る」「コイン投げ」）を全て平易な表現に置換。新規スクリプト `analyze_stage1_coverage.py`（pytest 6 本）・`calibrate_similarity_scale.py`（pytest 8 本）は残し、統計は `experiments/` に保持（報告書には非掲載）。