LLM との比較の進め方と費用の見積もり（案）

作成者：M2 一洋

1 目的

数式データベースがあることを前提に、作りたいモデルに使える式をデータベースから選ぶ性能を、大規模言語モデル（large language model, LLM）と提案手法で比べる。規模の異なる 4 つのモデル（Claude Haiku 5.5、Claude Sonnet 5.5、Claude Opus 5.5、Claude Fable 5.1）を使い、モデルの規模によって精度がどう変わるかも調べる。次の 2 つの方向性で行う。

- 方向性 **1**：データベースの全 11,146 式から、LLM に式を選ばせる。
- 方向性 **2**：提案手法の第 1 段の検索が残した候補 2,000 式から、式の詳しい情報を付けて、LLM に式を選ばせる。LLM が第 2 段の検索の代わりになるかを調べる。

2 2 つの方向性に共通の条件

- 呼び出し方：Anthropic の API（application programming interface）を、設定済みの API キーでプログラムから呼ぶ。モデル名、指示文の版、設定、日時を記録し、同じ手順で再実行できるようにする。
- 例題は与えない（ゼロショット）。訓練と検証のケース（正解の分かっているケース）は渡さない。
- **1** 回の呼び出しに渡すもの：指示文、選ぶ対象の式の一覧、テストケース 1 件（説明文、入力変数、出力変数）。
- 指示文：作りたいモデルを、入力変数の値から出力変数を計算できる式の組と説明し、その式の組が満たす条件（入出力変数の包含、自由度の整合、可解性。Kato and Kano, 2025 の要件 1〜3）を書いて、一覧から式を選ばせる。
- 出力：一覧の式の ID を、モデルに使う可能性の高い順に最大 20 個。
- 出典は渡さない：式の並びを無作為にし、ID も振り直して、どの式が同じ文献から来たかを分からなくする。提案手法は出典を使っていないためである。また、合成のケースの正解集合は同じ出典の式を優先して作っているので、出典が分かると、LLM だけが答えの手がかりを持つことになる。
- 判定：返された ID が正解集合 R_q に含まれるかで判定する（式の等価性は判定しない）。一覧にない ID は不正解とし、その順位を占めるものとする。同じ ID が重なったときは、2 回目以降を除く。
- 指標：正解式の数を $K = |R_q|$、手法が並べた上位 n 件を $\mathrm{Top}_n(q)$ とし、テストケースで平均する。提案手法の値も同じ式で計算する。

$$\mathrm{Recall@20} = \frac{|R_q \cap \mathrm{Top}_{20}(q)|}{K}, \qquad \mathrm{AP@20}(q) = \frac{1}{K} \sum_{e \in R_q} P(e)$$

  ここで $P(e)$ は、正解式 e が上位 20 件にあれば、その順位までの式のうち正解式の割合、なければ 0 である。MAP@20 は AP@20 のケース平均である。
- 思考の深さ（答える前に考える量の設定）：4 モデルとも同じ値（high）にそろえる。
- 実行の順：費用を抑えるため、安い Haiku と Sonnet を先に流し、その結果を確かめてから Opus

と Fable を流す。

3 方向性 1：データベース全体から選ぶ

一覧：データベースの全 11,146 式。各式には ID、式の表記（LaTeX 形式）、分野ラベルだけを付ける。1 回の入力は約 95.2 万トークン（LLM が文字列を数える単位）で、4 モデルに共通の上限 100 万トークンに収まる。変数記号の一覧と定義、式周辺の文章は入らない（変数記号とその定義を加えるだけで、一覧は約 199 万トークンになる）。参考までに、訓練と検証のケースを例題として加えると約 130 万トークンになり、これも上限を超える。

テストケース：提案手法と同じ 10 通りの分割のテストケースを使う。例題を渡さないので、同じケースへの入力はどの分割でも同じになる。そこで、異なるケースごとに 1 回だけ解かせ、その答えを、そのケースがテストに入るすべての分割で使う。呼び出しの回数は次のとおりである（設定 A は 3 種類の評価ケース 1,823 件、設定 B は合成のケース 1,000 件で評価する設定）。

- 10 通りの分割：テストケースは設定 A と B で延べ 7,026 件、異なるケースは 1,665 件なので、呼び出しは 1,665 回。ほかの手法と同じ分割で比べられ、10 通りの分割を対にした検定もできる。
- 3 通りの分割（乱数の種 42、123、456）：延べ 2,139 件、異なるケース 1,204 件なので、呼び出しは 1,204 回。

費用：一覧の部分は毎回同じなので、プロンプトキャッシュ（同じ入力の先頭部分を保存しておき、2 回目からは通常の 1/10〜1/40 の料金で読み出す仕組み）を使う。見積もりを表 1 に示す。1 回の呼び出しには 1 分ほどかかり、8 本並べて流すと、1,665 回で 1 モデルあたり約 3〜4 時間である。

表 1 Estimated API cost of direction 1 in US dollars, assuming 2,000 output tokens per call. The range in the last row assumes 70 to 8,000 output tokens per call.

モデル	10 通りの分割（1,665 回）	3 通りの分割（1,204 回）
Claude Haiku 5.5	88	64
Claude Sonnet 5.5	194	140
Claude Opus 5.5	387	280
Claude Fable 5.1	572	414
合計	1,241（976〜2,066）	898（706〜1,494）

4 方向性 2：第 1 段の候補から選ぶ

LLM が提案手法の第 2 段の検索の代わりになるかを調べる。

一覧：テストケースごとに、提案手法の第 1 段の検索（文章類似度 0.3、変数の一致度 0.7 の重み付き和）が残した上位 2,000 式。正解式はすべて候補に入る（10 通りの分割のテストケースで、候補から漏れた正解式は 0 本）。各式には ID、式の表記、変数記号とその定義、式周辺の文章、分野ラベルを付け、出典は付けない。1 回の入力は約 44〜55 万トークンである（40 ケースで試算）。

並べ方：候補は無作為に並べ、第 1 段の点数や順位は渡さない。LLM には、自分の判断で式を選ばせる。

方向性 1 との違い：指示文、答え方、判定、指標は方向性 1 と同じである。違うのは、選ぶ対象（データベース全体ではなく候補 2,000 式）と、各式に付ける情報の多さだけである。

費用：候補はケースごとに違うので、キャッシュが効かない。1 ケースを 4 モデルで解かせると、通常の料金で約 8.3 ドル、Batch API（結果がそろうまで最大 24 時間かかる代わりに料金が半額になる方式）で約 4.1 ドルかかる。そこで、方向性 1 のテストケースから 300 件を、ケースの種類（単一出典、出典横断、合成）と正解式の数の割合を保って無作為に選び、Batch API で 1 回ずつ解かせる案とした（表 2）。提案手法と方向性 1 とは、この 300 件で比べる。方向性 2 を行うかどうかは、方向性 1 の結果を見てから決める。

表 2　Estimated API cost of direction 2 in US dollars for 300 test cases, one call per case through the Batch API, assuming 490,000 input tokens and 2,000 output tokens per call.

モデル	300 件
Claude Haiku 5.5	38
Claude Sonnet 5.5	150
Claude Opus 5.5	300
Claude Fable 5.1	750
合計	約 1,240（1,130〜1,390）

参考までに、異なるテストケース 1,665 件をすべて解かせると、Batch API でも約 6,900 ドルかかる。

5　確認したいこと

1. 方向性 1 のテストケースを、10 通りの分割（1,665 回、約 1,240 ドル）にするか、3 通りの分割（1,204 回、約 900 ドル）にするか。
2. 方向性 2 を行うか。行う場合、300 件を 1 回ずつでよいか。
3. 4 つのモデル（Haiku 5.5、Sonnet 5.5、Opus 5.5、Fable 5.1）でよいか。

参考文献

S. Kato and M. Kano. Automated physical model building from literature sources: Combining equations based on four predefined requirements. *Computers & Chemical Engineering*, 200:109147, 2025.