

追補報告：自由度解析による訓練データ品質改善と Set-aware グラフ特徴量の提案

かずひろ

2026 年 4 月 19 日

本資料の位置づけ：本資料は 2026 年 4 月 13 日提出の進捗報告（4 月 17 日改訂版、以下「前回報告」）の追補である。前回報告後に実施した (1) 訓練データ品質改善, (2) グラフ特徴量の診断と再設計, (3) 複数次組合せ評価に関する新しい成果を報告する。前回報告で記載した手法・結果と重複する部分は省略している。

1 前回報告からの主な変更点

前回報告の主要結果は、1,107 訓練ケース・3,244 式で reranker-10（グラフ特徴量あり）が MRR 0.949 ± 0.031 を達成するというものであった。その後の精査により、以下の重要な問題と改善機会が判明した。

1. 訓練データに物理的に解けないケースが含まれていた：前回報告で指摘した「random_io の自由度未検証」の問題を定量的に確認し、1,107 ケース中約 400 ケースが自由度不整合（解くべき変数の数が方程式の数より多い）であった。
2. 既存のグラフ特徴量（f7–f9）がクリーンなデータでは有効に機能しない：自由度検証後に再評価したところ、reranker-10 が最良ではなくなり、reranker-7（基本 7 特徴量のみ）を下回るようになった。この結果は、従来の結論がデータ品質の問題と絡んでいた可能性を示唆する。
3. 評価指標が複数次の組合せ能力を測っていなかった：訓練ケースの 44% は 2 式以上が正解にも関わらず、MRR は「最初に見つかった正解の順位」しか見ておらず、複数次を揃える能力は評価されていなかった。
4. Set-aware 特徴量の導入で明確な改善：候補式同士の組合せを捉える 3 つの新特徴量（gComp, gCoh, gDom）を設計し、複数次タスクで統計的に有意な改善（ $p < 0.05$ ）を確認した。

2 訓練データの品質改善：自由度解析の適用

2.1 自由度解析の定義

各訓練ケースについて、正解式集合の変数を V_{model} 、入力変数（既知）を V_{in} 、出力変数（解を求める対象）を V_{out} とする。以下の全条件を満たすケースのみを採用する。

1. $V_{\text{in}} \subseteq V_{\text{model}}$ （入力変数は全て式中に現れる）

2. $V_{\text{out}} \subseteq V_{\text{model}} \setminus V_{\text{in}}$ (出力変数は全て未知側)
3. $|V_{\text{model}} \setminus V_{\text{in}}| \leq \text{正解式の本数}$ (式の数が未知数以上で物理的に解ける)

2.2 フィルタ適用結果

1,107 初回ケースのうち、上記 3 条件を全て満たしたのは 707 ケース (63.9%) であった。除外の主な原因は次の通り：

- **swap_io**: 123 件中 121 件 (98%) が除外。LLM 生成元ケースの入出力変数数が元々非対称な例が多く、スワップで自由度不整合が頻発した。
- **random_io**: 492 件中 159 件 (32%) が除外。ランダム I/O 割当てで未知数が方程式数を上回るケースが多かった。
- **original / context_paraphrased**: それぞれ約 25% が除外。LLM が生成した元ケース自体に入出力変数の誤りがあった例。

2.3 可解ケースの追加生成で 1,107 件に復元

除外によるデータ不足を補うため、各コアケースについて「正解式集合の変数 V から方程式数 n_{eq} 個を出力として選び残りを入力とする」アルゴリズム (自由度 = 0 を構成上保証) で 400 件の random_io を追加生成した。

表 1 自由度検証後の訓練データ内訳 (最終 1,107 ケース)

バリエーション	初回生成	最終採用	備考
original	123	93	LLM 生成の一部を除外
context_paraphrased	369	279	同上
swap_io	123	2	98% 除外 (手法自体が限定的)
random_io_from_models	492	733	フィルタ後 + 追加生成
合計	1,107	1,107	全件自由度 = 0 保証

2.4 自由度検証後の主要手法 MRR 再評価

同一の評価プロトコル (5 seed, source_id 分割) で baseline / reranker-7 / reranker-10 を再評価した結果は次の通り：

表 2 自由度検証後 1,107 ケースでの主要手法 MRR

手法	初回データ MRR	検証済データ MRR	変化
baseline	0.924 ± 0.040	0.937 ± 0.045	+0.013
reranker-7	0.937 ± 0.018	0.959 ± 0.036	+0.022
reranker-10	0.949 ± 0.031	0.939 ± 0.049	-0.010

重要な観察：

- 全手法で MRR が向上しており，自由度検証が学習と評価の品質を上げている。
- 一方で，**reranker-10** の優位性は消失し，**reranker-7** が最良となった。
- これは従来「グラフ特徴量が有効」とされてきた主張が，物理的に解けない不正ケースに依存していた可能性を示す。グラフ特徴量の現行設計（f7: 2 ホップ到達率，f8: 近傍 Jaccard，f9: 間接ブリッジ比率）を見直す必要がある。

3 既存グラフ特徴量の診断

既存 3 特徴量の識別力を診断するため，Stage 1 Top-50 候補ペアを収集し，各特徴量の正例/負例分布および単独 AUC を分析した。

表 3 特徴量別の単独 AUC (test set の Stage 1 Top-50 候補ペア)

特徴量	正例平均	負例平均	AUC
f1_io_jaccard (基本)	0.710	0.147	0.977
f5_reverse_cov (基本)	0.979	0.300	0.977
f3_input_cov (基本)	0.720	0.214	0.907
f2_svd_cos (基本)	0.426	0.160	0.820
f0_tfidf_cos (基本)	0.162	0.072	0.794
f6_domain_match (基本)	0.164	0.066	0.549
f7_2hop_reach (グラフ)	0.995	0.798	0.644
f8_neighbor_jaccard (グラフ)	0.733	0.364	0.810
f9_bridge_ratio (グラフ)	0.021	0.525	0.087

発見：

1. **f9_bridge_ratio** は AUC **0.087** で逆信号：正例では値が低く（平均 0.021）負例で高い（平均 0.525）。学習時にモデルを混乱させる要因となる。
2. **f7_2hop_reach** は値が飽和：正例 99.5%，負例 79.8% と両方とも高く，ユニーク値は 21 個のみで識別力が低い。
3. **f8_neighbor_jaccard** は f1/f5 と高相関（それぞれ 0.63, 0.70）で冗長。

これらの知見から，現行グラフ特徴量は「候補単体」を評価する設計であり，かつ基本特徴量と冗長または逆信号であるため，本タスクに効果的でないことが判明した。

4 Set-aware グラフ特徴量の設計

既存グラフ特徴量の限界を踏まえ，**候補同士の組合せを捉える**新しい特徴量を設計した。前提として，複数式の正解集合では「式同士が同じ物理モデルを記述」する関係があり，この情報を特徴量として取り込むのが狙いである。

4.1 3つの Set-aware 特徴量の定義

Stage 1 でランク付けされた上位 $K_{\text{ref}} = 5$ 件を参照集合 $\mathcal{S}$ とする。候補 c について、以下の 3 特徴量を計算する（候補自身が $\mathcal{S}$ に含まれる場合は除外）。

$$\text{gComp (補完性)} : \frac{|(V_c \cap V_q) \setminus \bigcup_{s \in \mathcal{S}} V_s|}{|V_q|}$$

候補が参照集合に欠けているクエリ変数をどれだけ補うかを測る。複数式の正解集合は互いに異なる変数を扱うため、補完性の高い候補が正解である可能性が高い。

$$\text{gCoh (一貫性)} : \frac{|V_c \cap \bigcup_{s \in \mathcal{S}} V_s|}{|V_c|}$$

候補の変数のうち、参照集合と共有される割合。同じ物理モデルを記述する式群は変数を共有しやすいため、一貫性の高い候補は「同じモデル群」の一員である可能性が高い。

$$\text{gDom (ドメイン一致)} : \frac{|\{s \in \mathcal{S} : \text{dom}(s) = \text{dom}(c)\}|}{|\mathcal{S}|}$$

候補と同じドメイン（分野）ラベルを持つ参照候補の割合。同ドメインに複数候補が集中していれば、そこに正解集合が密集している可能性が高い。

ここで V_c, V_s は式の変数集合、 V_q はクエリの入出力変数集合、 $\text{dom}(\cdot)$ は式のドメインラベルである。

4.2 reranker-10S の構成

既存グラフ特徴量の有害性を考慮し、新手法 **reranker-10S** は基本 7 特徴量 + Set-aware 3 特徴量の 10 次元構成とする（reranker-10 の既存グラフ 3 特徴量は含まない）。

$$\text{reranker-10S} = \underbrace{\text{基本 7}}_{\text{TF-IDF, Jaccard, SVD, 被覆率等}} + \underbrace{\text{Set-aware 3}}_{\text{gComp, gCoh, gDom}}$$

5 評価結果

5.1 複数式評価指標の導入

従来の MRR（最初に見つかった正解の順位の逆数）は単発 retrieval の能力を測るが、複数式の組合せを揃える能力は測らない。本研究の訓練データの 44% は 2 式以上の正解を持つため、以下の指標を追加で導入した。

MRR_worst

各ケース内の最下位の正解の逆順位。全ての正解を上位に揃える能力を測る。

FullRecall@K

全正解が上位 K 件内に含まれるケースの割合。

MAP (Mean Average Precision)

情報検索の標準指標。複数正解の順位を総合的に評価する。

複数式のみ MRR_worst / FullRecall@3

2 式以上正解のケース（483 件）に限定した評価。

5.2 5 seed 評価：set-aware 特徴量の効果

表 4 5 seed 評価結果（自由度検証済 1,107 ケース）

手法	MRR_first	FullR@3	MAP	複数式 FullR@3	複数式 MRR_worst
baseline	0.937	0.849	0.932	0.571	0.364
reranker-7	0.959	0.881	0.953	0.649	0.391
reranker-10（既存グラフ）	0.939	0.885	0.947	0.656	0.393
reranker-10S（set-aware）	0.981	0.904	0.974	0.713	0.409

reranker-10S が全指標で最良。特に複数式タスクの FullR@3 で +6.4%，複数式 MRR_worst で +1.8% の改善を示した。

5.3 アブレーション：各 Set-aware 特徴量の寄与

表 5 Set-aware 特徴量の個別寄与（5 seed, 単独追加）

手法	MRR_first	FullR@3	複数式 FullR@3	複数式 MRR_worst
reranker-7	0.959	0.881	0.649	0.391
reranker-7+gComp	0.974	0.873	0.633	0.387
reranker-7+gCoh	0.959	0.866	0.618	0.388
reranker-7+gDom	0.961	0.900	0.705	0.402
reranker-10S（全 3）	0.981	0.904	0.713	0.409

各特徴量の役割：

- **gDom（ドメイン一致）** が複数式タスクの主力。単独で複数式 FullR@3 を +5.6% 押し上げる。
- **gComp（補完性）** は単発 MRR を +1.5% 向上させるが、複数式では単独では逆効果（-1.6%）。
- **gCoh（一貫性）** は単独では効果が弱いですが、組合せ時には寄与する。
- 3 特徴量の組合せが最良：単独のどれよりも良い（明確な相乗効果）。

5.4 10 seed 評価と統計的有意性

5 seed での成果が偶然でないことを確認するため、10 seed で再評価し、対応 t 検定（paired t-test）で有意性を計算した。

結論：

- MAP の改善は高い有意性（ $p = 0.004$, 9 勝 1 分 0 敗）で、最も頑健な成果。
- 複数式 FullR@3 と 複数式 MRR_worst は統計的に有意（ $p < 0.05$, 片側）。
- 「複数式タスクで set-aware グラフ特徴量が有効」という主張は統計的に支持される。
- MRR_first は差分は正だが有意差なし（単発タスクでは base 7 で既に頭打ちに近い）。

表 6 10 seed 評価：reranker-10S vs reranker-7 の差分と有意性 (paired t -test)

指標	r7 平均	r10S 平均	差分	t 値	p 値 (片側)	判定
全体 MRR_first	0.955	0.965	+0.010	1.28	0.116	有意差なし
全体 FullR@3	0.826	0.854	+0.028	2.25	0.025	★ 有意 ($p < 0.05$)
MAP	0.936	0.955	+0.019	3.46	0.004	★★ 高い有意性
複数式 FullR@3	0.628	0.693	+0.065	2.12	0.032	★ 有意
複数式 MRR_worst	0.376	0.397	+0.021	2.28	0.024	★ 有意
複数式 MRR_first	0.936	0.953	+0.018	1.04	0.162	有意差なし

表 7 10 seed 間の勝敗

指標	r10S 勝	同点	r10S 負
MAP	9	1	0
複数式 FullR@3	7	1	2
全体 MRR_first	7	1	2
全体 FullR@3	6	2	2
複数式 MRR_worst	6	1	3

6 考察

6.1 なぜ既存グラフ特徴量は効かず、Set-aware は効くのか

既存の f7-f9 は「候補式とクエリ変数との関係」を測る。しかし、クエリ変数との関係は f1 (Jaccard) や f5 (逆被覆率) など基本特徴量で既に強く捉えられており、グラフ経由の間接情報は冗長となる (f7/f8)。f9 に至っては正例で低く負例で高いという逆信号を示した。

一方 Set-aware 特徴量は「候補式と他の候補式との関係」を測る。これは基本特徴量が全く捉えていない情報源であり、特に複数式の組合せ能力評価において有効である。

6.2 複数式タスクにおける GNN/グラフ情報の価値

本研究の訓練ケースの 44% は 2 式以上の正解を持つ。このような複数式組合せ retrieval では、単一の式の「クエリとの類似度」だけでは不十分で、候補同士の相補性や一貫性が重要となる。Set-aware 特徴量はこの直観を直接定式化したものであり、複数式 FullR@3 で +6.5% という大きな改善を示した。

これは、当初の研究動機である「数式間の変数共有関係から物理モデル群を同定する」という GNN/グラフベース手法の価値を複数式タスクで明確に示す結果である。

6.3 従来結論の修正

前回報告での「reranker-10 (既存グラフ特徴量あり) が最良」という結論は、自由度検証済みデータでは成立しない。一方で本追補で示した「set-aware 特徴量を用いた reranker-10S が最良」という結論は、統計的有意性を伴って支持される。すなわち、グラフ情報の活用方針を見直すことで、

GNN ベース手法の価値は依然として示せるというのが現段階の結論である.

7 論文化の方向性

1. 主題: 「Set-aware graph features for multi-equation physical model retrieval」
2. 主要な貢献:
 - 訓練データの自由度解析による品質改善手法の提案
 - 候補間関係を捉える set-aware グラフ特徴量の設計
 - 複数式 retrieval 評価指標の導入と統計的有意性の確認
3. 結果のハイライト:
 - MAP: 0.936 $\rightarrow$ 0.955 ($p = 0.004$)
 - 複数式 FullR@3: 0.628 $\rightarrow$ 0.693 ($p = 0.032$)
 - 既存グラフ特徴量 (f7-f9) の限界と新設計の必要性を診断で示す
4. ネガティブ結果も含む誠実な記述:
 - 既存グラフ特徴量は自由度検証済みデータでは逆効果となった事実を報告.
 - データ品質改善 (自由度解析) による改善も主効果として明示.

8 今後の計画 (更新版)

優先度	項目	目的
高	論文執筆 (本追補の成果を中心に)	Set-aware 特徴量の意義を主題に
高	Set-aware 特徴量の拡張	参照集合サイズ K_{ref} の最適化, listwise 学習の検証
中	訓練ケース増強 (123 $\rightarrow$ 200+ コア)	API 失敗分 2 バッチの再実行
中	swap_io の再設計	入出力対称性を持つ元ケースのみで再生成
低	5,000 式超への拡大	スケーリング曲線の飽和点同定
低	変数記述の意味類似度 (CodeBERT)	表記揺れ対応の学習的アプローチ