

進捗報告 v6 (追補) : データベース拡大・難ケース追加・ 評価指標の精緻化による Set-aware GNN リランカーの頑健 性検証

宮村 和大

2026 年 6 月 2 日

本資料の位置づけ：本資料は 2026 年 5 月 18 日提出の進捗報告 v5 (以下「前回報告」) の追補である。前回報告と重複する手法・背景の説明は省き、新規結果に絞る。数値はすべて experiments/ 配下の実験 JSON で確認した実測値であり、10 シード (source_id 単位で訓練/評価を分割しリークを防止) で評価した。

1 前回報告 (v5) からの変更点

- データを 3.4 倍に拡大：収録数式 3,244 → 11,146 式、訓練ケース 1,107 → 2,838 件。うち微分代数方程式系 (DAE) を模した難ケースを 1,000 件新規追加 (図 1)。
- 主指標を $\text{Recall}@K_{\text{correct}}$ に変更：天井で飽和する $\text{MRR}_{\text{first}}$ が隠していた差を可視化する指標 (情報検索の R-precision と同義) を採用。
- 難ケースほど本手法の優位が拡大：baseline との $\text{Recall}@K_{\text{correct}}$ 差は標準 +0.127 → DAE のみ +0.217 (図 2)。改善は複数式・多変数のケースに集中する (図 3a)。
- 仮説 B (分野横断収集の要否) を再検定し結論を訂正：v5 は $\text{MRR}_{\text{first}}$ で「差なし」としたが、 $\text{Recall}@K_{\text{correct}}$ ではフル DB が有意に優れる (+0.048, $p = 0.044$; 図 3b)。加えて 13 通りのハイパーパラメータで頑健 (§4.3)。
- 難易度別の LLM 比較と精度向上：難ケースを LLM 直接生成と同条件比較した結果、全設定で本手法 > baseline > LLM (図 2) で、最難 DAE でも本手法は LLM の約 2.6 倍。さらに Stage1 の天井診断に基づき、候補数 top- k 拡大と集合選択 (greedy 逐次選択) で DAE の厳格 $\text{Recall}@K_{\text{correct}}$ を 0.745 → 0.792 (+0.048)、実用 $\text{Recall}@20$ を 0.89 → 0.95 に改善した (§5)。

2 データセット：規模・内訳・難易度

データ規模と構成を図 1 に示す。訓練ケースは 2,838 件、うち 74.6% が正解に 2 式以上を要する複数式ケースであり、「式を組合せとして選ぶ」本手法の主戦場となっている。

新規追加した DAE 難ケース (1,000 件、Anthropic Claude Sonnet 4.5 で生成) は、物理モデルとして典型的な「常微分方程式 (ODE) + 付随する代数式」の連立を模す。生成手順は、(i) ODE を 1 本選んで正解集合の種とし、(ii) 同一文献内で変数を共有する式 (速度式・物性式など) を正解集合に追加し、(iii) 正解式数が $X \in \{1, \dots, 10\}$ に達するまで反復、(iv) 各式の代表変数を出力に加え

て自由度ゼロ（入力数 + 方程式数 = 出力数 + 既知数）を構成上保証する、というものである。たとえば連続槽型反応器（CSTR）で槽内濃度 $C_A(t)$ と反応速度 r_A を求める問題は、物質収支 ODE $V dC_A/dt = F(C_{A0} - C_A) - V r_A$ と Arrhenius 速度式 $r_A = k C_A$, $k = A \exp(-E/RT)$ を組合せて初めて解ける。




図 1 データセットの規模・内訳と難易度分布. (a) 訓練ケース 2,838 件の variant 別構成 (DAE 1,000 件を新規追加, 緑). (b) 正解式数の分布: 複数式 (2 式以上, 青) が全体の 74.6%.

3 評価指標 $\text{Recall}@K_{\text{correct}}$ の導入

従来の主指標 MRR_first (最初に当たった正解の順位の逆数) は、正解が 1 件でも上位に来れば 1.0 に近づくため、複数式を揃える能力を測れず、天井付近で飽和して手法間の差を覆い隠す。本版では、正解式が n_{correct} 件あるとき上位 $K = n_{\text{correct}}$ 件の正解割合 $\text{Recall}@K_{\text{correct}} = |\text{Top-}K \cap \mathcal{R}_q| / |\mathcal{R}_q|$ ($\mathcal{R}_q$ は正解集合, 情報検索の R-precision と同義) を主指標とする。「必要な式をちょうどその本数だけ上位に並べられたか」を直接測り、飽和しにくい。補助指標として MAP (平均適合率), MRR_first も併記する。

4 実験結果

4.1 難易度勾配: 難ケースほど優位が拡大

評価集合に占める難ケースの比率を 3 段階に変えて、baseline (古典 IR, Stage 1) ・ LLM 直接生成 ・ reranker-10S (本手法, Stage 2) の三者を比較した (図 2)。全 3 設定で **reranker-10S** > **baseline** > **LLM** の順であり、難ケースが増えると baseline は $\text{Recall}@K_{\text{correct}}$ が $0.79 \rightarrow 0.48$ へ、LLM はさらに急に $0.54 \rightarrow 0.26$ へ落ちる一方、本手法は $0.91 \rightarrow 0.70$ と緩やかにしか落ちない。本手法は LLM を全設定で $+0.37 \sim 0.45$ 上回り、最難の DAE でも 0.70 (LLM の約 2.6 倍) を保つ。数式グラフ上で式を組合せとして評価する発想が、難しい組合せ問題でこそ効くことを示す。なお $\text{Recall}@K_{\text{correct}}$ は上位ちょうど K 件に正解を全て揃える最も厳しい指標である。実用上の「上位 20 件に必要な式が含まれるか」を測る $\text{Recall}@20$ は本手法で 広域 0.99 / +DAE 0.91 / DAE のみ 0.86 に達し、最難の DAE でも人手レビュー前提なら実用域にある。




図2 難ケース比率の異なる3設定での三者比較 ($\text{Recall}@K_{\text{correct}}$). 全設定で $\text{reranker-10S} > \text{baseline} > \text{LLM}$. baseline・本手法は10シード平均 (エラーバー=標準偏差), LLMはX層化サンプル (24-39件) での評価. 赤は本手法と LLM の差.

4.2 本手法はどこで効くか／なぜ指標を変えたか

図3(a)は正解式数別の $\text{Recall}@K_{\text{correct}}$ である. 単一式では **baseline** が既に高く本手法の上乗せはほぼ無い (+0.02) が, 複数式では +0.21 ~ 0.26 の大幅改善を示す. 入力変数が多い (11 以上) ケースでも同様に +0.245 改善する. 本手法は「易しい問題を壊さず, 難しい組合せ問題で効く」という望ましい振舞いを持つ.

図3(b)は, 加納先生のご指摘「分野横断的に収集する必要はない」(仮説B)の再検定である. v5は MRR_first がフルDBと化学工学限定DBでほぼ同じ (差 +0.003) であったため「DB規模の影響なし」としていた. しかし飽和しない $\text{Recall}@K_{\text{correct}}$ ではフルDB (11,146式・全分野) が限定DBを有意に上回る (0.923 vs 0.875, 差 +0.048, 対応のある t 検定 $p = 0.044$, Wilcoxon $p = 0.037$, 効果量 Cohen's $d = 0.74$ 中程度). すなわち v5の暫定結論は指標選択の副作用であり, 広く集める方針の妥当性が支持された (ただし差は中程度で, 限定DBでも $\text{Recall}@K_{\text{correct}} = 0.87$ の実用水準には達する).

4.3 ハイパーパラメータ頑健性

「本手法の優位は脆弱なチューニングの産物では」という査読上の懸念に対し, 学習率 (10^{-4} – 10^{-2}), 隠れ層次元 (64/128/256), epoch (20/40), margin (0.1/0.3) を振った13設定で $\text{Recall}@K_{\text{correct}}$ を測った. 全13設定が 0.732–0.742 の狭い範囲に収まり, 設定間レンジ 0.0094 はシード間標準偏差 (約 0.097) の約 1/10 にすぎない. 本手法の強さは特定のチューニングに依存せず頑健である.

本手法はどこで効くか／なぜ Recall@K_{correct} を主指標にしたか




図 3 (a) 正解式数別の Recall@K_{correct} : 改善は複数式・複雑な問題ほど大きい. (b) 仮説 B の再検定: 飽和した MRR_first では差が見えないが, Recall@K_{correct} ではフル DB が有意に優位 ($p = 0.044$).

4.4 外部ベースライン: LLM 直接生成との同一条件比較

「LLM で直接解けるなら本手法は不要では」という加藤先生のご指摘に答えるため, 大規模言語モデル (Claude, Sonnet 系) を問題を解く側として用い, 背景文と入出力変数のみから数式を生成させて現行 11,146 式 DB と照合した (本研究で LLM を使うのはケース生成のみで, 検索タスクには使わない). 比較対象の baseline・reranker-10S も同一サブセット・同一 DB で再評価した (リーク防止のため対象ケースをテスト分割でのみ評価).

結果を図 4 に示す. 易しい単一ソースでは検索系 (両 Stage) が LLM を圧倒する (Recall@K_{correct} で baseline 0.982 / reranker 0.975 vs LLM 0.707). 一方難しい複数ソースでは, 古典 IR 単独は LLM を下回る ($0.575 < 0.842$) が, reranker-10S は baseline を +0.367 改善して LLM をも上回る (0.942). 文章類似度だけでは複数文献の式を組合せられず, Set-aware リランカーが本質的に必要であることを同一条件で実証した. なお本比較は単一 29 件・複数 20 件の小規模・held-out 評価 (1 ケースあたり平均約 1-2 シード) であり, 傾向の確認と位置づける.

5 精度向上: 天井診断・top-k 拡大・集合選択 (greedy)

最難の DAE で Recall@K_{correct} が 0.70 前後に留まる点について, 原因を診断し改善を試みた. まず Recall@K_{correct} は上位ちょうど K 件に正解を全て揃える最も厳しい指標であり, 実用的な Recall@20 (上位 20 件に必要な式が含まれるか) は本手法で DAE でも 0.86 ある点を再確認しておく.

診断: reranker は Stage1 が返す上位 K 候補のみを再順位付けするため, 到達上限は「正解式が上位 K に retrieve される割合」である. 図 5(a) のとおり DAE では Stage1 Recall@50 = 0.86 (高 X ケースで取りこぼし, $X=10$ で 0.68) で, top-200 では 0.96 まで上がる.

改善: 候補数 top- k を 50 $\rightarrow$ 200 に拡大して reranker-10S を再評価した (図 5(b)). 実用指




図 4 LLM 直接生成 vs baseline(Stage1) vs reranker-10S(Stage2) の同一条件比較 (Recall@ K_{correct} , 現行 11,146 式 DB). 複数ソースで baseline < LLM < 本手法.

標 **Recall@20** は $0.912 \rightarrow 0.968$ と明確に向上し, 厳しい Recall@ K_{correct} も $+0.02$ 改善した. Recall@ K_{correct} の伸びが小さいのは, 候補が揃っても上位ちょうど K 件に並べる順位付け (**Stage2**) が律速であるため. アブレーション (図 7) が示すとおり, 補完性・一貫性を軸とした Stage2 強化 (hard negative サンプリング・listwise 学習) が次の有力な打ち手である.

精度向上 — Stage1 の天井診断と top-k 拡大




図 5 精度向上. (a) Stage1 の retrieval 天井 (DAE): 既定 top-50 では正解の 14% を取りこぼす. (b) top- k を $50 \rightarrow 200$ に拡大すると Recall@20 が $0.912 \rightarrow 0.968$, Recall@ K_{correct} も $+0.02$ 改善 (reranker-10S, DAE, 3 シード).

■集合としての選択 (greedy 逐次選択) top- k 拡大でも厳格 Recall@ K_{correct} は $+0.02$ に留まる. 診断のとおり, 候補は上位に揃う一方でそれらをちょうど上位 K 件に「集合として」選ぶことが律速だからである. まず Stage2 の標準的強化を試したが, **hard negative** マイニング・listwise 損失・出力補完特徴 **gOutNov** はいずれも Recall@ K_{correct} を ≤ 0.006 しか動かさなかった (図 6a; 候補を独立にスコアする限り集合選択を表現できない). 一方, 学習済みモデルをそのまま使い, 1 式

選ぶごとに **set-aware** 特徴量を「既選択集合」を参照に再計算して次を選ぶ **greedy** 逐次選択を推論時に導入すると、 $\text{Recall}@K_{\text{correct}}$ が +0.018 改善した (3 つの特徴量構成で一貫). 効いた 2 レバー (top- k 拡大と greedy) を結合すると、DAE で $\text{Recall}@K_{\text{correct}}$ 0.745 $\rightarrow$ 0.792 (+0.048, +6.4%), 実用 $\text{Recall}@20$ 0.887 $\rightarrow$ 0.953 に達した (図 6b, 5 シード). 「集合としての選択」を陽に行うことが厳格指標を動かす鍵であると実証された.




図 6 Stage2 強化で何が厳格 $\text{Recall}@K_{\text{correct}}$ を動かすか. (a) 損失・負例・特徴の標準的改良は無効 (≤ 0.006 , 3 シード), 集合選択を陽に行う **greedy** 逐次選択のみ +0.018. (b) 効いた 2 レバー (top- k 拡大 + greedy) の結合で $\text{Recall}@K_{\text{correct}}$ +0.048 $\cdot$ $\text{Recall}@20$ +0.066 (5 シード).

6 補遺：特徴量アブレーションとシード分散

どの特徴量が効くか (図 7)：基本 7 特徴量に gComp (補完性) $\cdot$ gCoh (一貫性) $\cdot$ gDom (ドメイン一致) を単独／全部追加して比較した (+DAE, 3 シード). **gComp $\cdot$ gCoh** が各 +0.05 の主力で, gDom 単独はほぼ寄与しない (むしろ微減). 3 つ全て (reranker-10S) が最良であり, 補完性・一貫性が本手法の中核であることを示す. これは gDom の再設計が改善余地であることも示唆する.

シード分散 (図 8)：3 設定とも全 10 シードで **reranker-10S** が **baseline** を上回り, 箱の重なりも小さい. 優位は特定シードの偶然でなく分散に埋もれない安定したものである.

(注：図 F $\cdot$ 図 G は 3 シードのため絶対値は本文の 10 シード値とやや異なるが, モード間 $\cdot$ top- k 間の相対比較は妥当である.)

7 考察と今後の方針

- なぜ効くか：DAE $\cdot$ 複数次式 $\cdot$ 多変数のケースは単独式の文章類似度では絞れず, 式どうしの変数共有 (補完性 $\cdot$ 一貫性) という構造情報が効く. 易しい問題は **baseline** が天井のため上乗せは小さい (図 3a).
- 指標の重要性：MRR_first の飽和は DB 規模の効果 (仮説 B) も改善幅も隠していた. $\text{Recall}@K_{\text{correct}}$ への切替で初めて両者が可視化された.
- 頑健性と外部比較：13 設定で差が出ないことは優位が構造的な特徴量そのものに由来することを示す. LLM 直接生成との比較では全難易度で **reranker** $>$ **baseline** $>$ **LLM** であり, 難ケースほ




図7 Set-aware 3 特徴量のアブレーション (+DAE, 3 シード). gComp・gCoh が主力, gDom 単独は寄与薄, 3 つ全て (10S) が最良.




図8 3 設定での Recall@K_{correct} のシード別分布 (10 シード, 点は各シード). 全シードで reranker-10S が baseline を上回る.

ど LLM が大きく劣化する (古典 IR でも LLM でも足りず, 本手法が必要).

- 精度の上限と改善 (診断 → 失敗 → 成功): DAE の厳格 Recall@K_{correct} は, 候補は上位に揃う (Recall@20 = 0.91) 一方それらをちょうど上位 K 件に「集合として」選ぶことが律速である. Stage2 の標準的強化 (hard negative・listwise・gOutNov) は無効 (≤ 0.006 , 独立スコアリングでは集合選択を表現できない) だったが, 診断どおり集合選択を陽に行う greedy 逐次選択は +0.018, top- k 拡大と結合すると DAE で Recall@K_{correct} 0.745 → 0.792 (+0.048), 実用 Recall@20 0.887 → 0.953 に達した (§5, 図 6). 独立スコアリングの限界を「集合としての選択」で破れることを実証した.
- 今後: (1) 修論・論文「Set-aware graph features for multi-equation physical model retrieval」の執筆, (2) greedy を学習段階にも導入 (既選択集合を参照する特徴で teacher forcing 学習) して効果を増幅し, 候補集合への注意機構 / GNN へ発展, (3) 変数記述の意味類似度による表記揺

れの学習的吸収.

8 まとめ

データベースを 11,146 式・2,838 ケースに拡大し DAE 難ケースで難易度勾配を作ったところ, 難しい問題ほど **Set-aware** リランカーの優位 ($\text{Recall}@K_{\text{correct}}$) が $+0.13 \rightarrow +0.22$ と拡大した. 飽和しない $\text{Recall}@K_{\text{correct}}$ により分野横断収集の効果 (仮説 B, $+0.048$, $p = 0.044$) が新たに有意と判明し v5 の暫定結論を訂正, ハイパーパラメータにも頑健であった. 外部の LLM 直接生成とは全難易度で本手法 $>$ **baseline** $>$ **LLM** (最難 DAE で本手法は LLM の約 2.6 倍) で, 「LLM で直接解けるなら不要」との懸念を明確に否定した. DAE で $\text{Recall}@K_{\text{correct}}$ が低めなのは指標が厳格なため, 集合選択 (**greedy** 逐次選択) と **top- k** 拡大により厳格 $\text{Recall}@K_{\text{correct}}$ を $0.745 \rightarrow 0.792$ ($+0.048$)・実用 $\text{Recall}@20$ を $0.89 \rightarrow 0.95$ に改善した. 独立スコアリングの限界を「集合としての選択」で破れることを実証した.