

進捗報告 v6 (追補) : データベース拡大・難ケース追加・ 評価指標の精緻化による Set-aware GNN リランカーの頑健 性検証

宮村 和大

2026 年 6 月 2 日

本資料の位置づけ：本資料は 2026 年 5 月 18 日提出の進捗報告 v5 (以下「前回報告」) の追補である。前回報告と重複する手法・背景の説明は省き、新規結果に絞る。数値はすべて experiments/ 配下の実験 JSON で確認した実測値であり、10 シード (source_id 単位で訓練/評価を分割しリークを防止) で評価した。

1 前回報告 (v5) からの変更点

- データを 3.4 倍に拡大：収録数式 3,244 → 11,146 式、訓練ケース 1,107 → 2,838 件。うち微分代数方程式系 (DAE) を模した難ケースを 1,000 件新規追加 (図 1)。
- 主指標を $\text{Recall}@K_{\text{correct}}$ に変更：天井で飽和する $\text{MRR}_{\text{first}}$ が隠していた差を可視化する指標 (情報検索の R-precision と同義) を採用。
- 難ケースほど本手法の優位が拡大：baseline との $\text{Recall}@K_{\text{correct}}$ 差は標準 +0.127 → DAE のみ +0.217 (図 2)。改善は複数式・多変数のケースに集中する (図 3a)。
- 仮説 B (分野横断収集の要否) を再検定し結論を訂正：v5 は $\text{MRR}_{\text{first}}$ で「差なし」としたが、 $\text{Recall}@K_{\text{correct}}$ ではフル DB が有意に優れる (+0.048, $p = 0.044$; 図 3b)。加えて 13 通りのハイパーパラメータで頑健、外部の LLM 直接生成も上回る (図 4)。

2 データセット：規模・内訳・難易度

データ規模と構成を図 1 に示す。訓練ケースは 2,838 件、うち 74.6% が正解に 2 式以上を要する複数式ケースであり、「式を組合せとして選ぶ」本手法の主戦場となっている。

新規追加した DAE 難ケース (1,000 件, Anthropic Claude Sonnet 4.5 で生成) は、物理モデルとして典型的な「常微分方程式 (ODE) + 付随する代数式」の連立を模す。生成手順は、(i) ODE を 1 本選んで正解集合の種とし、(ii) 同一文献内で変数を共有する式 (速度式・物性式など) を正解集合に追加し、(iii) 正解式数が $X \in \{1, \dots, 10\}$ に達するまで反復、(iv) 各式の代表変数を出力に加えて自由度ゼロ (入力数 + 方程式数 = 出力数 + 既知数) を構成上保証する、というものである。たとえば連続槽型反応器 (CSTR) で槽内濃度 $C_A(t)$ と反応速度 r_A を求める問題は、物質収支 $\text{ODE } V dC_A/dt = F(C_{A0} - C_A) - Vr_A$ と Arrhenius 速度式 $r_A = k C_A$, $k = A \exp(-E/RT)$ を組合せて初めて解ける。

図A：データセットの規模・内訳と難易度分布




図 1 データセットの規模・内訳と難易度分布. (a) 訓練ケース 2,838 件の variant 別構成 (DAE 1,000 件を新規追加, 緑). (b) 正解式数の分布: 複数式 (2 式以上, 青) が全体の 74.6%.

3 評価指標 $\text{Recall}@K_{\text{correct}}$ の導入

従来の主指標 $\text{MRR}_{\text{first}}$ (最初に当たった正解の順位の逆数) は, 正解が 1 件でも上位に来れば 1.0 に近づくため, 複数式を揃える能力を測れず, 天井付近で飽和して手法間の差を覆い隠す. 本版では, 正解式が n_{correct} 件あるとき上位 $K = n_{\text{correct}}$ 件の正解割合 $\text{Recall}@K_{\text{correct}} = |\text{Top-}K \cap \mathcal{R}_q| / |\mathcal{R}_q|$ ($\mathcal{R}_q$ は正解集合, 情報検索の R-precision と同義) を主指標とする. 「必要な式をちょうどその本数だけ上位に並べられたか」を直接測り, 飽和しにくい. 補助指標として MAP (平均適合率), $\text{MRR}_{\text{first}}$ も併記する.

4 実験結果

4.1 難易度勾配: 難ケースほど優位が拡大

評価集合に占める難ケースの比率を 3 段階に変えて baseline (古典 IR, Stage 1) と reranker-10S (Set-aware 特徴量を含む Stage 2) を比較した (図 2). 古典 **IR** は難ケースが増えると $\text{Recall}@K_{\text{correct}}$ が $0.79 \rightarrow 0.48$ へ急落するのに対し, 本手法は $0.91 \rightarrow 0.70$ と緩やかにしか落ちず, 両者の差は $+0.127 \rightarrow +0.210 \rightarrow +0.217$ と単調に拡大する. 数式グラフ上で式を組合せとして評価する本手法の発想が, 難しい組合せ問題でこそ効くことを示す.

4.2 本手法はどこで効くか/なぜ指標を変えたか

図 3(a) は正解式数別の $\text{Recall}@K_{\text{correct}}$ である. 単一式では baseline が既に高く本手法の上乗せはほぼ無い ($+0.02$) が, 複数式では $+0.21 \sim 0.26$ の大幅改善を示す. 入力変数が多い (11 以上) ケースでも同様に $+0.245$ 改善する. 本手法は「易しい問題を壊さず, 難しい組合せ問題で効く」という望ましい振舞いを持つ.

図 3(b) は, 加納先生のご指摘「分野横断的に収集する必要はない」(仮説 B) の再検定である. v5




図2 難ケース比率の異なる3設定における $\text{Recall}@K_{\text{correct}}$ (10 シード平均, エラーバー=標準偏差). 難ケースが増えるほど baseline は低下し, 本手法との差 (赤) が拡大する.

は MRR_first がフル DB と化学工学限定 DB でほぼ同じ (差 +0.003) であったため「DB 規模の影響なし」としていた. しかし飽和しない $\text{Recall}@K_{\text{correct}}$ ではフル DB (11,146 式・全分野) が限定 DB を有意に上回る (0.923 vs 0.875, 差 +0.048, 対応のある t 検定 $p = 0.044$, Wilcoxon $p = 0.037$, 効果量 Cohen's $d = 0.74$ 中程度). すなわち v5 の暫定結論は指標選択の副作用であり, 広く集める方針の妥当性が支持された (ただし差は中程度で, 限定 DB でも $\text{Recall}@K_{\text{correct}} = 0.87$ の実用水準には達する).




図3 (a) 正解式数別の $\text{Recall}@K_{\text{correct}}$: 改善は複数式・複雑な問題ほど大きい. (b) 仮説 B の再検定: 飽和した MRR_first では差が見えないが, $\text{Recall}@K_{\text{correct}}$ ではフル DB が有意に優位 ($p = 0.044$).

4.3 ハイパーパラメータ頑健性

「本手法の優位は脆弱なチューニングの産物では」という査読上の懸念に対し、学習率 (10^{-4} – 10^{-2}), 隠れ層次元 (64/128/256), epoch (20/40), margin (0.1/0.3) を振った 13 設定で $\text{Recall}@K_{\text{correct}}$ を測った. 全 13 設定が 0.732–0.742 の狭い範囲に収まり, 設定間レンジ 0.0094 はシード間標準偏差 (約 0.097) の約 1/10 にすぎない. 本手法の強さは特定のチューニングに依存せず頑健である.

4.4 外部ベースライン: LLM 直接生成との同一条件比較

「LLM で直接解けるなら本手法は不要では」という加藤先生のご指摘に答えるため, 大規模言語モデル (Claude, Sonnet 系) を問題を解く側として用い, 背景文と入出力変数のみから数式を生成させて現行 11,146 式 DB と照合した (本研究で LLM を使うのはケース生成のみで, 検索タスクには使わない). 比較対象の baseline・reranker-10S も同一サブセット・同一 DB で再評価した (リーク防止のため対象ケースをテスト分割でのみ評価).

結果を図 4 に示す. 易しい単一ソースでは検索系 (両 Stage) が LLM を圧倒する ($\text{Recall}@K_{\text{correct}}$ で baseline 0.982 / reranker 0.975 vs LLM 0.707). 一方難しい複数ソースでは, 古典 IR 単独は LLM を下回る ($0.575 < 0.842$) が, reranker-10S は baseline を +0.367 改善して LLM をも上回る (0.942). 文章類似度だけでは複数文献の式を組合せられず, Set-aware リランカーが本質的に必要であることを同一条件で実証した. なお本比較は単一 29 件・複数 20 件の小規模・held-out 評価 (1 ケースあたり平均約 1–2 シード) であり, 傾向の確認と位置づける.




図 4 LLM 直接生成 vs baseline(Stage1) vs reranker-10S(Stage2) の同一条件比較 ($\text{Recall}@K_{\text{correct}}$, 現行 11,146 式 DB). 複数ソースで baseline < LLM < 本手法.

5 考察と今後の方針

- なぜ効くか：DAE・複数式・多変数のケースは単独式の文章類似度では絞れず，式どうしの変数共有（補完性・一貫性）という構造情報が効く．易しい問題は baseline が天井のため上乗せは小さい（図 3a）．
- 指標の重要性：MRR_first の飽和は DB 規模の効果（仮説 B）も改善幅も隠していた，Recall@ K_{correct} への切替で初めて両者が可視化された．
- 頑健性と外部比較：13 設定で差が出ないことは優位が構造的特徴量そのものに由来することを，LLM との同一条件比較は古典 IR では足りず本手法が必要であることを示す．
- 今後：(1) 修論・論文「Set-aware graph features for multi-equation physical model retrieval」の執筆，(2) LLM 外部比較の標本拡充（難ケースでの LLM 評価），(3) Set-aware 特徴量の拡張（listwise 学習・hard negative），(4) 変数記述の意味類似度による表記揺れの学習的吸収．

6 まとめ

データベースを 11,146 式・2,838 ケースに拡大し DAE 難ケースで難易度勾配を作ったところ，難しい問題ほど **Set-aware** リランカーの優位（Recall@ K_{correct} ）が $+0.13 \rightarrow +0.22$ と拡大した．飽和しない Recall@ K_{correct} により分野横断収集の効果（仮説 B， $+0.048$ ， $p = 0.044$ ）が新たに有意と判明し v5 の暫定結論を訂正，ハイパーパラメータにも頑健で，外部の LLM 直接生成を複数ソースで上回ることを同一条件で確認した．