

物理モデル自動構築：データベース大規模化・評価指標の精緻化・ 集合選択による精度向上

作成者：M2 一洋

1 前回レビュー (2026-05-19 ゼミ)

タスク：文献から数式を集め、入力（説明文 + 入出力変数）に対し物理モデル構築に必要な数式集合をグラフニューラルネットワーク（GNN）で順位付けして提示する。前回までの到達点は次の通り。

- 論文 39 報からの抽出 + LLM による化学工学近隣分野の汎用式生成で **3,244 式・訓練ケース 1,338 件** を構築。
- このデータで GNN を評価し **MRR**（平均逆順位；最初に当てた正解の順位の逆数の平均）**0.963**、**MAP**（平均適合率；正解の上位集中度）**0.953**。LLM 直接生成（Claude）を含む 3 手法比較で、文献横断ケースにおいて本手法が LLM より **MRR +18%**、**MAP +21%**。
- 議論点：(1)「関連性の低い数式も予測精度向上に機能するか」を判明させる実験の設計、(2) 論文 PDF の収集方法。
- 今後の予定：(a) 31 ドメイン × 論文 10 報を収集して再評価、(b) 数式数・入出力変数数・ソース数のヒストグラムを揃えた訓練／テスト分割とパラメータ調整、PSE Asia 準備。

2 今回の進捗 (要約)

前回の予定（データ収集・再評価・分割・調整）を完了し、さらに評価の精緻化と精度向上にまで踏み込んだ。要点は以下。

- データベースを **3.4 倍** に拡大：3,244 → **11,146 式**、1,338 → **2,838 ケース**。微分方程式と代数式が連立する系（微分代数方程式系、DAE）を模した難ケースを **1,000 件** 追加 (§3)。
- 評価指標を精緻化：MRR_first は天井で飽和し差を隠すため、正解数 K で測る $\text{Recall}@K_{\text{correct}}$ （情報検索の R-precision と同義）を主指標に採用 (§4)。
- 議論点 (1) への回答：分野横断的に広く集めた「関連性の低い」式も実際に精度を上げる（フル DB > 限定 DB、+0.048、 $p = 0.044$ ）ことを定量実証 (§5.2)。
- 難ケースほど本手法の優位が拡大し、全難易度で本手法 > 古典 IR > LLM (§5.1)。ハイパーパラメータにも頑健 (§5.3)。
- 精度向上：診断に基づき集合としての逐次選択（貪欲法、greedy）を導入し、最難 DAE で $\text{Recall}@K_{\text{correct}} 0.745 \rightarrow 0.792$ ・実用 $\text{Recall}@20 0.887 \rightarrow 0.953$ (§6)。漏れた正解の大半が「ほぼ正解」であることも示した (§6.1)。

3 データベースの大規模化

前回予定の「31 ドメイン × 論文 10 報の収集」を実施し、PDF 抽出・ハンドブック式・文献横断ケースを拡充して表 1 の規模に拡大した。訓練ケースの **74.6%** が正解に 2 式以上を要する複数式ケースであり、「式を組合せとして選ぶ」本手法の主戦場をなす。

新規追加した **DAE 難ケース**（1,000 件、Claude Sonnet 4.5 で生成、正解式数 $X \in \{1, \dots, 10\}$

表 1 データ規模 (前回ゼミ比)

項目	前回 (5/19)	今回
収録数式数	3,244	11,146
訓練ケース総数	1,338	2,838

各 100 件) は、典型的な物理モデルである「常微分方程式 (ODE) + 付随する代数式」の連立を模す。たとえば連続槽型反応器 (CSTR) で槽内濃度 C_A (mol/m³) と反応速度 r_A (mol/(m³·s)) を、流量 F (m³/s)・槽体積 V (m³)・入口濃度 C_{A0} (mol/m³) から求める問題は、物質収支 ODE $V dC_A/dt = F(C_{A0} - C_A) - V r_A$ と Arrhenius 速度式 $r_A = k C_A$ を組合せて初めて解ける。生成時に各式の代表変数を出力へ加え自由度ゼロ (入力数 + 方程式数 = 出力数 + 既知数) を構成上保証している。データの規模・内訳・難易度を図 1 に示す。

データセットの規模・内訳と難易度分布




図 1 (a) 訓練ケース 2,838 件の内訳 (DAE 1,000 件を新規追加)。(b) 正解式数の分布：複数式 (2 式以上) が 74.6%。

4 評価指標の精緻化

前回の主指標 MRR_first (最初に当たった正解の順位の逆数) は、正解が 1 件でも上位に来れば 1.0 に近づくため、複数式を揃える能力を測れず、天井付近で飽和して手法間の差を覆い隠す。本報告では、正解式が n_{correct} 件あるとき上位ちょうど $K = n_{\text{correct}}$ 件の正解割合 $\text{Recall}@K_{\text{correct}} = |\text{Top}_K \cap \mathcal{R}_q| / |\mathcal{R}_q|$ ($\mathcal{R}_q$ は正解集合、R-precision と同義) を主指標とする。「必要な式をちょうどその本数だけ上位に並べられたか」を直接測り、飽和しにくい。以降の評価はすべて 10 シード (source_id 単位で訓練／テストを分割しリーク防止) で行う。

5 評価結果

5.1 難易度勾配と 3 手法比較

評価集合に占める難ケースの比率を 3 段階に変え、baseline (比較対象＝古典的情報検索、Stage 1)・LLM 直接生成・reranker-10S (本手法＝候補集合を考慮して並べ替える再順位付け器、Stage 2) を比較した (図 2)。全 3 設定で **reranker > baseline > LLM** であり、難ケースが増えると baseline は $\text{Recall}@K_{\text{correct}}$ が $0.79 \rightarrow 0.48$ へ、**LLM** はさらに急に $0.54 \rightarrow 0.26$ へ落ちる一方、本手法は $0.91 \rightarrow 0.70$ と緩やかにしか落ちない。本手法は LLM を全設定で $+0.37 \sim 0.45$ 上回り、最難の DAE でも LLM の約 2.6 倍を保つ。前回の LLM 比較 (単一テストセット) を、より広い難易度と現行 11,146 式 DB へ拡張した結果である。




図 2 難ケース比率の異なる 3 設定での 3 者比較 ($\text{Recall}@K_{\text{correct}}$)。全設定で $\text{reranker} > \text{baseline} > \text{LLM}$ 。baseline・本手法は 10 シード平均 (エラーバー＝標準偏差)、LLM はサンプル評価。

前回ゼミの主結果であった文献横断 (複数ソース) 設定での **LLM** 比較も、現行 11,146 式 DB 上で同一条件 (リーク防止の held-out 評価) に更新した (図 3)。易しい単一ソースでは検索系 (両 Stage) が **LLM** を圧倒する ($\text{Recall}@K_{\text{correct}}$ で baseline 0.982 / reranker 0.975 vs LLM 0.707) 一方、難しい複数ソースでは古典 **IR** 単独 (baseline) は **LLM** を下回る ($0.575 < 0.842$) が、**reranker-10S** は baseline を $+0.367$ 改善して **LLM** をも上回る (0.942)。文章類似度と変数の一致だけでは複数文献の式を組合せられず、候補集合を考慮した再順位付け (reranker) が本質的に必要であることを示す。なお標本は単一ソース 29 件・複数ソース 20 件と小規模であり、傾向の確認と位置づける。




図 3 LLM 直接生成 vs baseline (Stage1) vs reranker-10S (Stage2) の同一条件比較 (Recall@ K_{correct} 、現行 11,146 式 DB)。複数ソースで baseline < LLM < 本手法。

5.2 【議論点 (1) への回答】分野横断的な収集は精度を上げるか

前回の議論点「関連性の低い数式も予測精度向上に機能するか」に答える実験を行った。具体的には、本手法の検索対象 DB をフル DB (11,146 式・全分野) と化学工学限定 DB に切替え、同一テストケースでの性能を比較した (reranker-10S、10 シード、対応のある検定)。結果を表 2 と図 4(b) に示す。

表 2 フル DB (全分野) vs 限定 DB (化学工学のみ) の本手法性能

指標	限定 DB	フル DB	差	p 値 (対応 t)	効果量 d
MRR_first	0.9593	0.9625	+0.0032	0.78 (n.s.)	0.09 (小)
Recall@ K_{correct}	0.8749	0.9229	+0.0480	0.044*	0.74 (中)
MAP	0.9309	0.9531	+0.0222	0.096	0.59 (中)

飽和した MRR_first では差が見えない (+0.003、 $p = 0.78$) が、飽和しない Recall@ K_{correct} ではフル DB が有意に優れる (+0.048)。ここで対応のある t 検定 (同一テストケースをシード間で対にして差を検定する手法) で $p = 0.044$ 、ノンパラメトリックな Wilcoxon 符号順位検定でも $p = 0.037$ 、効果量 Cohen's d (平均差を標準偏差で正規化した指標、0.2 小・0.5 中・0.8 大) は 0.74 (中程度) である。すなわち、直接は関連しない分野横断的な式も、広く集めることで予測精度を上げる。これは議論点 (1) への定量的な回答であり、「広く集めた上でテストに必要な分野の網羅を検証する」方針の妥当性を裏づける (ただし差は中程度で、限定 DB でも Recall@ $K_{\text{correct}} = 0.87$ の実用水準には達する)。あわせて、改善は複数式・多変数のケースに集中する (図 4(a)、単一式では ≈ 0 、複数式で +0.21 ~ 0.26) ことも確認した。


本手法はどこで効くか／なぜ Recall@K_{correct} を主指標にしたか

図 4 (a) 正解式数別の Recall@K_{correct} : 改善は複数式・複雑な問題ほど大きい。(b) 議論点 (1) の検証 : 飽和した MRR_first では差が見えないが、Recall@K_{correct} ではフル DB が有意に優位 ($p = 0.044$)。

5.3 頑健性

前回予定の「パラメータ調整」に関連し、本手法の優位が脆弱なチューニングの産物でないことを確認した。学習率 (10^{-4} – 10^{-2})・隠れ層次元 (64/128/256)・epoch (20/40)・margin (0.1/0.3) を振った 13 設定すべてが Recall@K_{correct} = 0.732–0.742 の狭い範囲に収まり、設定間レンジ 0.0094 はシード間標準偏差 (約 0.097) の約 1/10 にすぎない。優位は構造的特徴量そのものに由来し、特定のチューニングに依存しない。

6 精度向上：診断・集合選択 (greedy)・near-miss 分析

最難の DAE で Recall@K_{correct} が 0.70 前後に留まる点を診断し、改善した。なお Recall@K_{correct} は上位ちょうど K 件に正解を全て揃える最も厳しい指標であり、実用的な Recall@20 (上位 20 件に必要な式が含まれるか) は本手法で DAE でも 0.86 ある。

診断：reranker は Stage 1 が返す上位 K 候補のみを再順位付けするため、上限は「正解が上位 K に retrieve される割合」である。DAE では Stage 1 Recall@50 = 0.86 (高 X ケースで取りこぼし)。かつ現行 MLP は候補を独立にスコアするため、「集合としての選択」を表現できない。

試行と結果：まず Stage 2 の標準的強化 (hard negative マイニング・listwise 損失・出力補完特徴) を試したが、いずれも Recall@K_{correct} を ≤ 0.006 しか動かさなかった (図 5(a))。一方、学習済みモデルをそのまま使い、1 式選ぶごとに特徴量を「既選択集合」を参照に再計算して次を選ぶ逐次選択 (greedy) を推論時に導入すると、Recall@K_{correct} が各特徴量構成で +0.015~0.018 一貫して改善した (reranker-10S で +0.018)。効いた 2 レバー、すなわち Stage 1 が渡す候補数 (top- k 、正解数 K とは別概念) の 50 → 200 拡大と逐次選択を結合すると、DAE で Recall@K_{correct} 0.745 → 0.792 (+0.048、+6.4%)、Recall@20 0.887 → 0.953 に達した (図 5(b)、5 シード)。なおこの +0.048 は §5.2 の DB 規模効果 (同値だが別の結果) とは無関係である。「集合としての選択」を陽に行うこと

が厳格指標を動かす鍵であると実証された。

Stage2 強化：何が厳格 Recall@ $K_{correct}$ を動かすか




図 5 (a) 試した Stage 2 レバー：損失・負例・特徴の標準的改良は無効 (≤ 0.006)、集合選択 (greedy) のみ +0.018。(b) 効いた 2 レバー (top- k 拡大 + greedy) の結合で Recall@ $K_{correct}$ +0.048・Recall@20 +0.066。

6.1 漏れた正解はどれだけ惜しいか (near-miss 分析)

議論点に通じる問いとして、上位 K 件から漏れた正解がすぐ下に詰まっているのか遥か下方なのかを、余裕 m を足した回復曲線 $\text{Recall}@ (K + m)$ と超過順位 (順位 $-K$) の分布で分析した (図 6、候補 200 件予算で統一)。**reranker・greedy** は漏れた正解の 45–47% を上位 3 件以内に詰めており (baseline は 18%)、 $K + 3$ 件まで見れば **Recall** は 0.89–0.91 に達する。すなわち本手法の誤りの大半は「ほぼ正解 (near-miss)」であり、人手レビュー前提なら容易に拾える。一方、漏れの 12–13% は候補 200 件の外 (far-miss) で、これが残る改善余地 (Stage 1 の retrieval 強化) を指し示す。

漏れた正解はどれだけ上位に詰まっているか (DAE, top-200, 3 シード)




図 6 near-miss 分析 (DAE、候補 200 件予算)。(a) 回復曲線 $\text{Recall}@ (K + m)$ ($m=0$ が $\text{Recall}@K_{correct}$) : reranker・greedy は急に立ち上がり $K + 3$ で ≈ 0.9 。(b) 漏れた正解の超過順位 (順位 $-K$) の累積分布：左に立つほど「惜しい」。

7 今後の仕事

- 精度のさらなる向上：greedy を学習段階にも導入（既選択集合を参照する特徴で teacher forcing 学習）して効果を増幅。far-miss（漏れの 12–13%）を減らす **Stage 1 retrieval** の強化（候補生成の recall 改善）。
- **PSE Asia** 準備：本報告の難易度勾配・指標精緻化・分野横断収集の効果・精度向上を中核に、発表・原稿を整備。
- 論文執筆：「Set-aware graph features for multi-equation physical model retrieval」を軸に投稿準備。