

物理モデルの自動構築：設計した特徴量はなぜ効くのか ——精度向上の分解と、効く場所の特定

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

前回は、データベースを 11,146 式・2,838 ケースに拡大し、層化分割・DAE ケースの再生成を行った。その上で、文章類似度など基本 7 特徴量に集合特徴量 3 個を加えた計 10 特徴量を多層パーセプトロン (MLP) で学習し、候補の式を並べ直す本手法 (reranker-10S) を構築した。Recall@ K (物理モデルの正解式数 K に合わせ、上位 K 件に入った正解の割合) を設定 A (オリジナル+文献横断+DAE、1,823 件) で $0.521 \rightarrow 0.743$ (+0.222)、設定 B (DAE のみ 1,000 件) で $0.466 \rightarrow 0.689$ に改善し、全設定で本手法 > baseline (古典的情報検索手法) > LLM 直接生成となることを報告した。

2 今回の進捗

これに対し加藤先生から「設計した特徴量はなぜ、学習精度向上に効くのかの考察が重要」とのご指摘をいただいた。本報告では、この「なぜ」を実験で調べた。

(古典的検索手法と比べた) 精度向上 +0.222 は、次の 3 段に分解できた。baseline は文章類似度と変数の一致度の 2 特徴量を、固定の重み (7:3) で足すだけの方式である。(a) 同じ 2 特徴量のまま重み付けを固定から MLP の学習に変えると $0.521 \rightarrow 0.601$ (+0.080)。(b) 特徴量を 2 個から 7 個に増やすと $0.601 \rightarrow 0.693$ (+0.092)。(c) 集合特徴量 3 個を加えると $0.693 \rightarrow 0.743$ (+0.050)。さらに特徴量を 1 つずつ調べると、精度を上げるのは変数の重なりを見る特徴量だけで、話題の近さを見る特徴量 (意味の近さ・分野の一致) はどの形でも効かないことが分かった。集合特徴量の効果は複数次・多変数のケースで大きい (§3)。

3 実験：どの特徴量が・どんなケースで効くのか

方法：どの特徴量が効くかを見るため、特徴量を 1 つだけ土台に足したときの Recall@ K の変化を測った。土台は 2 つ用意した。土台 A は baseline と同じ 2 特徴量 (文章類似度・変数の一致度) を MLP で学習したもの、土台 B は基本 7 特徴量を学習したものである。土台 A には残る 5 個の基本特徴量を、土台 B には集合特徴量 3 個を、それぞれ 1 つずつ足した。各特徴量の定義は表 1 に示す。集合特徴量の効果を正解式数・入力変数数で層別した (図 1)。

結果 (表 2・図 1)：

- 基本特徴量の内訳 (土台 A から)：+0.092 のほぼ全部を式の特化度 1 個が担う ($0.601 \rightarrow 0.691$ 、+0.090)。この 1 個だけで 7 特徴量すべて (0.693) にほぼ届く。入力変数の被覆 (+0.019)・出力変数の被覆 (+0.006) は小さく、意味の近さ (SVD) は効果がない (-0.002 、 $p = 0.48$)。
- 話題の近さはどの形でも効かない：分野の一致は、基本特徴量として足しても (+0.002、 $p = 0.06$)、

表 1 10 個の特徴量の定義。式の変数を V_e 、クエリ（入力）の入出力変数を V_q （入力 V_{in} ・出力 V_{out} ）、既に選んだ式集合の変数を V_S とする。

特徴量	定義
基本特徴量（7 個）：各式を単独で評価	
文章類似度	説明文と式まわりの文章の単語の重なり（TF-IDF のコサイン類似度）
変数の一致度	入出力変数と式の変数の重なり $ V_q \cap V_e / V_q \cup V_e $ （Jaccard 係数）
意味の近さ	説明文と式を意味空間（SVD）に埋め込んだときのコサイン類似度
入力変数の被覆	入力変数のうち式に現れる割合 $ V_{in} \cap V_e / V_{in} $
出力変数の被覆	出力変数のうち式に現れる割合 $ V_{out} \cap V_e / V_{out} $
式の特化度	式の変数のうち入出力変数が占める割合 $ V_q \cap V_e / V_e $ （無関係な変数を持たない式ほど高い）
分野の一致	式の分野が説明文に現れれば 1、なければ 0
集合特徴量（3 個）：既に選んだ式集合（第 1 段で上位にきた数件）を基準に評価	
補完性	まだ覆えていない入出力変数を新たに補う割合 $ (V_q \cap V_e) \setminus V_S / V_q $
一貫性	式の変数のうち既選択集合と共有する割合 $ V_e \cap V_S / V_e $
分野の一致（集合版）	既選択集合のうち候補と同じ分野の式の割合

表 2 特徴量を 1 つだけ土台に足したときの Recall@K（1,823 ケース・乱数 10 通り）。差は直上の土台からの差、 p は乱数を対応させた t 検定。

方式・追加した特徴量	Recall@K	土台からの差	p 値
baseline（2 特徴量・固定重み・学習なし）	0.521	—	—
土台 A ：2 特徴量を MLP で学習	0.601	—	—
+ 意味の近さ（SVD）	0.599	−0.002	0.48
+ 入力変数の被覆	0.620	+0.019	< 0.001
+ 出力変数の被覆	0.607	+0.006	0.002
+ 式の特化度	0.691	+0.090	< 0.001
+ 分野の一致	0.603	+0.002	0.06
土台 B ：基本 7 特徴量を MLP で学習	0.693	—	—
+ 補完性	0.745	+0.052	< 0.001
+ 一貫性	0.743	+0.050	< 0.001
+ 分野の一致（集合版）	0.693	−0.000	0.98
本手法 reranker-10S（7 + 集合 3 特徴量）	0.743	—	—

集合特徴量として足しても（−0.000、 $p = 0.98$ ）変わらない。意味の近さ（SVD）も効かない（ $p = 0.48$ ）。効くのはいずれも変数の重なりを測る特徴量であった。

- 集合特徴量は組合せが難しいときに効く（土台 **B** から）：補完性・一貫性を足す効果は、正解式数 1 のケースでは 0、2〜3 式で最大（+0.07〜+0.12）。入力変数数では 6 個以下で 0、7〜15 個で最大（+0.07〜+0.09）、16 個以上では +0.035 に縮む（図 1）。
- 独立の手法（順列特徴量重要度）でも同じ結論（図 2）：土台を複数作るのでなく、最良モデル 1 つで各特徴量を壊した（値をシャッフルした）ときの Recall@K の低下を測ると、変数の重なりを測る 6 特徴量をまとめて壊すと 0.743 → 0.065 に崩れ（−0.678、 $p < 0.001$ ）、話題を測る 4 特徴量をまとめて壊してもほとんど変わらない（−0.006、有意でない）。原理の異なる 2 手法（再

訓練するアブレーションと、壊すだけの順列重要度) が同じ結論に至る。




図1 集合特徴量を土台 B (基本 7 特徴量) に 1 つ足したときの Recall@K の変化。(a) 正解式数別、(b) 入力変数数別。補完性 (青)・一貫性 (緑) は複数式・多変数の層でのみ正の効果を持ち、分野の一致 [集合版] (赤) は全層で 0 付近である。

順列特徴量重要度：モデルは変数重なりに依存し、話題にはほぼ依存しない




図2 最良モデル reranker-10S の順列特徴量重要度 (10 seed の平均 ± 標準偏差。重要度 = その特徴量の値をケース内でシャッフルしたときの Recall@K の低下)。(a) 特徴量ごと (色は群)、(b) 変数の重なり群 vs 話題群を丸ごと壊した場合 (点線は元の Recall@K = 0.743)。モデルは変数の重なりに依存し、話題はほとんど使っていない。

4 考察：何が分かったか

1. 本課題は「説明文に似た式を探す」検索ではない：効いた特徴量がすべて変数の重なりを測るもので、文章・話題の近さ (意味の近さ・分野の一致) はどの形でも効かなかった。つまり、古典的検索や LLM 直接生成が頼る文章・話題の類似では本課題は解けず、「同じ変数を持つ式」を選ぶことが要る (前回、両者とも本手法に劣った)。
2. さらに、式は集合として組み立てる必要がある：式どうしの組合せを見る集合特徴量が複数式・多変数のケースで効くこと (図 1)、および LLM 直接生成が必要な式を作れても上位 K 件に組み

ないこと（前回報告）は、物理モデルの構築が式を 1 本ずつ選ぶだけでなく変数を補い合う集合として組み立てる側面を持つことを示す。

3. 限界：(i) 特徴量の追加 $+0.092$ はほぼ式の特化度 1 個に由来し、集合特徴量の効果 ($+0.050$) はそれより小さい。(ii) 16 変数以上で集合特徴量の効果が縮む原因（補完性の基準の固定）は推定である。

5 まとめと今後の課題

今回：前回の改善 $+0.222$ を 3 段（重み付けの学習 $+0.080$ ・特徴量の追加 $+0.092$ ・集合特徴量 $+0.050$ ）に分解し、全特徴量を 1 つずつ評価して、精度を上げるのは変数の重なりを測る特徴量に限られることを示した。

今後の課題：

- 修士論文の骨子（作成済み）を加藤先生と相談しながら修正。
- 論文のロジックを補完するための追加実験を行う。