

物理モデルの自動構築：設計した特徴量はなぜ効くのか ——精度向上の分解と、効く場所の特定

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

前回は、データベースを 11,146 式・2,838 ケースに拡大し、層化分割・DAE ケースの再生成を行った。その上で、文章類似度など基本 7 特徴量に集合特徴量 3 個を加えた計 10 特徴量を多層パーセプトロン (MLP) で学習し、候補の式を並べ直す本手法 (reranker-10S) を構築した。Recall@ K (物理モデルの正解式数 K に合わせ、上位 K 件に入った正解の割合) を設定 A (オリジナル+文献横断+DAE、1,823 件) で $0.521 \rightarrow 0.743$ (+0.222)、設定 B (DAE のみ 1,000 件) で $0.466 \rightarrow 0.689$ に改善し、全設定で本手法 > baseline (古典的情報検索手法) > LLM 直接生成となることを報告した。

2 今回の進捗

これに対し加藤先生から「設計した特徴量はなぜ、学習精度向上に効くのかの考察が重要」とのご指摘をいただいた。本報告では、この「なぜ」を実験で調べた。

(古典的検索手法と比べた) 精度向上 +0.222 は、次の 3 段に分解できた。baseline は文章類似度と変数の一致度の 2 特徴量を、固定の重み (7:3) で足すだけの方式である。(a) 同じ 2 特徴量のまま重み付けを固定から MLP の学習に変えると $0.521 \rightarrow 0.601$ (+0.080)。(b) 特徴量を 2 個から 7 個に増やすと $0.601 \rightarrow 0.693$ (+0.092)。(c) 集合特徴量 3 個を加えると $0.693 \rightarrow 0.743$ (+0.050)。さらに特徴量を 1 つずつ調べると、精度を上げるのは変数の重なりを見る特徴量だけで、話題の近さを見る特徴量 (意味の近さ・分野の一致) はどの形でも効かないことが分かった。集合特徴量の効果は複数式・多変数のケースで大きい (§3)。

3 実験：どの特徴量が・どんなケースで効くのか

結論：精度を上げるのは変数の重なりを見る特徴量 (式の特化度・入出力変数の被覆・補完性・一貫性) だけであり、話題の近さを見る特徴量 (意味の近さ・分野の一致) は、基本特徴量として足しても集合特徴量として足しても効果がなかった。集合特徴量の効果は複数式・多変数のケースで大きい。

方法：どの特徴量が効くかを見るため、特徴量を 1 つだけ土台に足したときの Recall@ K の変化を測った。土台は 2 つ用意した。土台 A は baseline と同じ 2 特徴量 (文章類似度・変数の一致度) を MLP で学習したもの、土台 B は基本 7 特徴量を学習したものである。土台 A には残る 5 個の基本特徴量を、土台 B には集合特徴量 3 個を、それぞれ 1 つずつ足した。ここで式の特化度は「式の変数のうち、入出力変数が占める割合」(無関係な変数を持たない式ほど高い)、補完性は「候補の式が、いまカバーできていない入出力変数をどれだけ補うか」である。乱数を対応させた t 検定を行い、集合特徴量の効果を正解式数・入力変数数で層別した (図 1)。

表 1 特徴量を 1 つだけ土台に足したときの Recall@K (1,823 ケース・乱数 10 通り)。差は直上の土台からの差 (± は乱数間の標準偏差)、 p は乱数を対応させた t 検定。太字は最大の寄与。

方式・追加した特徴量	Recall@K	土台からの差	p 値
baseline (2 特徴量・固定重み・学習なし)	0.521	—	—
土台 A : 2 特徴量を MLP で学習	0.601	—	—
+ 意味の近さ (SVD)	0.599	-0.002	0.48
+ 入力変数の被覆	0.620	+0.019	< 0.001
+ 出力変数の被覆	0.607	+0.006	0.002
+ 式の特化度	0.691	+0.090	< 0.001
+ 分野の一致	0.603	+0.002	0.06
土台 B : 基本 7 特徴量を MLP で学習	0.693	—	—
+ 補完性	0.745	+0.052	< 0.001
+ 一貫性	0.743	+0.050	< 0.001
+ 分野の一致 (集合版)	0.693	-0.000	0.98
本手法 reranker-10S (7 + 集合 3 特徴量)	0.743	—	—

結果 (表 1・図 1):

- 基本特徴量の内訳 (土台 **A** から): +0.092 のほぼ全部を式の特化度 1 個が担う (0.601 → 0.691、+0.090)。この 1 個だけで 7 特徴量すべて (0.693) にほぼ届く。入力変数の被覆 (+0.019)・出力変数の被覆 (+0.006) は小さく、意味の近さ (SVD) は効果がない (-0.002、 $p = 0.48$)。
- 話題の近さはどの形でも効かない: 分野の一致は、基本特徴量として足しても (+0.002、 $p = 0.06$)、集合特徴量として足しても (-0.000、 $p = 0.98$) 変わらない。意味の近さ (SVD) も効かない。効くのはいずれも変数の重なりを測る特徴量であり、「話題が近い式」ではなく「同じ変数を持つ式」が要ることを示す。
- 集合特徴量は組合せが難しいときに効く (土台 **B** から): 補完性・一貫性を足す効果は、正解式数 1 のケースでは 0、2~3 式で最大 (+0.07~+0.12)。入力変数数では 6 個以下で 0、7~15 個で最大 (+0.07~+0.09)、16 個以上では +0.035 に縮む (図 1)。

最難のケース (多式・16 変数以上) で集合特徴量の効果が縮む点は、補完性の基準が「第 1 段の候補上位 5 件」に固定されていることが原因だと推定した。大きな系では、式を選ぶにつれ「まだ足りない変数」が変わっていくのに、固定の基準ではそれを追えないためである。

4 考察：何が分かったか

1. 効くのは変数の重なり、効かないのは話題の近さ: 全 10 特徴量を 1 つずつ調べると、精度を上げるのは変数の重なりを見る特徴量 (式の特化度・入出力変数の被覆・補完性・一貫性) だけで、話題の近さを見る特徴量 (意味の近さ・分野の一致) は基本特徴量でも集合特徴量でも効かない (表 1)。古典的検索や LLM が頼る「文章・話題の近さ」ではなく、変数の重なりが本課題を解く鍵である。
2. 組合せは複数式のときに効く: 式どうしの組合せを見る集合特徴量は、複数式・多変数のケースで効く (図 1)。前回報告のとおり、LLM 直接生成も必要な式を作れてはいるのに上位 K 件に組めない。物理モデルの構築が、式を 1 本ずつ選ぶだけでなく変数を補い合う集合として組み立て




図1 集合特徴量を土台 B (基本 7 特徴量) に 1 つ足したときの Recall@K の変化 (乱数 10 通り、エラーバーは乱数間の標準誤差)。(a) 正解式数別、(b) 入力変数数別。補完性 (青)・一貫性 (緑) は複数式・多変数の層でのみ正の効果を持ち、分野の一致〔集合版〕(赤) は全層で 0 付近である。

る側面を持つことを示す。

3. 限界：(i) 特徴量の追加 +0.092 はほぼ式の特化度 1 個に由来し、集合特徴量の効果 (+0.050) はそれより小さい。(ii) 16 変数以上で集合特徴量の効果が縮む原因 (補完性の基準の固定) は推定である。

5 まとめと今後の課題

今回：前回の改善 +0.222 を「重み付けの学習 +0.080」「特徴量の追加 +0.092」「集合特徴量 +0.050」に分解し、全特徴量を 1 つずつ調べて、精度を上げるのは変数の重なりを見る特徴量だけで、話題の近さを見る特徴量はどの形でも効かないこと、集合特徴量は複数式・多変数のケースで効くことを特定した。

今後の課題：

- 修士論文の本文化 (アウトラインと骨子 PDF は作成済みで、本報告の考察は考察章に組み込み済み)。
- 既存手法 (Kato and Kano, 2025 のルールベース式組合せ) との実例比較。
- PSE Asia 発表の準備。