

物理モデルの自動構築：期待した特徴量はなぜ効かなかったのか ——話題の近さの限界と、誤りの所在

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

前回は、古典的情報検索手法（baseline）から本手法（reranker-10S）への Recall@ K （正解式数 K に合わせ、上位 K 件に入った正解式の割合）の向上 +0.222 を 3 段——重み付けの学習 +0.080、特徴量の追加 +0.092、集合特徴量 +0.050——に分解した。そのうえで全 10 特徴量を 1 つずつ評価し、精度を上げるのは変数の重なりを測る特徴量に限られ、話題の近さを測る特徴量（意味の近さ・分野の一致）はどの形でも効かないことを報告した。

2 今回の進捗

これに対し加藤先生から「性能向上手法として期待していたことと結果との関連、およびその原因の考察が要る。正解・不正解のケースを見て分析すること。意味の近さが効かないのは、**TF-IDF** から **SVD** で計算したベクトルがケース間であまり変わらないためではないか」とのご指摘をいただいた。本報告では、この原因を実験で調べた。

1. ベクトルの差が小さいという仮説は成り立たなかった：ケースどうしのベクトルは十分に離れていた。コサイン類似度は無作為な 2 ケースの組で中央値 0.218 であるのに対し、内容が同じケースの組では 0.94 以上に集まる。意味の近さは、全データベース 11,146 式の中から正解式を選び出す力も十分に持っていた。
2. 原因は、候補を絞った後では話題の情報が余分になることであった：第 1 段が候補を 50 件に絞った後では、意味の近さは正解式と不正解式をほとんど区別できなくなる。変数の重なりを測る特徴量は、同じ条件でも区別できる。
3. 第 1 段の絞り込み方が、候補の中に見かけの逆相関を作っていた：候補の中では文章類似度と変数の一致度が逆相関し（相関係数 -0.404 ）、文章類似度はわずかに正解と逆を向く。
4. 本手法が上位 K 件に並べられなかった正解式のうち **61.8%** は、そもそも第 1 段の候補に入っていなかった：残る 38.2% は候補には入ったが順位が足りなかったものである。誤りの主因は、候補を並べ替える第 2 段ではなく、候補を絞る第 1 段にある。
5. 順位が足りなかった誤りも、話題の近さを強めれば直るものではなかった：上位 K 件に入らなかった正解式と、その代わりに上位へ入った誤りの式を突き合わせると、正解式のほうが話題が近い組は半分だけであった。話題の近さが手がかりになっているなら正解式のほうが近い組が多くなるはずなので、半分は手がかりになっていないことを意味する。
6. 第 1 段を変数寄りにすると上限が上がる：正解式が候補に入る割合（被覆率）は、現行の混合（文章 0.7 + 変数 0.3）では 0.920 だが、変数の一致度だけで絞ると 0.961 になる（候補 50 件のとき）。

7. 修士論文の第 3～5 章を本文にし、ケースの呼び方を整理した：あわせて骨子の記述と実装の食い違いを 4 件訂正した (§5)。

3 実験 1：意味の近さはどこで力を失うか

方法：モデルを訓練せず、データと第 1 段の性質だけから調べた。(a) ケースどうしのベクトルがどれだけ離れているかを、SVD で圧縮した空間と圧縮前の TF-IDF 空間の両方で測った（無作為に選んだ 20 万組のコサイン類似度）。(b) 1 つの特徴量だけで正解式を不正解式より上に並べられる割合 (AUC) を、全データベース 11,146 式を相手にした場合と第 1 段が選んだ候補 50 件の中の 2 条件で測った。AUC は 0.5 が識別力なし、1.0 が完全な分離を表す。

結果 (図 1・表 1)：

- 仮説は棄却された：ケース間のコサイン類似度は SVD 空間で中央値 0.218、圧縮前の TF-IDF 空間で 0.070 であり、0.5 を超える組は 5.4% にとどまる (図 1(a))。SVD への射影は類似度を平均で $0.088 \rightarrow 0.247$ と押し上げるが、区別が付かなくなるほどではない。決め手は全データベースでの識別力で、意味の近さ 1 つで AUC 0.950 に達する。ベクトルの差が失われていれば、この分離は起こらない。
- 0.218 がどれだけ「違う」かを同じ空間で確かめた：同じ核モデルから入出力だけ変えて作ったケースの組は中央値 1.000、同じケースの説明文を書き換えただけの組は 0.944、同じ文献に由来する別のケースの組は 0.445 である (図 2)。無作為な組の 0.218 は、言い換えの組 276 組のどれよりも低い。実際に 0.218 付近の組を見ると、一方は微生物がグルコースを消費する発酵系、もう一方は PI 制御下のタンク液位の応答で、話題は明確に異なる。なお全ケースが英語の化学工学の文章なので共通語彙による下駄があり、無関係でも 0 にはならない (無作為な組の四分位は 0.149 – 0.313)。この目盛りで読めば 0.218 は下端＝無関係にあたる。
- 候補を絞った後で力を失う：意味の近さの AUC は $0.950 \rightarrow 0.594$ 、文章類似度は $0.913 \rightarrow 0.437$ と大きく落ちるのに対し、変数の一致度は $0.999 \rightarrow 0.947$ を保つ (表 1)。候補 50 件の中だけで測ると、式の特化度は 0.965、分野の一致は 0.531 である (図 1(b))。
- 値が潰れているのではなく、値の違いが正誤と対応しない：候補の中での意味の近さのばらつき (標準偏差 0.121) は全体 (0.075) より大きい。第 1 段は文章類似度を重み 0.7 で使うので、候補 50 件は初めから話題の近い式ばかりが集まる。
- 絞り込みが見かけの逆相関を作る：候補は「文章類似度と変数の一致度の重み付き和が大きい式」だけの集まりなので、その中では文章類似度が高いことは変数が合っていないことの裏返しになる。実測で -0.404 (文章類似度と変数の一致度)、 -0.392 (文章類似度と式の特化度) であった。文章類似度の候補内 AUC が 0.5 を下回るのはこのためである。

表 1 1 つの特徴量だけで正解式を不正解式より上に並べられる割合 (AUC、1,823 ケースの平均 ± 標準誤差)。左は全データベース 11,146 式を相手にした場合、右は第 1 段が選んだ候補 50 件の中。

特徴量	全データベース	候補 50 件の中
変数の一致度	0.999 ± 0.000	0.947 ± 0.002
意味の近さ (SVD)	0.950 ± 0.003	0.594 ± 0.006
文章類似度	0.913 ± 0.003	0.437 ± 0.007




図 1 (a) ケースどうしのベクトルのコサイン類似度の分布 (無作為に選んだ 20 万組、破線は中央値)。(b) 候補 50 件の中で正解式を不正解式より上に並べられる割合 (1,823 ケースの平均、誤差棒は標準誤差。青は変数の重なりを測る特徴量、赤は話題の近さを測る特徴量)。




図 2 ケースどうしのベクトルのコサイン類似度の物差し (箱は四分位、縦線は中央値、ひげは四分位範囲の 1.5 倍、外れ値は非表示)。内容が同じ組 (上の 2 つ) は 0.87 以上に集まり、無作為な組 (最下段、中央値 0.218) とは重ならない。

4 実験 2：正解・不正解のケースを見る

方法：本手法 (reranker-10S) を乱数 1 通り (seed 42) で訓練し、テストの 423 ケースを、本手法が正解式をすべて上位 K 件にそろえられたケースと、そろえられなかったケースに分けた。上位 K 件に入らなかった正解式ごとに、第 1 段で候補 50 件に入らなかったものと、候補には入ったが上位 K 件から漏れたものを区別した。さらに後者について、「その特徴量を強めていれば順位が戻ったか」を次のように測った。上位 K 件に入らなかった正解式 1 本と、その代わりに上位へ入った誤りの式 1 本を組にし、各特徴量の値がどちらで大きいかを全組合せで数える。正解式のほうが大きい組が多ければ、その特徴量の重みを上げると順位が入れ替わる見込みがある。逆にこの割合が 0.5 なら、その特徴量から見て両者は区別が付かず、重みをいくら上げても順位は戻らない。

結果 (図 3) :

- 誤りの多くは第 1 段で生じている：正解式をすべてそろえられたのは 423 ケース中 212 ケース (50.1%) で、上位 K 件に入らなかった正解式は 435 本あった。うち 269 本 (61.8%) は第 1 段で候補に入らず、166 本 (38.2%) は候補に入ったが順位が足りなかった。
- そろえられないのは規模の大きいケースである：そろえられなかったケースの正解式数は平均 5.34 (そろえられたケースは 2.13)、入力変数数は 17.8 (同 10.8) であった。第 1 段の被覆率も 0.829 (同 1.000) に下がる。
- 話題の近さを強めても救えない：上位 K 件に入らなかった正解式が、代わりに上位へ入った誤りの式を上回る割合は、意味の近さ 0.516 ± 0.040 、分野の一致 0.494 ± 0.011 で、いずれも偶然と同じであった (図 3(b))。変数の一致度では 0.375 と、むしろ誤りの式のほうが大きい。残った誤りは現在のどの特徴量から見ても正解より良く見えている。
- 誤りの型は 2 つに分けられた。
 - 別の文献にある数学的に同じ式を選ぶ：回分発酵のケース (入力：時間 t ・比増殖速度 μ / 出力：菌体濃度 X) で、正解は出典文献の $dX/dt = \mu X$ (意味の近さ 0.369) だが、別の文献の $(1/X) dX/dt = \mu$ (0.72) と $dX/dt = \mu \cdot X$ (0.584) が上位に来た。3 式とも変数は同じで変数側の特徴量では区別できず、話題の近さは誤りのほうを強く推している。
 - 式の向きを表せない：非等温 CSTR の線形化応答のケース (出力：濃度偏差 C'_A) で、正解 $dC'_A/dt = a_{11}C'_A + a_{12}T' + \dots$ と誤り $dT'/dt = a_{21}C'_A + a_{22}T' + \dots$ が、特化度 1.0・変数の一致度 1.0・意味の近さ 0.321 と 0.323 とほぼ同値になった。両者の違いはどの変数を左辺で決める式かであり、変数の集合しか見ない現在の特徴量では表せない。
- 第 1 段の絞り込み方が上限を決めている：正解式が候補に入る割合 (被覆率) は第 2 段の Recall@ K の上限になる。現行の混合では $k = 50$ で 0.920、 $k = 200$ で 0.977 である。これに対し変数の一致度だけで絞ると $k = 50$ で 0.961 まで上がる (図 3(a))。文章類似度だけ (0.431)・意味の近さだけ (0.518) では大きく下がるので、変数と話題の両方が要るが、現行の重み付け (文章 0.7) は話題に寄りすぎている。




図 3 (a) 第 1 段の絞り込み方ごとの被覆率 (正解式が候補 k 件に入る割合。1,823 ケースの平均、誤差棒は標準誤差)。被覆率は第 2 段の Recall@ K の上限を与える。(b) 上位 K 件に入らなかった正解式が、代わりに上位へ入った誤りの式を各特徴量で上回る割合 (131 ケースの平均、誤差棒は標準誤差)。0.5 は偶然と同じで、その特徴量を強めても順位が戻らないことを意味する。

5 修士論文の本文化とケースの呼び方の整理

第 3 章 (手法)・第 4 章 (データセット)・第 5 章 (実験) を骨子から本文にした (全 21 ページ)。

ケースの呼び方を、正解の式集合をどう作ったかという 1 つの軸でそろえた (表 2)。従来の呼び方は出所と作り方の 2 つの軸が混ざっていた。「オリジナル」はケースの性質ではなくデータセットの履歴を指しており、「DAE」は他のケースも満たす性質である (文献掲載・文献横断のケースも微分代数方程式系である)。第 3 の族を分けているのは微分代数性ではなく、指定した規模になるよう合成した点である。

表 2 ケースの呼び方の整理。件数は評価に使う 1,823 件の内訳 (訓練のみに使う拡張ケース 1,015 件を除く)。

従来	今回	正解の式集合の作り方	件数
オリジナル	文献掲載ケース	その文献が 1 つのモデルとして載せている式の集合	92
文献横断	文献横断ケース	異なる文献の式を共有変数でつないで作った集合	731
DAE	合成ケース	指定した規模 X の閉じた系になるよう規則で成長させた集合	1,000

本文を書く際に実装を確認したところ、骨子の記述に 4 件の誤りが見つかったので訂正した。(i) 第 1 段のスコアは文章類似度と変数の一致度の 2 つの混合であり、骨子に書いた「7 特徴量」ではない (7 特徴量は第 2 段の入力である)。(ii) MLP の隠れ層は 64 ユニット 2 層である (骨子は 1 層)。(iii) 集合特徴量の基準にする式集合は第 1 段の上位 5 件であり、候補 50 件とは別である。(iv) 停止条件は出力変数をすべて覆い、かつ未知数の数が式の数以下である (骨子は等号のみ)。

6 考察

- 期待と結果の対応：期待どおりに効いたのは変数の重なりを測る特徴量で、期待に反したのは話題の近さを測る特徴量であった。ただし話題の近さが役に立たないのではない。全データベースから候補を絞る力はむしろ強く (AUC 0.950)、その仕事は第 1 段の時点で終わっている。二段構えの設計では、第 2 段で同じ情報をもう一度使おうとしていたことになる。
- ベクトルの作り方の問題ではない：TF-IDF から SVD という計算のしかたを変えても、この構図は変わらないと考えられる。ケース間のベクトルは離れており (中央値 0.218)、全データベースでの識別力も十分があるので、改善の余地は表現の精度ではなくどの段でどの情報を使うかにある。
- 本課題に固有の事情：標準的な物理式は文献をまたいで繰り返し現れる。正解が出典文献に紐づく以上、話題の近さは「別の文献にある同じ式」を推してしまい、強めるほど悪くなる場合がある (§4 の第 1 の型)。
- 次に効きそうところ：誤りの 61.8% は第 1 段で生じており、変数の一致度だけで絞れば被覆率は $0.920 \rightarrow 0.961$ に上がる。残る第 2 段の誤りには、式の向き (どの変数を決める式か) を表す特徴量が要る。
- 限界：(i) 正解・不正解の分析は乱数 1 通り (423 ケース) に基づく。(ii) 候補内の識別力の比較に

は検定を行っておらず、平均 ± 標準誤差を示すにとどめた。(iii) 第 1 段を変数寄りにすると上限が上がることを示したのであって、最終的な Recall@ K がどれだけ上がるかは確かめていない。

7 まとめと今後の課題

今回：意味の近さが効かない原因が、ご指摘のベクトルの計算方法ではなく、第 1 段で候補を絞った後の冗長性にあることを示した（全データベースでの識別力 0.950 に対し、候補の中では 0.594）。あわせて正解・不正解のケースを分けて調べ、上位 K 件に入らなかった正解式の 61.8% は第 1 段の候補に入っていなかったこと、残る誤りは話題の近さを強めても救えないこと（0.516）、誤りが「別の文献の同じ式」と「式の向きの区別が付かない」の 2 型であることを示した。

今後の課題：

- 第 1 段を変数寄りに再設計し、被覆率の向上が最終的な Recall@ K の向上に結びつくかを確かめる。
- 式の向き（どの変数を決める式か）を表す特徴量を設計する。
- 修士論文の第 6 章（結果と考察）を本文にする。