

物理モデルの自動構築：意味の近さが効かない原因と、 各特徴量の重要度

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

本手法は 2 段階構成である。第 1 段階では、データベースの全 11,146 式に、説明文と式まわりの文章がどれだけ似ているか（文章類似度）と、指定された入出力変数と式の変数がどれだけ重なるか（変数の一致度）を 7 対 3 の重みで足した点数を付け、上位 50 件を候補として絞り込む。第 2 段階では、その候補 50 件だけを対象に、10 個の特徴量を多層パーセプトロン（MLP）で学習して並べ直す。10 個のうち本報告で中心に扱う意味の近さは、説明文と式まわりの文章をそれぞれ 256 次元のベクトルに直し（単語を TF-IDF で重み付けし、SVD で次元を圧縮する）、その 2 本のコサイン類似度を取ったものである。単語がそのまま一致しなくても内容が近ければ大きくなることを期待して入れた特徴量である。

前は、古典的情報検索手法（baseline）から本手法（reranker-10S）への Recall@K（正解式数 K に合わせ、上位 K 件に入った正解式の割合）の向上 +0.222（設定 A：オリジナル＋文献横断＋DAE、1,823 件）を報告した。あわせて 10 特徴量を 1 つずつ足し直して評価し、精度を上げるのは変数の重なりを測る特徴量に限られ、話題の近さを測る特徴量（意味の近さ・分野の一致）はどの形でも効かないことを示した。

2 今回の進捗

加藤先生から「性能向上手法として期待していたことと結果との関連、およびその原因の考察が要る。意味の近さが効かないのは、TF-IDF から SVD で計算したベクトルがケース間であまり変わらないためではないか」とのご指摘をいただいた。本報告では 2 つの実験を行なった。

1. 意味の近さは、ケースどうしを十分に区別できていた：ベクトルが似すぎているという状況は起きておらず、意味の近さ 1 つだけで全 11,146 式の中から正解式を選び出すこともできる。それでも第 2 段階で効かないのは、第 1 段階が候補を絞った時点で、候補の中の式が話題ではそろってしまうからであった。
2. 各特徴量の重要度を、訓練し直さずに測った：訓練済みのモデルで特徴量の値をシャッフルし、Recall@K がどれだけ下がるかを測る方法（順列特徴量重要度、PFI）を実装した。モデルは変数の重なりを測る 6 特徴量に頼り切っており、話題の近さを測る 4 特徴量には頼っていない。

3 実験 1：意味の近さは区別を作れているか

方法：モデルを訓練せず、データと第 1 段階の性質だけから調べた。

(a) ケースどうしのベクトルがどれだけ離れているかを、コサイン類似度で測った。値の大小を判断できるように、内容が同じと分かっている組を同じ空間に置いて物差しを作った（言い換えの組・同

じ物理モデルで入出力だけ変えた組・同じ文献に由来する別ケースの組・無作為な組の 4 種類。組数は図 1 に示す)。

(b) 1 つの特徴量だけで正解式を不正解式より上に並べられる割合 (AUC、Area Under the ROC Curve) を、全データベース 11,146 式を相手にした場合と第 1 段が選んだ候補 50 件の中の 2 通りで測った。無作為に選んだ正解式 1 本と不正解式 1 本を比べて正解式のほうが値が大きい割合であり、0.5 が識別力なし、1.0 が完全な分離を表す。

結果 (図 1・表 1) :

- ベクトルはケースごとに十分離れていた：無作為な組のコサイン類似度は中央値 0.218、0.5 を超える組は 5.4% にとどまる。一方、内容が同じ言い換えの組は中央値 0.944、入出力だけ変えた組は 1.000 に集まり、言い換え 276 組はすべて 0.218 より大きい (図 1)。すなわち 0.218 は「内容が無関係な 2 ケース」の水準であり、ベクトルはケースの内容を区別できている。
- 全データベースを相手にすれば、意味の近さだけで正解式を選び出せる：意味の近さ 1 つの AUC は 0.950 に達する (表 1)。ベクトルの区別が失われていれば、この分離は起こらない。以上より、ご指摘の仮説は成り立たない。
- 候補を絞った後で効かなくなる：同じ意味の近さの AUC は、候補 50 件の中では 0.594 に落ちる。文章類似度は 0.437、分野の一致 (式の分野が説明文に現れれば 1 とする特徴量) は 0.531 で、いずれも識別力なしの 0.5 付近である。これに対し変数の一致度は 0.947、式の特化度 (式の変数のうち入出力変数が占める割合) は 0.965 を保つ。候補を 200 件に広げても意味の近さは 0.718 にとどまり、変数の一致度 0.977・式の特化度 0.984 との差は変わらない。
- 原因は第 1 段の絞り込みにある：第 1 段は文章類似度を重み 7 で使って候補を選ぶので、候補に残った不正解式は正解式と話題がそろっている。話題の近さは絞り込みには効くが、絞り込んだ後の選別には使えない。




図 1 ケースどうしのベクトルのコサイン類似度。内容が同じと分かっている組 (上 2 つ) を並べて、無作為な組の中央値 0.218 がどの水準かを示した。箱=四分位、縦線=中央値、ひげ=1.5 四分位範囲。

4 実験 2：各特徴量の重要度を

PFI (Permutation Feature Importance) 方法で測る

方法：これまで「どの特徴量が効くか」は、特徴量を 1 つずつ足したモデルを訓練し直して比べる方法で調べてきた (前回報告)。今回はこれとは別に、訓練済みのモデルを 1 つだけ用意し、ある特徴量の値をケース内でシャッフルして $\text{Recall}@K$ がどれだけ下がるかを測る方法 (PFI) を実装した。

表 1 1 つの特徴量だけで正解式を不正解式より上に並べられる割合 (AUC、1,823 ケースの平均 ± 標準偏差)。式の特化度と分野の一致は候補の中でのみ測った (全データベースを相手にした計算は行っていない)。

特徴量	全データベース 11,146 式	候補 50 件の中
変数の一致度	0.999 ± 0.000	0.947 ± 0.002
式の特化度	—	0.965 ± 0.001
意味の近さ	0.950 ± 0.003	0.594 ± 0.006
文章類似度	0.913 ± 0.003	0.437 ± 0.007
分野の一致	—	0.531 ± 0.003

訓練し直さないで、モデルが実際にその特徴量へどれだけ頼っているかを直接測れる。設定 A・乱数 10 通り・各特徴量あたり 20 回のシャッフルで実施した (シャッフルしないときの $\text{Recall}@K$ は 0.743)。特徴量は 1 つずつシャッフルするほか、変数の重なりを測る 6 特徴量と話題の近さを測る 4 特徴量 (内訳は図 2(a) の色分け) を、それぞれまとめてシャッフルした。

結果 (図 2) :

- モデルは変数の重なりに頼り切っている：変数の重なりを測る 6 特徴量をまとめてシャッフルすると、 $\text{Recall}@K$ は 0.743 から 0.065 に落ちる (低下 +0.678、 $p < 0.001$)。1 つずつでは式の特化度が +0.617 と突出し、変数の一致度 +0.062、補完性 +0.022、一貫性 +0.019、出力変数の被覆 +0.006 が続く (いずれも $p < 0.01$)。
- 話題の近さには頼っていない：話題の近さを測る 4 特徴量をまとめてシャッフルしても低下は +0.006 で、有意差は認められなかった ($p = 0.10$)。1 つずつ見ても、意味の近さ -0.003 ($p = 0.28$)、文章類似度 -0.003 ($p = 0.26$)、分野の一致 +0.002 ($p = 0.23$)、分野の一致 (集合版。既に選んだ式の集合のうち候補と同じ分野の式が占める割合) -0.000 ($p = 0.91$) で、いずれも 0 と区別が付かない。訓練し直す方法と同じ結論に至った。
- 変数の重なりを測る特徴量どうしは互いに代わりが利く：変数の一致度は 1 つだけシャッフルしても +0.062 しか下がらないのに、6 つまとめると +0.678 下がる。1 つ壊しても他の特徴量が同じ情報を補うためであり、変数の重なりという情報は不可欠だが、それを担う特徴量は取り替えが利くことを意味する。




図 2 特徴量の値をケース内でシャッフルしたときの $\text{Recall}@K$ の低下 (大きいほどモデルがその特徴量に頼っている)。誤差棒は乱数 10 通りの標準偏差。(b) の点線はシャッフル前の $\text{Recall}@K = 0.743$ 。

5 まとめと今後の課題

今回：意味の近さが効かない原因は、ご指摘のベクトルの計算方法ではなかった。ケースどうしのベクトルは内容が同じ組（中央値 0.944）とは分布が重ならないほど離れており、意味の近さ 1 つで全データベースから正解式を選び出す AUC も 0.950 に達する。それが候補 50 件の中で 0.594 に落ちるのは、第 1 段が文章類似度で候補を絞った時点で、候補の中の式が話題ではそろってしまうからである。あわせて各特徴量の重要度を訓練し直さずに測り、モデルが変数の重なりを測る 6 特徴量に頼り切り、話題の近さを測る 4 特徴量には頼っていない（低下 +0.678 対 +0.006）ことを確かめた。

今後の課題：

- 話題の近さは第 1 段の絞り込みでのみ効くので、第 2 段の特徴量からは外し、精度が変わらないことを確かめる。
- 候補の中で正解式と不正解式を分けているのは変数の重なりだけなので、変数の集合が同じ式どうしをどう区別するかを考える。
- 変数の重なりを測る特徴量は互いに代わりが利くので、より少ない特徴量で同じ精度に届くかを調べる。