

物理モデルの自動構築：意味の近さが効かない原因と、
各特徴量の重要度

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

本手法は 2 段構えである。第 1 段では、データベースの全 11,146 式に、説明文と式まわりの文章がどれだけ似ているか（文章類似度）と、指定された入出力変数と式の変数がどれだけ重なるか（変数の一致度）を 7 対 3 の重みで足した点数を付け、上位 50 件を候補として絞り込む。第 2 段では、その候補 50 件だけを対象に、10 個の特徴量を多層パーセプトロン（MLP）で学習して並べ直す。10 個の特徴量の意味と計算方法を表 1 にまとめる。

表 1 第 2 段が使う 10 個の特徴量。式が持つ変数の集合を V_e 、入力で指定された入出力変数の集合を V_q （入力 V_{in} ・出力 V_{out} ）、参照集合の式が持つ変数の集合を V_S とする。

特徴量	意味と計算方法
基本の 7 個：候補の式を 1 本ずつ、入力と照らして評価する	
文章類似度	説明文と式まわりの文章の、TF-IDF で重み付けした単語ベクトルのコサイン類似度
意味の近さ	同じ 2 つの文章を 256 次元に圧縮（TF-IDF + SVD）したベクトルのコサイン類似度。単語が一致しなくても内容が近ければ大きい
分野の一致	式に付いた分野名が説明文に現れれば 1、なければ 0
変数の一致度	入出力変数と式の変数がどれだけ重なるか。 $ V_q \cap V_e / V_q \cup V_e $ (Jaccard 係数)
入力変数の被覆	入力変数のうち式に現れる割合。 $ V_{in} \cap V_e / V_{in} $
出力変数の被覆	出力変数のうち式に現れる割合。 $ V_{out} \cap V_e / V_{out} $
式の特化度	式の変数のうち入出力変数が占める割合。 $ V_q \cap V_e / V_e $ 。無関係な変数を持たない式ほど大きい
集合の 3 個：第 1 段で上位 5 件に入った式を参照集合とし、それとの関係で評価する	
補完性	参照集合がまだ覆っていない入出力変数を、その式が新たに補う割合。 $ (V_q \cap V_e) \setminus V_S / V_q $
一貫性	式の変数のうち参照集合と共有する割合。 $ V_e \cap V_S / V_e $
分野の一致（集合版）	参照集合の式のうち、その式と分野名が同じものの割合

前回は、古典的情報検索手法（baseline）から本手法（reranker-10S）への Recall@ K （正解式数 K に合わせ、上位 K 件に入った正解式の割合）の向上 +0.222（設定 A：オリジナル＋文献横断＋DAE、1,823 件）を報告した。あわせて 10 特徴量を 1 つずつ足し直して評価し、精度を上げるのは変数の重なりを測る特徴量に限られ、話題の近さを測る特徴量（意味の近さ・分野の一致）はどの形でも効かないことを示した。

2 今回の進捗

加藤先生から「性能向上手法として期待していたことと結果との関連、およびその原因の考察が要る。意味の近さが効かないのは、TF-IDF から SVD で計算したベクトルがケース間であまり違わ

ないためではないか」とのご指摘をいただいた。本報告では 2 つの実験を行なった。

1. 意味の近さは、ケースどうしを十分に区別できていた：ベクトルが似すぎているという状況は起きておらず、意味の近さ 1 つだけで全 11,146 式の中から正解式を選び出すこともできる。それでも第 2 段で効かないのは、第 1 段が候補を絞った時点で、候補の中の式が話題ではそろってしまうからであった。
2. 各特徴量の重要度を、訓練し直さずに測った：訓練済みのモデルで特徴量の値をシャッフルし、Recall@K がどれだけ下がるかを測る方法（順列特徴量重要度、PFI）を実装した。モデルは変数の重なりを測る 6 特徴量に頼り切っており、話題の近さを測る 4 特徴量には頼っていない。

3 実験 1：意味の近さは区別を作れているか

方法：モデルを訓練せず、データと第 1 段の性質だけから調べた。

(a) ケースどうしのベクトルがどれだけ離れているかを、コサイン類似度で測った。値の大小を判断できるように、内容が同じと分かっている組と、互いに無関係と分かっている組を、同じ空間に置いて物差しを作った。組は、言い換えの組、同じ物理モデルで入出力だけ変えた組、同じ文献に由来する別ケースの組、互いに無関係な組（出典文献が重ならず、同じ物理モデルにも由来しない組）の 4 種類である（組数は図 1 に示す）。

(b) 1 つの特徴量だけで正解式を不正解式より上に並べられる割合（AUC、Area Under the ROC Curve）を測った。AUC は次の手順で求める。ケースごとに正解式 1 本と不正解式 1 本の組をすべて作り、各組でその特徴量の値を比べ、正解式のほうが大きい組の割合を数える。すべての組で正解式のほうが大きければ 1.0、値の大小が正解・不正解と無関係なら 0.5 になる。この AUC を、不正解式の範囲を全データベース 11,146 式とした場合と第 1 段が選んだ候補 50 件とした場合の 2 通りで測った。

結果（図 1・表 2）：

- ベクトルはケースの内容を区別できている：比較の基準に使う無関係な組（出典文献が重ならず、同じ物理モデルにも由来しない組）のコサイン類似度は中央値 0.213 にとどまる。一方、内容が同じまま説明文を書き換えた言い換えの組は中央値 0.944 で、**276 組**すべてが 0.213 を上回り、無関係な組と分布が重ならない（図 1）。
- 無関係な組でも類似度が高くなる場合はある：無関係な組のうち 0.5 を超えるのは 3.9% である。高い値になるのは、同じ種類の装置・現象を説明した組であった。例えば、どちらも連続攪拌槽反応器（CSTR）を扱う 2 ケースは 0.70 に達する。これは話題が実際に近いのだから、ベクトルの欠陥ではない。
- 全データベースを相手にすれば、意味の近さだけで正解式を選び出せる：意味の近さという特徴量 1 つだけで正解式を並べたときの AUC は、不正解式の範囲を全データベースとした場合 0.950 に達する（表 2）。ベクトルの区別が失われていれば、この分離は起こらない。以上より、ご指摘の仮説は成り立たない。
- 候補を絞った後で効かなくなる：同じ計算を、不正解式の範囲を候補 50 件に変えて行なうと、意味の近さの AUC は 0.950 から 0.594 に落ちる。文章類似度の AUC は 0.437、分野の一致の AUC は 0.531 で、いずれも識別力なしの 0.5 付近である。これに対し、変数の一致度の AUC は 0.947、式の特化度の AUC は 0.965 を保つ。候補を 200 件に広げても、意味の近さの AUC は

0.718 にとどまる。

- 原因は第 1 段の絞り込みにある：第 1 段は文章類似度を重み 7 で使って候補を選ぶので、候補に残った不正解式は正解式と話題がそろっている。話題の近さは絞り込みには効くが、絞り込んだ後の選別には使えない。




図 1 ケースどうしのベクトルのコサイン類似度。内容が同じと分かっている組（上 2 つ）と互いに無関係な組（最下段）を並べた。箱＝四分位、縦線＝中央値、ひげ＝1.5 四分位範囲。

表 2 1 つの特徴量だけで正解式を不正解式より上に並べられる割合（AUC、1,823 ケースの平均 ± 標準偏差）。列は不正解式の範囲の違いを表す。式の特化度と分野の一致は候補の中でのみ測った（全データベースを相手にした計算は行なっていない）。

特徴量	全データベース 11,146 式	候補 50 件の中
変数の一致度	0.999 ± 0.000	0.947 ± 0.002
式の特化度	—	0.965 ± 0.001
意味の近さ	0.950 ± 0.003	0.594 ± 0.006
文章類似度	0.913 ± 0.003	0.437 ± 0.007
分野の一致	—	0.531 ± 0.003

4 実験 2：各特徴量の重要度を

PFI (Permutation Feature Importance) 方法で測る

方法：これまで「どの特徴量が効くか」は、特徴量を 1 つずつ足したモデルを訓練し直して比べる方法で調べてきた（前回報告）。今回はこれとは別に、訓練済みのモデルをそのまま使い、ある特徴量の値だけを壊して Recall@K がどれだけ下がるかを測る方法（PFI）を実装した。手順は次のとおりである。訓練済みのモデルに対し、テストケースの候補式の間で対象の特徴量の値だけを無作為に入れ替える（これをシャッフルと呼ぶ）。他の 9 特徴量は元のままである。この入力で Recall@K を測り直し、シャッフル前からの低下をその特徴量の重要度とする。訓練し直さないで、モデルが実際にその特徴量へどれだけ頼っているかを直接測れる。偶然の入れ替わり方に結果が左右されないよう、シャッフルは入れ替え方を変えて 20 回繰り返して平均した。さらにこの測定全体を、データの分割と訓練をやり直した 10 個のモデル（主要比較と同じ乱数 10 通り）で繰り返し、平均と標準偏差を取った（シャッフルしないときの Recall@K は 0.743）。特徴量は 1 つずつシャッフルするほか、変数の重なりを測る 6 特徴量と話題の近さを測る 4 特徴量（内訳は図 2(a) の色分け）を、それぞれま

とめてシャッフルした。

結果 (図 2) :

- モデルは変数の重なりに頼り切っている：変数の重なりを測る 6 特徴量をまとめてシャッフルすると、Recall@K は 0.743 から 0.065 に落ちる (低下 +0.678、 $p < 0.001$)。1 つずつでは式の特化度が +0.617 と突出し、変数の一致度 +0.062、補完性 +0.022、一貫性 +0.019、出力変数の被覆 +0.006 が続く (いずれも $p < 0.01$)。
- 話題の近さには頼っていない：話題の近さを測る 4 特徴量をまとめてシャッフルしても低下は +0.006 で、有意差は認められなかった ($p = 0.10$)。1 つずつ見ても、意味の近さ -0.003 ($p = 0.28$)、文章類似度 -0.003 ($p = 0.26$)、分野の一致 +0.002 ($p = 0.23$)、分野の一致 (集合版) -0.000 ($p = 0.91$) で、いずれも 0 と区別が付かない。訓練し直す方法と同じ結論に至った。
- 変数の重なりを測る特徴量どうしは互いに代わりが利く：変数の一致度は 1 つだけシャッフルしても +0.062 しか下がらないのに、6 つまとめると +0.678 下がる。1 つ壊しても他の特徴量が同じ情報を補うためであり、変数の重なりという情報は不可欠だが、それを担う特徴量は取り替えが利くことを意味する。




図 2 特徴量の値をケース内でシャッフルしたときの Recall@K の低下 (大きいほどモデルがその特徴量に頼っている)。誤差棒は乱数 10 通りの標準偏差。(b) の点線はシャッフル前の Recall@K = 0.743。

5 まとめと今後の課題

今回：意味の近さが効かない原因は、ご指摘のベクトルの計算方法ではなかった。無関係な組のベクトル (中央値 0.213) は内容が同じ組 (中央値 0.944) と分布が重ならないほど離れており、意味の近さだけの AUC も全データベースを相手にすれば 0.950 に達する。それが候補 50 件の中で 0.594 に落ちるのは、第 1 段が候補を絞った時点で、候補の中の式が話題ではそろってしまうからである。あわせて各特徴量の重要度を訓練し直さずに測り、モデルが変数の重なりを測る 6 特徴量に頼り切り、話題の近さを測る 4 特徴量には頼っていないことを確かめた (低下 +0.678 対 +0.006)。

今後の課題：

- 話題の近さは第 1 段でのみ効くので、第 2 段の特徴量から外して精度が変わらないことを確かめる。
- 候補の中で正解式を分けているのは変数の重なりだけなので、変数の集合が同じ式どうしをどう区別するかを考える。
- 変数の重なりを測る特徴量は互いに代わりが利くので、より少ない特徴量で足りるかを調べる。