

物理モデルの自動構築：意味の近さが効かない原因と、 各特徴量の重要度

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

本手法は 2 段階構成である。第 1 段階では、データベースの全 11,146 式に、説明文と式まわりの文章がどれだけ似ているか（文章類似度）と、指定された入出力変数と式の変数がどれだけ重なるか（変数の一致度）を 7 対 3 の重みで足した点数を付け、上位 50 件を候補として絞り込む。第 2 段階では、その候補 50 件だけを対象に、10 個の特徴量を多層パーセプトロン（MLP）で学習して並べ直す。10 個のうち本報告で中心に扱う意味の近さは、説明文と式まわりの文章をそれぞれ 256 次元のベクトルに直し（単語を TF-IDF で重み付けし、SVD で次元を圧縮する）、その 2 本のコサイン類似度を取ったものである。単語がそのまま一致しなくても内容が近ければ大きくなることを期待して入れた特徴量である。

前は、古典的情報検索手法（baseline）から本手法（reranker-10S）への Recall@K（正解式数 K に合わせ、上位 K 件に入った正解式の割合）の向上 +0.222（設定 A：オリジナル＋文献横断＋DAE、1,823 件）を報告した。あわせて 10 特徴量を 1 つずつ足し直して評価し、精度を上げるのは変数の重なりを測る特徴量に限られ、話題の近さを測る特徴量（意味の近さ・分野の一致）はどの形でも効かないことを示した。

2 今回の進捗

加藤先生から「性能向上手法として期待していたことと結果との関連、およびその原因の考察が要る。意味の近さが効かないのは、TF-IDF から SVD で計算したベクトルがケース間であまり変わらないためではないか」とのご指摘をいただいた。本報告では 2 つの実験を行なった。

1. 意味の近さは、ケースどうしを十分に区別できていた：ベクトルが似すぎているという状況は起きておらず、意味の近さ 1 つだけで全 11,146 式の中から正解式を選び出すこともできる。それでも第 2 段階で効かないのは、第 1 段階が候補を絞った時点で、候補の中の式が話題ではそろってしまうからであった。
2. 各特徴量の重要度を、訓練し直さずに測った：訓練済みのモデルで特徴量の値をシャッフルし、Recall@K がどれだけ下がるかを測る方法（順列特徴量重要度、PFI）を実装した。モデルは変数の重なりを測る 6 特徴量に頼り切っており、話題の近さを測る 4 特徴量には頼っていない。

3 実験 1：意味の近さは区別を作れているか

方法：モデルを訓練せず、データと第 1 段階の性質だけから調べた。

(a) ケースどうしのベクトルがどれだけ離れているかを、コサイン類似度で測った。値の大小を判断できるように、内容が同じと分かっている組と、互いに無関係と分かっている組を、同じ空間に置い

て物差しを作った。組は、言い換えの組、同じ物理モデルで入出力だけ変えた組、同じ文献に由来する別ケースの組、互いに無関係な組（出典文献が重ならず、同じ物理モデルにも由来しない組）の 4 種類である（組数は図 1 に示す）。

(b) 1 つの特徴量だけで正解式を不正解式より上に並べられる割合（AUC、Area Under the ROC Curve）を測った。AUC は次の手順で求める。ケースごとに正解式 1 本と不正解式 1 本の組をすべて作り、各組でその特徴量の値を比べ、正解式のほうが大きい組の割合を数える。すべての組で正解式のほうが大きければ 1.0、値の大小が正解・不正解と無関係なら 0.5 になる。この AUC を、不正解式の範囲を全データベース 11,146 式とした場合と第 1 段が選んだ候補 50 件とした場合の 2 通りで測った。

結果（図 1・表 1）：

- ベクトルはケースの内容を区別できている：比較の基準に使う無関係な組（出典文献が重ならず、同じ物理モデルにも由来しない組）のコサイン類似度は中央値 0.213 にとどまる。一方、内容が同じまま説明文を書き換えた言い換えの組は中央値 0.944 で、**276 組**すべてが 0.213 を上回り、無関係な組と分布が重ならない（図 1）。
- 無関係な組でも類似度が高くなる場合はある：無関係な組のうち 0.5 を超えるのは 3.9% で、高い値になるのは 2 通りであった。(i) 同じ種類の装置・現象を説明した組。例えば、どちらも連続攪拌槽反応器（CSTR）を扱う 2 ケースは 0.70 に達する。これは話題が実際に近いのだから、ベクトルの欠陥ではない。(ii) 文献横断ケースのうち、説明文を同じ雛形から作ったため文面がほぼ同じ組。こちらは最大 0.999 に達する。
- 全データベースを相手にすれば、意味の近さだけで正解式を選び出せる：意味の近さという特徴量 1 つだけで正解式を並べたときの AUC は、不正解式の範囲を全データベースとした場合 0.950 に達する（表 1）。ベクトルの区別が失われていれば、この分離は起こらない。以上より、ご指摘の仮説は成り立たない。
- 候補を絞った後で効かなくなる：同じ計算を、不正解式の範囲を候補 50 件に変えて行なうと、意味の近さの AUC は 0.950 から 0.594 に落ちる。文章類似度の AUC は 0.437、分野の一致（式の分野が説明文に現れれば 1 とする特徴量）の AUC は 0.531 で、いずれも識別力なしの 0.5 付近である。これに対し、変数の一致度の AUC は 0.947、式の特化度（式の変数のうち入出力変数が占める割合）の AUC は 0.965 を保つ。候補を 200 件に広げても、意味の近さの AUC は 0.718 にとどまり、変数の一致度（0.977）・式の特化度（0.984）との差は変わらない。
- 原因は第 1 段の絞り込みにある：第 1 段は文章類似度を重み 7 で使って候補を選ぶので、候補に残った不正解式は正解式と話題がそろっている。話題の近さは絞り込みには効くが、絞り込んだ後の選別には使えない。

4 実験 2：各特徴量の重要度を

PFI (Permutation Feature Importance) 方法で測る

方法：これまで「どの特徴量が効くか」は、特徴量を 1 つずつ足したモデルを訓練し直して比べる方法で調べてきた（前回報告）。今回はこれとは別に、訓練済みのモデルをそのまま使い、ある特徴量の値だけを壊して $\text{Recall}@K$ がどれだけ下がるかを測る方法（PFI）を実装した。手順は次のとおりである。訓練済みのモデルに対し、テストケースの候補式の間で対象の特徴量の値だけを無作為に入れ




図 1 ケースどうしのベクトルのコサイン類似度。内容が同じと分かっている組（上 2 つ）と互いに無関係な組（最下段）を並べた。箱＝四分位、縦線＝中央値、ひげ＝1.5 四分位範囲。

表 1 1 つの特徴量だけで正解式を不正解式より上に並べられる割合（AUC、1,823 ケースの平均 ± 標準誤差）。列は不正解式の範囲の違いを表す。式の特化度と分野の一致は候補の中でのみ測った（全データベースを相手にした計算は行っていない）。

特徴量	全データベース 11,146 式	候補 50 件の中
変数の一致度	0.999 ± 0.000	0.947 ± 0.002
式の特化度	—	0.965 ± 0.001
意味の近さ	0.950 ± 0.003	0.594 ± 0.006
文章類似度	0.913 ± 0.003	0.437 ± 0.007
分野の一致	—	0.531 ± 0.003

替える（これをシャッフルと呼ぶ）。他の 9 特徴量は元のままである。この入力で $\text{Recall}@K$ を測り直し、シャッフル前からの低下をその特徴量の重要度とする。モデルが頼っていない特徴量なら、壊しても $\text{Recall}@K$ は下がらない。訓練し直さないで、モデルが実際にその特徴量へどれだけ頼っているかを直接測れる。偶然の入れ替わり方に結果が左右されないよう、シャッフルは入れ替え方を変えて 20 回繰り返して平均した。さらにこの測定全体を、主要比較（設定 A）と同じ乱数 10 通り、すなわちデータの分割と訓練をやり直した 10 個のモデルで繰り返し、平均と標準偏差を取った（シャッフルしないときの $\text{Recall}@K$ は 0.743）。特徴量は 1 つずつシャッフルするほか、変数の重なりを測る 6 特徴量と話題の近さを測る 4 特徴量（内訳は図 2(a) の色分け）を、それぞれまとめてシャッフルした。

結果（図 2）：

- モデルは変数の重なりに頼り切っている：変数の重なりを測る 6 特徴量をまとめてシャッフルすると、 $\text{Recall}@K$ は 0.743 から 0.065 に落ちる（低下 +0.678、 $p < 0.001$ ）。1 つずつでは式の特化度が +0.617 と突出し、変数の一致度 +0.062、補完性 +0.022、一貫性 +0.019、出力変数の被覆 +0.006 が続く（いずれも $p < 0.01$ ）。
- 話題の近さには頼っていない：話題の近さを測る 4 特徴量をまとめてシャッフルしても低下は +0.006 で、有意差は認められなかった（ $p = 0.10$ ）。1 つずつ見ても、意味の近さ -0.003（ $p = 0.28$ ）、文章類似度 -0.003（ $p = 0.26$ ）、分野の一致 +0.002（ $p = 0.23$ ）、分野の一致（集合版。既に選んだ式の集合のうち候補と同じ分野の式が占める割合） -0.000（ $p = 0.91$ ）で、いずれも 0 と区別が付かない。訓練し直す方法と同じ結論に至った。
- 変数の重なりを測る特徴量どうしは互いに代わりが利く：変数の一致度は 1 つだけシャッフルし

でも $+0.062$ しか下がらないのに、6 つまとめると $+0.678$ 下がる。1 つ壊しても他の特徴量が同じ情報を補うためであり、変数の重なりという情報は不可欠だが、それを担う特徴量は取り替えが利くことを意味する。




図 2 特徴量の値をケース内でシャッフルしたときの Recall@K の低下 (大きいほどモデルがその特徴量に頼っている)。誤差棒は乱数 10 通りの標準偏差。(b) の点線はシャッフル前の Recall@K = 0.743。

5 まとめと今後の課題

今回：意味の近さが効かない原因は、ご指摘のベクトルの計算方法ではなかった。無関係な組のベクトル (中央値 0.213) は内容が同じ組 (中央値 0.944) と分布が重ならないほど離れており、意味の近さだけで正解式を並べた AUC も、全データベースを相手にすれば 0.950 に達する。それが候補 50 件の中で 0.594 に落ちるのは、第 1 段が文章類似度で候補を絞った時点で、候補の中の式が話題ではそろってしまうからである。あわせて各特徴量の重要度を訓練し直さずに測り、モデルが変数の重なりを測る 6 特徴量に頼り切り、話題の近さを測る 4 特徴量には頼っていない (低下 $+0.678$ 対 $+0.006$) ことを確かめた。

今後の課題：

- 話題の近さは第 1 段の絞り込みでのみ効くので、第 2 段の特徴量からは外し、精度が変わらないことを確かめる。
- 候補の中で正解式と不正解式を分けているのは変数の重なりだけなので、変数の集合が同じ式どうしをどう区別するかを考える。
- 変数の重なりを測る特徴量は互いに代わりが利くので、より少ない特徴量で同じ精度に届くかを調べる。