

物理モデルの自動構築：期待した特徴量はなぜ効かなかったのか ——話題の近さの限界と、誤りの所在

作成者：M2 一洋

1 前回ゼミレビュー

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

本手法は 2 段構えである。第 1 段では、データベースの全 11,146 式に、説明文と式まわりの文章がどれだけ似ているか（文章類似度）と、指定された入出力変数と式の変数がどれだけ重なるか（変数の一致度）を 7 対 3 の重みで足した点数を付け、上位 50 件を候補として絞り込む。第 2 段では、その候補だけを対象に、10 個の特徴量を多層パーセプトロン（MLP）で学習して並べ直す。候補件数 k は実験によって使い分けており、精度の主要比較では 50 件、データ拡張後に行った逐次選択や自己停止の実験では 200 件を用いている。今回、この違いが結論を左右することが分かったので、以下では両方で測った結果を並べて示す。

前は、古典的情報検索手法（baseline、第 1 段の点数で全式を並べるだけの方式）から本手法（reranker-10S）への Recall@ K （正解式数 K に合わせ、上位 K 件に入った正解式の割合）の向上 +0.222（設定 A：オリジナル＋文献横断＋DAE、1,823 件）を 3 段——重み付けの学習 +0.080、特徴量の追加 +0.092、既に選んだ式との関係を見る特徴量（集合特徴量）+0.050——に分解した。そのうえで全 10 特徴量を 1 つずつ評価し、精度を上げるのは変数の重なりを測る特徴量に限られ、話題の近さを測る特徴量（意味の近さ・分野の一致）はどの形でも効かないことを報告した。

2 今回の進捗

これに対し加藤先生から「性能向上手法として期待していたことと結果との関連、およびその原因の考察が要る。正解・不正解のケースを見て分析すること。意味の近さが効かないのは、**TF-IDF** から **SVD** で計算したベクトルがケース間であまり変わらないためではないか」とのご指摘をいただいた。本報告では、この原因を実験で調べた。

1. ベクトルの差が小さいという仮説は成り立たなかった：ケースどうしのベクトルは十分に離れていた。コサイン類似度は無作為な 2 ケースの組で中央値 0.218 であるのに対し、内容が同じケースの組では 0.94 以上に集まる。意味の近さは、全データベース 11,146 式の中から正解式を選び出す力も十分に持っていた。
2. 原因は、候補を絞った後では話題の情報が余分になることであった：第 1 段が候補を絞った後では、意味の近さは正解式と不正解式をほとんど区別できなくなる。候補を 200 件に広げると識別力はいくらか戻るが、変数の重なりを測る特徴量には遠く及ばない。
3. 第 1 段の絞り込み方が、候補の中に見かけの逆相関を作っていた：候補の中では文章類似度と変数の一致度が逆相関する（相関係数は候補 50 件で -0.404 、200 件で -0.344 ）。絞り込みが厳しいほど強くなる。
4. 誤りがどこで生じるかは、候補件数で入れ替わる：候補 50 件では、本手法が上位 K 件に並べ

られなかった正解式 435 本のうち 61.8% が第 1 段の候補に入っていなかったものである。候補 200 件にすると 373 本中 28.4% に下がり、残り 71.6% は候補に入ったのに順位が足りなかったものになる。候補を広げれば絞り込みの取りこぼしはおおむね解消し、残るのは並べ替えの問題である。

5. その並べ替えの誤りは、話題の近さを強めても直らない：上位 K 件に入らなかった正解式と、その代わりに上位へ入った誤りの式を突き合わせると、意味の近さで正解式のほうが大きい組は、候補 50 件で半分 (0.516)、候補 200 件では半分を下回る (0.421)。意味の近さが手がかりになっているなら正解式のほうが大きい組が多くなるはずで、そうになっていない。候補を広げるほどこの傾向は強まる。
6. 分野の一致が効かないのは「無効」ではなく「相殺」であった：前回、特徴量の値をシャッフルして精度の低下を測る方法（順列特徴量重要度）で、分野の一致は全体平均 -0.000 ($p = 0.91$) と報告した。今回ケースごとに分解すると、この特徴量が正解式を上位に寄せているケースでは平均 $+0.012$ の低下、逆向きに働いているケースでは -0.034 (=壊すとかえって精度が上がる) で、両者が打ち消し合っていた。
7. 上限を引き上げたのは、重み付けの変更ではなく候補件数を広げたことであった：正解式が候補に入る割合（被覆率）は、第 2 段をどれだけ改良しても超えられない上限になる。現行の重み（文章類似度 7 対 変数の一致度 3）では候補 50 件で 0.920、200 件で 0.977 である。変数の一致度だけで絞ると 50 件で 0.961 まで上がるが、200 件では 0.991 で現行との差は小さい。設定 B (DAE のみ 1,000 件) では、候補を 50 件から 200 件に広げると Recall@ K が $0.689 \rightarrow 0.724$ (乱数 10 通り) に上がる。

3 実験 1：意味の近さはどこで力を失うか

方法：モデルを訓練せず、データと第 1 段の性質だけから調べた。(a) ケースどうしのベクトルがどれだけ離れているかを測った。ベクトルは、文章に出てくる単語の重み付き出現頻度を並べたもの (TF-IDF) と、それを 256 次元に圧縮したもの (SVD) の 2 通りを用い、無作為に選んだ 20 万組のコサイン類似度を求めた。(b) 1 つの特徴量だけで正解式を不正解式より上に並べられる割合 (AUC) を、全データベース 11,146 式を相手にした場合と第 1 段が選んだ候補の中で測った。候補は 50 件と 200 件の両方を試した。AUC は 0.5 が識別力なし、1.0 が完全な分離を表す。

結果 (図 1・表 1)：

- 仮説は棄却された：ケース間のコサイン類似度は SVD 空間で中央値 0.218、圧縮前の TF-IDF 空間で 0.070 であり、0.5 を超える組は 5.4% にとどまる (図 1(a))。SVD への射影は類似度を平均で $0.088 \rightarrow 0.247$ と押し上げるが、区別が付かなくなるほどではない。決め手は全データベースでの識別力で、意味の近さ 1 つで AUC 0.950 に達する。ベクトルの差が失われていれば、この分離は起こらない。
- 0.218 がどれだけ「違う」かを同じ空間で確かめた：同じ核モデルから入出力だけ変えて作ったケースの組は中央値 1.000、同じケースの説明文を書き換えただけの組は 0.944、同じ文献に由来する別のケースの組は 0.445 である (図 2)。無作為な組の 0.218 は、言い換えの組 276 組のどれよりも低い。実際に 0.218 付近の組を見ると、一方は微生物がグルコースを消費する発酵系、もう一方は PI 制御下のタンク液位の応答で、話題は明確に異なる。なお全ケースが英語の化学工学の

文章なので共通語彙による下駄があり、無関係でも 0 にはならない（無作為な組の四分位は 0.149 - 0.313）。この目盛りで読めば 0.218 は下端＝無関係にあたる。

- 候補を絞った後で力を失う：意味の近さの AUC は全データベースの 0.950 から、候補 50 件で 0.594、候補 200 件でも 0.718 に落ちる。文章類似度は 0.913 から 0.437 / 0.572 に落ちる。これに対し変数の一致度は 0.999 から 0.947 / 0.977 を保つ（表 1）。候補の中だけで測ると式の特化度は 0.965 / 0.984 と最も高く、分野の一致は 0.531 / 0.548 にとどまる（図 1(b)）。候補を広げれば話題の近さの識別力はいくらか戻るが、変数を見る特徴量との差は埋まらない。
- 値が潰れているのではなく、値の違いが正誤と対応しない：候補の中での意味の近さのばらつき（標準偏差 0.121）は全体（0.075）より大きい。第 1 段は文章類似度を重み 0.7 で使うので、候補 50 件は初めから話題の近い式ばかりが集まる。
- 絞り込みが見かけの逆相関を作る：候補は「文章類似度と変数の一致度の重み付き和が大きい式」だけの集まりなので、その中では文章類似度が高いことは変数が合っていないことの裏返しになる。文章類似度と変数の一致度の相関は候補 50 件で -0.404 、200 件で -0.344 であった。候補 50 件では文章類似度の候補内 AUC が 0.437 と 0.5 を下回るが、200 件では 0.572 と逆転が解消する。絞り込みが厳しいほどこの見かけの逆相関が強くなることを示している。

表 1 1 つの特徴量だけで正解式を不正解式より上に並べられる割合（AUC、1,823 ケースの平均 ± 標準誤差）。全データベース 11,146 式を相手にした場合と、第 1 段が選んだ候補の中で測った場合を比べる。式の特化度は候補の中でのみ測った。

特徴量	全データベース	候補 50 件の中	候補 200 件の中
変数の一致度	0.999 ± 0.000	0.947 ± 0.002	0.977 ± 0.001
式の特化度	—	0.965 ± 0.001	0.984 ± 0.000
意味の近さ（SVD）	0.950 ± 0.003	0.594 ± 0.006	0.718 ± 0.006
文章類似度	0.913 ± 0.003	0.437 ± 0.007	0.572 ± 0.007




図 1 (a) ケースどうしのベクトルのコサイン類似度の分布（無作為に選んだ 20 万組、破線は中央値）。(b) 候補 50 件の中で正解式を不正解式より上に並べられる割合（1,823 ケースの平均、誤差棒は標準誤差。青は変数の重なりを測る特徴量、赤は話題の近さを測る特徴量）。




図2 ケースどうしのベクトルのコサイン類似度の物差し (箱は四分位、縦線は中央値、ひげは四分位範囲の 1.5 倍、外れ値は非表示)。内容が同じ組 (上の 2 つ) は 0.87 以上に集まり、無作為な組 (最下段、中央値 0.218) とは重ならない。

4 実験 2：正解・不正解のケースを見る

方法：本手法 (reranker-10S) を乱数 1 通り (seed 42) で訓練し、テストの 423 ケースを、本手法が正解式をすべて上位 K 件にそろえられたケースと、そろえられなかったケースに分けた。上位 K 件に入らなかった正解式ごとに、第 1 段で候補に入らなかったものと、候補には入ったが上位 K 件から漏れたものを区別した。候補 50 件と 200 件で同じ手順を繰り返した。さらに後者について、「その特徴量を強めていれば順位が戻ったか」を次のように測った。1 つのケースの中で、上位 K 件に入らなかった正解式 1 本と、その代わりに上位へ入った誤りの式 1 本を組にし (両者が複数あれば総当たり)、着目する特徴量の値が正解式のほうが大きい組の割合を求める。同値の組は 0.5 と数える。これをケースごとに求め、該当するケース (候補 50 件で 131 件、200 件で 182 件) にわたって平均した値を報告する。形は AUC と同じで、「見逃した正解式を 1 本、居座った誤りの式を 1 本選んだとき、正解式のほうが値が大きい確率」を表す。この割合が高ければ、その特徴量の重みを上げると順位が入れ替わる見込みがある。0.5 ならその特徴量から見て両者は区別が付かず、重みを上げても順位は戻らない。0.5 を下回れば、重みを上げるとかえって悪化する。

結果 (図 3)：

- 誤りの内訳は候補件数で入れ替わる：候補 50 件では、正解式をすべてそろえられたのは 423 ケース中 212 ケース (50.1%) で、上位 K 件に入らなかった正解式は 435 本あった。うち 269 本 (61.8%) は第 1 段で候補に入らず、166 本 (38.2%) は候補に入ったが順位が足りなかった。候補 200 件にすると Recall@ K は 0.791 $\rightarrow$ 0.807 に上がり、入らなかった正解式は 373 本に減る。その内訳は第 1 段が 106 本 (28.4%)、並べ替えが 267 本 (71.6%) と逆転する。候補を広げれば絞り込みの取りこぼしはおおむね解消し、残るのは並べ替えの問題になる。
- そろえられないのは規模の大きいケースである：候補 50 件で、そろえられなかったケースの正解式数は平均 5.34 (そろえられたケースは 2.13)、入力変数数は 17.8 (同 10.8) であった。第 1 段の被覆率も 0.829 (同 1.000) に下がる。候補 200 件でも傾向は同じで (5.23 対 2.28、17.2 対 11.6)、規模が難しさを決めることは候補件数によらない。

- 話題の近さを強めても救えない：上位 K 件に入らなかった正解式が、代わりに上位へ入った誤りの式を上回る割合は、候補 50 件で意味の近さ 0.516 ± 0.040 ・分野の一致 0.494 ± 0.011 と偶然と同じであり、候補 200 件では意味の近さ 0.421 ± 0.032 とむしろ 0.5 を下回る (図 3(b))。変数の一致度も $0.375 / 0.262$ と誤りの式のほうが大きい。残った誤りは現在のどの特徴量から見ても正解より良く見えており、候補を広げるほどその傾向が強まる。
- 誤りの型は 2 つに分けられた。
 - 別の文献にある数学的に同じ式を選ぶ：回分発酵のケース（入力：時間 t ・比増殖速度 μ / 出力：菌体濃度 X ）で、正解は出典文献の $dX/dt = \mu X$ （意味の近さ 0.369）だが、別の文献の $(1/X)dX/dt = \mu$ (0.72) と $dX/dt = \mu \cdot X$ (0.584) が上位に来た。3 式とも変数は同じで変数側の特徴量では区別できず、話題の近さは誤りのほうを強く推している。
 - 式の向きを表せない：非等温 CSTR の線形化応答のケース（出力：濃度偏差 C'_A ）で、正解 $dC'_A/dt = a_{11}C'_A + a_{12}T' + \dots$ と誤り $dT'/dt = a_{21}C'_A + a_{22}T' + \dots$ が、特化度 1.0・変数の一致度 1.0・意味の近さ 0.321 と 0.323 とほぼ同値になった。両者の違いはどの変数を左辺で決める式かであり、変数の集合しか見ない現在の特徴量では表せない。
- 上限を決めているのは候補件数である：正解式が候補に入る割合（被覆率）は第 2 段の Recall@ K の上限になる。現行の重みでは $k = 50$ で 0.920、 $k = 200$ で 0.977、 $k = 400$ で 0.989 と、候補件数を増やすだけで上限が上がる (図 3(a))。変数の一致度だけで絞ると $k = 50$ で 0.961 まで上がるが、 $k = 200$ では 0.991 で現行との差は 0.014 にとどまる。文章類似度だけ ($k = 50$ で 0.431)・意味の近さだけ (0.518) では大きく下がるので絞り込みには話題の情報も要るが、候補を広げれば重み付けの調整はほとんど不要になる。




図3 (a) 第1段の絞り込み方ごとの被覆率（正解式が候補 k 件に入る割合。1,823 ケースの平均、誤差棒は標準誤差）。被覆率は第2段の Recall@ K の上限を与える。(b) 上位 K 件に入らなかった正解式が、代わりに上位へ入った誤りの式を各特徴量で上回る組の割合（ケースごとに求めた割合の平均。候補 50 件は 131 ケース、200 件は 182 ケース。誤差棒は標準誤差）。0.5 は偶然と同じで、その特徴量を強めても順位が戻らないことを意味する。

5 実験 3：どのケースがその特徴量に依存しているか

方法：前回報告した順列特徴量重要度（ある特徴量の値をケース内でシャッフルし、Recall@ K がどれだけ下がるかを測る方法）は、1,823 ケース全体を平均した値であった。今回はこれをケースごと

に分解し、どのケースが崩れるのかとケースの性質との関係を調べた。同一のケースは複数の乱数でテストに現れるため、記録をそのまま数えると同じケースを何度も数えることになる。ケース単位に集約してから検定した（727 ケース）。

結果（表 2）：

- 崩れるケースは限られる：補完性をシャッフルして順位が崩れるのは 727 ケース中 78 件（10.7%）、一貫性は 120 件（16.5%）、分野の一致は 46 件（6.3%）である。残りのケースは、その特徴量が無くても順位が変わらない。
- 崩れるかどうかを決めるのは系の大きさである：崩れるケースは正解式数・入力変数数・出典数が大きい（一貫性では正解式数 3.29 対 2.41、入力変数数 14.28 対 11.62、いずれも $p < 0.01$ ）。当初は「その特徴量が正解式と不正解式をよく分けているケースほど依存する」と考えたが、補完性ではその関係は認められなかった（順位相関 -0.011 、 $p = 0.78$ ）。
- 分野の一致の寄与ゼロは「効かない」ではなく「相殺」であった：全体平均は -0.000 （ $p = 0.91$ ）だが、ケースを分けると、この特徴量が正解式を上位に寄せているケース（1,169 件）では平均 $+0.012$ の低下、逆向きに働いているケース（414 件）では -0.034 、すなわちシャッフルするとかえって精度が上がる。両者が打ち消し合って平均がゼロになっていた（ $p = 1.3 \times 10^{-8}$ ）。補完性と一貫性にはこの相殺は無く、どちらの向きのケースでも低下は正である。

表 2 集合特徴量をケース内でシャッフルしたときの Recall@K の低下を、ケースごとに分解した結果（727 ケースに集約、平均 ± 標準誤差）。「順位が崩れるケース」は、シャッフルによって正解式が上位 K 件から外れるケースの割合。右の 2 列は、その特徴量が正解式を上位に寄せているケースと逆向きに働いているケースに分けた低下である。低下が負の値は、シャッフルするとかえって精度が上がることを意味する。

特徴量	順位が崩れるケース	Recall@K の低下	
		正しい向きのケース	逆向きのケース
補完性	78 / 727 (10.7%)	$+0.026 \pm 0.003$	$+0.013 \pm 0.013$
一貫性	120 / 727 (16.5%)	$+0.024 \pm 0.003$	$+0.047 \pm 0.008$
分野の一致	46 / 727 (6.3%)	$+0.012 \pm 0.002$	-0.034 ± 0.006

6 考察

1. 期待と結果の対応：期待どおりに効いたのは変数の重なりを測る特徴量で、期待に反したのは話題の近さを測る特徴量であった。ただし話題の近さが役に立たないのではない。全データベースから候補を絞る力はむしろ強く（AUC 0.950）、その仕事は第 1 段の時点で終わっている。二段構えの設計では、第 2 段で同じ情報をもう一度使おうとしていたことになる。候補を 200 件に広げても、話題の近さの識別力は 0.718 で式の特化度の 0.984 に届かず、この構図は変わらない。
2. ベクトルの作り方の問題ではない：TF-IDF から SVD という計算のしかたを変えても、この構図は変わらないと考えられる。ケース間のベクトルは離れており（中央値 0.218）、全データベースでの識別力も十分にあるので、改善の余地は表現の精度ではなくどの段でどの情報を使うかにある。
3. 本課題に固有の事情：標準的な物理式は文献をまたいで繰り返し現れる。正解が出典文献に紐づく以上、話題の近さは「別の文献にある同じ式」を推してしまい、強めるほど悪くなる場合があ

る (§4 の第 1 の型)。

4. 次に効きそうなところ：候補件数を 50 件から 200 件に広げると、被覆率は $0.920 \rightarrow 0.977$ に上がり、第 1 段由来の誤りは 61.8% から 28.4% に減る。逐次選択や自己停止の実験は既に 200 件で行っているので、残る課題は並べ替えの側にある。そこには式の向き（どの変数を決める式か）を表す特徴量が要る。第 1 段の重み付けを変数寄りにする案は、候補 200 件では上限が $0.977 \rightarrow 0.991$ と余地が小さく、優先度は下がる。
5. 分野の一致は「無害な無効特徴」ではない：全体平均がゼロでも、ケースによっては精度を下けている (§5)。効かない特徴量を残しておく判断は、平均だけを見て下すべきではない。
6. 限界：(i) 正解・不正解の分析は乱数 1 通り (423 ケース) に基づく。(ii) 候補内の識別力の比較には検定を行っておらず、平均 $\pm$ 標準誤差を示すにとどめた。(iii) 話題の近さが効かないという前回の結論は候補 50 件で得たものである。候補 200 件では候補内の識別力が $0.594 \rightarrow 0.718$ に上がるので、候補 200 件でも寄与がゼロかどうかは測り直す必要がある。

7 まとめと今後の課題

今回：意味の近さが効かない原因が、ご指摘のベクトルの計算方法ではなく、第 1 段で候補を絞った後の冗長性にあることを示した（全データベースでの識別力 0.950 に対し、候補の中では $0.594 / 0.718$ ）。あわせて正解・不正解のケースを分けて調べ、誤りの所在が候補件数で入れ替わること（第 1 段由来は候補 50 件で 61.8%、200 件で 28.4%）、残る並べ替えの誤りは話題の近さを強めても救えないこと（ $0.516 / 0.421$ ）、誤りが「別の文献の同じ式」と「式の向きの区別が付かない」の 2 型であることを示した。さらに順列特徴量重要度をケースごとに分解し、分野の一致の寄与ゼロが「効かない」ではなく「相殺」であること（正しい向きのケースで $+0.012$ 、逆向きのケースで -0.034 ）を明らかにした。

今後の課題：

- 精度の主要比較（ $+0.222$ の分解）と特徴量の評価を候補 200 件でも測り直し、話題の近さが効かないという結論が候補件数に依存しないことを確かめる。
- 候補を広げても残る並べ替えの誤りに対し、式の向き（どの変数を決める式か）を表す特徴量を設計する。
- 分野の一致は逆向きに働くケースで精度を下けているので、この特徴量を外した場合の精度を測る。