

物理モデルの自動構築：手法と結果・考察の全体まとめ

作成者：M2 一洋

1 本報告の位置づけ

研究の目的：科学文献から数式を集めておき、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、そのモデルを構成するのに必要な数式の集合を提示する。

本報告は、手法 (§2)・データと評価方法 (§3)・現時点までの結果と考察 (§4~§10) を 1 つにまとめた全体版である。§6~§9 はこれまでのゼミ報告に載せていなかった結果であり、うち §9 後半の実験（第 1 段の作り直し）は今回新たに行なったものである。なお §4~§8 の数値はすべて第 1 段の重みが現行（文章 0.7 / 変数 0.3）のときの結果で、この重み自体の見直しを §9 で扱う。

2 手法

2.1 課題の定式化

入力は、作りたいモデルの説明文と、与えられる変数（入力変数）・求めたい変数（出力変数）である。データベースの 11,146 式の中から、そのモデルを構成する正解の式集合 (K 本) を選び出す。物理モデルは独立な式の寄せ集めではなく、変数を共有し連立して解く系なので、選んだ式集合が「解ける形」かどうか問う。本報告では、出力変数がすべて式に現れ、かつ未知の変数の数が式の数以下（入力変数を与えれば残りが一意に決まる状態）のとき、その式集合は閉じている（自由度ゼロ）と言う。

2.2 第 1 段：候補の絞り込み

第 1 段では、データベースの全式に、説明文と式まわりの文章がどれだけ似ているか（文章類似度）と、指定された入出力変数と式の変数がどれだけ重なるか（変数の一致度）に、それぞれ 0.7 と 0.3 の重みを掛けて足した点数を付け、上位 $k = 50$ 件を候補として絞り込む。

正解式のうち候補 50 件に入った割合を被覆率と呼ぶ。第 2 段は候補の中しか並べ直せないなので、被覆率は第 2 段の精度の上限を与える。現行の重みでの被覆率は 0.920 である（1,823 ケースの平均。重みと上限の関係は §9 で扱う）。

2.3 第 2 段：10 個の特徴量による並べ直し

第 2 段では、候補 50 件だけを対象に、10 個の特徴量を多層パーセプトロン（MLP、隠れ層 64 ユニット 2 層）で点数化して並べ直す。学習は「正解式の点数を、同じ候補内の不正解式より上げる」ペア比較の損失で行なう。10 個の特徴量の意味と計算方法を表 1 にまとめる。

表 1 第 2 段が使う 10 個の特徴量。式が持つ変数の集合を V_e 、入力で指定された入出力変数の集合を V_q (入力 V_{in} ・出力 V_{out})、参照集合の式が持つ変数の集合を V_S とする。

特徴量	意味と計算方法
基本の 7 個：候補の式を 1 本ずつ、入力と照らして評価する	
文章類似度	説明文と式まわりの文章の、TF-IDF で重み付けした単語ベクトルのコサイン類似度
意味の近さ	同じ 2 つの文章を 256 次元に圧縮 (TF-IDF + SVD) したベクトルのコサイン類似度。単語が一致しなくても内容が近ければ大きい
分野の一致	式に付いた分野名が説明文に現れれば 1、なければ 0
変数の一致度	入出力変数と式の変数がどれだけ重なるか。 $ V_q \cap V_e / V_q \cup V_e $ (Jaccard 係数)
入力変数の被覆	入力変数のうち式に現れる割合。 $ V_{in} \cap V_e / V_{in} $
出力変数の被覆	出力変数のうち式に現れる割合。 $ V_{out} \cap V_e / V_{out} $
式の特化度	式の変数のうち入出力変数が占める割合。 $ V_q \cap V_e / V_e $ 。無関係な変数を持たない式ほど大きい
集合の 3 個：第 1 段で上位 5 件に入った式を参照集合とし、それとの関係で評価する	
補完性	参照集合がまだ覆っていない入出力変数を、その式が新たに補う割合。 $ ((V_q \cap V_e) \setminus V_S) / V_q $
一貫性	式の変数のうち参照集合と共有する割合。 $ V_e \cap V_S / V_e $
分野の一致 (集合版)	参照集合の式のうち、その式と分野名が同じものの割合

2.4 逐次選択

集合の 3 特徴量は「参照集合との関係」で決まるが、上の並べ直しでは参照集合を第 1 段の上位 5 件に固定している。これに対し逐次選択では、まず 1 本目として、この固定参照の点数 (前節の並べ直しと同じ 10 特徴量の点数) が最も高い式を選ぶ。第 1 段の 1 位ではなく、第 2 段が採点し直した 1 位である。2 本目からは、式を 1 本選ぶごとに、集合の 3 特徴量を「既に選んだ式」を参照集合にして計算し直し、残りの候補から次の 1 本を選ぶ。さらに学習も逐次の手順で行なえる：学習時に正解の式を 1 本ずつ既選択に加えながら、各段階で「次の正解式」を不正解式より上に押し上げるよう学習する。これにより、学習と推論が同じ問い (「これらを選んだ今、系を閉じるために次に要する式はどれか」) を解くようになる。

2.5 自由度ゼロ停止

ここまでの並べ直しが返すのは式の順位である。答え (式の集合) として取り出すには「上位何本を採るか」を別に決める必要があり、本報告の評価では、その本数として正解の式数 K を教えて上位 K 本を採らせている。しかし実際の利用者は K を知らない。そこで、逐次選択で 1 本選ぶごとに「選んだ集合が閉じたか」 (出力変数をすべて含み、未知の変数の数 $\leq$ 式の数) を確かめ、閉じた時点で自動的に止まる規則を加えた。これなら本数を教えられなくても答えの集合を返せ、返す集合は構成上「解ける形」で閉じている。

3 データセットと評価方法

3.1 数式データベースと評価ケース

データベースは 361 の出典から集めた 11,146 式である。うち 10,476 式は文献 329 件から LLM (Gemini 2.5 Pro) が抽出し、残る 670 式は同じ LLM が分野ごとに生成した基礎式集 32 件の式である (元になる文献はない)。各式は「式・変数の集合・式まわりの文章・出典・分野名」を持つ。変数は記号の完全一致で照合し、表記の正規化は行っていない (C_A と $C_A(t)$ は別変数として扱う)。

評価ケースは表 2 の 3 種類、計 1,823 件である。呼び方は式の出所と正解集合の作り方に沿ってそろえた (これまでの報告の「オリジナル」を単一出典、「文献横断」を出典横断、「DAE」を合成と呼ぶ。中身は同じ)。このほか、既存ケースの入出力の入替や説明文の言い換えで作った拡張ケース 1,015 件を訓練にのみ使う。拡張を評価に入れると易しい複製で点が水増しされるため (差が +0.222 から +0.156 に縮んで見える)、評価からは除外した。

表 2 評価ケースの 3 種類。「式数」は正解集合の平均本数 (括弧は最大)。

種類	正解集合の作り方	件数	式数
単一出典	1 つの出典の式から、LLM が「必要十分かつ最小」と判断した組を選ぶ	92	1.34 (4)
出典横断	2~3 の出典の式を組み合わせる	731	2.03 (3)
合成	微分方程式から出発し、変数を共有する式を足して指定サイズ X の閉じた系に育てる ($X = 1 \sim 10$ 各 100 件。解けることが構成上保証)	1,000	5.50 (10)

単一出典の正解集合は、出典が示すモデルそのものではない。LLM (Gemini 2.5 Pro) に式の ID・出典・分野名・変数記号だけの一覧を渡して「必要十分かつ最小」の組を選ばせ、入力を与えたときに未知数と式の数が等しくなるケースだけを残した。そのため 92 件中 67 件が 1 式で、61 件は基礎式集の式からなる。出典横断は、500 件がプログラムで選んだ「変数を 2 個以上共有する式の対」、231 件が開発時に LLM (Claude) が書いた 33 組とその入出力を変えた派生で、うち 189 件は式どうしに変数を 1 つも共有しない。

評価は設定 A (3 種類すべて、1,823 件) と設定 B (合成のみ、1,000 件=正解集合が最も大きく最難) で行なう。1,823 件のうち 90.8% は正解が 2 式以上で、平均は 3.90 式である。

3.2 分割・指標・比較手法

訓練とテストは出典単位で分ける (同じ出典のケースが両側に入ると答え漏れになるため)。分け方は 400 通りの無作為候補から、難しさに関わる 4 つの分布 (正解式数・入力変数数・出力変数数・出典数) が訓練とテストで最もそろった 1 通りを選ぶ (層化)。すべての実験を同じ乱数 10 通りで繰り返し、平均と乱数間のばらつきを報告する。差の検定には乱数 10 通りの対応を取った Wilcoxon 符号順位検定を使う ($n = 10$ の最小 p 値は 0.00195 で、これは「10 通りすべてで勝った」ことを意味する)。

主指標は Recall@ K (正解式数 K に合わせ、上位 K 件に入った正解式の割合。情報検索でいう R-precision) である。補助として MAP (Mean Average Precision) と Recall@20 も報告する。自由度ゼロ停止は「集合」を返すので、完全一致率 (返した集合が正解集合と完全に一致した割合)・集合 F1・閉包率 (返した集合が閉じている割合) で評価する。

比較手法は次の 3 つである。古典的情報検索手法 (**baseline**) は、第 1 段と同じ点数 (文章類似度 $0.7 + \text{変数の一致度 } 0.3$) で全 11,146 式を並べる (学習なし・候補の絞り込みなし)。LLM 直接生成は、同じ入力を LLM (claude-sonnet-4-5) に与えて必要な式をそのまま書かせる。生成された式が正解式と数学的に等価かは別の上位モデル (claude-opus-4-8) が判定し、等価なら正解と数えて同じ指標で採点する (判定に費用がかかるため各設定約 50 件の一様サンプル)。本手法 (**reranker-10S**) は §2 の 2 段構成である。

4 結果 1：全体比較 — 難しいケースほど差が開く

表 3 に全体比較を示す。本手法は Recall@ K を設定 A で $0.521 \rightarrow 0.743$ (+0.222)、設定 B で $0.466 \rightarrow 0.689$ (+0.223) に上げ、どちらも乱数 10 通りすべてで baseline を上回った (Wilcoxon $p = 0.00195$)。LLM 直接生成は 0.254 (A)・0.226 (B) にとどまる。ただし順位を問わず「等価な式をどこかに書けたか」で数えると 0.419 (A)・0.343 (B) に達するので、LLM は式を書けないのではなく、正解 K 本の集合として組めない。また正解式には特定の文献で係数を当てはめた経験式が多く、その文献を読んでいない生成器は同じ式を書けない。検索はこの点で有利である。

表 3 全体比較 (Recall@ K は乱数 10 通りの平均 $\pm$ 標準偏差)。LLM 直接生成は各設定約 50 件の一様サンプルによる 1 回評価のため、ばらつきと MAP・Recall@20 は付きない。

設定	手法	Recall@ K	MAP	Recall@20
A (1,823 件)	古典的情報検索手法 (baseline)	0.521 ± 0.045	0.581	0.836
	LLM 直接生成 ($n = 48$)	0.254	—	—
	本手法 (reranker-10S)	0.743 ± 0.054	0.863	0.909
B (合成のみ 1,000 件)	古典的情報検索手法 (baseline)	0.466 ± 0.037	0.512	0.721
	LLM 直接生成 ($n = 50$)	0.226	—	—
	本手法 (reranker-10S)	0.689 ± 0.033	0.832	0.838

差はケースが難しいほど開く。正解が 1 式のケースでは baseline 0.849 対 本手法 0.878 (差 +0.03) でほぼ並ぶが、正解式数が増えると baseline は 10 式で 0.281 まで落ち、本手法は 0.543 にとどまる (差 +0.21~+0.29)。入力変数数でも差は +0.05 (5 個以下) から +0.28 (21 個以上) へ広がる。つまり 1 本の式を探す課題はほぼ解けており、本手法の価値は「集合として選ぶ」難しいケースにある。

5 結果 2：向上の内訳と、モデルが実際に頼っている特徴量

設定 A の +0.222 は 3 段に分解できる。(i) 重みの学習：baseline と同じ 2 特徴量 (文章類似度・変数の一致度) だけを MLP で学習し直すと $0.521 \rightarrow 0.601$ (+0.080)。(ii) 特徴量の追加：基本 7 個にすると $0.601 \rightarrow 0.693$ (+0.092)。ただし式の特化度を 1 つ足すだけで 0.691 (+0.090) に達し、この段はほぼ特化度 1 本が担う。(iii) 集合の特徴量：3 個を足すと $0.693 \rightarrow 0.743$ (+0.050、Wilcoxon $p = 0.00195$)。内訳は補完性 +0.052・一貫性 +0.050 (各 $p = 0.00195$) で、この 2 つは互いに代わりが利く (3 つ足しても 1 つ分しか上がらない)。分野の一致 (集合版) は -0.000 ($p = 0.98$) で寄与しない。

集合特徴量の上乗せ +0.050 は一様ではない。正解が 1 式のケースではゼロ (参照集合が役立ちようがない)、正解 3 式で最大 (+0.102)、そして最難端 (入力 16 変数以上) では +0.035 に半減する

(11–15 変数では $+0.078$)。この頭打ちへの対処は §6 で述べる。

各特徴量の重要度は、訓練済みモデルの入力のうち 1 つの特徴量の値だけを候補間で無作為に入れ替え（シャッフル）、**Recall@K** の低下を測る方法（PFI、Permutation Feature Importance）でも確かめた（図 1）。変数の重なりを測る 6 特徴量をまとめてシャッフルすると **Recall@K** は $0.743 \rightarrow 0.065$ に崩れる（低下 $+0.678$ 、 $p < 0.001$ ）。話題の近さを測る 4 特徴量ではまとめても $+0.006$ （ $p = 0.10$ 、有意でない）。特徴量を足して訓練し直す方法（アブレーション）と、訓練済みモデルを壊す方法（PFI）が同じ結論に至った：効くのは変数の重なりであり、話題の近さではない。




図 1 特徴量の値をケース内でシャッフルしたときの **Recall@K** の低下（大きいほどモデルがその特徴量に頼っている）。誤差棒は乱数 10 通りの標準偏差。(b) の点線はシャッフル前の **Recall@K** = 0.743。

6 結果 3：逐次選択は最難ケースの頭打ちを解く

§5 の頭打ちの原因を「参照集合を第 1 段の上位 5 件に固定しているため、長い正解集合では参照が実際の選択と食い違っていくから」と推定し、§2.4 の逐次選択で介入した。この比較は候補を $k = 200$ 件に広げて行なう（被覆率の上限が $0.920 \rightarrow 0.978$ に上がるため、数値は表 3 の $k = 50$ とは直接比べない）。

設定 B（合成のみ）で、参照固定 $0.724 <$ 選び方のみ逐次 $0.756 <$ 学習も逐次 0.765 となった（10 乱数）。学習を逐次にする上乗せ $+0.009$ は有意である（Wilcoxon $p = 0.037$ ）。そして効き目は予測した場所に集中する：正解 8 式以上のケースで、学習版逐次は参照固定を $+0.056$ 上回る（ $p = 0.00195$ ）。設定 A でも $0.757 < 0.787 < 0.797$ と同じ並びになる（ただし A では学習版と選び方のみの差 $+0.010$ に有意差は認められない、 $p = 0.13$ ）。「頭打ちの原因を推定し、そこだけ直す介入をし、予測した場所で回復する」という手順で、集合特徴量が効いている仕組みを確かめた。

7 結果 4：式の本数を教えなくても、解ける集合を返して自分で止まる

自由度ゼロ停止（ K を教えない）を、同じ学習版逐次モデルで「 K を教えて上位 K 本を返す場合」と比べた。完全一致率は K を教えた場合と完全に同じ（設定 A 0.526 、設定 B 0.368 。全ケース・全乱数の延べ 7,026 件で判定が 1 件も食い違わない）。理由は単純で、完全に正しい選択は閉じた系そのものだから、閉じた時点で止まれば同じ集合になる。集合 F1 の低下はわずかで（A -0.008 、B -0.023 、対応 t 検定 $p = 0.006 \cdot 0.0001$ ）、一方閉包率は K を教えた場合より高い（A 0.936 対

0.865、B 0.883 対 0.781)：上位 K 本は解ける保証がないが、自由度ゼロ停止は閉じるまで選び続けるからである。止まる位置の誤りは中央値 0 で、誤るときはほぼ全て多めに選ぶ方向であった（設定 B は誤った 545 件すべて、設定 A は 4,594 件中 1 件だけ少なめ）。

正直な注記：本データでは正解式数が出力変数数とほぼ等しい（出典横断・合成で 100%）ため、「 K を当てること」自体は難しくない。主張は K 予測ではなく、自分で止まれることと返す集合が解ける形で閉じている保証である。

8 結果 5：話題の近さはなぜ効かないか（原因のまとめと新しい発見）

話題を見る 4 特徴量（文章類似度・意味の近さ・分野の一致・同集合版）は、どの形でも第 2 段に寄与しない：分野の一致を 2 特徴量に足しても $+0.002$ ($p = 0.06$)、意味の近さでは -0.002 ($p = 0.48$)、集合版は -0.000 ($p = 0.98$)。分野名を統合して粗くしても（1,958 群・100 群・40 群）寄与は最大 $+0.0006$ で全て $p > 0.6$ である。原因は前回までに報告した 2 つに加え、今回 1 つを追加できた。

(1) 絞り込みの後では話題がそろってしまう（既報）：意味の近さ 1 つで正解式を並べる力（AUC、正解式が不正解式より高い値を取る組の割合）は、全データベース相手なら 0.950 あるのに、候補 50 件の中では 0.594 に落ちる（表 4）。話題の仕事は第 1 段の絞り込みで終わっている。(2) 選抜が作る見かけの逆相関（既報）：候補は「文章類似度+変数の一致度が高い式」だけの集合なので、その中では文章類似度の高さが変数の合わなさの裏返しになり（相関 -0.404 ）、文章類似度は候補内でわずかに逆向きの信号になる（AUC 0.437）。

表 4 1 つの特徴量だけで正解式を不正解式より上に並べられる割合（AUC、1,823 ケースの平均 ± 標準誤差）。列は不正解式の範囲の違いを表す。

特徴量	全データベース 11,146 式	候補 50 件の中
変数の一致度	0.999 ± 0.000	0.947 ± 0.002
式の特化度	—	0.965 ± 0.001
意味の近さ	0.950 ± 0.003	0.594 ± 0.006
文章類似度	0.913 ± 0.003	0.437 ± 0.007

(3) 全体ゼロの正体は「打ち消し合い」だった（今回報告）：分野の一致（集合版）の重要度をケースごとに分けて見ると、候補の中でこの特徴量の値が正解式側で高いケース（1,169 件）ではシャッフルで Recall@ K が 0.012 下がり、不正解式側で高いケース（414 件）では逆に 0.034 上がる（Mann–Whitney の U 検定、 $p = 1.3 \times 10^{-8}$ 。同じケースが複数の乱数に現れる分は 1 件に集約して数えた）。加重平均するとちょうどゼロになる。つまりモデルはこの特徴量をケースごとには使っており、役立つケースと精度を下げるケースが打ち消し合って全体でゼロに見える。分野名の統合で消えなかったのだから、この特徴量を生かすには「正しい向きを向くケース」を増やす別の工夫が要る。

9 結果 6：誤りの過半は第 1 段で生まれる — 作り直すと

0.743 → 0.780

取り逃した正解式がどこで漏れたかを 1 分割（乱数 42、テスト 423 件、取り逃し 435 本）で数えると、**61.8%** は第 1 段で候補 50 件に入らず、38.2% が候補に入ったのに上位 K 件から漏れた。候

補を 200 件に広げると比率は逆転し（第 1 段 28.4%・並べ直し 71.6%）、取り逃し自体は 373 本に減る。つまり $k = 50$ の主要比較では第 1 段が、 $k = 200$ の逐次選択では並べ直しが、それぞれ誤りの主因である。

解けないケースは種類ではなく大ききで決まる：解けたケースの正解は平均 2.13 式・入力 10.8 変数、落ちたケースは 5.34 式・17.8 変数で（どちらも Mann-Whitney $p < 10^{-14}$ ）、落ちたケースは被覆率自体が 0.83 に下がっている（解けたケースは 1.00）。並べ直して漏れた正解式は、いま持っているどの特徴量でも救えない：漏れた正解式とその上に居た不正解式の組で、正解側の値が高い割合は意味の近さで 0.516（偶然と同水準）、変数の一致度では 0.375（むしろ不正解側が高い）である。

残る誤りには 2 つの型がある。型 1：別文献の同一式。標準的な式は文献をまたいで繰り返し現れるため、数学的に同一の式を別文献から選んでしまう（例：回分発酵の $dX/dt = \mu X$ で、別文献に載った同じ増殖式が上位に来た。話題の近さはむしろ誤り側を推す）。型 2：式の向き。特徴量は変数の集合しか見ないため、同じ変数から別の変数を決める 2 本の式（例：線形化した反応器の dC'_A/dt の式と dT'/dt の式）が全特徴量で同点になる。どちらの型も話題の情報では直らない。

以上の分析は「誤りの過半は第 1 段で生まれ、第 1 段を変数寄りにすれば上限（被覆率）が上がる」ことを意味する。そこで第 1 段の重み（文章 0.7／変数 0.3）を $(0.5, 0.5) \cdot (0.3, 0.7) \cdot (0.0, 1.0)$ に変えて、候補作り・訓練・評価のすべてを同じ重みでやり直した（今回の新規実験。設定 A・乱数 10 通り）。重みを最初から 0.3/0.7 と決めなかったのは、この重みの根拠が上の誤り分析そのものだからである（分析の前に選ぶ理由がなく、分析の後なら予測どおり効くかを確かめられる）。

上限は予測どおり上がり、最良は予測の先にあった（図 2(a)）。 $k = 50$ の被覆率は現行 0.920 から、変数のみで 0.961（予測した値）、そして文章 0.3 + 変数 0.7 で 0.967 まで上がる。この中間重みはどの候補件数でも最良で、文章の情報は重みを下げれば端で役に立つ（正しい直し方は「文章を捨てる」ではなく「優先順位を逆にする」）。

上がった上限は最終精度にほぼそのまま変換される（図 2(b)）。文章 0.3 + 変数 0.7 で訓練し直した本手法は $\text{Recall}@K = 0.743 \rightarrow \mathbf{0.780}$ （+0.037、Wilcoxon $p = 0.00195$ 、乱数 10 通りすべてで向上）。4 通りの重みの被覆率の順序と最終精度の順序は完全に一致し、上限の増分 +0.047 のうち約 8 割が最終精度に届いた。効き目は上の分析で特定した場所に集中する：正解 8 式以上のケースで +0.094（ $p = 0.00195$ ）。なお変数寄りの 3 通りはいずれも全乱数で現行を上回るので、この結論は「最良の重みを選んだから」ではない。baseline 自体も 0.521 $\rightarrow$ 約 0.60 に上がる（学習なしで得られる分）。

最強の構成（学習版逐次・ $k = 200$ ）でも効き目は残る：0.797 $\rightarrow$ 0.810（+0.013、 $p = 0.0098$ 、10 乱数中 9 で向上）、正解 8 式以上で +0.035（ $p = 0.00195$ ）。 $k = 200$ では重み間の被覆率差が +0.015 まで縮むが、その約 9 割が最終精度に変換された。第 2 段は、第 1 段が入れてくれた正解候補をほぼ使い切っている。残る誤りは上の並べ直しの誤り（型 1・型 2）であり、これは窓の広げ方や重みでは直らない。

10 現時点の限界

- 合成ケースの説明文は LLM が書いたもので、人が書く依頼文と文体が違う可能性がある（式・入出力は規則で決まる）。
- 評価はデータベースの中に閉じており、データベースに無い式は検索できない。LLM 直接生成と




図2 第1段の重みを変える実験 (設定 A)。(a) 重み別の被覆率 (1,823 ケースの平均 ± 標準誤差)。点線は実験で使う $k = 50$ と $k = 200$ 。(b) 候補作り・訓練・評価を同じ重みで行なったときの $\text{Recall}@K$ ($k = 50$ 。箱=乱数 10 通りの四分位、横線=中央値、点=各乱数の値)。被覆率の順序と最終精度の順序が一致し、文章 0.3 + 変数 0.7 が両方で最良になる。

の比較は各設定約 50 件で、等価判定 (別モデルによる機械判定) の人手検証は行なっていない。

- 変数の重なりを測る 6 特徴量だけで課題の大半が解ける (シャッフルで 0.68 低下)。これは、どのケースも入出力変数を正解式の変数記号から取っている (クエリと正解が同じ表記を使う) という本データの作り方も反映しており、表記の揺れた実際のクエリへそのまま移るかは未検証である。
- 逐次の学習は正解を 1 本ずつ与える手順であり、推論時は自分の選択 (誤り込み) を参照する。この食い違いは残っている。

11 まとめと今後の課題

まとめ：数式集合の検索は、候補を絞って (第1段)、集合として並べ直す (第2段) 2 段階構成で、 $\text{Recall}@K$ を 0.521 → 0.743 に上げられる。効いている信号は変数の重なり (中でも式の特化度) であり、話題の近さはどの形でも効かない。その原因を「絞り込み後の冗長性・選抜の逆相関・打ち消し合い」として特定した。逐次選択は最難ケースの頭打ちを解き (+0.056)、自由度ゼロ停止は式の本数を教えられなくても解ける集合を返して止まる。誤りの過半が第1段で生まれると特定できたので、第1段を変数寄りに作り直したところ、予測どおり上限が上がり、 $\text{Recall}@K$ は 0.780 (最強構成では 0.810) まで伸びた。

今後の課題：

- 第1段の重みの既定を文章 0.3 / 変数 0.7 に切り替え、§4~§8 の全実験をこの重みで張り直す (本報告のそれらの数値は現行重みでの結果である)。
- 残る誤りの 2 つの型のうち「式の向き」(どの変数を決める式か) を表す特徴量を設計する。
- 比較手法を増やす (BM25 などの標準的な検索手法、埋め込みベクトル検索)。
- LLM による等価判定の妥当性を、一部を人手で判定して確かめる。