

物理モデルの自動構築のための数式集合の検索 関連研究の再調査と本研究の位置付け

報告者：M2 一洋

確認者：加藤

Abstract

本研究の目的は、複数の情報源から収集した数式の中からモデル構築に必要な数式を自動で選定する手法を開発することである。作成するモデルは、説明文とモデルの入出力変数で表される。提案手法は 2 段階の処理から構成される。第 1 段では、収集した多量の数式を、説明文と式周辺の文章（文脈）の近さと入出力変数の重複率で採点し、上位 N_1 件に絞る。第 2 段では、10 個の特徴量を持つ多層パーセプトロン（multilayer perceptron, MLP）を用いて、第 1 段で選択した数式を並べ直す。モデルを構成する数式の数には事前にわからないため、上位から 1 式ずつ選び、選んだ式に出力変数がすべて現れ、入力変数以外の変数の数が式の数以下になった時点で選択を止める（20 式選んでも満たさなければ打ち切る）。提案手法を文献など 361 件の情報源から集めた 11,146 式と、評価用の 1,823 ケースで評価した結果、上位 K 件に入った正解式の割合 $\text{Recall}@K$ (K は正解式の数) は、第 1 段と同じ採点で全数式を並べる古典的な情報検索手法の 0.521 から、**0.743** に上がった。並べ直しでは、主に変数の重複率に基づく特徴量が効き、文脈の近さはほとんど効かなかった。

1 進捗と議論のポイント

- 物理モデルの自動構築・シンボリック回帰・情報検索と再順位付け・大規模言語モデル（large language model, LLM）による式の生成・数式検索という 5 つの観点から、関連研究を再調査し、本研究との違いを整理した（3 節）。
- 前回の計画のうち、LLM による等価判定の妥当性を、別の LLM で判定し直して確かめた（2 節）。
- 議論したい点：本研究と式の組合せ法 [1] との違いを、文脈を扱えることに置いている。しかし評価ケースでは入出力変数だけで式をほぼ絞れ、文脈の効果はまだ示せていない（3.1 節）。文脈が効く場面を示す評価の設計について、意見をいただきたい。

2 前回の振り返り

2.1 計画の達成状況

前回のゼミ（9 月 9 日）で挙げた 4 つの計画の状況は次のとおりである。

- 第 1 段の重みを変えて全実験をやり直す（文脈の近さ 0.3、変数の重複率 0.7）：未達成。関連研究の再調査を優先した。
- 「式の向き」（どの変数を決める式か）を表す特徴量の設計：未達成（同上）。
- 比較手法の追加（BM25 と、埋め込みベクトルによる検索）：本手法と同じ評価の枠組みで測定した。結果は、実験設定の妥当性を確かめてから報告する（4 節）。
- LLM による等価判定の妥当性の確認：人手による確認は行っていない。代わりに、LLM 直接生成の評価で判定した全 608 組（生成した式と正解式の組）を、判定に使ったもの（Claude Opus 4.8）とは別の LLM（Claude Fable 5.1）で判定し直した。2 つの判定の一致率は 88.0%（Cohen の $\kappa = 0.72$ ）で、判定が分かれた 73 組のうち 71 組は、元の判定だけが等価としていた。判定し直した LLM の判定で数えると、LLM 直接生成の $\text{Recall}@K$ は 0.254 から 0.198 に下がる。

3 関連研究の再調査と本研究との違い

本研究に関係する 5 つの分野について、先行研究を述べ、各項の最後に本研究との違いを置く。

3.1 物理モデルの自動構築に関する研究

Kato and Kano [2, 3] は、対象プロセスの文献を集め、式・変数・実験データを取り出し、文献の間で同じものを指す情報を見分け、目的のモデルに組み直す自動物理モデル構築器 AutoPMoB（Automated Physical Model Builder）を提案した。研究室ではその要素技術が段階ごとに開発されてきた（Fig. 1）。情報の抽出では、文献から変数記号を取り出す手法と注釈ツール VARAT（Variable Annotation Tool）[4] と、変数の定義を抽出するためのデータ拡張手法 [5] が開発された。同義性の判定では、2 つの変数の定義




Fig. 1: The four stages of the automated physical model builder (AutoPMoB) and the studies of our group at each stage. This study (blue) belongs to the model-building stage.

が同じ量かを判定する言語モデル ProcessBERT [6] と、2 つの式群が等価かを判定する手法 [7, 8] が開発された。後者は、数式処理システムを用いて、一方の式群にだけ現れる変数を消去したうえで式を 1 つずつ比べ、見た目ではなく同じ計算をするかで等価を判定する。

モデルの構築を扱う Kato and Kano [1, 9] が、本研究に最も近い。文献から抽出した式には、重複した式・中間的な式・互いに矛盾する式が混じる。Kato and Kano [1] は、モデルの構築を、入出力がそろったことや整合することなど、あらかじめ定めた 4 つの要件を満たすように式を組み合わせる問題として定式化し、要件を満たすモデルを漏れなく、無駄な計算を省いて求めるアルゴリズムを提案した。8 つの事例で、目的のモデルをすべて構築できることを示している。

本研究との違い：Kato and Kano [1] の組合せ法は、式とその変数から、要件を満たす組合せをすべて求める。本研究は、作りたいモデルの説明文も入力に取り、説明文と式周辺の文章（**文脈**）の近さも使って、必要な式を上位に並べる。ただし、目的のモデルに関係する式を絞るだけなら、文脈は必須ではない。前回までの評価でも、第 1 段を変数の重複率だけで行っても正解式の 96.1% が上位 $N_1 = 50$ 件の候補に残り、文脈を加えても 96.7% にしか上がらなかった。並べ直しても、主に効いていたのは変数の重複率に基づく特徴量であった。これは、評価ケースが入出力変数を正解式と同じ記号で与えており、記号の一致で式を絞られるためでもある。文脈が必要になるのは、要件を満たす組合せが複数あって説明文でしか選べない場合や、ユーザが文献と違う記号で変数を書いた場合である。このような場合に文脈が効くことは、まだ示していない（4 節）。

3.2 シンボリック回帰：数値データからの式の導出

シンボリック回帰は、数値データに合う数式を、係数だけでなく式の形も含めて探す手法である [10]。Schmidt and Lipson [11] は、物理の予備知識を使わずに、単振動子から二重振り子までの運動の計測データから、ハミルトニアン、ラグランジアン、保存則を導いた。SINDy (Sparse Identification of Nonlinear Dynamics) [12] は候補となる多数の項から疎な回帰で少数の項を選んで支配方程式を求め、AI Feynman [10] はニューラルネットワークによる当てはめと物理に着想を得た手法を組み合わせでファインマン物理学講義の 100 式をすべて導いた。ALAMO (Automated Learning of Algebraic Models for Optimization) [13] は、シミュレーションや実験で得た少数のデータから、簡潔な代数式の代理モデルを作る。ただし、式の形の候補は組合せが膨大であり、データだけから探すのは難しい [14]。LLM-SR [14] は、LLM に分野の知識から式の**骨格**（係数を未定にした式の形）を提案させ、係数をデータに当てはめる。分野の知識を使うことで探索が効率化し、学習データの範囲外でも、従来のシンボリック回帰より正確な式が得られた。

本研究との違い：シンボリック回帰は、数値データから物理モデルを導く。本研究は数値データから導くのではなく、文献に載った式に基づいてモデルを組み立てる。そのため対象プロセスの測定データを必要とせず、モデルを構成する数式のうち文献由来のもの（データベースの式の 94.0%）には出典がある。また、数値だけを扱う従来のシンボリック回帰と異なり、本研究は文脈を扱える。両者は組み合わせることでもできる。本研究が文献から選んだ式は、係数を未定にすれば、シンボリック回帰の骨格の候補として使える。LLM-SR で LLM が提案する骨格と違い、この骨格には出典がある。

3.3 情報検索と再順位付け

情報検索は、クエリ（検索の入力として与える文や語）との関連度で文書などの項目を並べる技術である [15]。古典的な手法には、単語の出現頻度と珍しさを重みを付ける TF-IDF (Term Frequency-Inverse

Document Frequency) [16]、確率モデルに基づく採点式 BM25 [17]、特異値分解で文書を低次元の意味の空間に写す潜在意味解析 [18] などがある。近年は、高速な第 1 段の検索で候補を絞り、BERT (Bidirectional Encoder Representations from Transformers) [19] などの学習した言語モデルで候補を並べ直す 2 段構えが広く使われ [20]、第 1 段の検索を学習した埋め込みベクトルで行う密ベクトル検索 [21] もある。本手法は、この 2 段構えに加え、正解と不正解の組の順位を学ぶ学習方法 [22] と、潜在意味解析 (第 2 段の特徴量の 1 つに使用) を受け継いでいる。

本研究との違い：これらの手法は、各項目をクエリとの関係だけで採点し、他の項目とは無関係に並べる。代表的な例外である MMR (Maximal Marginal Relevance) [23] は、既に選んだ文書に似た候補を減点し、検索結果の重複を減らす。本研究で必要な関係は、これとは異なる。物理モデルは変数を共有して連立する式の集まりなので、良い候補とは、上位の式と変数を共有してつながり (一貫性)、まだ足りない入出力変数を補う (補完性) 式である。MMR が避ける「似ていること」と違い、変数の共有は、式が系としてつながっていることを示す。求めるのは結果の多様さではなく、集めた式が連立方程式として解けることである。前回報告したとおり、候補を上位の式との関係で評価する 3 個の特徴量 (集合の特徴量) を加えると、Recall@K は 0.693 から 0.743 に上がり、その上昇は補完性と一貫性が担っていた。

3.4 LLM による式の直接生成

LLM は自然言語の指示から専門知識を直接生成でき [24]、3.2 節の LLM-SR のように式の骨格の提案にも使われている。必要な式を LLM に書かせることは、検索の自然な代替である。

本研究との違い：LLM が生成した式には出典がない。LLM がもっともらしいが根拠のない内容を生成する現象 (ハルシネーション) はよく知られており [25]、生成された式が正しいかを、ユーザは根拠をたどって確かめられない。物理モデルは式を連立して解くので、誤った式が 1 つ混じるだけで、その式とつながる変数の値がすべて誤りうる。本研究はデータベースから式を選ぶため、文献由来の式については、ユーザが根拠として対応する文献を確認できる。ただし、データベースの式のうち 6.0% (670 式) は LLM で作成した基礎式集の式であり、出典の文献がない。前回報告したとおり、LLM に同じ入力を与えて式を書かせる手法の Recall@K は 0.254 (評価用ケースから一様に抜き出した 48 ケースでの評価) で、本手法の 0.743 を下回った。

3.5 数式検索

数式検索は、文章や式をクエリにして式を探す分野であり、式の認識と検索の技術は体系的にまとめられている [26]。ここでは、検索手法と検索対象の 2 つの観点から、本研究との関係を整理する。

検索手法：式どうしの比べ方には、式を記号の列 (文字列) として比べる方法のほか、式を演算子の木で表し、葉から根への経路の一致で構造の似かたを測る方法 [27] や、式の木を埋め込みベクトルに変換して比べる方法 [28] などがある。本研究にとって、これらは式どうしを比べる部分に取り入れられる要素技術である。本手法は第 2 段で候補を上位の式と比べているが、使うのは式に含まれる変数の集合だけという素朴な方法である。数式検索の手法を取り入れて性能が上がるかの検証は、今後の課題とする。

検索対象：国立情報学研究所の評価型会議 NTCIR (NII Testbeds and Community for Information access Research) の数式検索課題 [29] は arXiv の論文と Wikipedia を対象に、ARQMath (Answer Retrieval for Questions on Math) [30] は数学の質問投稿サイト Math Stack Exchange を対象に、評価の枠組みを整えた。これらの課題は、クエリに似た式を 1 つずつ探す。本研究が探すのは、入力変数を与えれば出力変数が決まる (自由度ゼロの) 連立方程式となる式の集合であり、1 つの式の価値は、一緒に選ばれる式によって変わる。調べた範囲では、この条件を課す評価課題は数式検索の分野に見当たらない。

3.6 まとめ

5 つの分野と本研究との違いを Table 1 にまとめる。本研究は、数値データから式を導くのではなく文献由来の式に基づいてモデルを組み立て、その際に文脈を扱える。この点で、数値データだけを扱う従来のシンボリック回帰と異なる。式の組合せ法 [1] とは説明文と文脈を入力に取る点で異なるが、文脈が効く場面を示すことが残っている。情報検索や数式検索と異なり連立方程式として解ける式の集合を探し、LLM

Table 1: Research fields related to this study and how this study differs from them.

分野	代表的な先行研究	返すもの	本研究との違い
物理モデルの自動構築 (研究室)	AutoPMoB [2, 3]、式の組合せ法 [1, 9]	要件を満たす式の組合せ (漏れなく)	説明文と文脈も使って、必要な式を上位に並べる (文脈が効く場面の実証は今後)
シンボリック回帰	Schmidt and Lipson [11]、SINDy [12]、AI Feynman [10]、ALAMO [13]、LLM-SR [14]	数値データに合う式	数値データでなく文献由来の式に基づき、文脈を扱う。選んだ式は骨格の候補にもなる
情報検索と再順位付け	TF-IDF [16]、BM25 [17]、BERT による再順位付け [20]、MMR [23]	1 件ずつ採点した文書の順位	候補を上位の式との関係 (変数の共有と補完) でも評価する
LLM による式の生成	GPT-3 [24]	生成した式 (出典なし)	文献由来の式を出典つきで選ぶ
数式検索	NTCIR [29]、ARQMath [30]、木構造の類似検索 [27]、埋め込み [28]	クエリに似た式 1 つずつ	連立方程式として解ける式の集合を探す。式どうしの比較に数式検索の手法を取り入れられる

による生成と異なり文献由来の式を出典つきで選ぶ。数式検索の手法は、本研究の式どうしの比較に取り入れられる。

4 今後の計画

- **次回ゼミまでに**：実験設定（データの数、パラメータなど）で妥当な評価ができているかを確かめる。確かめながら、第 1 段の重みを変えた全実験のやり直しを進める。
- **その次のゼミまでに**：文脈が効く場面を示す評価を設計する。たとえば、入出力変数を文献と違う記号で与えたケースで、文脈を使う場合と使わない場合を比べる。

References

- [1] Shota Kato and Manabu Kano. Automated physical model building from literature sources: Combining equations based on four predefined requirements. *Computers & Chemical Engineering*, 200:109147, 2025. doi:10.1016/j.compchemeng.2025.109147.
- [2] Shota Kato and Manabu Kano. Towards An Automated Physical Model Builder: CSTR Case Study. *Computer Aided Chemical Engineering*, 49:1669–1674, 2022. doi:10.1016/B978-0-323-85159-6.50278-5.
- [3] Shota Kato and Manabu Kano. Prototype of Automated Physical Model Builder: Challenges and Opportunities. *Computer Aided Chemical Engineering*, 53:2839–2844, 2024. doi:10.1016/B978-0-443-28824-1.50474-9.
- [4] Shota Kato and Manabu Kano. VARAT: Variable Annotation Tool for Documents on Manufacturing Processes. *Journal of Chemical Engineering of Japan*, 58(1):2454461, 2025. doi:10.1080/00219592.2025.2454461.
- [5] Kotaro Nagayama, Shota Kato, and Manabu Kano. Data Augmentation Method Utilizing Template Sentences for Variable Definition Extraction. In *Natural Language Processing and Information Systems (NLDB 2024)*, Lecture Notes in Computer Science, pages 151–165, 2024. doi:10.1007/978-3-031-70239-6_11.
- [6] Shota Kato, Kazuki Kanegami, and Manabu Kano. ProcessBERT: A Pre-trained Language Model for Judging Equivalence of Variable Definitions in Process Models. *IFAC-PapersOnLine*, 55(7):957–962, 2022. doi:10.1016/j.ifacol.2022.07.568.
- [7] Chunpu Zhang, Shota Kato, and Manabu Kano. Equivalence Judgment of Equation Groups Representing Process Dynamics. *Computer Aided Chemical Engineering*, 49:1513–1518, 2022. doi:10.1016/B978-0-323-85159-6.50252-9.
- [8] Shota Kato, Chunpu Zhang, and Manabu Kano. Simple algorithm for judging equivalence of differential-algebraic equation systems. *Scientific Reports*, 13(1):11534, 2023. doi:10.1038/s41598-023-38254-y.
- [9] Shota Kato and Manabu Kano. Efficient physical model building algorithm using equations extracted from documents. *Computer Aided Chemical Engineering*, 52:151–156, 2023. doi:10.1016/B978-0-443-15274-0.50025-1.
- [10] Silviu-Marian Udrescu and Max Tegmark. AI Feynman: A physics-inspired method for symbolic regression. *Science Advances*, 6(16):eaay2631, 2020. doi:10.1126/sciadv.aay2631.
- [11] Michael Schmidt and Hod Lipson. Distilling Free-Form Natural Laws from Experimental Data. *Science*, 324(5923): 81–85, 2009. doi:10.1126/science.1165893.
- [12] Steven L. Brunton, Joshua L. Proctor, and J. Nathan Kutz. Discovering governing equations from data by sparse identification of nonlinear dynamical systems. *Proceedings of the National Academy of Sciences*, 113(15):3932–3937, 2016. doi:10.1073/pnas.1517384113.
- [13] Alison Cozad, Nikolaos V. Sahinidis, and David C. Miller. Learning surrogate models for simulation-based optimization. *AIChE Journal*, 60(6):2211–2227, 2014. doi:10.1002/aic.14418.
- [14] Parshin Shojaei, Kazem Meidani, Shashank Gupta, Amir Barati Farimani, and Chandan K. Reddy. LLM-SR: Scientific Equation Discovery via Programming with Large Language Models. In *International Conference on Learning Representations (ICLR)*, 2025.
- [15] Christopher D. Manning, Prabhakar Raghavan, and Hinrich Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008.

- [16] Gerard Salton and Christopher Buckley. Term-weighting approaches in automatic text retrieval. *Information Processing & Management*, 24(5):513–523, 1988. doi:[10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0).
- [17] Stephen Robertson and Hugo Zaragoza. The Probabilistic Relevance Framework: BM25 and Beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389, 2009. doi:[10.1561/15000000019](https://doi.org/10.1561/15000000019).
- [18] Scott Deerwester, Susan T. Dumais, George W. Furnas, Thomas K. Landauer, and Richard Harshman. Indexing by latent semantic analysis. *Journal of the American Society for Information Science*, 41(6):391–407, 1990.
- [19] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*, volume 1, pages 4171–4186, 2019. doi:[10.18653/v1/N19-1423](https://doi.org/10.18653/v1/N19-1423).
- [20] Rodrigo Nogueira and Kyunghyun Cho. Passage Re-ranking with BERT. arXiv:1901.04085, 2019.
- [21] Vladimir Karpukhin, Barlas Oguz, Sewon Min, et al. Dense Passage Retrieval for Open-Domain Question Answering. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*, pages 6769–6781, 2020. doi:[10.18653/v1/2020.emnlp-main.550](https://doi.org/10.18653/v1/2020.emnlp-main.550).
- [22] Tie-Yan Liu. Learning to Rank for Information Retrieval. *Foundations and Trends in Information Retrieval*, 3(3): 225–331, 2009. doi:[10.1561/15000000016](https://doi.org/10.1561/15000000016).
- [23] Jaime Carbonell and Jade Goldstein. The use of MMR, diversity-based reranking for reordering documents and producing summaries. In *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval*, pages 335–336, 1998. doi:[10.1145/290941.291025](https://doi.org/10.1145/290941.291025).
- [24] Tom Brown, Benjamin Mann, Nick Ryder, et al. Language Models are Few-Shot Learners. In *Advances in Neural Information Processing Systems*, volume 33, pages 1877–1901, 2020.
- [25] Ziwei Ji, Nayeon Lee, Rita Frieske, et al. Survey of Hallucination in Natural Language Generation. *ACM Computing Surveys*, 55(12):248:1–248:38, 2023. doi:[10.1145/3571730](https://doi.org/10.1145/3571730).
- [26] Richard Zanibbi and Dorothea Blostein. Recognition and retrieval of mathematical expressions. *International Journal on Document Analysis and Recognition*, 15(4):331–357, 2012. doi:[10.1007/s10032-011-0174-4](https://doi.org/10.1007/s10032-011-0174-4).
- [27] Wei Zhong and Richard Zanibbi. Structural Similarity Search for Formulas Using Leaf-Root Paths in Operator Subtrees. In *Advances in Information Retrieval (ECIR 2019)*, volume 11437 of *Lecture Notes in Computer Science*, pages 116–129, 2019. doi:[10.1007/978-3-030-15712-8_8](https://doi.org/10.1007/978-3-030-15712-8_8).
- [28] Behrooz Mansouri, Shaurya Rohatgi, Douglas W. Oard, Jian Wu, C. Lee Giles, and Richard Zanibbi. Tangent-CFT: An Embedding Model for Mathematical Formulas. In *Proceedings of the 2019 ACM SIGIR International Conference on Theory of Information Retrieval*, pages 11–18, 2019. doi:[10.1145/3341981.3344235](https://doi.org/10.1145/3341981.3344235).
- [29] Richard Zanibbi, Akiko Aizawa, Michael Kohlhase, Iadh Ounis, Goran Topić, and Kenny Davila. NTCIR-12 MathIR Task Overview. In *Proceedings of the 12th NTCIR Conference on Evaluation of Information Access Technologies*, pages 299–308, 2016.
- [30] Richard Zanibbi, Douglas W. Oard, Anurag Agarwal, and Behrooz Mansouri. Overview of ARQMath 2020: CLEF Lab on Answer Retrieval for Questions on Math. In *Experimental IR Meets Multilinguality, Multimodality, and Interaction (CLEF 2020)*, volume 12260 of *Lecture Notes in Computer Science*, pages 169–193, 2020. doi:[10.1007/978-3-030-58219-7_15](https://doi.org/10.1007/978-3-030-58219-7_15).