

目次

研究紹介：グラフニューラルネットワークを用いた物理モデルの自動構築	1
0. 話の流れ	1
1. 目的	2
2. 関連研究	3
3. 手法	5
4. 結果と考察	7
5. まとめ	10
付録：話し方のメモ	10

研究紹介：グラフニューラルネットワークを用いた物理モデルの自動構築

対象：新メンバー 前提知識：GNN・物理モデルの予備知識は不要 発表者：かずひろ

0. 話の流れ

本発表は、研究発表の標準構成に沿って進めます。

1. 目的 — 本研究で何を達成したいか
 2. 関連研究 — この問題は世界でどのように解かれているか
 3. 手法 — どのような方針で解くか
 4. 結果と考察 — 現時点で何がわかっているか
 5. まとめ — 全体像と今後の展望
-

1. 目的

1.1 物理モデルとは何か

物理モデル：対象プロセスの挙動を記述する**数式の集まり**。反応速度、物質収支、熱収支、輸送現象などを連立させ、**入力条件（流量・温度・濃度など）から出力変数（生成物濃度、反応器温度など）を定量的に予測** できる形式を指す。

例：連続槽型反応器（CSTR）の動特性モデル

$$\frac{dC_A}{dt} = \frac{F}{V}(C_{A,\text{in}} - C_A) - k(T) C_A$$

$$\frac{dT}{dt} = \frac{F}{V}(T_{\text{in}} - T) + \frac{(-\Delta H)}{\rho c_p} k(T) C_A - \frac{UA}{V\rho c_p}(T - T_c)$$

このような式を連立すれば、反応器の温度と濃度の時間変化が計算できる。

1.2 誰が物理モデルを必要とするか

定性的な説明（「温度を高めにして十分に反応させる」）では不十分で、**定量的予測が必要となる場面**がある。代表例：

- **プロセス設計**：パイロット装置から実機へのスケールアップ時、新しい運転条件下での挙動を事前に予測する
- **制御系設計**：プラントの動特性を把握したうえで、**制御器ゲインや整定時間を決定する**
- **プロセス最適化**：**収率・エネルギー消費・環境負荷などを数値的に比較して最良条件**を選ぶ
- **安全解析**：**暴走反応・異常運転時の挙動をシミュレーションし、安全対策を設計する**

これらの業務では、「**実装された数式モデル**」そのものが不可欠な成果物となる。

1.3 現状の課題

物理モデルの構築は、現在ほぼすべて **専門家の手作業**で行われている。典型的な流れは次のとおり：

1. 対象プロセスに関連する教科書・論文を調査
2. 必要な数式（保存則、素反応速度、物性相関式など）を選別
3. 変数の対応関係を確認し、連立して解ける形に整理
4. シミュレーションと検証を反復

この過程は 数週間から数ヶ月を要し、熟練者の経験に強く依存する（属人化）。結果として、モデル構築が設計業務全体のボトルネックになる場面が多い。

1.4 本研究の目的

上記の課題に対し、本研究の目的は以下である。

プロセスの自然言語記述と求めたい変数の情報から、必要な数式群を文献中の実在数式から自動選択し、連立可能なモデルを構成する手法を確立する。

特に重視するのは次の 2 点：

- ・ ハルシネーションの排除：提示されるすべての数式が実在し、出典を辿れる
- ・ 組合せの整合性：個別の式を寄せ集めるのではなく、連立したときに閉じた系を成す

2. 関連研究

物理モデル自動構築の関連研究は、大きく 3 つの流派に整理できる。

2.1 流派 A：シンボリックリグレッション (SR)

実験データ（入力と出力の数値ペア）から、それを説明する数式 $f(x)$ を探索する手法群。代表例：AI Feynman (Udrescu & Tegmark, 2020)、PySR など。

- ・ 長所：データから未知の関係式を発見できる可能性がある
- ・ 短所：
 - － 実験データが前提であり、設計段階や新規プロセスでは利用困難
 - － 既知の物理法則を明示的に取り込みにくい

- － 工学的に意味のある形（保存則や無次元化された形式）に収束しにくい

2.2 流派 B：LLM による直接生成

大規模言語モデル（GPT-4、Claude 等）に「このプロセスのモデルを書いて」と直接依頼する手法。
近年増加している。

- 長所：自然言語で指示でき、即座に応答が得られる
- 短所：
 - － ハルシネーション：存在しない式や、定数を捏造した式を自信を持って出力する
 - － 根拠の追跡不能：どの文献のどの式に基づくかを特定できず、再現性と検証可能性が低い
 - － 組合せ整合性が弱い：個々の式は妥当でも、連立系として自由度が閉じない（未知数が多すぎる／式が不足する）ケースが生じやすい

2.3 流派 C：文献からの Retrieval（本研究の位置づけ）

教科書や論文から抽出した 実在する数式のデータベースを構築し、そこから条件に合う数式群を 選び出す手法。「生成」ではなく「検索と選択」として問題を定式化する。

- 長所：
 - － 提示される式はすべて実在し、出典が追跡可能
 - － ハルシネーションが原理的に発生しない
 - － 「正解集合」を定義できるため、精度を定量評価できる
- 課題：
 - － 選択の粒度が文献収録式の範囲に制限される
 - － 新規の式は発見できない（SR と相補関係）

本研究は流派 C に位置づけられる。現在、3,244 の実在数式を収録したデータベースを構築している。

3. 手法

3.1 問題設定

入力：プロセスの自然言語記述と、既知変数（入力）・求めたい変数（出力）の集合
出力：連立して出力変数を解ける、実在数式の集合

3.2 基本戦略：2 段階 Retrieval

段階	処理	役割
Stage 1	文脈類似度（TF-IDF） + 変数一致度（Jaccard）で上位候補を選抜	大域的な絞り込み
Stage 2	学習済みランカーで順序を並び替え	精密な選択

Stage 1 は古典的な情報検索手法で十分機能する。研究の中心は Stage 2 で、ここにグラフニューラルネットワーク（GNN）を組み合わせる。

3.3 なぜ GNN を用いるか

数式データには、テキストだけでは表現しきれない **構造的情報** が豊富に含まれている。

- 同じ変数を用いる式同士は、同じ現象を記述している **可能性が高い**
- 同じ分野で頻繁に共起する式は、連立して使われる **蓋然性が高い**
- ある式の出力変数が、別の式の入力変数として必要になる **関係**

これらは **ノードとエッジで構成されるグラフ** として自然に表現できる。GNN（Graph Neural Network）は、ノードの属性と **エッジの関係** を同時に扱い、**間接的な関係** まで含めてノード表現を更新する。単なる平文処理では捉えにくい情報を活用できる点で、本問題に適している。

本研究で扱う文脈情報の範囲（明確化）：

文脈情報は粒度によって二段階に分けられる。本研究が現時点で扱っているのは、このうち前者のみである。

情報の粒度	本研究での扱い
式全体の文脈（式テキスト、周辺の説明文、ドメイン名）	○利用する（Stage 1 の TF-IDF、Stage 2 の文脈類似度特徴量、SVD 類似度特徴量）
変数単位の意味（各変数の物理的意味の自然言語記述）	× 現時点では未使用。変数マッチングは記号の完全一致に基づく

たとえば、比熱を c_p と書く文献と C_p と書く文献があった場合、本研究の現在の実装では両者は別の変数として扱われる。この制約を踏まえたうえで、変数レベルの意味類似度を導入することは今後の課題としている (§4.4 で後述)。

3.4 直感的な説明：SNS の例え

A さんと C さんに直接の接点はないが、共通の友人 B がいるとする。このとき「A と C も友人である可能性が高い」と推測できる。直接は見えない関係を、構造から推測することが可能である。

SNS	数式ネットワーク
人物	数式
友人関係	共通変数を持つ／同じ分野で共起する
A と C の潜在的関係	共通変数 T を介して関連する式 α と式 β の対応

この発想が、Stage 2 の特徴量設計の基盤となっている。

3.5 単発選択と組合せ選択の違い

研究を進めるうち、**選択すべき数式は 1 本とは限らない**ことが明らかになった。実際の物理モデルは、エネルギー保存式・物質収支式・反応速度式など、複数式の**組合せ**で成立する。このため、候補を個別に評価する**従来設計**では不十分で、**候補同士の相性を評価する**必要がある。

映画製作の比喻：

- **役職で選ぶ**：監督・俳優・エディターそれぞれの履歴書を見る ⇨ **式の個別適合性**
- **相性で選ぶ**：キャスト同士の共演歴・作風の一致 ⇨ **式同士の変数共有・ドメイン一致**

優秀な役者を個別に集めてもよい作品にならないのと同様、個別に適合する数式を集めても、連立して閉じた系になるとは限らない。

3.6 Set-aware な特徴量設計

候補式単体の属性に加え、**すでに上位にある候補との関係**を評価する特徴量を導入する。具体的には以下の 3 種：

1. **補完性**：候補が、上位候補群ではまだカバーされていないクエリ変数をどれだけ補うか
2. **一貫性**：候補の変数が、上位候補群の変数とどれだけ共有されているか
3. **ドメイン整合性**：候補の分野が、上位候補群の分野と一致しているか

これらは「候補同士の組合せ」を直接評価するため、単発の特徴量では捉えられない情報を提供する。

4. 結果と考察

4.1 データセットと評価指標

- 式データベース：3,244 式（**教科書** + **論文**からの抽出）
- **訓練ケース**：1,107 件（物理的に求解可能な条件を満たすよう検証済み）
- 評価指標：
 - **MRR_first**：最初の正解式の逆順位（単発評価）

- **FullRecall@K**：上位 K 件に全正解式が含まれる割合（集合評価）
- **MAP**：Mean Average Precision

4.2 主要な結果

手法	MRR_first	FullRecall@3	MAP
ベースライン（Stage 1 スコアのみ）	0.937	0.826	0.936
リランカー（個別特徴量 7 次元）	0.959	0.881	0.953
リランカー + Set-aware 特徴量	0.980	0.904	0.974

10 種のランダムシードで検証した結果、Set-aware 特徴量の導入による改善は以下の指標で **統計的に有意** であった。

- MAP： $p = 0.004$ （ t -検定、両側）
- **複数次正解式ケースに限定した FullRecall@3**： $p = 0.032$

4.3 考察

個別の数式選択では、テキスト類似度と変数一致度で得られる情報がほぼ飽和しており、グラフ構造を単純に追加しても改善は限定的であった。**しかし、複次数を同時に選ぶ課題に移ると状況が一変する。候補同士の関係性を評価する特徴量を導入することで、統計的に有意な改善が得られた。**

この知見は、GNN の有効性についての一般的な示唆を与える。すなわち、「**単一対象のスコアリング**」ではなく、「**対象集合の整合性評価**」こそ、グラフ構造の情報が差別化を生む場面である。

4.4 今後の展望

現状の整理：文脈情報の利用状況

本研究は「文脈情報」を二段階に分けて扱っており、それぞれの利用状況を明確にしておく。

情報の粒度	現在の利用状況	具体的な使い方
式レベルの文脈（式テキスト・周辺説明文・ドメイン名）	○利用済み	Stage 1 の TF-IDF 類似度、Stage 2 の文脈類似度特徴量 (f0) と SVD 類似度特徴量 (f2) で使用
変数レベルの意味（変数の自然言語記述、例：「流体 j の比熱」）	× 未利用	変数のマッチングは 記号の完全一致に基づいており、意味情報は活用していない

つまり、式全体の文脈は既に活用しているが、個々の変数の物理的意味までは活用できていない。このため次のような問題が残っている。

- 同じ物理量でも文献によって記号表記が異なる（例：比熱を c_p と書く文献と C_p と書く文献）
場合、現システムは別変数として扱う
- 結果として、変数共有関係を表すグラフで本来張るべきエッジが欠落し、組合せ評価の精度が制限される

今後取り組む方向

1. 変数の意味類似度の導入：各変数に付与された自然言語記述（例：Heat capacity of fluid j）を埋め込み空間で比較し、記号が異なっても意味が近い変数をソフトに同一視する仕組みを導入する。これにより、表記揺れを吸収しつつ、誤った統合のリスクを制御できる。
2. 式データベースの拡大（3,244 式 → 5,000+ 式）：ドメイン網羅性の向上
3. 実プロセスでのケーススタディ：本手法を実際のプロセス設計・制御設計の場面に適用し、実用性と限界を評価する

5. まとめ

1. **目的**：物理モデル構築を自動化し、設計・制御・最適化の基盤を提供する
2. **関連研究**：SR はデータ依存、LLM 直接生成はハルシネーションと組合せ整合性の問題。本研究は実在数式からの **Retrieval** に定式化することで、両者の欠点を回避する
3. **手法**：2 段階 Retrieval を採用し、Stage 2 に **Set-aware な GNN 特徴量** を組み込む
4. **結果**：単発選択では既存手法で十分だが、**複数式の組合せ選択**では Set-aware 特徴量が統計的に有意な改善を示した
5. **展望**：意味ベースの類似度導入と、データ規模の拡大

ご清聴ありがとうございました。ご質問・ご指摘をいただければ幸いです。

付録：話し方のメモ

- 冒頭で「話の流れ」を必ず示し、聴衆に全体像を共有する
- 各セクションの冒頭で「これから何の話をするか」を一文で述べる
- 数式を出す際は、記号の物理的意味を必ず口頭で補足する（ C_A は「A 成分の濃度」、 ΔH は「反応熱」など）
- 統計結果（ p 値、MRR）を出すときは、指標の意味を一言添える（「MRR は正解の順位の逆数の平均、1.0 で完全正解」）
- 専門用語（GNN、Retrieval、TF-IDF、Jaccard、MRR）は初出時に日本語で言い換える