

修士論文 骨子：文献から抽出した数式と文脈を用いた 物理モデル自動構築のための数式集合検索

(Equation-Set Retrieval Using Equations and Context Extracted from the Literature for Automated Physical Model Building)

作成者：M2 一洋

【本資料について】英語骨子 (thesis/master_thesis/main.pdf、16 ページ) のレビュー用和文要約。各箇条書きが本文の 1 段落に対応する。

論文の主張（要約）

本論文は、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、複数文献から集めた数式データベース（DB、11,146 式・361 ソース）の中から、そのモデルを構成する数式の集合を検索して提示する手法を提案する。核心は、候補の式を 1 本ずつでなくすでに選んだ集合との関係で評価する集合特徴量である。評価指標 Recall@K（必要な式を、正解式数 K 件の上位枠に過不足なくそろえられた割合）は、古典的な情報検索（IR）の 0.521 から **0.743**（設定 A）へ、最難の微分代数方程式系（DAE）ケースのみでも 0.466 から **0.689** へ、いずれも +0.22 改善する（Wilcoxon 符号順位検定 $p = 0.00195$ ）。大規模言語モデル（LLM）に必要な数式を直接生成させる方法（0.23–0.30）に対しても優位性を示す。さらに、(i) 上乘せの源泉が構造的な集合特徴量であることの実証、(ii) 上乘せが頭打ちになる最難ケースの学習版 greedy（貪欲法）による回復、(iii) 正解式数 K を知らずに「解ける系」を返す自由度停止、までを一貫した流れとして示す。

第 1 章 序論（Introduction）

1. 物理モデルはデジタルツインの実現やプロセスの設計・運転に不可欠だが、構築には膨大な文献調査と試行錯誤を要する。
2. 我々のグループはこれを自動化する物理モデル自動構築システム AutoPMoB（automated physical model builder）の開発を目指しており、変数同義性判定（ProcessBERT）などの要素技術を積み上げてきた。本研究はその次の段階＝抽出済みの数式をモデルへ組み上げる工程を担う。
3. 物理モデルは変数を共有し連立して初めて解ける系（方程式数＝未知数の数、自由度ゼロ）なので、文章類似度だけの検索では足りない。
4. そこで 2 段階検索（第 1 段 7 特徴量 → 第 2 段 集合特徴量 3 個 + MLP）に、学習版 greedy と自由度停止を加えた手法を提案する。
5. 評価は 11,146 式 DB・解けることを保証した DAE ケース・ソース単位の層化分割（10 乱数）で行う。
6. 貢献 3 点：(1) 解けることを構造的に保証したデータセット、(2) 集合を考慮した 2 段階検索（+0.22、古典 IR と LLM 直接生成の双方に優位）、(3) 機構の実証 → 学習版 greedy → 自由度停止。

第 2 章 関連研究（Related Work）

4 系統（AutoPMoB 要素技術／情報検索と再順位付け／LLM による知識の直接生成／数式検索）を概観し、各系統の末尾で本研究との相違＝独立に関連する項目でなく、連立して解ける集合を返す点に毎回戻

る。実文献の引用は本文の段階で検証のうえ追加する。

第 3 章 手法 (Set-aware Equation-Set Retrieval)

1. 問題定式化：入力 $q = (\text{説明文}, \text{入力変数}, \text{出力変数})$ 、出力 = DB 中の数式の順位付き集合。自由度（未知数の数と方程式の数の差）が 0 のとき系は閉じ、入力を与えれば解が一意に定まる。
2. 第 1 段：入力 q の説明文と数式の文脈テキスト（文献から式とともに抽出した周辺説明）との文章類似度（TF-IDF：単語の出現頻度に基づく重み付け。特異値分解 SVD による圧縮版も併用）、入出力変数と式中変数の重なり（Jaccard 係数）、入力・出力の被覆率、ドメイン（分野）一致など計 7 特徴量で候補を絞る。これが比較対象の baseline（古典的情報検索）でもある。
3. 第 2 段：集合特徴量 3 個 — 補完性 gComp（未充足の入出力変数をどれだけ補うか）・一貫性 gCoh（既選択集合と変数をどれだけ共有するか）・ドメイン一致 gDom — を加えた計 10 特徴量を多層パーセプトロン（MLP）で評点する（reranker-10S。S は set-aware = 集合考慮の意）。
4. 逐次選択 3 方式：静的／推論時 greedy（式を 1 本選ぶたびに集合特徴量を再計算して次を選ぶ貪欲法）／学習版 greedy（teacher forcing：訓練時にも正解の部分集合を文脈として与え、訓練と推論の条件を一致させる）。
5. 自由度停止： K を与えずに、系が閉じた時点で自動停止する。

第 4 章 データセット (Equation Database and Test Case Construction)

1. 数式 DB：論文 329 報を LLM（Gemini 2.5 Pro）で抽出 + 32 分野の基礎式 670 式を生成し、11,146 式・361 ソースに拡大（3,244 式から）。
2. ケース 2,838 件：オリジナル 92・複数文献 731（規則ベース、LLM 不使用）・DAE 1,000・データ拡張 1,015（訓練のみ、評価から除外）。複数次式ケースが 74.6%。
3. DAE ケース生成：加藤先生にご指摘いただいた手順（常微分方程式（ODE）を出発点として変数を共有する式を追加し、方程式数 = 未知数の正方系のみ採用。 $X = 1..10 \times$ 各 100 件）。説明文の生成のみ LLM（Claude）を使用。
4. 層化分割：ソース（文献）単位で 6:2:2 に分け（言い換えによる答え漏れを防止）、無作為な 400 候補から 4 つの分布（数式数・入出力変数数・横断ソース数 = 正解式が何件の文献にまたがるか）のずれ（ L_1 距離：割合差の総和）が最小の分割を選択。10 乱数で反復。

第 5 章 実験 (Experiments)

設定 A（オリジナル + 複数文献 + DAE、1,823 件）と設定 B（DAE のみ 1,000 件）。拡張込みで評価すると baseline が +0.101 水増しされ本手法の効果を過小評価するため、主要評価から除外する。比較 3 手法 = baseline（古典 IR）／reranker-10S（本手法）／LLM 直接生成（生成式の等価性を別の LLM で判定、各設定 $n \approx 50$ ）。指標は Recall@ K ・MAP（平均適合率：正解をどれだけ上位にまとめられたか）・Recall@20（上位 20 件に正解が入る割合）。自由度停止には完全一致率・集合 F1・閉包率（返した集合が自由度ゼロで閉じている割合）を用いる。10 乱数の対応あり Wilcoxon 符号順位検定を行う（ $n = 10$ の両側最小 p は 0.00195）。

第 6 章 結果と考察 (Results and Discussion)

流れ：性能 → 機構 → 介入 → 自己停止 → 留意点。

- 全体（表 1）：設定 A で 0.521→0.743、設定 B で 0.466→0.689（いずれも $p = 0.00195$ 、10 乱数全勝）。LLM 直接生成は 0.23–0.30 にとどまる一方、順位を問わない coverage（等価な式を生成できた割合）は 0.34–0.57 = 「生成はできるが上位 K 件に並べられない」。
- 特性格：数式数・入力変数数が多い難しいケースほど優位性が拡大（+0.03 → +0.21~0.29）。ソース数は数式数と交絡しており単独の効果ではない。
- 機構：補完性 +0.052・一貫性 +0.050 は各単独で有意、ドメイン一致は寄与ゼロ（ $p = 0.98$ ）。上乘せは単一式ケースではほぼゼロ、正解式数 2~3 で最大（ $X = 3$ で +0.12）となり、最も難しいケース群では頭打ちになる。
- 介入：この頭打ちを学習版 greedy が回復する。DAE で静的 0.724 < 推論 greedy 0.756 < 学習版 0.765（学習版 vs 推論 $p = 0.037$ ）、 $X \geq 8$ で静的比 +0.056。設定 A でも 0.757 < 0.787 < 0.797（greedy vs 静的は有意 $p = 0.00195$ 、学習版 vs 推論の +0.010 は非有意 $p = 0.13$ 。greedy 系は第 1 段の候補数 top- k を 200 に広げているため表 1 の値とは直接比較しない）。
- 自由度停止：完全一致率は、正解式数 K を教えた場合（oracle- K ）と厳密に同一（DAE 0.368 / 設定 A 0.526）。閉包率は oracle- K を上回り（0.883 vs 0.781、0.936 vs 0.865）= 解ける系を返す保証。集合 F1 のコストは僅少（設定 A -0.008）。ただし本データでは $K \approx$ 出力変数数のため K 予測自体は自明であり、主張は「自己停止+閉包保証」に置く。
- 留意点：DAE の説明文は LLM 生成、ソース数の交絡、分割方式は 400 候補から選んだ 1 つ、DB 内評価（DB にない式は検索できない）。

表 1 全体結果（baseline・本手法は層化分割・10 乱数の平均、± は乱数間の標準偏差）。LLM 直接生成は各設定の一樣サンプル（A: $n = 48$ 、B: $n = 50$ ）の単発評価で、生成式の等価性を別の LLM で判定して採点した（使用モデルは付録に記録）。coverage（等価な式を生成できた割合、順位不問）は 0.419（A）・0.343（B）。

設定	手法	Recall@ K	MAP	Recall@20
A (1,823 件)	baseline (古典 IR)	0.521 ± 0.045	0.581	0.836
	LLM 直接生成 (外部比較)	0.254	—	—
	reranker-10S (本手法)	0.743 ± 0.054	0.863	0.909
B (DAE のみ 1,000 件)	baseline (古典 IR)	0.466 ± 0.037	0.512	0.721
	LLM 直接生成 (外部比較)	0.226	—	—
	reranker-10S (本手法)	0.689 ± 0.033	0.832	0.838

第 7 章 結論 (Conclusion)

貢献 3 点（データセット／集合を考慮した 2 段階検索／機構実証と自己停止）を要約し、今後の課題として scheduled sampling（訓練中に正解の代わりに自身の予測を混ぜて与え、訓練と推論の差をさらに縮める手法）の導入、DB にない式を含む実課題での検証、AutoPMoB パイプラインへの統合を挙げる。