

修士論文 骨子：文献から抽出した数式と文脈を用いた 物理モデル自動構築のための数式集合検索

(Equation-Set Retrieval Using Equations and Context Extracted from the Literature for Automated
Physical Model Building)

作成者：M2 一洋

【本資料について】英語骨子（thesis/master_thesis/main.pdf、16 ページ）のレビュー用和文要約である。章立て・段落構成は英語版と同一で、各箇条書きが本文の 1 段落（先頭文）に対応する。

論文の主張（要約）

本論文は、「どんな物理モデルを作りたいか」（説明文と入出力変数）を入力すると、複数文献から集めた数式データベース（11,146 式・361 ソース）の中から、そのモデルを構成する数式の集合を検索して提示する手法を提案する。核心は、候補の式を 1 本ずつでなくすでに選んだ集合との関係で評価する集合特徴量である。Recall@ K は古典的検索の 0.521 から **0.743**（設定 A）へ、最難の DAE のみでも 0.466 から **0.689** へ、いずれも +0.22 改善する（Wilcoxon 符号順位検定 $p = 0.00195$ ）。LLM 直接生成（0.23–0.30）に対しても優位性を示す。さらに、(i) 上乘せの源泉が構造的な集合特徴量であることの実証、(ii) 学習版 greedy による最難端の回復、(iii) 正解式数 K を知らずに「解ける系」を返す自由度停止、までを一貫した流れとして示す。

第 1 章 序論（Introduction）

1. 物理モデルはデジタルツインの実現やプロセスの設計・運転に不可欠だが、構築には膨大な文献調査と試行錯誤を要する。
2. 我々のグループはこれを自動化する AutoPMoB の開発を目指しており、変数同義性判定（Process-BERT）などの要素技術を積み上げてきた。本研究はその次の段階＝抽出済みの数式をモデルへ組み上げる工程を担う。
3. 物理モデルは変数を共有し連立して初めて解ける系（方程式数＝未知数の数、自由度ゼロ）なので、文章類似度だけの検索では足りない。
4. そこで 2 段階検索（第 1 段 7 特徴量 → 第 2 段 集合特徴量 3 個 + MLP）に、学習版 greedy と自由度停止を加えた手法を提案する。
5. 評価は 11,146 式 DB・解けることを保証した DAE ケース・ソース単位の層化分割（10 乱数）で行う。
6. 貢献 3 点：(1) 解けることを構造的に保証したデータセット、(2) 集合を考慮した 2 段階検索（+0.22、古典 IR と LLM 直接生成の双方に優位）、(3) 機構の実証 → 学習版 greedy → 自由度停止。

第 2 章 関連研究（Related Work）

4 系統（AutoPMoB 要素技術／情報検索と再順位付け／LLM による知識の直接生成／数式検索）を概観し、各系統の末尾で本研究との相違＝独立に関連する項目でなく、連立して解ける集合を返す点に

毎回戻る。実文献の引用は本文化の段階で検証のうえ追加する。

第 3 章 手法 (Set-aware Equation-Set Retrieval)

1. 問題定式化：入力 $q = (\text{説明文}, \text{入力変数}, \text{出力変数})$ 、出力 = DB 中の数式の順位付き集合。自由度 $\text{DoF}(S) = |\text{未知数}| - |S|$ が 0 のとき系は閉じる（解ける）。
2. 第 1 段：7 特徴量（説明文との TF-IDF 類似度・入出力変数との Jaccard・SVD 潜在類似度・入力被覆率・出力被覆率・変数適合率・ドメイン一致）で候補を絞る。これが比較対象の baseline でもある。
3. 第 2 段：集合特徴量 3 個 — 補完性 gComp（未充足の入出力変数をどれだけ補うか）・一貫性 gCoh（既選択集合と変数をどれだけ共有するか）・ドメイン一致 gDom — を加えた 10 特徴量を MLP で評点（reranker-10S）。
4. 逐次選択 3 方式：静的／推論時 greedy（選ぶたびに集合特徴量を再計算）／学習版 greedy（teacher forcing で訓練時も逐次文脈を与え、訓練と推論の条件を一致させる）。
5. 自由度停止： K を与えずに、系が閉じた時点で自動停止する。

第 4 章 データセット (Equation Database and Test Case Construction)

1. 数式 DB：論文 329 報を LLM (Gemini 2.5 Pro) で抽出 + 32 分野の基礎式 670 式を生成し、11,146 式・361 ソースに拡大（3,244 式から）。
2. ケース 2,838 件：オリジナル 92・複数文献 731（規則ベース、LLM 不使用）・DAE 1,000・データ拡張 1,015（訓練のみ、評価から除外）。複数次ケースが 74.6%。
3. DAE ケース生成：加藤先生にご指摘いただいた手順（ODE を種に、変数を共有する式を追加し、方程式数 = 未知数の正方系のみ採用。 $X = 1..10 \times$ 各 100 件）。説明文の生成のみ LLM (Claude) を使用。
4. 層化分割：ソース単位で 6:2:2 に分け（言い換えによる答え漏れを防止）、400 候補から 4 分布（数式数・入出力変数数・横断ソース数）の L_1 距離最小の分割を選択。10 乱数で反復。

第 5 章 実験 (Experiments)

設定 A（原型 + 複数文献 + DAE、1,823 件）と設定 B（DAE のみ 1,000 件）。拡張込みで評価すると baseline が +0.101 水増しされ本手法の効果を過小評価するため、主要評価から除外する。比較 3 手法 = baseline（古典 IR）／reranker-10S（本手法）／LLM 直接生成（生成式の等価性を別 LLM で判定、各設定 $n \approx 50$ ）。指標は Recall@ K ・MAP・Recall@20、自由度停止には完全一致率・集合 F1・閉包率。10 乱数の対応あり Wilcoxon 符号順位検定を行う（ $n = 10$ の両側最小 p は 0.00195）。

第 6 章 結果と考察 (Results and Discussion)

流れ：性能 → 機構 → 介入 → 自己停止 → 留意点。

1. 全体（表 1）：設定 A で 0.521→0.743、設定 B で 0.466→0.689（いずれも $p = 0.00195$ 、10 乱数全

- 勝)。LLM 直接生成は 0.23–0.30 にとどまる一方、順位を問わない coverage は 0.34–0.57 = 「生成はできるが上位 K 件に並べられない」。
2. 特性別：数式数・入力変数数が多い難しいケースほど優位性が拡大 (+0.03 $\rightarrow$ +0.21~0.29)。ソース数は数式数と交絡しており単独の効果ではない。
 3. 機構：補完性 +0.052・一貫性 +0.050 は各単独で有意、ドメイン一致は寄与ゼロ ($p = 0.98$)。上乘せは閾値+こぶ型 ($X = 3$ で +0.12) で、最難端では飽和する。
 4. 介入：学習版 greedy が飽和を回復。DAE で静的 0.724 < 推論 greedy 0.756 < 学習版 0.765 (学習版 vs 推論 $p = 0.037$)、 $X \geq 8$ で静的比 +0.056。設定 A でも 0.757 < 0.787 < 0.797 (greedy vs 静的は有意 $p = 0.00195$ 、学習版 vs 推論の +0.010 は非有意 $p = 0.13$ 。greedy 系は top- $k=200$ のため表 1 の値とは直接比較しない)。
 5. 自由度停止：完全一致率は K 既知の oracle と厳密に同一 (DAE 0.368 / 設定 A 0.526)。閉包率は oracle を上回り (0.883 vs 0.781、0.936 vs 0.865) = 解ける系を返す保証。集合 F1 のコストは僅少 (設定 A -0.008)。ただし本データでは $K \approx$ 出力変数数のため K 予測自体は自明であり、主張は「自己停止+閉包保証」に置く。
 6. 留意点：DAE の説明文は LLM 生成、ソース数の交絡、分割方式は 400 候補から選んだ 1 つ、DB 内評価 (DB にない式は検索できない)。

表 1 全体結果 (baseline・本手法は層化分割・10 乱数の平均、 $\pm$ は乱数間の標準偏差)。LLM 直接生成は各設定の一様サンプル (A: $n = 48$ 、B: $n = 50$) の単発評価で、生成式の等価性を別の LLM (claude-opus-4-8) で判定して採点した。順位を問わない coverage は 0.419 (A)・0.343 (B)。

設定	手法	Recall@ K	MAP	Recall@20
A (1,823 件)	baseline (古典 IR)	0.521 $\pm$ 0.045	0.581	0.836
	LLM 直接生成 (外部比較)	0.254	—	—
	reranker-10S (本手法)	0.743 $\pm$ 0.054	0.863	0.909
B (DAE のみ 1,000 件)	baseline (古典 IR)	0.466 $\pm$ 0.037	0.512	0.721
	LLM 直接生成 (外部比較)	0.226	—	—
	reranker-10S (本手法)	0.689 $\pm$ 0.033	0.832	0.838

第 7 章 結論 (Conclusion)

貢献 3 点 (データセット／集合を考慮した 2 段階検索／機構実証と自己停止) を要約し、今後の課題として scheduled sampling による学習版 greedy の改善、DB 外の式を含む実モデリング課題での検証、AutoPMoB パイプラインへの統合を挙げる。