物理モデルの自動構築のための数式集合の検索
大規模言語モデルとの比較の方法と結果

報告者：M2 一洋

Abstract

本研究の目的は、複数の情報源から収集した数式の中から、作りたいモデルに使える可能性の高い数式を提示する手法を開発することである。提案手法は 2 段階の処理から構成される。第 1 段では、数式を、作りたいモデルの説明文と式周辺の文章の近さと、入出力変数の重複率で採点し、上位 N_1 件に絞る。第 2 段では、10 個の特徴量を持つ多層パーセプトロンで並べ直し、上位 20 件を提示する。本報告では、大規模言語モデルに全 11,146 式を渡して式を選ばせ、提案手法と同じ規則で判定して比べた。1,731 ケースで評価した結果、上位 20 件に入った正解式の割合は、古典的な情報検索手法が 0.922、提案手法が 0.992、Claude Opus 5.5 が 0.932、Claude Haiku 5.5 が 0.530 であり、提案手法が 10 通りの分け方すべてで両モデルを上回った。

1 進捗と議論のポイント

- **比較の目的**：同じデータベースと同じ判定の規則のもとで、提案手法と大規模言語モデル（large language model, LLM）のそれぞれの長所と短所を見つける。精度を比べるだけでなく、どのようなケースでどちらが正解式を上位に選べるか、費用、答えの回ごとのばらつきも比べる。高性能と低コストの 2 つのモデルを使い、モデルの規模による違いも見る。
- LLM との比較を行なった。LLM に、データベースの全 11,146 式と、テストケース 1 件のクエリ（作りたいモデルの説明文と入出力変数）を渡して式を 20 個選ばせ、選んだ式が正解式かを、提案手法と同じ規則で判定した。表記が同じ式は、正解集合の中でも手法の答えの中でも 1 本と数え、答えが 20 本に足りなければ下の順位の式で補った。
- Claude Opus 5.5 と Claude Haiku 5.5 で、テストケース 1,673 件を 3 回ずつ解かせた。費用は 2 モデルで 1,314 ドルだった。全ケースの Recall@20（上位 20 件に入った正解式の割合）は、Opus 5.5 が 0.932、Haiku 5.5 が 0.530 で、提案手法の 0.992 を 10 通りの分け方すべてで下回った。Opus 5.5 は古典的な情報検索手法（0.922）を 10 通りのうち 9 通りで上回り、Haiku 5.5 は 10 通りすべてで下回った。
- **議論したい点**：次の 2 点について、意見をいただきたい。
  (1) この比較方法は公平か。この方法で、提案手法と LLM の性能を本当に比べられるか。
  (2) 費用の 90〜94% は、呼び出しのたびにデータベース（952,144 トークン。トークンは LLM が文字列を数える単位）を読み出す料金だった。もっと費用を抑えて比べる方法はないか。

2 大規模言語モデルとの比較の方法

2.1 何を比べるか

LLM は多くの文献を学習しており、データベースを渡せば、作りたいモデルに使う式を自ら選べる可能性がある。そこで、LLM にも提案手法と同じデータベースとクエリを渡して式を選ばせ、提案手法と同じ規則で判定して、提案手法と古典的な情報検索手法（以下 baseline）と比べる。評価用の各ケースには、クエリと、作りたいモデルを構成する式の集合（正解集合。その式を正解式とよぶ）を決めてある。ケースは出典の単位で訓練用、検証用、テスト用に分け、分け方を 10 通り変えて評価する。これまでの比較では、LLM に式を書かせ、書かれた式が正解式と同じかを別の LLM に判定させていた。そのため、LLM と提案手法は別の問題を解いており、判定の方法も違っていた。10 月 14 日に加藤先生と議論し、データベースから式を選ばせて式の ID で判定する方法に改めた。

2.2 LLM に渡すもの

1 回の呼び出しで、LLM に、指示文、データベース、テストケース 1 件のクエリを渡す（指示文と入力の形は Appendix A）。各手法が使う情報を Table 1 にまとめる。

- **データベース**：各式を、ID、式の表記、分野ラベル（式が扱う分野の名前）の 3 つだけで渡す。使う LLM の入力の上限は 100 万トークンであり、この形でも、指示文とデータベースで 952,144 トークンになる。変数記号とその定義を加えると約 199 万トークンになって上限を超えるため、変数記号の一覧と定義、式周辺の文章は渡さない。ただし、式の表記には変数が記号で書かれている。

Table 1: Information used by each method.

情報	提案手法	baseline	LLM
クエリ（説明文、入力変数、出力変数）	○	○	○
式の表記と分野ラベル	○	○	○
式の変数記号の一覧	○	○	×
式周辺の文章	○	○	×
変数記号の定義の文章	×	×	×
出典	×	×	×
正解の分かっているケース	訓練用と検証用	検証用	×

- **出典**：渡さない。式の並びを無作為にし、ID も 1〜11,146 の番号に振り直す（元の ID は出典の名前を含む）。提案手法は出典を使わないためである。また、合成のケース（微分方程式から始め、プログラムで式を足して作った 1,000 件）の正解集合は、同じ出典の式を優先して作ったので、出典が分かると、LLM だけが答えの手がかりを持つことになる。
- **解いた例**：渡さない。正解の分かっているケースを例として見せずに解かせる（ゼロショット）ためである。
- **答え方**：作りたいモデルに使う式の ID を、可能性の高い順に 20 個答えさせる。モデルを構成すると判断した式を先に挙げるよう指示する。指示文には、モデルの式の組が満たす条件として、Kato and Kano [1] の要件のうち変数と式の数え方に関する 3 つ（入出力変数がすべていずれかの式に現れる、式の数が入力変数以外の変数の数に等しい、入出力変数以外の変数は 2 本以上の式に現れる）を書く。
- **モデル**：Anthropic の LLM（Claude）から、高性能の Claude Opus 5.5 と、低コストの Claude Haiku 5.5 を使った。答える前に考える量の設定（effort）は、どちらのモデルも high にそろえた。呼び出しはプログラムから行ない、モデル名、指示文の版、設定、日時、使ったトークン数、応答をすべて記録した。

2.3 判定と指標

判定：手法が答えた式が正解集合 R_q（q はクエリ）に含まれれば正解、含まれなければ不正解とする。データベースには、表記が同じ式が別の ID で入っていることがある。LLM には出典も式周辺の文章も渡さないので、LLM はそれらを区別できない。そこで、空白と、LaTeX の間隔や括弧の大きさの命令を除いて同じ文字列の式を同じ式とみなし、正解集合の中でも、手法が並べた式の中でも、同じ式は 1 本と数える。手法が並べた式から同じ式の 2 本目以降を除いて上位 20 件に足りない分は、21 位以降の式を順に繰り上げて 20 件にする（LLM は 20 個の ID を答えるので、20 個を超えて答えたときだけ繰り上げられる）。式を変形すると同じになる式は、同じ式とみなさない。データベースにない ID は不正解とし、その順位を占めるものとする。提案手法と baseline も同じ規則で判定する。

指標：正解式の数を $K = |R_q|$（表記が同じ式は 1 本と数える）、手法が並べた上位 20 件を $\mathrm{Top}_{20}(q)$ として、テスト用のケースごとに

$$\mathrm{Recall@20}(q) = \frac{|R_q \cap \mathrm{Top}_{20}(q)|}{K}, \qquad \mathrm{AP@20}(q) = \frac{1}{K} \sum_{e \in R_q} P(e)$$

を求める。$P(e)$ は、正解式 e が上位 20 件にあれば、e の順位までの式のうち正解式の割合、なければ 0 である。AP@20 のケースの平均を MAP@20（mean average precision）とよぶ。MAP@20 は、正解式がどれだけ上位に集まっているかを表す。LLM には 20 件を答えさせるので、どの手法も上位 20 件で比べる。

比べ方：提案手法と baseline と同じ 10 通りの分け方を使い、分け方ごとにテスト用のケースで平均した値を求めて、10 通りの平均 ± 標準偏差と、10 通りのうち何通りで一方が上回ったかを示す。評価は、全ケースを使う場合と、合成のケースだけを使う場合（分け方はそれぞれ 10 通り）の 2 つで行なう。

呼び出しの回数：LLM には解いた例を渡さないので、同じケースへの入力は、どの分け方でも同じになる。そこで、異なるテスト用のケースごとに 3 回、独立に解かせ、その答えを、そのケースがテスト用に入るすべての分け方で使う。ケースの値は 3 回の平均とする。10 通りの分け方のテスト用のケースは、全ケースの評価で延べ 4,229 件、合成のケースの評価で延べ 2,432 件あり、異なるケースは合わせて 1,673 件

Table 2: Estimated cost in US dollars of 5,019 calls (1,673 test cases × 3 runs), assuming 2,000 output tokens per call (about 970 for Claude Haiku 5.5, measured in a trial).

モデル	データベースの読み出し	キャッシュへの保存	テストケースの入力	出力	合計	読み出しの割合	合計（出力 70〜8,000）
Claude Haiku 5.5	238.9	0.6	0.8	12.2	252.5	95%	241〜341
Claude Sonnet 5.5	477.9	2.4	3.0	100.4	583.7	82%	487〜885
Claude Opus 5.5	955.8	4.8	6.1	200.8	1,167.4	82%	974〜1,770
Claude Fable 5.1	1,194.7	11.9	15.2	501.9	1,723.7	69%	1,239〜3,229

Table 3: Recall@20 and MAP@20 of the four methods (mean ± SD over 10 splits). Equations with the same notation are counted once, in the answer and in the correct set, and the answer is refilled from the ranks below up to 20 equations.

	全ケース（1,731 件）		合成のケース（1,000 件）	
手法	Recall@20	MAP@20	Recall@20	MAP@20
baseline	0.922 ± 0.012	0.733 ± 0.033	0.854 ± 0.025	0.636 ± 0.027
提案手法	0.992 ± 0.003	0.906 ± 0.024	0.985 ± 0.005	0.867 ± 0.026
Claude Opus 5.5	0.932 ± 0.015	0.823 ± 0.034	0.912 ± 0.013	0.794 ± 0.025
Claude Haiku 5.5	0.530 ± 0.056	0.331 ± 0.046	0.562 ± 0.046	0.339 ± 0.033

である。したがって、呼び出しは 1 モデルにつき 5,019 回（1,673 件 × 3 回）である。Claude Haiku 5.5 で、種類の違う 3 件を 3 回ずつ解かせて試したところ、正解式が 5 本の合成のケースでは、Recall@20 が回によって 0.600、0.800、0.000 と変わった。そこで、回の間のばらつき（答えの一致と、Recall@20 の回の間の標準偏差）もあわせて示し、ばらつきが大きければ回数を増やし、小さければ減らす。

2.4 費用の見積もり

1 回の入力は、指示文とデータベースの 952,144 トークンと、テストケースの平均 303 トークンである。データベースの部分は毎回同じなので、プロンプトキャッシュを使う。プロンプトキャッシュは、入力の先頭部分を保存しておき、次の呼び出しでは、その部分を通常の入力の 2.5〜10%（モデルによる）の料金で読み出す仕組みである（保存には、通常の入力の 1.25 倍の料金がかかる）。出力のトークン数（答える前に考えた分を含む）は、Claude Haiku 5.5 では、3 件を 3 回ずつ解かせた試しの実測から 1 回約 970 トークンとし、ほかのモデルでは 1 回 2,000 トークンと仮定した。料金は、2026 年 11 月 1 日に確かめた料金表 [2] による。

見積もりを Table 2 に示す。1 モデルで 5,019 回を流す費用は 252〜1,724 ドルで、2 モデルでは、組み合わせによって 1,420〜2,307 ドルになる。どのモデルでも、費用の 69〜95% は、呼び出しのたびにデータベースを読み出す料金である。出力が 1 回 70〜8,000 トークンの範囲で変わると、合計は Table 2 の右端の列のように変わる。

3 結果

3.1 全ケースと合成のケース

Table 3 に、10 通りの分け方の平均と標準偏差を示す。全ケースの評価では、Recall@20 は提案手法が 0.992、Claude Opus 5.5 が 0.932、Claude Haiku 5.5 が 0.530 であり、提案手法は Recall@20 と MAP@20 のどちらでも、10 通りの分け方すべてで両モデルを上回った。Opus 5.5 は baseline を、Recall@20 では 10 通りのうち 9 通り（差は 10 通りの平均で 0.010）、MAP@20 では 10 通りすべて（差は 0.089）で上回り、Haiku 5.5 はどちらの指標でも 10 通りすべてで下回った。合成のケースだけの評価では、Opus 5.5 は baseline を両方の指標で 10 通りすべてで上回った（Recall@20 の差は 0.058）。

3.2 ケースの種類別

Table 4 に、全ケースの評価を、ケースの種類ごとに示す。単一出典のケースは 1 つの文献の式だけから、出典横断のケースは複数の文献の式から正解集合を作ったもので、合成のケースは 2.2 節で述べたものである。1 通りの分け方のテスト用のケースは、単一出典が 10〜32 件、出典横断が 119〜200 件、合成が

Table 4: Recall@20 and MAP@20 by case type, all cases (mean ± SD over 10 splits).

	単一出典		出典横断		合成	
手法	Recall@20	MAP@20	Recall@20	MAP@20	Recall@20	MAP@20
baseline	1.000 ± 0.000	0.957 ± 0.039	0.989 ± 0.007	0.802 ± 0.024	0.870 ± 0.020	0.668 ± 0.038
提案手法	1.000 ± 0.000	0.967 ± 0.020	1.000 ± 0.000	0.944 ± 0.016	0.986 ± 0.004	0.877 ± 0.032
Claude Opus 5.5	0.964 ± 0.033	0.926 ± 0.050	0.950 ± 0.026	0.833 ± 0.053	0.916 ± 0.011	0.807 ± 0.025
Claude Haiku 5.5	0.823 ± 0.047	0.463 ± 0.054	0.429 ± 0.111	0.278 ± 0.080	0.575 ± 0.044	0.354 ± 0.036

160〜304 件である。Opus 5.5 は、単一出典のケースでは提案手法に近い値（Recall@20 0.964、MAP@20 0.926）であったが、出典横断と合成のケースでは提案手法を下回った。baseline と比べると、Opus 5.5 は合成のケースでは Recall@20 と MAP@20 の両方で上回ったが、単一出典のケースでは両方で下回り、出典横断のケースでは MAP@20 で上回って Recall@20 で下回った。Haiku 5.5 はどの種類でも baseline を下回り、出典横断のケースの Recall@20 は 0.429 であった。

3.3 回の間のばらつきと答えの形

同じケースを 3 回解かせたときの Recall@20 の回の間の標準偏差は、ケースの平均で Opus 5.5 が 0.040、Haiku 5.5 が 0.142 であった。3 回とも Recall@20 が同じ値だったケースは、Opus 5.5 が 73.2%、Haiku 5.5 が 40.6% である。3 回の答えから 2 回ずつ組を作って求めた、答えた ID の集合の Jaccard 係数（共通の ID の数を、どちらかの答えにある ID の数で割った値）の平均は、Opus 5.5 が 0.573、Haiku 5.5 が 0.324 で、3 回とも同じ並びを答えたケースは、Opus 5.5 が 0.06%、Haiku 5.5 が 2.0% であった。ケースの値は 3 回の平均とし、回数は 3 回とした。

Opus 5.5 は 5,019 回すべてで答えを返し、4,838 回（96.4%）で指示どおり 20 個の ID を答えた。データベースにない ID を含む答えが 21 回、同じ ID を重ねた答えが 75 回あった。Haiku 5.5 は、144 回（2.9%）で API の安全機能が応答を止めたため答えが得られず、この回は正解式が 1 本も入らなかったものとして数えた。20 個の ID を答えたのは 4,412 回（87.9%）で、20 個を超えて答えた回が 645 回、同じ ID を重ねた答えが 626 回あった。LLM の答えには、表記が同じ式が別の ID で 2 本以上入っていることが多く、同じ式を 1 本に詰めると、Opus 5.5 では 5,019 回のうち 3,013 回、Haiku 5.5 では 1,994 回で 20 本に足りなかった（詰めた後の本数は平均で 17.9 本と 18.5 本）。21 位以降から補えたのは、20 個を超えて答えた Opus 5.5 の 20 回と Haiku 5.5 の 236 回である。

3.4 費用

5,019 回の費用は、Claude Haiku 5.5 が 255.23 ドル、Claude Opus 5.5 が 1,058.93 ドル、合計 1,314.16 ドルであった。そのうちデータベースの読み出しの料金は、Haiku 5.5 で 93.6%、Opus 5.5 で 90.2% を占めた。Opus 5.5 の費用が見積もり（1,167.4 ドル）より少なかったのは、出力が 1 回平均 876 トークンで、見積もりの仮定（2,000 トークン）より少なかったためである。Haiku 5.5 の出力は 1 回平均 1,150 トークンで、試しからの見積もり（約 970 トークン）より多く、費用も見積もり（252.5 ドル）より 2.7 ドル多かった。

4 今後の計画

- 提案手法と LLM のそれぞれが上位 20 件に入れられなかった正解式を、ケースの種類ごとに調べ、2 つの手法の長所と短所をまとめる。

References

[1] Shota Kato and Manabu Kano. Automated physical model building from literature sources: Combining equations based on four predefined requirements. *Computers & Chemical Engineering*, 200:109147, 2025. doi:10.1016/j.compchemeng.2025.109147.

[2] Anthropic. Pricing. https://platform.claude.com/docs/en/about-claude/pricing, 2026. Accessed November 1, 2026.

Appendix A　LLM に与える指示文と入力の形

system として指示文を、user の 1 つ目のブロックとしてデータベースを、2 つ目のブロックとしてテストケースを、この順に送る。データベースのブロックの末尾にキャッシュの区切りを置くので、2 回目以降の呼び出しでは、指示文とデータベースをキャッシュから読み出す。どのモデルにも同じ指示文を使う。<TAB> はタブ文字を表す。データベースは、11,146 行のうち先頭の 1 行だけを示す。テストケースの < > の部分には、そのケースの説明文と変数記号を入れる。

```
[system]
You are an expert in physical modeling. You select equations from an equation database for building a physical model.

# Task
An engineer wants to build a physical model: a set of equations with which the output variables can be computed once the
↪  input variables are given. The engineer describes the model and lists its input variables and output variables.
↪  Choose, from the equation database, the equations that the engineer should use.

The set of equations that forms the model satisfies these conditions:
1. Every input variable and every output variable appears in at least one equation of the set.
2. The number of equations equals the number of variables of the set that are not input variables.
3. Every variable of the set that is neither an input nor an output variable appears in at least two equations of the
↪  set.

# Equation database
<equation_database> lists equations extracted from the literature, in no particular order. Each line has three fields
↪  separated by tabs: the equation ID, the domain label of the equation, and the equation in LaTeX.

# Answer
For the task in <task>, list 20 equation IDs, from the most to the least likely to belong to the model. Put first the
↪  equations that you judge to form the model. Use only IDs from the database, and list each ID once. In the task,
↪  variable symbols in a list are separated by " ; ".

[user, block 1: equation database, cached]
<equation_database count="11146">
1<TAB>Educational Psychology Time-Series Analysis<TAB>MSSD = \frac{1}{N-1} \sum_{t=2}^{N} (x_t - x_{t-1})^2
...
</equation_database>

[user, block 2: test case]
<task>
Description: <description of the model>
Input variables: <symbol> ; <symbol> ; ...
Output variables: <symbol> ; ...
</task>

List the IDs of the database equations for this task.

[output format (JSON schema)]
{"type": "object", "properties": {"equation_ids": {"type": "array", "items": {"type": "integer"}}}, "required":
↪  ["equation_ids"], "additionalProperties": false}
```