

グラフニューラルネットワークを用いた、物理モデルの自動構築。

プロセスの自然言語記述から、文献中の実在数式を検索し——

連立可能な数式群を自動で選び出す。根拠を辿れる、自動物理モデリングへの挑戦。

SPEAKER

丁 一洋

加納研究室・M2

DATASET

3,244 式

論文 2,574 + ハンドブック 670

GROUP

物理モデル自動構築

加藤先生、古荘

KEY RESULT

MAP 0.974

p = 0.004 (高度に有意)

以下の構成で進めます。

§ 1

目的

物理モデルとは何か／誰が必要とするか／現状の課題／本研究の目的

§ 3

手法

問題設定／2 段階の数式検索／グラフ構造／組合せ選択／Set-aware 特徴量

§ 5

まとめ

5 項目の再確認

§ 2

関連研究

3 流派の比較 — シンボリック回帰、大規模言語モデル、数式検索

§ 4

結果・考察

3,244 式 × 1,107 ケース／3 指標比較／統計的有意性／今後の展望

物理モデル構築の手作業を、自動化する。

物理モデルとは、保存則・反応速度論・輸送現象論といった科学原理に基づく**数式の組合せ**で、対象プロセスに関わる物理量の関係を記述したもの。

FIGURE 1.1 連続槽型反応器 (CSTR) の動特性モデル — 例

EQ 1 / 物質収支

$$dC_A/dt = (F/V)(C_{A,in} - C_A) - k(T) \cdot C_A$$

反応成分 A の濃度変化 —— 流入と流出、反応消費のバランス

EQ 2 / エネルギー収支

$$dT/dt = (F/V)(T_{in} - T) + (-\Delta H)/(\rho c_p) \cdot k(T) \cdot C_A - (UA)/(V \rho c_p)(T - T_c)$$

反応器内温度の変化 —— 流入・反応熱・冷媒への熱除去のバランス

EQ 3 / 反応速度定数

$$k(T) = A \cdot \exp(-E_a / (RT)) \quad (\text{Arrhenius 式})$$

温度依存の反応速度定数 —— 温度 T の関数として表現

§ 1.2 誰が物理モデルを必要とするか

定性的な説明では不十分で、**定量的な予測・判断が必要となる場面**で使われる。代表例：

01

プロセス設計

パイロットから実機へのスケールアップ。反応器体積・熱交換器面積・流量の決定。

02

制御系設計

プラント動特性を把握し、制御構造の選定と制御器の性能評価。

03

プロセス最適化

収率・エネルギー・環境負荷を目的関数とし、制約下で運転条件を最適化。

04

プロセス安全

異常運転・外乱を事前にシミュレーション。暴走反応の回避などに使われる。

CONTEXT

既存プロセスなら **プロセスシミュレータ** (Aspen / gPROMS / Simulink) で事足りる。しかし **新規プロセス／複数分野の連成／文献ベースの再現** では、内蔵モデルでは対応できない。

§ 1.3 現状の課題

シミュレータで対応できない場面では、教科書や論文を調査し、必要な式を選別・連立する作業を **人手で** 行う。

所要時間

数日 ～ 数週間

対象の複雑さと熟練度に依存。熟練者の経験頼みで、再現性に課題。

中間作業

文献調査 → 式の同定 → 連立

「読んで整理して書き出す」まで、一つ一つが手作業。

結果

効率と再現性のボトルネック

同じ条件でも、担当する人によって得られる数式群が変わる。

§ 1.4 本研究の目的

GOAL

プロセスの自然言語記述と求めたい変数の情報から、文献中の実在数式データベースを検索し、連立可能な数式群を自動選択する手法を確立する。

要件 1

ハルシネーションの排除

出力される数式は全て実在し、出典(文献・ページ・式番号)を辿れる。

要件 2

自由度的に解ける数式群

選ばれた式群を連立したときに、**未知数の数と独立な式の数**が一致する(自由度ゼロ)ことを保証。

物理モデル自動構築の、3つの流派。

この問題は世界中で研究が進んでいます。大きく3つの流派に整理できます。

流派 A

SR

シンボリック 回帰

入出力データ $\{(x_i, y_i)\}$ から、 $y \approx f(x)$ となる数式 f を探索する（遺伝的プログラミング、AI Feynman 等）。

- 未知の関係式を発見できる可能性
- 実験データが前提 → 設計・新規プロセスでは利用困難
- 既知の物理法則を明示的に取り込みにくい
- 得られた式が工学的に意味ある形になる保証がない

具体例: AI Feynman は 1 公式あたり **10^5 点** の入出力ペアが必要。例: $F = G m_1 m_2 / r^2$ の再発見に **10 万組**。

流派 B

LLM

大規模言語 モデル直接生成

GPT-4 / Claude 等に自然言語でプロセス記述を与え、数式を直接生成させる（ChemCrow, Ramos ら 2024）。

- 自然言語で指示でき、応答は数秒～数十秒
- ハルシネーション（対 数式検索）: 存在しない式や定数を捏造
- 根拠追跡困難（対 数式検索）: 出典を辿れない
- 組合せ整合性が不安定: 自由度が合わない系を出力する場合がある

数式データ → SNS → グラフ → グラフニューラルネットワーク

流派 C を GNN 的アプローチで解くことに至った**着想の流れ**をお話しします。数式は一つ一つが独立した個体として存在する一方で、互いに**変数共有・共起・入出力連鎖**といった関係で繋がっている。このような「個体 + 関係」で構成されるデータを眺めたときに最初に想起されたのが——**SNS**でした。

STEP 01

SNS の友人関係




A と C も友達では？

A さんと C さんに直接の接点がなくとも、**共通の友人 B** がいれば関係を推測できる。

STEP 02


数式ネットワーク(= グラフ)



ノード = 数式、エッジ = 共通変数。共通変数 \$T\$ を介して**2 ホップ先の関係**から推測できる。

STEP 03

グラフニューラルネットワーク



グラフ上でノードの特徴量と関係性を**同時に扱う**学習手法。本研究の道具として自然な選択。

FIGURE 2.1 SNS と数式ネットワークの対応

SNS	=	数式ネットワーク
人物	=	数式
友人関係	=	共通変数で結ばれる関係
$A \leftrightarrow B \leftrightarrow C$	=	式 e_1 — 変数 T — 式 e_2 (両方が T を含む)

図 2.1: SNS は要するにグラフ (ノード = 人物、エッジ = 友人)。グラフ上でノード属性と関係を同時に扱う代表手法が **グラフニューラルネットワーク**。

文献からの数式検索 + グラフニューラルネットワーク

教科書・論文から抽出した**実在する数式のデータベース**を、数式ネットワーク上の**グラフニューラルネットワーク**で検索する。「生成」ではなく「検索と選択」。

- 全て実在 → ハルシネーションが原理的に起こらない
 - 正解を**式 ID 集合**として定義 → 自動評価が明快
- 出典追跡可能 (書名・論文・式番号)
 - 自由度条件を明示的に検査できる

課題: データベース収録式に限定 (新規式は発見できない)。シンボリック回帰と相補関係。

シンボリック回帰は **データが要る**。大規模言語モデル直接生成は **ハルシネーション・根拠・整合性** の問題。本研究は **数式検索(流派 C) + GNN 的アプローチ**で両者の欠点を回避する。

入力 → 2 段階の検索 → 数式群。

§ 3.1 問題設定

入力

プロセス記述 + 変数集合

- 自然言語でのプロセス記述
- 既知変数 V_{in} (入力として与える物理量の記号)
- 求めたい変数 V_{out} (出力として解きたい物理量)

出力

連立可能な数式の集合

V_{in} と連立して V_{out} を解けるような、データベース内の数式の集合。

§ 3.2 基本戦略 — 2 段階の数式検索

データベースには数千の式が収録されており、全ての式を精密評価するのは計算量の観点で非現実的。情報検索で標準的な **2 段階アーキテクチャ** を採用する。

Input

クエリ

プロセス記述 + 入出力変数集合

自然言語

Stage 1 / 0(N)

大域的絞り込み

TF-IDF 文脈類似度 + Jaccard 変数一致度で、上位 $K = 50$ 件を選抜

3,244 → 50

$\alpha = 0.7$

Recall@50 99%+

精密評価 — 研究の中心

10 次元特徴ベクトル → 多層パーセプトロン → スコアで並べ替え。**ここにグラフ構造の情報を組み込む。**

MLP 64 × 2

Dropout 0.1

Output

ランキング

スコア降順で並び替えた数式ランキング

式 ID 集合

FIGURE 3.2 Stage 1 のスコア — 2 つの古典的な統計量の線形結合

EQ
$$S_{\text{Stage1}}(q, e) = \alpha \cdot \text{sim}_{\text{text}}(q, e) + (1 - \alpha) \cdot \text{sim}_{\text{var}}(q, e) \quad \alpha = 0.7$$

TF-IDF

文脈類似度

文書ベクトル同士のコサイン類似度。「ある文書に何度も現れるが、他にはあまり現れない語」が大きな重みを持つ。

JACCARD

変数一致度


クエリの入出力変数集合 V_q と式の変数集合 V_e の記号レベルの重なり: $|V_q \cap V_e| / |V_q \cup V_e|$

図 3.2: 大規模言語モデルは使わず、決定論的な古典手法で高速に絞り込む。 $\alpha = 0.7$ は検証データ上のグリッドサーチで決定。

§ 3.3 グラフ構造とモデルの入出力

なぜグラフか。 数式データには、単独のテキストでは捉えきれない「式と式の関係性」が豊富にある。3 つの作業仮説 —— 変数共有 / 共起 / 入出力連鎖。

FIGURE 3.3 式 × 変数の二部グラフ(サンプル)



二部グラフの構成

ノード: 式 3,244 個 + 変数 ≈3,700 個 (同一記号は同一ノード)
エッジ: 式 e が変数 v を含むとき $e-v$ に無向エッジ
特徴ベクトル: 式は CodeBERT 768 次元、変数は含む式の平均

WORKING HYPOTHESES

- ①**変数共有**: 同じ変数を持つ式は連立されやすい
- ②**共起**: 同じ文献で共起する式は連立されやすい
- ③**入出力連鎖**: ある式の出力が別式の入力になる

図 3.3: 本研究は「変数共有」という最も基本的な関係に着目し、式 × 変数の二部グラフを採用。上記は作業仮説であり、実験で検証すべき対象 (§ 4)。

FIGURE 3.4 Stage 2 リランカー — 多層パーセプトロン(MLP) 本体

INPUT $\varphi(q, c) = [\varphi_1, \varphi_2, \dots, \varphi_{10}]^\top \in \mathbb{R}^{10}$

LAYER 1 $h_1 = \text{ReLU}(W_1 \varphi + b_1) \in \mathbb{R}^{64}$

LAYER 2 $h_2 = \text{ReLU}(W_2 h_1 + b_2) \in \mathbb{R}^{64}$

SCORE $s(q, c) = w_3^\top h_2 + b_3 \in \mathbb{R}$

ドロップアウト $p=0.1$ を訓練時のみ適用 —— 64 次元のうち平均 6〜7 個が 0 になり、残りが $1/0.9 \approx 1.11$ 倍に拡大。モデルが特定ユニットに過度に依存するのを防ぐ(実質的なアンサンブル効果)。

READ THE EQUATIONS

10 次元の特徴ベクトル $\varphi(q, c)$ を入力として、**2 層の隠れ層** (それぞれ 64 次元、ReLU 活性化) を経て、最終的にスカラスコア $s(q, c)$ を出力する多層パーセプトロンである。

FIGURE 3.5 10 次元特徴ベクトルの内訳 — 基本 7 + Set-aware 3

#	特 徴 量	意 味
ψ_1	TF-IDF 余弦類似度	クエリ文脈と式テキストのテキスト類似度
ψ_2	変数集合の Jaccard 係数	クエリ I/O 変数と式の変数の記号一致率
ψ_3	SVD 空間の余弦類似度	TF-IDF を 256 次元 SVD に圧縮した意味類似度
ψ_4	入力変数カバー率	クエリ入力変数のうち式に含まれる割合
ψ_5	出力変数カバー率	クエリ出力変数のうち式に含まれる割合
ψ_6	逆カバー率	式の全変数のうち、クエリ I/O に含まれる割合
ψ_7	ドメイン一致	式のドメインがクエリ文脈と一致するか
ψ_8 ★	補完性 (Comp)	候補が参照集合 S_{ref} ではまだカバーされないクエリ変数をどれだけ補うか
ψ_9 ★	一貫性 (Coh)	候補の変数が S_{ref} とどれだけ共有されているか
ψ_{10} ★	ドメイン整合性 (Dom)	候補のドメインが S_{ref} のドメインと一致する割合

図 3.5: ★ の 3 特徴量 (Set-aware) が候補同士の組合せを評価する仕掛け。ここが本研究の貢献の中心。

§ 3.4 単発選択から組合せ選択へ

本研究の正解集合は **1 式とは限らない**。訓練ケースの約 44% は正解が 2 式以上。
候補 1 件ずつ独立にスコアする「単発選択」では、次のような失敗が起こる：

ケース 1

変数がかぶって全出力を解けない

候補 A と B が両方高スコアだが、同じ変数しかカバーしておらず、連立してもクエリの全出力変数が解けない。

ケース 2


ドメインがかみ合わない

候補 A はドメイン X、候補 B はドメイン Y。両者が組み合わせられて使われた先例が文献上ない。

§ 3.5 Set-aware 特徴量の定義

Stage 1 スコアで上位 $K' = 5$ 件を参照集合 S_{ref} とし、各候補 c について 3 特徴量を計算。

FIGURE 3.6 Set-aware — 参照集合 S_{ref} との整合性を評価



① 補完性 (Comp)

$| (V_{\text{query}} \cap V_c) \setminus V_{S_{\text{ref}}} | \setminus \wedge, | V_{\text{query}} |$
 S_{ref} で未カバーなクエリ変数を c がどれだけ補うか

② 一貫性 (Coh)

$| V_c \cap V_{S_{\text{ref}}} | \setminus \wedge, | V_c |$
 c の変数のうち S_{ref} と共有する割合

③ ドメイン整合性 (Dom)

$| \{ s \in S_{\text{ref}} : \text{dom}(s) = \text{dom}(c) \} | \setminus \wedge, | S_{\text{ref}} |$
 S_{ref} のうち c と同ドメインに属する割合

図 3.6: 候補 c を単独では見ず、参照集合との関係で評価する。これが「組合せの整合性」を扱う仕掛け。

Stage 1 (TF-IDF + Jaccard) で **3,244 → 50 件**、Stage 2 (MLP + 10 特徴量) で精密ランキング。うち **3 特徴量 ($\varphi_8, \varphi_9, \varphi_{10}$) が Set-aware** で、組合せの整合性を評価する。

Set-aware が、複数式の組合せで有意な差を生んだ。

§ 4.1 データセット

3,244

総式数

論文 2,574 + ハンドブック 670

813

細粒度ドメイン

CSTR / 熱交換 / 反応動力学 ...

1,107

訓練ケース

4 バリエントで拡張

60 / 20 / 20


train / val / test

文献単位 (source_id) で分割

なぜ文献単位の分割？

ケース単位のランダム分割では、同じ文献由来のケース (同じ正解式、類似した文脈) が訓練とテストの両方に入り、**データリーク**が起きる。文献単位なら、テストは**訓練で一度も見えていない source** に対する性能となる。

FIGURE 4.1 1,107 訓練ケースの内訳



- **original 93**: 大規模言語モデル (Gemini 2.5 Pro) が種ケースを生成
- **paraphrased 279**: 前置き文を 3 通りに言い換え (決定論的)
- **random_io 733**: 入出力を再割当 + 自由度解析通過のみ (決定論的)
- **swap_io 2**: 入出力入れ替え (自由度解析通過のみ)

正解式数の分布: 1 式 56.1% / 2 式 36.4% / 3 式以上 7.5%
→ **約 44% が複数式正解** → Set-aware の動機

図 4.1: 大規模言語モデルは「種ケース」生成という言語モデルでしか書けない部分に限定。派生は全て決定論的プログラムで展開。

FIGURE 4.2 3つの評価指標の違い

指標	値域	意味
MRR_first	$[1/N, 1]$	最初の正解式の順位の逆数平均。「最初の 1 つが何位か」だけを見る。
FullRecall@K	$[0, 1]$	上位 K 件に 全ての正解式 が含まれるケースの割合。複数式正解を重視。
MAP	$[0, 1]$	全正解が前方にまとまっているほど高い 。情報検索の標準指標。

EXAMPLE

正解が 3 式 ($R_q = \{a, b, c\}$)、ランキング $[a, x, b, y, c, \dots]$ (1位, 3位, 5位 が正解)
 $AP = (\frac{1}{1} + 0.67 + 0.60) / 3 \approx 0.756$
全正解が 1〜3 位なら $AP = 1$ (前方にまとまるほど高い)

FIGURE 4.3 3 手法 × 3 指標 の比較

手法	MRR_FIRST	FULLRECALL@3	MAP
ベースライン (Stage 1 のみ)	0.937	0.826	0.936
リランカー (基本 7 次元)	0.959	0.881	0.953
★ リランカー + Set-aware (10 次元)	0.980	0.904	0.974

図 4.3: ランダムシード 10 通りの平均値。10 次元 (Set-aware 込み) が全指標で最良。

MRR_first = 0.980

最初の正解式は平均で順位 ≈ 1.02 位。**ほぼ常に 1 位**に出てる。

FullRecall@3 = 0.904

約 **90%** のケースで上位 3 件に全正解が揃う。

MAP = 0.974

全正解が**前方にほぼ隙間なく詰まっている**。

統計的有意性 — 対応あり \$t\$-検定

観察された差が**偶然のばらつきか、手法の改善か**を対応あり \$t\$-検定で判定。\$p\$ 値は「実際には差がなかったとしたら、観察された以上の差が偶然生じる確率」。慣例として \$p < 0.05\$ で有意、\$p < 0.01\$ で高度に有意。

MAP

t = 3.46

p = 0.004

複数式 FullRecall@3

t = 2.12

p = 0.032

複数式 MRR_worst

t = 2.28

p = 0.024

MRR_first(全体)

t = 1.28

p = 0.231

グラフ構造の真価は、単一対象のスコアリングではなく、
対象集合の整合性評価で発揮される。

単発評価 (MRR_first) では差が出ない (\$p = 0.231\$)。しかし複数式の組合せ評価 (FullRecall@3・MRR_worst) では \$+6.5\%, +5.5\%\$ の改善が統計的に有意。

§ 4.5 今後の展望

DIRECTION A

変数レベルの意味類似度

現状は記号完全一致のみ (\$c_p\$ vs \$C_p\$ は別扱い)。変数マッチングを意味ベースに拡張し、表記揺れを吸収する。

DIRECTION B

データ拡大(2 方向)

- ① 単一ドメイン内の網羅性強化
- ② 新規分野(バイオプロセス、半導体) への拡張。分けて検討する。

DIRECTION C

実プロセス応用

実際のプロセス設計・制御設計業務に本手法を適用し、実用性と限界を評価する。

本日のお話、5 項目で振り返り。

01 / 目的

自動化

物理モデル構築の手作業を自動化し、設計・制御・最適化・安全解析の基盤を提供する。

02 / 関連研究

3 流派

シンボリック回帰 (データ依存) / 大規模言語モデル (ハルシネーション) / **数式検索 (実在式)**。

03 / 手法

2 段階検索

式 3,244 × 変数 3,700 の二部グラフ上で、Stage 1 → Stage 2。**Set-aware 特徴量**を組み込む。

04 / 結果

有意な改善

複数式の組合せ評価 (FullRecall@3, MAP) で Set-aware が統計的に有意 —— **$p = 0.004$** – **0.032** 。

05 / 展望

3 方向

意味類似度導入 / データ拡大 (単一ドメイン強化 + 新分野) / 実プロセス応用。