

目次

研究紹介発表原稿	2
【ページ 1】 タイトルスライド	3
【ページ 2】 §0 話の流れ	4
【ページ 3】 §1.1 物理モデルとは何か	5
【ページ 4】 §1.2 誰が物理モデルを必要とするか／ §1.3 現状の課題	7
【ページ 5】 §1.4 本研究の目的	9
【ページ 6】 §2 関連研究 — 流派 A と流派 B	10
【ページ 7】 着想の流れ — SNS から始まる	12
【ページ 8】 SNS → グラフ → GNN	14
【ページ 9】 SNS と数式ネットワークの対応・流派 C の位置づけ	15
【ページ 10】 §2 セクション要約	16
【ページ 11】 §3.1 問題設定／ §3.2 2 段階の数式検索	17
【ページ 12】 Stage 1 スコアの式／ Stage 2 の位置づけ	19
【ページ 13】 §3.3 グラフ構造	21
【ページ 14】 3 つの作業仮説	22
【ページ 15】 Stage 2 リランカーの中身 (MLP)	23
【ページ 16】 10 次元特徴ベクトルの内訳	25

【ページ 17】 §3.4 単発選択から組合せ選択へ／ §3.5 Set-aware の導入	26
【ページ 18】 Set-aware 3 特徴量の定義	28
【ページ 19】 §3 セクション要約	29
【ページ 20】 §4.1 データセット — 規模と分割	30
【ページ 21】 1,107 ケースの内訳	31
【ページ 22】 §4.2 評価指標	33
【ページ 23】 §4.3 主要な結果	34
【ページ 24】 統計的有意性の詳細／主結論	36
【ページ 25】 §4.5 今後の展望	37
【ページ 26】 §5 まとめ	39
発表のコツ（読み上げ前のチェック）	40

研究紹介発表原稿

対応スライド：docs/研究紹介 ppt.pdf（全 26 ページ）発表

者：丁 一洋（加納研究室 M2）想定時間：約 18～20 分使い

方：スライドをめくりながら、このまま読み上げてください。

ページごとに区切っております。[] は話し方のメモで読み上

げません。

【ページ 1】 タイトルスライド

皆さん、こんにちは。加納研究室 M2 の丁一洋です。本日は「グラフニューラルネットワークを用いた、物理モデルの自動構築」というテーマで研究紹介をさせていただきます。

一言で何をしているかと言うと、**プロセスの自然言語記述から、文献中の実在する数式を検索して、連立可能な数式群を自動で選び出す**、という研究です。ハルシネーション、つまり存在しない式を捏造する問題を原理的に避けつつ、選ばれた式は全て出典を辿れる——そういう自動物理モデリングを目指しています。

グループは、加藤先生、古荘さんとご一緒させていただいている「物理モデル自動構築」グループです。現在データベースには **3,244 式**、最もよく機能する指標で **MAP が 0.974**、

p 値は 0.004 で高度に有意、という結果が得られています。

では、始めさせていただきます。

【ページ 2】 §0 話の流れ

まず本日の話の流れです。研究発表の標準的な構成、「**目的** → **関連研究** → **手法** → **結果と考察** → **まとめ**」の順で進めます。

1 つ目の「**目的**」では、物理モデルとは何か、誰が必要としているか、そして現状の課題は何かをお話しします。2 つ目の「**関連研究**」では、この問題が世界でどう解かれているか、3 つの流派に整理してご紹介します。3 つ目の「**手法**」が本研究の本体です。問題設定から 2 段階の数式検索、グラフ構造、Set-aware 特徴量まで順に追います。4 つ目の「**結果と考察**」

では、3,244 式 $\times$ 1,107 ケースの実験設定、3 つの指標での比較、統計的有意性を扱います。最後に 5 項目で全体をまとめます。

【ページ 3】 §1.1 物理モデルとは何か

では §1、目的から入ります。

まず「物理モデル」という言葉を定義しておきます。本研究で物理モデルと呼ぶのは、**保存則・反応速度論・輸送現象論**といった科学原理に基づく数式の組合せで、対象プロセスに関わる物理量の関係を記述したものです。

具体例として、**連続槽型反応器、CSTR の動特性モデル**を見てください。3 つの式で構成されています。

1 つ目は **物質収支**。反応成分 A の濃度 C_A の時間変化を、流

入と流出、それから反応消費のバランスで表しています。2 目は **エネルギー収支**。反応器内温度 T の時間変化で、流入・反応熱・冷媒への熱除去のバランスです。3 目は Arrhenius 式で、温度依存の **反応速度定数** $k(T)$ を指数関数で表現しています。

こうした式の組合せが、本研究で対象とする「物理モデル」です。「入力から出力を計算する関数」という狭い定義ではなく、**変数間の関係式の集合**、という広い捉え方をしている点がポイントです。どの変数を入力にしてどれを出力にするかは、使う文脈によって変わります。

【ページ 4】 §1.2 誰が物理モデルを必要とするか／

§1.3 現状の課題

では、こういった物理モデルを **誰が必要としている** のでしょうか。

定性的な説明、たとえば「温度を高めにして十分に反応させる」では不十分で、**定量的な予測や判断が必要な場面**で使われます。代表例を 4 つ挙げています。

プロセス設計では、パイロット装置から実機へのスケールアップで、反応器体積や流量を決めるのに使います。**制御系設計**では、プラントの動特性を把握した上で、制御構造を選び、制御器を設計します。**プロセス最適化**では、収率・エネルギー・環境負荷を目的関数として、運転条件を最適化します。**プロセス安全**では、異常運転や外乱を事前にシミュレー

ションして、暴走反応などを回避します。

つまり、実際にモデルを必要としているのは、工場のオーナーではなくエンジニア・研究者です。

ここで補足すると、既存プロセスで標準的なユニット操作であれば、Aspen Plus や gPROMS のような プロセスシミュレータに内蔵されたモデルを使えば済みます。問題は、新規プロセス、複数分野の連成、文献ベースの再現という場面では内蔵モデルでは対応できない、という点です。

下の §1.3 を見てください。シミュレータで対応できない場面では、教科書や論文を調査して、必要な式を選別・連立する作業を人手で行うことになります。所要時間は数日から数週間のオーダー、対象の複雑さと熟練度に依存します。ここが本研究が解決したい課題です。

【ページ 5】 §1.4 本研究の目的

手作業部分をもう少し分解しますと、「文献調査 → 式の同定 → 連立」という流れで、読んで整理して書き出すまでの一つ一つが手作業です。結果として、同じ条件でも担当者によって得られる数式群が変わるという、効率と再現性のボトルネックが生じています。

そこで本研究の目的です。

プロセスの自然言語記述と求めたい変数の情報から、文献中の実在数式データベースを検索し、連立可能な数式群を自動選択する手法を確立する。

重視する要件は 2 点あります。

要件 1 はハルシネーションの排除です。出力される数式は全て実在していて、文献・ページ・式番号まで出典を辿れる

こと。

要件 2 は自由度的に解ける数式群であること。選ばれた式群を連立したときに、未知数の数と独立な式の数が一致する、つまり自由度がゼロであることを保証します。これを満たさないと、未知数が過剰で解が一意にならなかったり、逆に式が過剰で解が存在しなかったりします。

【ページ 6】 §2 関連研究 — 流派 A と流派 B

続いて関連研究に移ります。

この問題、実は世界中で研究されていまして、大きく **3 つの流派**に整理できます。順に見ていきます。

流派 A、シンボリック回帰。これは入出力データの数値ペアから、 $y \approx f(x)$ となる数式 f を探索する手法です。遺伝的

プログラミングや、AI Feynman という手法が代表例です。

長所は **未知の関係式を発見できる可能性がある**こと。ただし短所として、**実験データが前提**なので設計段階や新規プロセスでは使えません。また、得られた式が工学的に意味のある形、たとえば保存則の形とか、無次元化された形に必ずしも収束するとは限りません。

データ量の感覚を持っていただくために具体例を挙げますと、AI Feynman は 1 公式あたり 10^5 点、**10 万組の入出力ペア**を使っています。たとえば万有引力則 $F = Gm_1m_2/r^2$ を再発見するのに、 (m_1, m_2, r, F) の組を 10 万組生成して探索する。このデータ量は実験室で人手では到底集まらず、大規模シミュレーションが前提になります。

流派 B、大規模言語モデルによる直接生成。GPT-4 や Claude にプロセス記述を自然言語で与え、**数式を直接書かせる**手法です。ChemCrow や Ramos らの研究が代表例です。

長所は 自然言語で指示でき、応答は数秒～数十秒と速いこと。しかし短所は複数あります。比較対象を明記していますが、まずハルシネーション。存在しない式や定数を捏造してしまい、モデル自身はその正誤を判定できません。次に**根拠追跡の困難**。生成された式が文献のどこに対応するか辿れません。そして**組合せ整合性の不安定性**。自由度が合わない、つまり解けない式の集合を出力することがあります。

【ページ 7】 着想の流れ — SNS から始まる

ここから 流派 C、本研究の位置づけに入りますが、少し遠回りして、どうして私がグラフニューラルネットワーク的アプローチに至ったか、その着想の流れをお話しさせてください。

研究を始めたとき、数式データをまず眺めたんですね。すると気づいたのは、**数式は一つ一つが独立した個体として存在**

する一方で、互いに関係で繋がっているということです。関係というのは、変数を共有していたり、同じ文献に共起していたり、ある式の出力が別の式の入力になっていたり。

この「個体 + 関係」という構造のデータを眺めたときに、**真っ先に頭に浮かんだのが SNS** でした。

図の STEP 01 を見てください。SNS の友人関係でよく言われる話です。AさんとCさんに直接の接点がなくとも、共通の友人Bがいれば、AとCも関係あるのでは、と推測できる。この間接的な関係を辿る発想は、数式データでも同じように使えるのではないかと直感しました。

【ページ 8】 SNS → グラフ → GNN

STEP 02 を見てください。SNS のアナロジーを数式に適用したものです。

ノードを数式、エッジを共通変数と考えます。式 e_1 と e_2 に直接の繋がりがなくても、**共通の変数 T** が両方に含まれていれば、 $e_1 \leftrightarrow T \leftrightarrow e_2$ という **2 ホップ先の関係** で繋がります。ここから「式 e_1 と e_2 も連立される可能性がある」と推測できる、というわけです。

STEP 03。ここまで来ると推論は自然に繋がります。SNS は要するに**グラフ**です。ノードとエッジの構造です。そして、**グラフ上でノードの特徴量と関係性を同時に扱う代表的な学習手法**と言えば、**グラフニューラルネットワーク（GNN）**です。これが本研究の道具として自然な選択になりました。

【ページ 9】 SNS と数式ネットワークの対応・流派 C の位置づけ

上の図 2.1 に、SNS と数式ネットワークの対応関係をまとめてあります。

- 人物 = 数式
- 友人関係 = 共通変数で結ばれる関係
- $A \leftrightarrow B \leftrightarrow C = \text{式 } e_1 - \text{変数 } T - \text{式 } e_2$

ここから本研究の立ち位置に戻ります。

流派 C、文献からの数式検索。教科書や論文から抽出した**実在する数式のデータベース**を構築し、そこから条件に合う式群を**選び出す**手法です。「生成」ではなく「検索と選択」として問題を定式化する、という点がポイントです。

長所は 4 つ挙げています。全て実在するのでハルシネーションが原理的に起こらない。出典を辿れる。正解を式 ID の集合として定義できるため自動評価が明快。そして自由度条件を明示的に検査できる。

課題は、データベース収録式に限定されるので、全く新しい式は発見できないこと。この点でシンボリック回帰とは相補関係にあります。既存式の組立てたい場合は数式検索、既存式で説明できない現象はシンボリック回帰、と使い分けることになります。

【ページ 10】 §2 セクション要約

関連研究のまとめです。

シンボリック回帰はデータが要る。設計段階では使えない。

大規模言語モデル直接生成はハルシネーション・根拠追跡・
組合せ整合性の問題を抱えている。これに対して 本研究は、
数式検索（流派 C）+ GNN 的アプローチで両者の欠点を
回避する。これが本研究の位置づけです。

【ページ 11】 §3.1 問題設定／ §3.2 2 段階の数式 検索

では §3、手法に入ります。

§3.1 問題設定。 入力は 3 つ。(1) プロセスの自然言語記述、
(2) 既知変数の集合 V_{in} 、(3) 求めたい変数の集合 V_{out} 。出力
は V_{in} と連立して V_{out} を解けるような、データベース内の
数式の集合 です。

イメージを掴むため、できるだけシンプルな具体例で説明し

ます。水タンクの液位変化 を求める問題です。

(1) 自然言語でのプロセス記述：「タンクに水が流入し、同時に流出している。タンクの液位の時間変化を求めたい。」

(2) 既知変数 V_{in} ：流入量 F_{in} 、流出量 F_{out} 、タンクの断面積 A の 3 つ。

(3) 求めたい変数 V_{out} ：液位 h 、1 つだけ。

この入力に対して、本手法は $A \cdot dh/dt = F_{in} - F_{out}$ という 1 本の物質収支式をデータベースから引き当てることが期待されます。1 式・未知数 1 個で自由度ゼロ。

この「(1) (2) (3) を与えれば、データベースから正解の式群を自動で選び出す」という枠組みは、§1.1 でお見せした CSTR のような、複数の式を連立する複雑な系にもそのまま適用されます。

§3.2 基本戦略、2 段階の数式検索。

データベースには数千の式が収録されています。全ての式を精密評価するのは計算量の観点で非現実的なので、情報検索で標準的な **2 段階アーキテクチャ** を採用します。

Stage 1 は大域的な絞り込み。計算量 $O(N)$ 、3,244 件を 50 件まで絞ります。使うのは **TF - IDF** による**文脈類似度** と **Jaccard** による**変数一致度** の線形結合。重み $\alpha = 0.7$ です。ポイントは、この Stage 1 だけでも **Recall@50 が 99% 以上**、つまり正解がほぼ必ず上位 50 件に入ります。Stage 2 の前段として十分に機能する水準です。

【ページ 12】 Stage 1 スコアの式／ Stage 2 の位置づけ

図 3.2 に Stage 1 のスコアの式を書いています。

$$S_{\text{Stage1}}(q, e) = \alpha \cdot \text{sim}_{\text{text}}(q, e) + (1 - \alpha) \cdot \text{sim}_{\text{var}}(q, e), \quad \alpha = 0$$

TF - IDF 文脈類似度は、クエリのプロセス記述と、式の周辺説明文をベクトル化して、コサイン類似度を取ります。「ある文書に何度も出て、他の文書にはあまり出ない語」が大きな重みを持つ、という古典的な仕組みです。ここでは大規模言語モデルは一切使わず、決定論的な古典手法を採用しています。

Jaccard 変数一致度 は、クエリの入出力変数集合と、式の変数集合の記号レベルの重なり、共通集合を和集合で割った値です。

$\alpha = 0.7$ は検証データ上のグリッドサーチで決定しました。

そして ★ **Stage 2** が、研究の中心 です。計算量は $O(K)$ 、

$K = 50$ 件を精密評価して並べ替えます。具体的には 10 次元の特徴ベクトルを多層パーセプトロンに入力してスコアを出し、そのスコア順に並べ替える。ここにグラフ構造の情報を組み込むのが、本研究の貢献です。

【ページ 13】 §3.3 グラフ構造

図 3.3、式と変数の二部グラフ を見てください。

ノードは 2 種類です。式ノードが 3,244 個、変数ノードが約 3,700 個。同じ記号は同一ノードとして扱います。

エッジは、式 e が変数 v を含むとき、 $e - v$ を繋ぐ無向エッジを張ります。それだけ。シンプルな二部グラフです。

ノードの特徴ベクトルは、式ノードは CodeBERT による 768 次元の埋め込み、変数ノードは、その変数を含む全ての

式ノード特徴の平均としています。

【ページ 14】 3 つの作業仮説

「そもそもなぜグラフ構造を使うのか」ですが、作業仮説を 3 つ挙げています。

1 つ目、**変数共有**：同じ変数を持つ式は連立されやすい。2 つ目、**共起**：同じ文献で共起する式は連立されやすい。3 つ目、**入出力連鎖**：ある式の出力が別式の入力になる関係。

これらはいくまで **作業仮説**であって、実験で検証すべき対象です。実際、初期研究では本格的なグラフニューラルネットワーク、具体的には GCN や GAT も試しましたが、**単体**ではベースラインを超えられませんでした。そのため現在は「グラフ特徴量 + 多層パーセプトロン」の形に落ち着いてい

ます。ここは §4 の結果で改めて検証します。

【ページ 15】 Stage 2 リランカーの中身 (MLP)

図 3.4。Stage 2 リランカー、つまり **多層パーセプトロン本体**の構成です。

入力は **10 次元の特徴ベクトル** $\phi(q, c)$ 。クエリ q と候補式 c から計算します。第 1 層で ReLU 活性化を経て **64 次元**の隠れベクトル $\mathbf{h}_1$ に。第 2 層でもう一度 ReLU を通して **64 次元**の $\mathbf{h}_2$ に。最後に線形写像で**スカラースコア** $s(q, c)$ を出力します。

ドロップアウトについて説明します。これは過学習を防ぐための、ニューラルネットワークではよく使われる仕掛けです。

イメージは「**10 人のチームで毎日ランダムに 1 人が休む**」

ルールです。そうすると、どの 1 人にも仕事を集中させられなくなり、メンバー全員が互いの仕事のある程度代替できるよう学習します。結果、誰か一人の調子が悪くてもプロジェクトが回る、頑健なチームになる。

ニューラルネットワークでも同じです。訓練中、隠れ層の 64 次元ベクトルの各要素を、**確率 10% で独立に 0 に置き換**えます。平均すると毎回 6~7 個のユニットが使われない状態で学習が進む。

置き換えなかった要素は $1/0.9 \approx 1.11$ 倍に拡大します。これは「10% が抜けた分の合計値を埋め合わせる」という**期待値保存** の操作です。

この効果は **2 つ** あります。1 つ目は、**特定のユニットへの過度な依存を防ぐ**。どのユニットもいつ休まされるかわからないので、情報が複数のユニットに冗長に分散されます。2 つ目は、**毎回異なる部分ネットワークで予測することになるの**

で、結果的に大量のサブネットワークの平均を学習していることになる。これを**実質的なアンサンブル効果**と呼びます。

評価時はマスクを外して全ユニットを使い、決定論的に推論します。本研究では訓練データが約 1,100 ケースと比較的少ないので、過学習抑制の観点からドロップアウトが重要な役割を果たします。

【ページ 16】10 次元特徴ベクトルの内訳

図 3.5。10 次元特徴ベクトルの **内訳** です。

基本 7 次元 は候補 1 件と、クエリ 1 件の関係だけから計算される特徴量です。- ϕ_1 は TF-IDF 余弦類似度、 ϕ_2 は Jaccard 変数一致度、 ϕ_3 は SVD 空間の余弦類似度。- ϕ_4, ϕ_5 は入力変数・出力変数のカバー率。- ϕ_6 は逆カバー率、 ϕ_7

はドメイン一致フラグ。

ここまでは単発の特徴量です。

★ 印の $\phi_8, \phi_9, \phi_{10}$ が Set-aware 特徴量で、候補同士の組合せを評価する仕掛けです。 ϕ_8 が補完性、 ϕ_9 が一貫性、 ϕ_{10} がドメイン整合性。ここが本研究の貢献の中心です。次のスライドで詳しく説明します。

【ページ 17】 §3.4 単発選択から組合せ選択へ／

§3.5 Set-aware の導入

§3.4. 単発選択から組合せ選択へ。

本研究の正解集合は 1 式とは限りません。訓練ケースの 約 44% は正解が 2 式以上 です。

候補 1 件ずつ独立にスコアする「単発選択」だと、次のような失敗が起こります。

ケース 1： 候補 A と B が両方高スコアだけれど、**同じ変数しかカバーしていなくて**、連立してもクエリの全出力変数が解けない。

ケース 2： 候補 A はドメイン X、B はドメイン Y。両者が**組み合わせあって使われた先例が文献上ない**。

こういう失敗を避けるには、候補を単独ではなく、**他の候補との組合せの中で評価する必要があります**。それが §3.5 **Set-aware 特徴量** です。

具体的には、Stage 1 スコアで **上位 $K' = 5$ 件を参照集合 S_{ref} とし**、各候補 c についてこの参照集合との関係を 3 つの特徴量で計算します。

【ページ 18】 Set-aware 3 特徴量の定義

図 3.6。Set-aware 3 特徴量の詳細です。

① **補完性 (Complementarity)** : 候補 c が、参照集合 S_{ref} ではまだカバーされていないクエリ変数をどれだけ補うか。

図の「未カバー」部分を補う割合、と直感的には捉えてください。式で書くと、クエリ変数と候補変数の共通集合から、参照集合の変数を差し引いたものを、クエリ変数のサイズで割る。

② **一貫性 (Coherence)** : 候補 c の変数のうち、参照集合と共有する割合。参照集合と「話が噛み合っているか」を測ります。

③ **ドメイン整合性 (Domain Consistency)** : 参照集合の式のうち、 c と同じドメインに属する割合。ドメイン的に浮

いていないかを見ます。

図 3.6 右下のまとめにある通り、候補 c を単独で見ず、参照集合との関係で評価する。これが「組合せの整合性」を扱う仕掛けです。

【ページ 19】 §3 セクション要約

§3 のまとめです。

Stage 1 で TF-IDF と Jaccard を使って 3,244 件を 50 件に絞る。**Stage 2** で多層パーセプトロンと 10 次元特徴量を使って精密ランキングする。このうち 3 特徴量 ($\phi_8, \phi_9, \phi_{10}$) が **Set-aware** で、組合せの整合性を評価する。

これが手法の全体像です。

【ページ 20】 §4.1 データセット — 規模と分割

ここから §4 結果と考察 です。

§4.1 データセット。数字を 4 つ挙げています。

総式数 3,244。内訳は 論文 PDF 由来 2,574 式 とハンドブック由来 670 式。細粒度ドメイン 813 種類。CSTR、熱交換、反応動力学、などなど。訓練ケース 1,107 件。4 バリエーションで拡張したものです。次のスライドで詳述します。分割は文献単位 (source_id) で 60 / 20 / 20、訓練・検証・テストです。

ここで下の注意書きが重要です。「なぜ文献単位の分割？」

素朴にケース単位でランダム分割すると、同じ文献由来のケース（同じ正解式、類似した文脈）が訓練とテストの両方に入ってしまう、データリークが起きます。モデルは見覚え

のある式を引くだけで高スコアになり、真の汎化性能は測れません。文献単位で分割することで、テストは訓練で一度も見えていない source に対する性能となります。これは本研究の実運用、つまり「新しい論文が追加されたときに正しい式を見つける」という目標に直結する評価方針です。

【ページ 21】 1,107 ケースの内訳

図 4.1。1,107 訓練ケースの内訳です。4 つのバリエーションがあります。

original 93 件：大規模言語モデル（Gemini 2.5 Pro）が種ケースを生成します。プロセス記述と、それに対応する正解式集合を直接生成させたものです。これは言語モデルでしか書けない部分なので、ここだけ大規模言語モデルを使っています。

paraphrased 279 件：original の文脈文を **3 通り**に言い換えたもの。決定論的なテンプレート置換なので、**大規模言語モデルは使いません**。

random_io 733 件：original の正解式から**入出力変数を再**割当したもの。割当後、**自由度解析で物理的に可解なもの**だけ採用しています。これも決定論的。

swap_io 2 件：入出力を入れ替えて、やはり自由度解析を通過したもののみ。

正解式数の分布を見ると、**1 式正解が 56.1%、2 式正解が 36.4%、3 式以上が 7.5%**。約 **44% が複数式正解** です。これが Set-aware 特徴量を導入する動機になっています。

【ページ 22】 §4.2 評価指標

§4.2 評価指標。3 つの指標を使っています。図 4.2 で違いを比較しています。

MRR_first。値域は $[1/N, 1]$ 、 $N = 3,244$ なのでほぼ $[0, 1]$ 。最初に現れた正解式の順位の逆数の平均 です。「最初の 1 つが何位か」しか見ません。

FullRecall@K。値域は $[0, 1]$ 。上位 K 件に全ての正解式が含まれるケースの割合。複数式正解を重視する指標です。

MAP (Mean Average Precision)。値域は $[0, 1]$ 。全正解が前方にまとまっているほど高くなる、情報検索の標準指標です。

下の EXAMPLE で MAP の直感を説明しています。正解が 3 式 $\{a, b, c\}$ 、ランキングが $[a, x, b, y, c, \dots]$ で、1 位・

3 位・5 位が正解の場合：

AP は、正解の各位置での precision の平均。 $1/1 + 2/3 + 3/5$ を 3 で割って、約 0.756。全正解が 1 位から 3 位に詰まっていれば $AP = 1$ で満点です。前方にまとまっているほど高いという感覚が掴めるかと思います。

【ページ 23】 §4.3 主要な結果

§4.3 主要な結果。10 シードの平均値です。

3 手法 × 3 指標 の比較表を見てください。

ベースライン、つまり Stage 1 スコアだけで並べた場合、MRR_first 0.937、FullRecall@3 0.826、MAP 0.936。既にかなり高い。

リランカーに基本 7 次元特徴量だけ 入れると、MRR_first

0.959、FullRecall@3 0.881、MAP 0.953。単発特徴量の追加で改善。

そして ★ Set-aware の 3 特徴量を加えた 10 次元で、MRR_first 0.980、FullRecall@3 0.904、MAP 0.974。全指標で最良 です。

数字の意味ですが、MRR_first = 0.980 は、最初の正解式は平均で順位 ≈ 1.02 位、つまりほぼ常に 1 位に出てくる。FullRecall@3 = 0.904 は、約 90% のケースで上位 3 件に全正解が揃う。MAP = 0.974 は、全正解が前方にほぼ隙間なく詰まっている。

こういう水準です。

ここで、統計的有意性 の話をします。

同じ実験でもランダムシードを変えれば結果は揺らぎます。

観察された差が偶然のばらつきなのか、手法の改善なのかを

判定するのに、**対応あり t -検定** を使いました。 p 値は、「実際には差がなかったとしたら、観察された以上の差が偶然生じる確率」です。 $p < 0.05$ で**有意**、 $p < 0.01$ で**高度に有意**、が慣例です。

【ページ 24】 統計的有意性の詳細／主結論

t 検定の結果です。4 つの指標に分けて書いています。

MAP は $t = 3.46$ 、 $p = 0.004$ 、**高度に有意**。複数次式 **FullRecall@3** は $p = 0.032$ 、**有意**。複数次式 **MRR_worst** は $p = 0.024$ 、**有意**。ところが、**MRR_first** 全体は $p = 0.231$ 、**有意ではない**。

ここで重要な発見があります。

単発評価 (MRR_first) では差が出ません。しかし複

数式の組合せ評価 (FullRecall@3・MRR_worst) では
+6.5%, +5.5% の改善が統計的に有意 になります。

この非対称性から、本研究の主結論が導かれます。[少し間を取って]

グラフ構造の真価は、単一対象のスコアリングではなく、対象集合の整合性評価で発揮される。

これが一番お伝えしたい知見です。個々の式を当てるだけなら従来手法で十分ですが、**複数式を同時に、しかも整合性を持って選ぶ**という問題設定において、グラフ構造から得られる Set-aware 特徴量が有意な改善をもたらします。

【ページ 25】 §4.5 今後の展望

§4.5 今後の展望を 3 方向、お話しします。

方向 A：変数レベルの意味類似度の導入。現状は記号完全一致のみで、たとえば c_p と C_p は別扱いです。変数マッチングを意味ベースに拡張し、**表記揺れを吸収**することで、変数共有エッジの欠落を減らす方針です。

方向 B：データ拡大を 2 方向に分けて 進めます。1 つは既存ドメインの網羅性を強化する **単一ドメイン内の増強**。もう 1 つは**新規分野への拡張**、バイオプロセスや半導体プロセスの追加です。この 2 つは性質が違うので、分けて検討すべきだと考えています。

方向 C：実プロセスでのケーススタディ。実際のプロセス設計や制御設計の業務に本手法を適用し、**実用性と限界を評価**します。

【ページ 26】 §5 まとめ

最後にまとめです。5 項目で振り返ります。

01 目的：物理モデル構築の手作業を **自動化**し、設計・制御・最適化・安全解析の基盤を提供する。

02 関連研究：**3 流派**を整理しました。シンボリック回帰はデータ依存、大規模言語モデルはハルシネーションの問題、数式検索は実在式からの選択、というそれぞれの特徴。

03 手法：式 3,244 個 × 変数 3,700 個の **二部グラフ**上で **2 段階検索**。Stage 1 で絞り、Stage 2 のリランカーに **Set-aware 特徴量** を組み込む、というのが本研究の設計です。

04 結果：複数式の組合せ評価で **Set-aware** が統計的に有意な改善、 p 値は **0.004 から 0.032** の範囲。

05 展望：意味類似度の導入・データ拡大・実プロセス応用の

3 方向で進めます。

以上で発表を終わります。ご清聴ありがとうございました。

発表のコツ（読み上げ前のチェック）

- 全体の目安：18～20 分。ページ 12（Stage 1 式）、15（MLP）、23（結果）、24（統計的有意性）は少しゆっくり。
- 大きな引用の前は必ず間を取る：ページ 24 の「グラフ構造の真価は…」の前は 1 秒ほど止めて、聴衆の注意を引いてから読む。
- 数式ページ（12, 15, 18）は、式を読み上げず、直感的な意味を言葉で言い換える（スライドに式は書いてあるので、式そのものを口頭で読むと冗長）。
- 質疑応答に備える FAQ：

- 「10 シードはどう選んだ？」 → [42, 123, 456, 789, 1024, 2024, 3141, 5926, 7777, 9999]、事前固定、チェリーピッキングなし
- 「TF-IDF に LLM は使っている？」 → 使っていません。古典的統計手法で完全に決定論的
- 「本格 GNN (GCN/GAT) は？」 → 試したがベースラインを超えられず。現在は MLP + グラフ特徴量
- 「MAP = 0.974 はどのくらい良い？」 → ランダムで約 0.003、Web 検索の一般的な MAP は 0.3 – 0.6。閉世界 IR では 0.9+ が到達可能域で本研究はその上位